



UNL. FACULTAD DE
INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez

Liliana Forzani

Condiciones de optimalidad

En un problema de optimización general con restricciones funcionales, de la forma

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right. \right\}, \end{array}$$

las condiciones de optimalidad definen los requisitos que deben cumplir los puntos óptimos. En lo que sigue, asumiremos siempre que trabajamos con funciones diferenciables.

I | Condiciones de optimalidad de primer orden

Optimización sin restricciones

De cursos anteriores recordemos que, cuando se pretende optimizar una función f en un dominio abierto, una condición necesaria para que un punto sea óptimo es que verifique

$$\nabla f(\mathbf{x}) = \mathbf{0}. \quad (1.4.1)$$

Demostración. Sea $\mathbf{x}^* \in \mathbb{R}^p$ un minimizador de la función $f : \mathbb{R}^p \rightarrow \mathbb{R}$ y sea $\mathbf{d} \in \mathbb{R}^p$ una dirección arbitraria. Entonces se cumple

$$f(\mathbf{x}^* + t\mathbf{d}) \geq f(\mathbf{x}^*) \quad \forall t \in \mathbb{R} : \mathbf{x}^* + t\mathbf{d} \in \text{dom } f.$$

Así, tenemos que

$$\lim_{t \rightarrow 0^-} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} \leq 0 \quad \text{y} \quad \lim_{t \rightarrow 0^+} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} \geq 0.$$

En consecuencia, como f es diferenciable, la derivada direccional de f en $\mathbf{x}^*$ a lo largo de $\mathbf{d}$ existe y debe ser

$$\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}^*) := \lim_{t \rightarrow 0} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} = 0.$$

Usando la propiedad $\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}) = \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle_2$, se deduce

$$\langle \nabla f(\mathbf{x}^*), \mathbf{d} \rangle_2 = 0.$$

Finalmente, dado que $\mathbf{d}$ es arbitrario, concluimos que $\nabla f(\mathbf{x}^*) = \mathbf{0}$. ■



La condición $\nabla f(\mathbf{x}) = \mathbf{0}$ no caracteriza únicamente puntos óptimos en un sentido global, sino también a aquellos donde f alcanza un extremo local. De hecho, la prueba puede adaptarse a tal caso escribiendo

$$f(\mathbf{x} + t\mathbf{d}) \geq f(\mathbf{x}) \quad \forall t \in \mathbb{R} : |t| < \varepsilon,$$

donde $\mathbf{x}$ es un punto de extremo local, $\mathbf{d}$ es una dirección arbitraria y $\varepsilon > 0$ es lo suficientemente pequeño como para que $\mathbf{x} + t\mathbf{d}$ permanezca en un entorno donde se verifica la definición de mínimo local.

Pero cuidado: lo anterior es *solo una condición necesaria* que todos los puntos óptimos deben cumplir, pero no implica que cualquier punto que la satisfaga sea automáticamente óptimo. En otras palabras, las soluciones de $\nabla f(\mathbf{x}) = \mathbf{0}$ forman una lista de puntos candidatos para minimizar, llamados *puntos críticos*.

De inmediato surgen dos preguntas claves:

¿Cuál es la generalización de la condición necesaria $\nabla f(\mathbf{x}) = \mathbf{0}$ cuando enfrentamos un problema de optimización con restricciones?

¿Bajo qué circunstancias $\nabla f(\mathbf{x}) = \mathbf{0}$ también se convierte en una condición suficiente para la optimalidad?

Para el caso de optimización sin restricciones, podemos responder a la segunda pregunta con un resultado muy importante en optimización convexa, consecuencia directa del Teorema 1.2.19.

Teorema 1.4.1 (Condición suficiente y necesaria de optimalidad de primer orden sin restricciones para funciones convexas). Sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable y convexa. Entonces $\mathbf{x}^* \in \text{dom } f$ es un minimizador de f si y solo si

$$\nabla f(\mathbf{x}^*) = \mathbf{0}.$$

Optimización con restricciones

Para generalizar la condición necesaria $\nabla f(\mathbf{x}) = \mathbf{0}$ al caso de optimización con restricciones, es fundamental tener en cuenta que, en un punto dado, podemos estar limitados en la elección de las direcciones de movimiento $\mathbf{d} \in \mathbb{R}^p$. Para que la posibilidad de aproximarnos a un punto factible $\mathbf{x}$ sin salirnos del conjunto factible Ω dependa de la dirección $\mathbf{d}$ considerada, consideraremos únicamente desplazamientos de la forma $\mathbf{x} + t\mathbf{d}$, con $t \geq 0$. Es fácil ver que esta limitación modifica el análisis realizado en la prueba anterior, conduciendo a la siguiente generalización natural:

$$\langle \nabla f(\mathbf{x}^*), \mathbf{d} \rangle_2 \geq 0 \quad \forall \mathbf{d} \in \mathbb{R}^p : \mathbf{x}^* + t\mathbf{d} \in \Omega, \quad (1.4.2)$$

para cualquier $t \geq 0$ lo suficientemente pequeño.

A partir de esto, nos preguntamos:

¿Cuáles son las direcciones $\mathbf{d}$ que nos permiten permanecer en Ω desde un punto $\mathbf{x}$?

¿Qué implicancias tiene (1.4.2) para el vector gradiente $\nabla f(\mathbf{x})$?

Una idea inicial para caracterizar el conjunto de direcciones permitidas es tomar cualquier otro punto $\mathbf{y} \in \Omega$ y observar qué sucede con la dirección desde $\mathbf{x}$ hacia $\mathbf{y}$. Esta dirección, $\mathbf{d} = \mathbf{y} - \mathbf{x}$, será válida siempre que Ω sea convexo. En efecto, en tal caso, nos aseguramos $\mathbf{x} + t\mathbf{d} \in \Omega$ para $0 \leq t \leq 1$. Así, podemos hacer una primera suposición con el objetivo de formalizar una condición necesaria de optimalidad:

Primer supuesto

Ω un conjunto convexo

Inmediatamente tenemos el siguiente resultado, cuya demostración se obtiene directamente de ajustar la prueba vista para el caso de optimización sin restricciones.

Teorema 1.4.2 (Condición necesaria de optimalidad de primer orden para un conjunto factible convexo). *Sea $\Omega \subset \mathbb{R}^p$ convexo y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable. Si $\mathbf{x}^* \in \Omega$ es un minimizador de f sobre Ω , entonces*

$$\langle \nabla f(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle_2 \geq 0 \quad \forall \mathbf{y} \in \Omega. \quad (1.4.3)$$




Figura 1.4.1: Interpretación geométrica de la condición necesaria (1.4.3) cuando $\nabla f(\mathbf{x}^*) \neq 0$.

En un punto óptimo $\mathbf{x}^*$, el vector gradiente o bien es nulo o bien forma un ángulo nulo, agudo o recto con todas las direcciones de la forma $\mathbf{y} - \mathbf{x}^*$ (ver Figura 1.4.1). En efecto, si $\nabla f(\mathbf{x}^*) \neq 0$, se verifica

$$\langle \nabla f(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle_2 = \|\nabla f(\mathbf{x}^*)\|_2 \|\mathbf{y} - \mathbf{x}^*\|_2 \cos \alpha \geq 0 \iff \cos \alpha \geq 0.$$

Ahora bien, nosotros estamos interesados en hallar $\mathbf{x}^*$. En este sentido, la condición (1.4.3) nos sirve para identificar aquellos puntos $\mathbf{x} \in \Omega$ candidatos a ser óptimos (siguiendo la terminología habitual, los llamaremos *puntos críticos*). En consecuencia, si consideramos el vector opuesto al gradiente, los puntos críticos serán aquellos que verifiquen

$$\langle -\nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2 \leq 0 \quad \forall \mathbf{y} \in \Omega. \quad (1.4.4)$$

Esto vincula nuestro análisis con la Definición 1.2.11 de cono normal: la expresión (1.4.4) es equivalente a escribir $-\nabla f(\mathbf{x}) \in N_\Omega(\mathbf{x})$. En consecuencia, podemos afirmar que:

Bajo las condiciones del Teorema 1.4.2, si $\mathbf{x}^*$ es un minimizador de f sobre Ω , entonces

$$-\nabla f(\mathbf{x}^*) \in N_\Omega(\mathbf{x}^*).$$




Figura 1.4.2: Idea geométrica de la condición del gradiente para tres puntos críticos $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3 \in \Omega$ y un punto no crítico $\mathbf{x}_4 \in \Omega$. En el caso de $\mathbf{x}_3$, se tiene $\nabla f(\mathbf{x}_3) = \mathbf{0}$.

En la Figura 1.4.2 se presenta la geometría derivada de la condición necesaria establecida, para el caso en que Ω es un poliedro. Las posiciones de los puntos críticos corresponden a los ejemplos de conos normales vistos en la Sección 2. En particular, para puntos interiores de Ω , la condición se reduce a la ecuación $\nabla f(\mathbf{x}) = \mathbf{0}$, típica de los problemas sin restricciones.

El comportamiento de $-\nabla f(\mathbf{x})$ en términos de conos normales constituye, sin dudas, la idea principal de nuestro análisis, que procuraremos extender a formas más generales de Ω .

Observar que la condición provista por el Teorema 1.4.2 es necesaria pero no suficiente. Podemos pensar rápidamente en ejemplos de mínimos locales en el interior de Ω , tales como el Ejemplo 1.1.3. A continuación, veremos un ejemplo en el cual un punto crítico ocurre en la frontera de Ω , pero no es cierto que sea un punto óptimo.

Ejemplo 1.4.3: Punto crítico no óptimo


Consideremos el problema

$$\begin{aligned} &\text{minimizar} && x_2 - x_1^2 \\ &\text{sujeto a} && 2x_1 + x_2 \leq 1, \\ &&& -2x_1 + x_2 \leq 1, \\ &&& x_2 \geq 0. \end{aligned}$$

El conjunto factible Ω es el triángulo de vértices $(-\frac{1}{2}, 0)$, $(\frac{1}{2}, 0)$ y $(0, 1)$. En $\mathbf{x} = (0, 0)$ se tiene $\nabla f(0, 0) = (0, 1)$. La condición del Teorema 1.4.2 para este punto se expresa como

$$\langle (0, 1), \mathbf{y} - (0, 0) \rangle_2 = y_2 \geq 0 \quad \forall \mathbf{y} \in \Omega.$$

Esto es cierto, de acuerdo a la definición de Ω . Sin embargo, el punto $(0, 0)$ no es óptimo: $f(0, 0) = 0$, mientras que el valor óptimo es $-\frac{1}{4}$ y ocurre en los vértices $(\pm\frac{1}{2}, 0)$.



Segundo supuesto

f una función convexa

Para el notable caso de las funciones convexas, la condición del Teorema 1.4.2 sí es suficiente.

Teorema 1.4.4 (Condición suficiente y necesaria de optimalidad de primer orden para un conjunto factible convexo y una función objetivo convexa). *Sea $\Omega \subseteq \mathbb{R}^p$ convexo y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable convexa. Entonces $\mathbf{x}^*$ es un minimizador de f en Ω si y solo si se verifica*

$$-\nabla f(\mathbf{x}^*) \in N_{\Omega}(\mathbf{x}^*). \quad (1.4.5)$$

Demostración. En virtud del Teorema 1.4.2, debemos probar únicamente la suficiencia. Sea $\mathbf{x} \in \Omega$ tal que $-\nabla f(\mathbf{x}) \in N_\Omega(\mathbf{x})$, entonces

$$\langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2 \geq 0 \quad \forall \mathbf{y} \in \Omega.$$

Por condición de primer orden para convexidad (Teorema 1.2.19), resulta

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \underbrace{\langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2}_{\geq 0} \geq f(\mathbf{x})$$

para todo $\mathbf{y} \in \Omega$, lo cual significa que $\mathbf{x}$ es un minimizador de f en Ω . ■



El Teorema 1.4.4 se puede aplicar a todo problema de optimización convexa, pero es un resultado más general.

Ejemplo 1.4.5: Aplicación de condición suficiente y necesaria de optimalidad en un problema de optimización convexa

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 \\ &\text{sujeto a} && x_1 + x_2 \leq 1.5, \\ &&& x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

con

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \quad \text{y} \quad \mathbf{b} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

El conjunto factible Ω es el triángulo con vértices $(0,0)$, $(1.5,0)$ y $(0,1.5)$, por lo tanto es convexo. Respecto a la función objetivo, tenemos

$$\nabla f(\mathbf{x}) = A^\top (A\mathbf{x} - \mathbf{b}) = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \left[\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \mathbf{x} - \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right] = \begin{pmatrix} x_1 - 1 \\ 4x_2 - 2 \end{pmatrix},$$

y


$$\nabla^2 f(\mathbf{x}) = A^\top A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$$

Claramente $\nabla^2 f(\mathbf{x}) \succeq 0$, lo cual significa que f es convexa. En consecuencia, estamos en condiciones de aplicar el Teorema 1.4.4. Para ello, hagamos el siguiente análisis:

- $\nabla f(\mathbf{x}) \neq \mathbf{0}$ para todo punto interior de Ω , lo cual implica que no hay puntos óptimos en el interior.
- En el lado $\{(0,t) \mid 0 < t < 1.5\}$, $-\nabla f(\mathbf{x}) = (1, 2 - 4t)$. Pero el cono normal está

determinado por la dirección normal $(-1, 0)$, lo cual significa que $-\nabla f(\mathbf{x}) \in N_{\Omega}(\mathbf{x})$ si y solo si es de la forma $(-a, 0)$ con $a > 0$, lo cual no puede ocurrir. Por lo tanto, no hay puntos óptimos en esta porción de frontera.

- En el lado $\{(t, 1.5 - t) \mid 0 < t < 1.5\}$, tenemos que $-\nabla f(\mathbf{x}) = (1 - t, 4t - 4)$ y la dirección normal es $(1, 1)$. Esto significa que (1.4.5) es cierto si ambas componentes de $-\nabla f(\mathbf{x})$ son iguales, lo cual resulta en $t = 1$. De esta manera, el punto $(1, 0.5)$, con $\nabla f(1, 0.5) = \mathbf{0}$, es un punto óptimo del problema.
- Faltan los vértices del triángulo. En la siguiente figura se muestra el comportamiento de $-\nabla f(\mathbf{x})$ en cada uno de ellos. Dado que no cumplen la condición suficiente y necesaria (1.4.5), ningún vértice es un punto óptimo.



En conclusión, el problema tiene solución única:

$$\mathbf{x}^* = (1, 0.5) \quad \text{y} \quad p^* = f(1, 0.5) = 0.$$

II | Condiciones de Karush-Kuhn-Tucker (KKT)

Hasta ahora hemos visto que, para Ω convexo (*primer supuesto*), una condición necesaria para que un punto $\mathbf{x}$ sea óptimo es que el vector opuesto al gradiente de la función objetivo pertenezca al cono normal $N_{\Omega}(\mathbf{x})$. Además, si la función objetivo es convexa (*segundo supuesto*), dicha condición resulta también suficiente.

Aunque el Teorema 1.4.4 es general, y contempla los problemas de optimización convexa, su

aplicación práctica puede resultar poco directa. Afortunadamente, cuando el conjunto factible Ω está definido por restricciones funcionales diferenciables, es posible expresar estas condiciones de manera más estructurada a partir de la caracterización de los conos normales, lo cual conduce a las que se conocen como *condiciones de Karush-Kuhn-Tucker* (o, simplemente, condiciones KKT).

Para formular las condiciones KKT, comenzaremos analizando el caso particular de restricciones afines, para lograr intuición, y luego generalizaremos al caso de restricciones no lineales.

El caso particular de restricciones afines

Caso especial

Ω un poliedro

Vamos a considerar el caso en que Ω es un poliedro definido a partir de la intersección de un número finito de semiespacios e hiperplanos. Es decir, es de la forma

$$\Omega = \{\mathbf{x} \in \mathbb{R}^p \mid A\mathbf{x} \preceq \mathbf{b}, C\mathbf{x} = \mathbf{d}\}, \quad (1.4.6)$$

donde $A \in \mathbb{R}^{r \times p}$, $C \in \mathbb{R}^{m \times p}$, $\mathbf{b} \in \mathbb{R}^r$ y $\mathbf{d} \in \mathbb{R}^m$.

Definición 1.4.6 (Restricción activa). Una restricción de desigualdad $g(\mathbf{x}) \leq 0$ se dice que está *activa* en un punto $\mathbf{x}_0$ si allí se cumple con igualdad; es decir, si

$$g(\mathbf{x}_0) = 0.$$

Esto significa que $\mathbf{x}_0$ pertenece a la frontera del conjunto $\{\mathbf{x} \in \mathbb{R}^p \mid g(\mathbf{x}) \leq 0\}$.

En los ejemplos de conos normales vistos en la Sección 2, analizamos su definición según la posición del punto de interés: si $\mathbf{x}$ es interior a Ω , resulta simplemente $N_\Omega(\mathbf{x}) = \{\mathbf{0}\}$, mientras que si $\mathbf{x}$ pertenece a la frontera de Ω , el cono normal queda determinado por las direcciones que definen los semiespacios e hiperplanos. No obstante, en dichos ejemplos hemos considerado casos particulares de Ω : un hiperplano, un semiespacio y la intersección de dos semiespacios. Necesitamos extender ese análisis a cualquier poliedro Ω y caracterizar el cono normal en cualquier punto de Ω . El siguiente resultado nos proporciona dicha caracterización.

Teorema 1.4.7 (Cono normal en un punto de un poliedro). Sea Ω el poliedro definido por (1.4.6). Para $\mathbf{x} \in \Omega$, sea $I(\mathbf{x})$ el conjunto de índices de las restricciones activas; esto es,

$$I(\mathbf{x}) := \left\{ i \in \{1, \dots, r\} \mid \mathbf{a}_i^\top \mathbf{x} = b_i \right\}.$$

Entonces, el cono normal en $\mathbf{x}$ está dado por

$$N_\Omega(\mathbf{x}) = \left\{ \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j \mid \lambda_i \in \mathbb{R}_0^+, \nu_j \in \mathbb{R} \right\}.$$

Demostración. En primer lugar, fijemos $\lambda_i \in \mathbb{R}_0^+$, $\nu_j \in \mathbb{R}$, y probemos que la dirección

$$\mathbf{d} = \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j$$

pertenece a $N_\Omega(\mathbf{x})$: para $\mathbf{y} \in \Omega$ arbitrario, resulta

$$\begin{aligned} \langle \mathbf{d}, \mathbf{y} - \mathbf{x} \rangle_2 &= \left\langle \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j, \mathbf{y} - \mathbf{x} \right\rangle_2 \\ &= \sum_{i \in I(\mathbf{x})} \lambda_i (\langle \mathbf{a}_i, \mathbf{y} \rangle_2 - \langle \mathbf{a}_i, \mathbf{x} \rangle_2) + \sum_{j=1}^m \nu_j (\langle \mathbf{c}_j, \mathbf{y} \rangle_2 - \langle \mathbf{c}_j, \mathbf{x} \rangle_2) \\ &\leq 0, \end{aligned}$$

donde en el último paso se usó el hecho que $\langle \mathbf{a}_i, \mathbf{y} \rangle_2 \leq b_i$, $\langle \mathbf{a}_i, \mathbf{x} \rangle_2 = b_i$, $\langle \mathbf{c}_j, \mathbf{y} \rangle_2 = \langle \mathbf{c}_j, \mathbf{x} \rangle_2 = d_j$.

En segundo lugar, probamos que toda dirección $\mathbf{d} \in N_\Omega(\mathbf{x})$ pertenece al conjunto

$$C := \left\{ \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j \mid \lambda_i \in \mathbb{R}_0^+, \nu_j \in \mathbb{R} \right\}$$

Por reducción al absurdo, supongamos $\mathbf{d} \notin C$. Dado que C es un cono convexo cerrado no vacío (esto es fácil de verificar y queda como ejercicio), podemos separar C y $\mathbf{d}$ mediante un hiperplano³; esto es, existe $\mathbf{u} \in \mathbb{R}^n$ tal que

$$\langle \mathbf{u}, \mathbf{d} \rangle_2 < 0 \quad \text{y} \quad \langle \mathbf{u}, \mathbf{p} \rangle_2 \geq 0 \quad \forall \mathbf{p} \in C.$$

En particular, tenemos $\langle \mathbf{u}, \mathbf{a}_i \rangle_2 \geq 0$ para las restricciones activas y $\langle \mathbf{u}, \mathbf{c}_j \rangle_2 = 0$; esto último por el hecho de que $\pm \mathbf{c}_j \in C$. Como consecuencia, podemos afirmar que para un $\delta > 0$ lo suficientemente pequeño, el punto $\mathbf{y} := \mathbf{x} - \delta \mathbf{u}$ pertenece a Ω . En efecto, se verifica

$$\begin{aligned} \langle \mathbf{a}_i, \mathbf{x} - \delta \mathbf{u} \rangle_2 &= \langle \mathbf{a}_i, \mathbf{x} \rangle_2 - \delta \langle \mathbf{a}_i, \mathbf{u} \rangle_2 \leq b_i \quad \forall i \in I(\mathbf{x}), \\ \langle \mathbf{c}_j, \mathbf{x} - \delta \mathbf{u} \rangle_2 &= \langle \mathbf{c}_j, \mathbf{x} \rangle_2 = d_j \quad \forall j = 1, \dots, m, \end{aligned}$$

mientras que para las restricciones no activas se usa el hecho de que δ es suficientemente pequeño. Finalmente, esto nos conduce a contradecir $\mathbf{d} \in N_\Omega(\mathbf{x})$, ya que

$$\langle \mathbf{d}, \mathbf{x} - (\mathbf{x} - \delta \mathbf{u}) \rangle_2 = -\delta \langle \mathbf{d}, \mathbf{u} \rangle_2 > 0.$$

Luego, debe ser $\mathbf{d} \in C$, lo cual concluye la prueba. ■



La suma en la expresión del cono normal puede ser reescrita sin restringir $i \in I(\mathbf{x})$, imponiendo $\lambda_i = 0$ para todo $i \notin I(\mathbf{x})$. Esta imposición queda implícita de forma inmediata si se escribe

$$\sum_{i=1}^r \lambda_i (\mathbf{a}_i^\top \mathbf{x} - b_i) = 0 \quad \lambda_i \in \mathbb{R}_0^+. \quad (1.4.7)$$

³Esto es un *teorema de separación*: si $C \subset \mathbb{R}^p$ es un cono convexo cerrado no vacío y $\mathbf{x} \notin C$, existe un hiperplano que pasa por el origen y separa $\mathbf{x}$ de C .

En forma vectorial, (1.4.7) puede escribirse como $\lambda^\top (A\mathbf{x} - \mathbf{b}) = 0$, donde $\lambda = (\lambda_1, \dots, \lambda_m)^\top$. Con esta notación, podemos escribir el cono normal del Teorema 1.4.7 así:

$$N_\Omega(\mathbf{x}) = \left\{ A^\top \lambda + C^\top \nu \mid \lambda^\top (A\mathbf{x} - \mathbf{b}) = 0, \lambda \in (\mathbb{R}_0^+)^r, \nu \in \mathbb{R}^m \right\}.$$

 Verifique que el resultado del Teorema 1.4.7 contempla los ejemplos de conos normales vistos en la Sección 2.

La condición de optimalidad $-\nabla f(\mathbf{x}^*) \in N_\Omega(\mathbf{x}^*)$ del Teorema 1.4.4 se traduce como

$$-\nabla f(\mathbf{x}^*) = \sum_{i \in I(\mathbf{x})} \lambda_i^* \mathbf{a}_i + \sum_{j=1}^m \nu_j^* \mathbf{c}_j, \quad \lambda_i^* \in \mathbb{R}^+, \nu_j^* \in \mathbb{R}.$$

O, equivalentemente,

$$-\nabla f(\mathbf{x}^*) = \sum_{i \in I(\mathbf{x})} \lambda_i^* \nabla g_i(\mathbf{x}) + \sum_{j=1}^m \nu_j^* \nabla h_j(\mathbf{x}), \quad \lambda_i^* \in \mathbb{R}^+, \nu_j^* \in \mathbb{R}.$$

donde $g_i(\mathbf{x}) = \mathbf{a}_i^\top \mathbf{x} - b_i$ y $h_j(\mathbf{x}) = \mathbf{c}_j^\top \mathbf{x} - d_j$ son las funciones de restricción que definen Ω . Los coeficientes λ_i y ν_j son *multiplicadores* asociados a las restricciones.

Ahora bien, dado que Ω es un poliedro (y, por lo tanto, un conjunto convexo), los Teoremas 1.4.2 y 1.4.4 pueden ser aplicados en este contexto. Obtenemos así el siguiente resultado.

Corolario 1.4.8 (Condición necesaria de optimalidad de primer orden para un conjunto factible poliedral). *Sea Ω el poliedro definido por (1.4.6), y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable. Si $\mathbf{x}^* \in \Omega$ es un minimizador de f sobre Ω , entonces existen $\lambda^* \in (\mathbb{R}_0^+)^r$ y $\nu^* \in \mathbb{R}^m$ tales que $\lambda_i^* (\mathbf{a}_i^\top \mathbf{x}^* - b_i) = 0$ para todo $i = 1, \dots, r$ y*

$$-\nabla f(\mathbf{x}^*) = \sum_{i=1}^r \lambda_i^* \mathbf{a}_i + \sum_{j=1}^m \nu_j^* \mathbf{c}_j. \quad (1.4.8)$$

Además, si f es convexa, esta condición es también suficiente.

Ejemplo 1.4.9: Verificación de condición necesaria de optimalidad

Consideremos el problema de optimización del Ejemplo 1.4.3 y veamos que sus puntos óptimos verifican la condición (1.4.8). Para $(\frac{1}{2}, 0)$ (análogamente para $(-\frac{1}{2}, 0)$) tenemos

$$-\nabla f(\frac{1}{2}, 0) = (1, -1).$$

Las restricciones determinan $\mathbf{a}_1 = (2, 1)$, $\mathbf{a}_2 = (-2, 1)$ y $\mathbf{a}_3 = (0, -1)$. Entonces debemos hallar $\lambda_1, \lambda_2, \lambda_3 \in \mathbb{R}_0^+$ tales que

$$(1, -1) = \lambda_1(2, 1) + \lambda_2(-2, 1) + \lambda_3(0, -1).$$

Como la segunda restricción no está activa, debe ser $\lambda_2 = 0$, lo cual reduce la expresión anterior a

$$\begin{cases} 2\lambda_1 = 1, \\ \lambda_1 - \lambda_3 = -1, \end{cases}$$

cuya solución es $\lambda_1 = \frac{1}{2}$ y $\lambda_3 = -\frac{3}{2}$. Por lo tanto, se verifica la condición de optimalidad:

$$-\nabla f\left(\frac{1}{2}, 0\right) = \frac{1}{2}(2, 1) + \frac{3}{2}(0, -1).$$

Importante

Las condiciones del Corolario 1.4.8, conocidas como *condiciones de Karush-Kuhn-Tucker* (KKT), se formulan a partir de diferentes componentes:

- **Factibilidad primal:** El punto $\mathbf{x}$ debe ser un punto factible.
- **Factibilidad dual:** Los multiplicadores asociados a las restricciones de desigualdad deben ser no negativos.

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, r.$$

- **Holgura complementaria:** Los multiplicadores asociados a las restricciones de desigualdad solo pueden ser positivos si la restricción está activa.

$$\lambda_i (\mathbf{a}_i^\top \mathbf{x} - b_i) = 0 \quad \forall i = 1, \dots, r.$$

- **Estacionariedad:** El opuesto del vector gradiente debe ser una combinación lineal de los gradientes de las restricciones.

$$-\nabla f(\mathbf{x}) = \sum_{i=1}^r \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j,$$

o bien

$$\nabla f(\mathbf{x}) + \sum_{i=1}^r \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j = \mathbf{0}.$$

En particular, si $\mathbf{x}$ es un punto interior de Ω , las condiciones KKT se reducen a

$$\nabla f(\mathbf{x}) = \mathbf{0}.$$

Por supuesto, el Corolario 1.4.8 representa un criterio para obtener puntos críticos si Ω es un poliedro. Más aún, si f es convexa, dicho criterio caracteriza los puntos óptimos. En resumen, hasta aquí tenemos que:

Si Ω es un poliedro, entonces las condiciones KKT son necesarias para que un punto sea óptimo. Si, además, f es convexa, las condiciones KKT son también suficientes.

Ejemplo 1.4.10: Minimización cuadrática convexa con restricciones de igualdad

Sean $P \in \mathbf{S}_+^p$, $\mathbf{q} \in \mathbb{R}^p$, $c \in \mathbb{R}$, $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^m$. Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \mathbf{x}^\top P \mathbf{x} + \mathbf{q}^\top \mathbf{x} + c \\ &\text{sujeto a} && A \mathbf{x} = \mathbf{b}. \end{aligned}$$

Dado que la función objetivo es convexa, el Corolario 1.4.8 nos asegura que las condiciones KKT son suficientes y necesarias. Además, teniendo en cuenta que solo hay restricciones de igualdad, a saber, $h_j(\mathbf{x}) = \mathbf{a}_j^\top \mathbf{x} - b_j$, únicamente debemos analizar las condiciones de factibilidad primal y estacionariedad. La condición de estacionariedad es:

$$\begin{aligned} -\nabla f(\mathbf{x}^*) &= \sum_{j=1}^m \nu_j^* \nabla h_j(\mathbf{x}^*) \\ -(P \mathbf{x}^* + \mathbf{q}) &= A^\top \boldsymbol{\nu}^* \\ P \mathbf{x}^* + \mathbf{q} + A^\top \boldsymbol{\nu}^* &= \mathbf{0}. \end{aligned}$$

Agregando la factibilidad primal $A \mathbf{x}^* = \mathbf{b}$, obtenemos finalmente un sistema de $p + m$ ecuaciones con $p + m$ incógnitas:

$$\begin{pmatrix} P & A^\top \\ A & 0 \end{pmatrix} \begin{pmatrix} \mathbf{x}^* \\ \boldsymbol{\nu}^* \end{pmatrix} = \begin{pmatrix} -\mathbf{q} \\ \mathbf{b} \end{pmatrix}.$$

 Proponga casos para el Ejemplo 1.4.10, con $\mathbf{x} \in \mathbb{R}^2$ y $m = 2$.

Ejemplo 1.4.11: Minimización cuadrática convexa con restricciones de desigualdad

Sean

$$P = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}, \quad \mathbf{q} = \begin{pmatrix} -2 \\ -2 \end{pmatrix}.$$

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \mathbf{x}^\top P \mathbf{x} + \mathbf{q}^\top \mathbf{x} \\ &\text{sujeto a} && x_1 + x_2 \leq 1.5, \\ &&& x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

Dado que $P \succeq 0$, la función objetivo es convexa. Su expresión es

$$f(x_1, x_2) = \frac{1}{2} x_1^2 + 2x_2^2 - 2x_1 - 2x_2.$$

Además, el conjunto factible Ω es un poliedro. Por lo tanto, por Corolario 1.4.8, las condiciones KKT son suficientes y necesarias para la optimalidad. Las definimos a continuación:

$$\begin{aligned} x_1^* + x_2^* - 1.5 &\leq 0, \quad x_1^* \geq 0, \quad x_2^* \geq 0 && \text{(Factibilidad primal)} \\ \lambda_i^* &\geq 0 \quad \forall i = 1, 2, 3 && \text{(Factibilidad dual)} \end{aligned}$$

$$\lambda_1^*(x_1^* + x_2^* - 1.5) = 0, \lambda_2^*x_1^* = 0, \lambda_3^*x_2^* = 0 \quad (\text{Holgura complementaria})$$

$$(P\mathbf{x}^* + \mathbf{q}) + \lambda_1^* \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} \lambda_2^* \\ \lambda_3^* \end{pmatrix} = \mathbf{0} \quad (\text{Estacionariedad})$$

Reemplazando P y $\mathbf{q}$, de la condición de estacionariedad resulta

$$\begin{pmatrix} x_1^* - 2 + \lambda_1^* - \lambda_2^* \\ 4x_2^* - 2 + \lambda_1^* - \lambda_3^* \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}. \quad (1.4.9)$$

Si $\lambda_1^* = 0$, se deduce $\lambda_2^* = x_1^* - 2$ y $\lambda_3^* = 4x_2^* - 2$. Luego, por holgura complementaria, resultan $(x_1^* - 2)x_1^* = 0$ y $(4x_2^* - 2)x_2^* = 0$, con soluciones factibles $(0, 0)$ y $(0, 0.5)$. Ambas deben ser descartadas, pues violan la factibilidad dual.

En consecuencia, debe ser $\lambda_1^* \neq 0$. Esto significa que la restricción $x_1 + x_2 \leq 1.5$ está activa, tal que

$$x_1^* + x_2^* - 1.5 = 0. \quad (1.4.10)$$

Ahora, veamos que $x_1^* \neq 0$ y $x_2^* \neq 0$. Si $x_1^* = 0$ (análogamente para x_2^*), de la primera ecuación en (1.4.9) se deduce $\lambda_2^* = \lambda_1^* - 2$, tal que $\lambda_1^* \geq 2$. Además, (1.4.10) resulta en $x_2^* = 1.5$. Así, de la segunda ecuación de (1.4.9) se deduce

$$\lambda_3^* = 4 + \lambda_1^* \geq 6,$$

lo cual contradice la holgura complementaria $\lambda_3^*x_2^* = 0$ que en este caso exige sea $\lambda_3^* = 0$.

En limpio, sabemos que debe ser $\lambda_1^* \neq 0$, $x_1^* \neq 0$, $x_2^* \neq 0$. Esto implica que $\lambda_2^* = 0$, $\lambda_3^* = 0$ y la única restricción activa es g_1 , tal que

$$g_1(\mathbf{x}^*) = x_1^* + x_2^* - 1.5 = 0. \quad (1.4.11)$$

Luego, las condiciones KKT se reducen al siguiente sistema, que resulta de (1.4.9) y (1.4.11):

$$\begin{pmatrix} 1 & 0 & 1 \\ 0 & 4 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} x_1^* \\ x_2^* \\ \lambda_1^* \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \\ 1.5 \end{pmatrix}.$$

La solución del sistema nos da el único punto óptimo del problema:

$$\mathbf{x}^* = (1.2, 0.3) \quad \text{con } \lambda_1^* = 0.8.$$

Es importante remarcar que la unicidad de la solución es consistente con el hecho de que hemos resuelto un problema de optimización convexa cuya función objetivo es estrictamente convexa.

Generalización

Volvamos al caso general de nuestro interés:

$$\begin{aligned} & \text{minimizar} && f(\mathbf{x}) \\ & \text{sujeto a} && \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right. \right\}, \end{aligned} \quad (1.4.12)$$

donde el conjunto factible Ω está definido como una intersección de restricciones funcionales diferenciables. La generalización del análisis previo surge del siguiente hecho:

El conjunto de direcciones que forma un ángulo obtuso (o recto) con todas las direcciones desde $\mathbf{x}^*$ que permanecen en Ω coincide con el cono normal de la linearización de las restricciones activas en $\mathbf{x}^*$.




Figura 1.4.3: Cono normal de la linearización de restricciones activas en un punto $\mathbf{x}_0 \in \Omega$.

Esta idea es más bien intuitiva, por lo cual no estamos en condiciones de extender el Teorema 1.4.7 ni el Corolario 1.4.8 de manera rigurosa. Sin embargo, lo que sí haremos es extender el concepto de las condiciones KKT, dejando para más adelante el análisis de su aplicabilidad. Para ello, utilizaremos los resultados de la sección anterior en $\tilde{\Omega}$, la *linearización* de Ω en un punto dado. Pero, ¿qué conjunto es $\tilde{\Omega}$?

Sea $\mathbf{x}^* \in \Omega$ un punto óptimo y sea $I(\mathbf{x}^*)$ el conjunto de índices de las restricciones activas. Para modelar el comportamiento local de Ω en $\mathbf{x}^*$, consideramos las siguientes linearizaciones:

$$\begin{aligned} \tilde{g}_i(\mathbf{x}) &:= g_i(\mathbf{x}^*) + \nabla g_i(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) && \forall i \in I(\mathbf{x}^*), \\ \tilde{h}_j(\mathbf{x}) &:= h_j(\mathbf{x}^*) + \nabla h_j(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) && \forall j = 1, \dots, m. \end{aligned}$$

De este modo, la linearización de Ω queda definida como

$$\tilde{\Omega} = \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} \tilde{g}_i(\mathbf{x}) \leq 0, \quad i \in I(\mathbf{x}^*) \\ \tilde{h}_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right. \right\}.$$

Como puede observarse en la Figura 1.4.3, $\tilde{\Omega}$ es un poliedro que aproxima a Ω cerca de $\mathbf{x}^*$. Los vectores normales a los hiperplanos y a las fronteras de los semiespacios que definen a $\tilde{\Omega}$ están

determinados por $\nabla \tilde{g}_i(\mathbf{x})$ y $\nabla \tilde{h}_j(\mathbf{x})$, los cuales verifican

$$\nabla \tilde{g}_i(\mathbf{x}) = \nabla g_i(\mathbf{x}^*) \quad \text{y} \quad \nabla \tilde{h}_j(\mathbf{x}) = \nabla h_j(\mathbf{x}^*).$$

La construcción de $\tilde{\Omega}$ nos permite aplicar el Teorema 1.4.7 para caracterizar el cono normal en $\mathbf{x}^*$ como sigue:

$$N_{\tilde{\Omega}}(\mathbf{x}^*) = \left\{ \sum_{i \in I(\mathbf{x}^*)} \lambda_i \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \nu_j \nabla h_j(\mathbf{x}^*) \mid \lambda_i \in \mathbb{R}_0^+, \nu_j \in \mathbb{R} \right\},$$

Si bien los teoremas de optimalidad para $\tilde{\Omega}$ no pueden extenderse de forma directa a Ω , la forma en que fue construida esta linearización y la caracterización de su cono normal sugieren que es posible obtener condiciones de optimalidad para Ω a partir de las condiciones de optimalidad correspondientes a $\tilde{\Omega}$. No obstante, para establecer rigurosamente esta relación necesitamos imponer hipótesis adicionales que garanticen un comportamiento adecuado de las restricciones en $\mathbf{x}^*$.

En principio, formalizaremos el concepto de las condiciones KKT y luego analizaremos bajo qué condiciones estas permiten caracterizar la optimalidad de $\mathbf{x}^*$.

Definición 1.4.12 (Condiciones de Karush-Kuhn-Tucker (KKT)). Sea un problema de optimización con función objetivo diferenciable y restricciones funcionales, de la forma general (1.4.12). Las *condiciones KKT* en un punto $\mathbf{x} \in \mathbb{R}^p$ están dadas por:

■ **Factibilidad primal:**

$$\begin{aligned} g_i(\mathbf{x}) &\leq 0 & \forall i = 1, \dots, r, \\ h_j(\mathbf{x}) &= 0 & \forall j = 1, \dots, m. \end{aligned}$$

■ **Factibilidad dual:**

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, r.$$

■ **Holgura complementaria:**

$$\lambda_i g_i(\mathbf{x}) = 0 \quad \forall i = 1, \dots, r.$$

■ **Estacionariedad:**

$$-\nabla f(\mathbf{x}) = \sum_{i=1}^r \lambda_i \nabla g_i(\mathbf{x}) + \sum_{j=1}^m \nu_j \nabla h_j(\mathbf{x}).$$

Hasta ahora tenemos claro que, si el conjunto factible es un poliedro, las condiciones KKT se cumplen en los puntos óptimos. Sin embargo, esto no siempre es cierto en condiciones generales; hay situaciones en las que un punto óptimo no satisface las condiciones KKT. En otras palabras:

Las condiciones KKT a menudo son necesarias para la optimalidad, pero
no siempre.

A continuación, veremos un ejemplo que ilustra precisamente esta situación. Luego, estudiaremos bajo qué circunstancias podemos asegurar que las condiciones KKT sí constituyen un criterio necesario de optimalidad, análisis que se conoce bajo el concepto de *cualificación de restricciones*.


Ejemplo 1.4.13: Falla de condiciones KKT en un punto óptimo

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && -x \\ &\text{sujeto a} && y - (1 - x)^3 \leq 0, \\ &&& x \geq 0, y \geq 0. \end{aligned}$$

La función objetivo es $f(x, y) = -x$, y las funciones de restricción son $g_1(x, y) = y - (1 - x)^3$, $g_2(x, y) = -x$ y $g_3(x, y) = -y$. Entonces

$$\begin{aligned} \nabla f(x, y) &= (-1, 0), \\ \nabla g_1(x, y) &= (-3(1 - x)^2, 1), \quad \nabla g_2(x, y) = (-1, 0), \quad \nabla g_3(x, y) = (0, -1). \end{aligned}$$



Como se puede apreciar en la figura, $(x^*, y^*) = (1, 0)$ es el único punto óptimo de este problema. Pero en él, los gradientes de la función objetivo y de las restricciones activas son

$$\begin{aligned} \nabla f(x^*, y^*) &= (-1, 0), \\ \nabla g_1(x^*, y^*) &= (0, 1), \quad \nabla g_3(x^*, y^*) = (0, -1). \end{aligned}$$

Claramente, no hay manera de encontrar multiplicadores λ_1 y λ_3 que verifiquen la condición de estacionariedad

$$\underbrace{-\nabla f(x^*, y^*)}_{(1,0)} = \lambda_1 \underbrace{\nabla g_1(x^*, y^*)}_{(0,1)} + \lambda_3 \underbrace{\nabla g_3(x^*, y^*)}_{(0,-1)}.$$

En consecuencia, las condiciones KKT fallan en este caso.

Cualificación de restricciones

Una *cualificación de restricciones* es una condición adicional que se impone sobre las restricciones de un problema de optimización, con el fin de evitar comportamientos degenerados y garantizar ciertas propiedades teóricas deseables. En particular, nuestro interés es asegurar que las condiciones KKT sean efectivamente condiciones necesarias de optimalidad.

Sea $\mathbf{x}^*$ un punto óptimo de Ω . Las cualificaciones de restricciones más frecuentes son:

- **Restricciones afines:** Esto lo hemos estudiado como caso particular en la sección anterior, ya que el conjunto factible Ω es un poliedro. Por lo tanto, no hace falta imponer cualificaciones adicionales.
- **Restricciones de desigualdad cóncavas y restricciones de igualdad afines:** Si las restricciones de desigualdad activas $\{g_i \mid i \in I(\mathbf{x}^*)\}$ son funciones diferenciables cóncavas en una vecindad convexa de $\mathbf{x}^*$ y las restricciones de igualdad $\{h_j \mid j = 1, \dots, m\}$ son funciones afines, entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.
- **Independencia lineal de los gradientes (LICQ):** Si todas las funciones de restricción son continuamente diferenciables y el conjunto

$$\{\nabla g_i(\mathbf{x}^*) \mid i \in I(\mathbf{x}^*)\} \cup \{\nabla h_j(\mathbf{x}^*) \mid j = 1, \dots, m\}$$

es linealmente independiente, entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.

✍ Exprese la condición LICQ para el caso en que hay una única restricción. Luego, analice el problema

$$\begin{aligned} &\text{maximizar} && \|\mathbf{X} - \mathbf{w}\mathbf{w}^\top \mathbf{X}\|_F^2 \\ &\text{sujeto a} && \|\mathbf{w}\|_2 = 1, \end{aligned}$$

con $\mathbf{X} \in \mathbb{R}^{n \times p}$ y $\mathbf{w} \in \mathbb{R}^p$. Este problema corresponde a la formulación de PCA para hallar la primer componente principal de $\mathbf{X}$.

- **Condición de Slater:** Si las restricciones de desigualdad $\{g_i \mid i = 1, \dots, r\}$ son funciones diferenciables convexas, las restricciones de igualdad $\{h_j \mid j = 1, \dots, m\}$ son funciones afines y, además, existe un punto *estrictamente factible*; esto es,

$$\exists \mathbf{x}_0 \in \text{relint } \mathcal{D} : g_i(\mathbf{x}_0) < 0 \wedge h_j(\mathbf{x}_0) = 0 \quad \forall i = 1, \dots, r, \forall j = 1, \dots, m,$$

entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.

La aparición de $\text{relint } \mathcal{D}$ permite que el punto estrictamente factible no se encuentre en el borde relativo del dominio y, por tanto, que sea posible realizar pequeñas perturbaciones en cualquier dirección. Esto resulta particularmente importante cuando $\mathcal{D}$ está contenido en un subespacio afín de $\mathbb{R}^p$ y, por lo tanto, tiene interior vacío. Cuando $\mathcal{D}$ tiene interior no vacío, se tiene $\text{relint } \mathcal{D} = \text{int } \mathcal{D}$.

La condición de Slater es la cualificación de restricciones más común para garantizar que las condiciones KKT son necesarias para que un punto sea óptimo. Es importante remarcar que la condición de *factibilidad estricta* es fundamental y no puede relajarse.

 Confirme lo expresado anteriormente analizando el problema

$$\begin{array}{ll} \text{minimizar} & x \\ \text{sujeto a} & x^2 \leq 0. \end{array}$$

Además, la condición de convexidad tampoco puede relajarse, como se ve en el Ejemplo 1.4.13, donde la función de restricción $g_1(x, y) = y - (1 - x)^3$ no es convexa en un entorno del punto óptimo $(1, 0)$.

Importante

Si no hay restricciones de desigualdad y las restricciones de igualdad son afines, la condición de Slater se reduce a la existencia de un punto factible en relint $\mathcal{D}$. En consecuencia, en problemas de la forma

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & A\mathbf{x} = \mathbf{b}, \end{array}$$

con $\text{dom } f = \mathbb{R}^p$, la existencia de un punto factible es suficiente para garantizar que las condiciones KKT se satisfacen en todo punto óptimo.

Ahora bien, si a la condición de Slater le añadimos la hipótesis de que la función objetivo f es convexa, entonces las condiciones KKT no solo son necesarias, sino que también resultan suficientes para garantizar la optimalidad. Este escenario corresponde a los problemas de optimización convexa con funciones diferenciables, en los cuales el punto óptimo queda completamente caracterizado por las condiciones KKT.

Teorema 1.4.14 (Caracterización de optimalidad mediante KKT). *Sea un problema de optimización convexa de la forma*

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r, \\ & A\mathbf{x} = \mathbf{b}, \end{array}$$

con $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^m$. Si la función objetivo f y las funciones de restricción $g_1, \dots, g_r$ son diferenciables, y además las restricciones verifican la condición de Slater, entonces las condiciones KKT son suficientes y necesarias para que un punto sea óptimo.

Demostración. Probaremos únicamente la suficiencia. Sea $\mathbf{x}_0$ un punto factible que verifica las condiciones KKT. Entonces, la condición de estacionariedad nos permite afirmar que existen

$\lambda \in \mathbb{R}^r$, con $\lambda \succeq \mathbf{0}$, y $\nu \in \mathbb{R}^m$ tales que

$$\nabla f(\mathbf{x}_0) + \sum_{i=1}^r \lambda_i \nabla g_i(\mathbf{x}_0) + A^\top \nu = \mathbf{0}. \quad (1.4.13)$$

Dado que f y g_i son funciones convexas, también es convexa la función $L : \mathbb{R}^p \rightarrow \mathbb{R}$ definida por

$$L(\mathbf{x}) := f(\mathbf{x}) + \sum_{i=1}^r \lambda_i g_i(\mathbf{x}) + \nu^\top (A\mathbf{x} - \mathbf{b}).$$

Por condición de optimalidad de primer orden sin restricciones para funciones convexas (Teorema 1.4.1), la expresión (1.4.13) implica que $\mathbf{x}_0$ es el minimizador de $L(\mathbf{x}_0)$. Además, es fácil ver que $L(\mathbf{x}) \leq f(\mathbf{x})$ para todo $\mathbf{x}$ factible. En consecuencia, se deduce

$$f(\mathbf{x}_0) = L(\mathbf{x}_0) \leq L(\mathbf{x}) \leq f(\mathbf{x}) \quad \forall \mathbf{x} \text{ factible},$$

donde la primera igualdad es cierta gracias a la condición de holgura complementaria

$$\lambda_i g_i(\mathbf{x}_0) = 0 \quad \forall i = 1, \dots, r.$$

Luego, $\mathbf{x}_0$ es punto óptimo del problema, tal como queríamos probar. ■

✍ En la demostración anterior, justifique que L es una función convexa, $L(\mathbf{x}) \leq f(\mathbf{x})$ para todo $\mathbf{x}$ factible y $L(\mathbf{x}_0) = f(\mathbf{x}_0)$.

Ejemplo 1.4.15: Condiciones KKT suficientes y necesarias para optimalidad

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && x_1^2 + x_2^2 \\ &\text{sujeto a} && x_1 + x_2 \leq 1, \\ &&& x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

Claramente, el único punto óptimo es $\mathbf{x}^* = \mathbf{0}$. Además, se cumple la condición de Slater para KKT: en primer lugar, las restricciones de desigualdad están definidas por funciones afines (y, por lo tanto, convexas); en segundo lugar, el punto $(0.2, 0.2)$ es estrictamente factible para las restricciones activas en $\mathbf{0}$. Por lo tanto, podemos afirmar que las condiciones KKT son suficientes y necesarias para la optimalidad.

Vamos a verificar la conclusión anterior. Las condiciones KKT son:

$$\begin{aligned} x_1^* + x_2^* - 1 &\leq 0, \quad x_1^* \geq 0, \quad x_2^* \geq 0 && \text{(Factibilidad primal)} \\ \lambda_i^* &\geq 0 \quad \forall i = 1, 2, 3 && \text{(Factibilidad dual)} \\ \lambda_1^*(x_1^* + x_2^* - 1) &= 0, \quad \lambda_2^* x_1^* = 0, \quad \lambda_3^* x_2^* = 0 && \text{(Holgura complementaria)} \\ -2x_1^* &= \lambda_1^* - \lambda_2^*, \quad -2x_2^* = \lambda_1^* - \lambda_3^* && \text{(Estacionariedad)} \end{aligned}$$

El único punto que cumple todas estas condiciones es $\mathbf{x}^* = \mathbf{0}$, con $\lambda^* = \mathbf{0}$. Para justificar esto,

veamos que suponer $x_1^* > 0$ (análogamente para $x_2^* > 0$) conduce a un absurdo:

- Por holgura complementaria, debe ser $\lambda_2^* = 0$.
- Por condición de estacionariedad, $\lambda_1^* < 0$, lo cual contradice la factibilidad dual.

III | Dualidad

La teoría de la dualidad es fundamental en optimización, pues permite reformular problemas mediante funciones duales que pueden proporcionar información valiosa sobre la solución óptima.

Función dual de Lagrange

Definición 1.4.16 (Lagrangiano). Sea un problema de optimización de la forma general (1.4.12). Se denomina *Lagrangiano* a la función $\mathcal{L} : \mathbb{R}^p \times \mathbb{R}^r \times \mathbb{R}^m \rightarrow \mathbb{R}$ definida por

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) := f(\mathbf{x}) + \sum_{i=1}^r \lambda_i g_i(\mathbf{x}) + \sum_{j=1}^m \nu_j h_j(\mathbf{x}),$$

con $\text{dom } \mathcal{L} := \mathcal{D} \times \mathbb{R}^r \times \mathbb{R}^m$. Las componentes de $\boldsymbol{\lambda}$ y $\boldsymbol{\nu}$ se denominan *multiplicadores de Lagrange*.

En adelante, nos referiremos al problema de optimización general como *problema primal*. A partir del Lagrangiano, construimos a continuación una función que luego nos permitirá derivar una cota inferior para el valor óptimo p^* del problema primal.

Definición 1.4.17 (Función dual de Lagrange). Sea $\mathcal{L}$ el Lagrangiano de la Definición 1.4.16. Se denomina *función dual de Lagrange* a $\mathcal{G} : \mathbb{R}^r \times \mathbb{R}^m \rightarrow \mathbb{R}$ definida por

$$\mathcal{G}(\boldsymbol{\lambda}, \boldsymbol{\nu}) := \inf_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}).$$

Cuando el Lagrangiano no está acotado inferiormente en $\mathbf{x}$, se asume el valor $-\infty$.

Observar que, para un $\mathbf{x}$ fijo, el Lagrangiano es una función afín de $(\boldsymbol{\lambda}, \boldsymbol{\nu})$, de manera que la función dual $\mathcal{G}$ es el ínfimo puntual de una familia de funciones afines. Como consecuencia, de acuerdo con las operaciones que preservan convexidad vistas en la Sección 2, podemos afirmar que $\mathcal{G}$ es siempre una función cóncava, lo cual será fundamental más adelante.

Importante

La función dual $\mathcal{G}$ es una cota inferior del valor óptimo p^* del problema primal, en el siguiente sentido: para todo $\boldsymbol{\lambda} \succeq \mathbf{0}$ y para todo $\boldsymbol{\nu}$, resulta

$$\mathcal{G}(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq p^*.$$

 Justifique la propiedad anterior.

Ejemplo 1.4.18: Solución de mínima norma de un sistema de ecuaciones lineales (parte 1)

Sean $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^m$. Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \mathbf{x}^\top \mathbf{x} \\ &\text{sujeto a} && A\mathbf{x} = \mathbf{b}. \end{aligned}$$

Al no haber restricciones de desigualdad, el Lagrangiano es

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\nu}) = \mathbf{x}^\top \mathbf{x} + \boldsymbol{\nu}^\top (A\mathbf{x} - \mathbf{b}).$$

Dado que $\mathcal{L}$ es una función convexa, podemos minimizar respecto de $\mathbf{x}$ usando la condición de optimalidad $\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\nu}) = \mathbf{0}$. Resulta

$$\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\nu}) = 2\mathbf{x} + A^\top \boldsymbol{\nu} = \mathbf{0} \quad \rightarrow \quad \mathbf{x} = -\frac{1}{2} A^\top \boldsymbol{\nu}.$$

La función dual es

$$\begin{aligned} \mathcal{G}(\boldsymbol{\nu}) &= \mathcal{L}\left(-\frac{1}{2} A^\top \boldsymbol{\nu}, \boldsymbol{\nu}\right) \\ &= \left(-\frac{1}{2} A^\top \boldsymbol{\nu}\right)^\top \left(-\frac{1}{2} A^\top \boldsymbol{\nu}\right) + \boldsymbol{\nu}^\top \left(A \left(-\frac{1}{2} A^\top \boldsymbol{\nu}\right) - \mathbf{b}\right) \\ &= -\frac{1}{4} \boldsymbol{\nu}^\top A A^\top \boldsymbol{\nu} - \boldsymbol{\nu}^\top \mathbf{b}, \end{aligned}$$

la cual es una función cuadrática cóncava. Por propiedad, podemos afirmar que

$$-\frac{1}{4} \boldsymbol{\nu}^\top A A^\top \boldsymbol{\nu} - \boldsymbol{\nu}^\top \mathbf{b} \leq p^* \quad \forall \boldsymbol{\nu} \in \mathbb{R}^m.$$

El problema dual de Lagrange

Una pregunta de interés es:

¿Cuál es el valor máximo d^* de $\mathcal{G}(\boldsymbol{\lambda}, \boldsymbol{\nu})$ si asumimos $\boldsymbol{\lambda} \succeq \mathbf{0}$?

Definición 1.4.19 (Problema dual de Lagrange). Sea $\mathcal{G}$ la función dual de Lagrange asociado al problema primal. El *problema dual de Lagrange* es

$$\begin{aligned} &\text{maximizar} && \mathcal{G}(\boldsymbol{\lambda}, \boldsymbol{\nu}) \\ &\text{sujeto a} && \boldsymbol{\lambda} \succeq \mathbf{0}. \end{aligned}$$

El valor óptimo del problema dual se denota con d^* . Además, se dice que $(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ son los *multiplicadores de Lagrange óptimos* si verifican $\mathcal{G}(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = d^*$.

Dado que $\mathcal{G}$ es una función cóncava, podemos afirmar que:

El problema dual es siempre un problema de optimización convexo.

Dualidad débil

El valor óptimo d^* del problema dual es la mejor cota inferior de p^* que podemos obtener mediante la función dual de Lagrange. La desigualdad

$$d^* \leq p^* \quad (1.4.14)$$

se conoce como *dualidad débil*, y es cierta incluso si el problema primal no es convexo. También podemos afirmar que:

- Si el problema primal no tiene cota inferior ($p^* = -\infty$), entonces el problema dual es infactible ($d^* = -\infty$).
- Si el problema dual no tiene cota superior ($d^* = \infty$), entonces el problema primal es infactible ($p^* = \infty$).

Nos referiremos a la diferencia $p^* - d^*$ como *brecha de dualidad óptima* del problema primal. Es importante remarcar que la ventaja de trabajar con la dualidad débil radica en que, en ocasiones, permite obtener eficientemente cotas inferiores del valor óptimo primal.

Dualidad fuerte

La *dualidad fuerte* se cumple si ocurre

$$d^* = p^*. \quad (1.4.15)$$

Hay dos hechos importantes a tener en cuenta:

- La dualidad fuerte, en general, no se cumple.
- Si el problema primal es convexo, la dualidad fuerte usualmente se cumple.

La cualificación de restricciones más común para asegurar la dualidad fuerte es la *condición de Slater* definida anteriormente. Formalizaremos esto en el siguiente teorema.

Teorema 1.4.20 (Teorema de Slater). *Sea un problema de optimización convexa de la forma*

$$\begin{aligned} &\text{minimizar} && f(\mathbf{x}) \\ &\text{sujeto a} && g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r, \\ &&& A\mathbf{x} = \mathbf{b}, \end{aligned}$$

con $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^m$. Si se satisface la condición de Slater de que existe un punto estrictamente

factible; esto es,

$$\exists \mathbf{x}_0 \in \text{relint } \mathcal{D} : g_i(\mathbf{x}_0) < 0 \ \forall i = 1, \dots, r \ \wedge \ A\mathbf{x}_0 = \mathbf{b},$$

entonces se cumple la dualidad fuerte.

✍ Utilice el siguiente ejemplo para mostrar que Slater no es una condición necesaria para la dualidad fuerte.

$$\begin{array}{ll} \text{minimizar} & x^2 \\ \text{sujeto a} & x^2 \leq 0. \end{array}$$

Ejemplo 1.4.21: Solución de mínima norma de un sistema de ecuaciones lineales (parte 2)

Consideremos el problema del Ejemplo 1.4.18, con $m = 1$:

$$\begin{array}{ll} \text{minimizar} & \mathbf{x}^\top \mathbf{x} \\ \text{sujeto a} & \mathbf{a}^\top \mathbf{x} = b, \end{array}$$

con $\mathbf{a} \in \mathbb{R}^p$ y $b \in \mathbb{R}$. Tenemos un solo multiplicador de Lagrange, $\nu \in \mathbb{R}$, y la función dual es

$$\mathcal{G}(\nu) = -\frac{1}{4} \|\mathbf{a}\|_2^2 \nu^2 - b\nu.$$

Por lo tanto, el problema dual es

$$\begin{array}{ll} \text{maximizar} & -\frac{1}{4} \|\mathbf{a}\|_2^2 \nu^2 - b\nu \\ \text{sujeto a} & \nu > 0. \end{array}$$

Este es un problema fácil de resolver, porque $\mathcal{G}(\nu)$ es una función cuadrática de una variable, de manera que la solución está dada por su vértice. Resulta

$$\nu^* = -\frac{2b}{\|\mathbf{a}\|_2^2} \quad \text{tal que} \quad d^* = \mathcal{G}(\nu^*) = \frac{b^2}{\|\mathbf{a}\|_2^2}.$$

Dado que se cumplen las condiciones del Teorema 1.4.20 (problema de optimización convexa + condición de Slater), podemos concluir que hay dualidad fuerte. Luego,

$$p^* = \frac{b^2}{\|\mathbf{a}\|_2^2}.$$

Observar que esto muestra que la distancia del hiperplano $\mathbf{a}^\top \mathbf{x} = b$ al origen es $b/\|\mathbf{a}\|_2$, tal como lo mencionamos en la Sección 2.

Relación entre dualidad y KKT

Analicemos la siguiente pregunta:

¿Qué implicancias tiene la dualidad fuerte $d^* = p^*$?

Para ello, vamos a suponer que los puntos óptimos existen, tanto para el problema primal ($\mathbf{x}^*$) como para el problema dual ($\boldsymbol{\lambda}^*$ y $\boldsymbol{\nu}^*$). Además, es importante recordar que en el problema dual se impone la restricción $\boldsymbol{\lambda} \succeq \mathbf{0}$.

La dualidad fuerte significa que

$$\underbrace{f(\mathbf{x}^*)}_{p^*} = \underbrace{\mathcal{G}(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)}_{d^*} = \inf_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*). \quad (1.4.16)$$

Hay que tener cuidado al interpretar la expresión (1.4.16): si bien garantiza que $f(\mathbf{x}^*)$ es el valor ínfimo del Lagrangiano, no nos dice nada acerca de cuál es el valor de $\mathbf{x}$ donde dicho ínfimo se alcanza, y en principio solo podemos escribir

$$f(\mathbf{x}^*) \leq \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$$

No obstante, la naturaleza de los multiplicadores de Lagrange y las restricciones funcionales nos permiten agregar

$$f(\mathbf{x}^*) \leq \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = f(\mathbf{x}^*) + \underbrace{\sum_{i=1}^r \lambda_i g_i(\mathbf{x}^*)}_{\leq 0} + \underbrace{\sum_{j=1}^m \nu_j h_j(\mathbf{x}^*)}_{=0} \leq f(\mathbf{x}^*).$$

Luego, por antisimetría, debe ser

$$f(\mathbf{x}^*) = \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = f(\mathbf{x}^*) + \sum_{i=1}^r \lambda_i g_i(\mathbf{x}^*). \quad (1.4.17)$$

En consecuencia, a partir de (1.4.16) y (1.4.17) podemos concluir que, bajo dualidad fuerte, la terna $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ verifica dos condiciones KKT de la Definición 1.4.12: holgura complementaria y estacionariedad. En efecto:

- *Holgura complementaria*: para que la igualdad en (1.4.17) sea cierta, debe ser

$$\sum_{i=1}^r \lambda_i g_i(\mathbf{x}^*) = 0.$$

Pero los términos son no positivos, por lo cual esto es equivalente a pedir

$$\lambda_i g_i(\mathbf{x}^*) = 0 \quad \forall i = 1, \dots, r.$$

- *Estacionariedad*: el ínfimo de $\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ sí ocurre en $\mathbf{x}^*$:

$$\mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = \inf_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*).$$

La suposición de que la función objetivo y las funciones de restricción son diferenciables garantiza que el Lagrangiano también lo es. Además, si las funciones involucradas están definidas en conjuntos abiertos, podemos asegurar que $\text{dom } \mathcal{L} := \mathcal{D} \times \mathbb{R}^r \times \mathbb{R}^m$ es un conjunto abierto de $\mathbb{R}^{p+r+m}$. Así, $\mathbf{x}^*$ es un punto interior de $\text{dom } \mathcal{L}$ y, por lo tanto, la condición de optimalidad de primer orden asegura que

$$\nabla \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = \mathbf{0}.$$

Reemplazando por

$$\nabla \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = \nabla f(\mathbf{x}^*) + \sum_{i=1}^r \lambda_i^* \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \nu_j^* \nabla h_j(\mathbf{x}^*),$$

obtenemos

$$-\nabla f(\mathbf{x}^*) = \sum_{i=1}^r \lambda_i^* \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \nu_j^* \nabla h_j(\mathbf{x}^*).$$

Por supuesto, la factibilidad primal y la factibilidad dual son inmediatas del hecho de asumir que $\mathbf{x}^*$ es óptimo para el problema primal y $(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ son óptimos para el problema dual, respectivamente. Así, estamos en condiciones de afirmar que las condiciones KKT son necesarias para la dualidad fuerte, tal y como lo establece el siguiente teorema.

Teorema 1.4.22 (Dualidad y KKT). *Sea $\mathbf{x}^*$ un punto óptimo primal y $(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ un punto óptimo dual. Si $d^* = p^*$, entonces la terna $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*)$ satisface las condiciones de Karush-Kuhn-Tucker.*

Ejemplo 1.4.23: Problema de *water-filling*

Veamos un ejemplo clásico de *teoría de la información*. Consideremos un sistema de comunicación con p canales para transmisión de información y supongamos que la potencia total disponible para transmitir es limitada. El objetivo es distribuir la potencia total, que para facilitar el análisis se normaliza al valor 1. Así, si denotamos x_i la potencia asignada al i -ésimo canal, tenemos que

$$\sum_{i=1}^p x_i = \mathbf{1}^\top \mathbf{x} = 1, \quad x_i \geq 0.$$

Un modelo típico para la capacidad máxima de transmisión es

$$\sum_{i=1}^p \log(x_i + \alpha_i),$$

donde $\alpha_i > 0$ representa el ruido del i -ésimo canal. Esto deriva en el siguiente problema de optimización convexa:

$$\begin{aligned} &\text{minimizar} && -\sum_{i=1}^p \log(x_i + \alpha_i) \\ &\text{sujeto a} && \mathbf{1}^\top \mathbf{x} = 1, \\ &&& \mathbf{x} \succeq \mathbf{0}. \end{aligned}$$

Observar que hay p restricciones de desigualdad, con $g_i(\mathbf{x}) = x_i$, y una única restricción de igualdad, con $h(\mathbf{x}) = \mathbf{1}^\top \mathbf{x}$. Claramente la condición de Slater se cumple: podemos tomar, por ejemplo, el punto estrictamente factible $x_i = 1/p$ (para todo $i = 1, \dots, p$). Por lo tanto, podemos asegurar que se cumple la dualidad fuerte y que las condiciones KKT son suficientes y necesarias para la optimalidad.

Las condiciones KKT son:

$$\begin{aligned}
 \mathbf{x}^* &\succeq \mathbf{0}, \mathbf{1}^\top \mathbf{x}^* = 1 && \text{(Factibilidad primal)} \\
 \boldsymbol{\lambda}^* &\succeq \mathbf{0} && \text{(Factibilidad dual)} \\
 \lambda_i^* x_i^* &= 0 \quad \forall i = 1, \dots, p && \text{(Holgura complementaria)} \\
 \frac{1}{x_i^* + \alpha_i} &= -\lambda_i^* + \nu^* \quad \forall i = 1, \dots, p && \text{(Estacionariedad)}
 \end{aligned}$$

La última condición puede reescribirse como

$$\lambda_i^* = \nu^* - \frac{1}{x_i^* + \alpha_i},$$

lo que permite combinarla con las demás condiciones que involucran $\boldsymbol{\lambda}$, facilitando así la eliminación de este multiplicador. Nos quedan así las siguientes expresiones:

$$\begin{aligned}
 \mathbf{x}^* &\succeq \mathbf{0}, \mathbf{1}^\top \mathbf{x}^* = 1, \\
 \left(\nu^* - \frac{1}{x_i^* + \alpha_i} \right) x_i^* &= 0 \quad \forall i = 1, \dots, p, \\
 \nu^* - \frac{1}{x_i^* + \alpha_i} &\geq 0 \quad \forall i = 1, \dots, p.
 \end{aligned}$$


El análisis de las últimas dos, junto con $\mathbf{x}^* \succeq \mathbf{0}$, permiten deducir que

$$x_i^* = \begin{cases} 1/\nu^* - \alpha_i & \text{si } \nu^* < \frac{1}{\alpha_i}, \\ 0 & \text{si } \nu^* \geq \frac{1}{\alpha_i}. \end{cases} = \max\{0, 1/\nu^* - \alpha_i\}.$$

Finalmente, el uso de la condición $\mathbf{1}^\top \mathbf{x}^* = 1$ resulta en

$$\sum_{i=1}^p \max\{0, 1/\nu^* - \alpha_i\} = 1. \quad (1.4.18)$$

El lado izquierdo de (1.4.18) corresponde a una función de $1/\nu^*$ que es continua, creciente por tramos y con puntos de quiebre en los valores α_i , tal y como lo ejemplifica la siguiente figura:



Este método de solución se conoce como *water-filling* por la siguiente interpretación: si α_i es

el nivel del suelo en el punto i e inundamos la región con agua hasta la altura $1/\nu^*$, entonces la cantidad total de agua es justamente

$$\sum_{i=1}^p \max\{0, 1/\nu^* - \alpha_i\}.$$

El problema de optimización, con esta interpretación, consiste en aumentar el nivel de inundación hasta haber usado una cantidad total de agua igual a 1, de manera tal que la profundidad de agua sobre el punto i -ésimo es justamente el valor óptimo x_i^* .





Figura 1.4.4: Método de *water-filling*: la región se inunda hasta un nivel $1/\nu^*$, utilizando una cantidad total de agua igual a 1.

Finalizamos esta sección con un cuadro resumen con los principales resultados.



Referencias

Boyd, S. & Vandenberghe, L. (2004). *Convex optimization*. Cambridge University Press.

Farina, G. (2024–2025). *MIT 6.7220: Nonlinear Optimization*. Course material and lecture notes. Massachusetts Institute of Technology. URL: <https://www.mit.edu/~gfarina/notes/>.