



UNL. FACULTAD DE
INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez

Liliana Forzani

Condiciones de optimalidad

En un problema de optimización general con restricciones funcionales, de la forma

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right. \right\}, \end{array}$$

las condiciones de optimalidad definen los requisitos que deben cumplir los puntos óptimos. En lo que sigue, asumiremos siempre que trabajamos con funciones diferenciables.

1.4.1 | Condiciones de optimalidad de primer orden

Optimización sin restricciones

De cursos anteriores recordemos que, cuando se pretende optimizar una función f en su dominio, una condición necesaria (siempre que $\text{dom } f$ sea un conjunto abierto) para que un punto sea óptimo es que verifique

$$\nabla f(\mathbf{x}) = \mathbf{0}. \quad (1.4.1)$$

☑ *Prueba.* Sea $\mathbf{x}^* \in \mathbb{R}^p$ un minimizador de la función $f : \mathbb{R}^p \rightarrow \mathbb{R}$ y sea $\mathbf{d} \in \mathbb{R}^p$ una dirección arbitraria. Entonces se cumple

$$f(\mathbf{x}^* + t\mathbf{d}) \geq f(\mathbf{x}^*) \quad \forall t \in \mathbb{R} : \mathbf{x}^* + t\mathbf{d} \in \text{dom } f.$$

Así, tenemos que

$$\lim_{t \rightarrow 0^-} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} \leq 0 \quad \text{y} \quad \lim_{t \rightarrow 0^+} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} \geq 0.$$

En consecuencia, como f es diferenciable, la derivada direccional de f en $\mathbf{x}^*$ a lo largo de $\mathbf{d}$ existe y debe ser

$$\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}^*) := \lim_{t \rightarrow 0} \frac{f(\mathbf{x}^* + t\mathbf{d}) - f(\mathbf{x}^*)}{t} = 0.$$

Usando la propiedad $\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}) = \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle_2$, se deduce

$$\langle \nabla f(\mathbf{x}^*), \mathbf{d} \rangle_2 = 0.$$

Finalmente, dado que $\mathbf{d}$ es arbitrario, concluimos que $\nabla f(\mathbf{x}^*) = \mathbf{0}$. ■



La condición $\nabla f(\mathbf{x}) = \mathbf{0}$ no caracteriza únicamente puntos óptimos en un sentido global, sino también a aquellos donde f alcanza un extremo local. De hecho, la prueba puede adaptarse a tal caso escribiendo

$$f(\mathbf{x} + t\mathbf{d}) \geq f(\mathbf{x}) \quad \text{para todo } 0 \leq t < \varepsilon,$$

donde $\mathbf{x}$ es un punto de extremo local, $\mathbf{d}$ es una dirección arbitraria y $\varepsilon > 0$ es lo suficientemente pequeño como para que $\mathbf{x} + t\mathbf{d}$ permanezca en un entorno donde se verifica la definición de mínimo local.

Pero cuidado: lo anterior es *solo una condición necesaria* que todos los puntos óptimos deben cumplir, pero no implica que cualquier punto que la satisfaga sea automáticamente óptimo. En otras palabras, las soluciones de $\nabla f(\mathbf{x}) = \mathbf{0}$ forman una lista de puntos candidatos para minimizar, llamados *puntos críticos*.

De inmediato surgen dos preguntas claves:

¿Cuál es la generalización de la condición necesaria $\nabla f(\mathbf{x}) = \mathbf{0}$ cuando enfrentamos un problema de optimización con restricciones?

¿Bajo qué circunstancias $\nabla f(\mathbf{x}) = \mathbf{0}$ también se convierte en una condición suficiente para la optimalidad?

Para el caso de optimización sin restricciones, podemos responder a la segunda pregunta con un resultado muy importante en optimización convexa, relacionado con el Teorema 3 de la Sección 2.

Teorema 1.4.1 (Condición suficiente y necesaria de optimalidad de primer orden sin restricciones para funciones convexas). *Sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable y convexa. Entonces $\mathbf{x}^* \in \text{dom } f$ es un minimizador de f si y solo si*

$$\nabla f(\mathbf{x}^*) = \mathbf{0}.$$

Optimización con restricciones

Para generalizar la condición necesaria $\nabla f(\mathbf{x}) = \mathbf{0}$ al caso de optimización con restricciones, es importante respetar el sentido de una dirección $\mathbf{d} \in \mathbb{R}^p$, razón por la cual vamos a restringir el movimiento $\mathbf{x} + t\mathbf{d}$ a valores no negativos del parámetro; esto es, $t \geq 0$. De esta manera, la posibilidad de aproximarnos a un punto factible $\mathbf{x}$ sin salirnos del conjunto factible Ω va a depender exclusivamente de la dirección $\mathbf{d}$ considerada. Esto conduce a una generalización natural de la condición de optimalidad provista por la prueba anterior, a saber:

$$\langle \nabla f(\mathbf{x}^*), \mathbf{d} \rangle_2 \geq 0 \quad \forall \mathbf{d} \in \mathbb{R}^p : \mathbf{x}^* + t\mathbf{d} \in \Omega, \quad (1.4.2)$$

para cualquier $t > 0$ lo suficientemente pequeño. A partir de esto, nos preguntamos:

¿Cuáles son las direcciones $\mathbf{d}$ que nos permiten permanecer en Ω desde el punto $\mathbf{x}$?

¿Qué implicancias tiene (1.4.2) para el vector gradiente $\nabla f(\mathbf{x})$?

Una idea inicial para caracterizar el conjunto de direcciones permitidas es tomar cualquier otro punto $\mathbf{y} \in \Omega$ y observar qué sucede con la dirección desde $\mathbf{x}$ hacia $\mathbf{y}$. Esta dirección, $\mathbf{d} = \mathbf{y} - \mathbf{x}$, será válida siempre que Ω sea convexo (ver Definición 3 de la Sección 2). Claramente, en tal caso, (1.4.2) se verifica trivialmente tomando $t \leq 1$. Por ese motivo, podemos hacer la primera suposición con el objetivo de formalizar una condición necesaria de optimalidad:

Primer supuesto

Ω un conjunto convexo

Bajo esta suposición, tenemos el siguiente resultado, cuya demostración se obtiene directamente de ajustar la prueba vista para (1.4.1).

Teorema 1.4.2 (Condición necesaria de optimalidad de primer orden para un conjunto factible convexo). *Sea $\Omega \subset \mathbb{R}^p$ convexo y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable. Si $\mathbf{x}^* \in \Omega$ es un minimizador de f sobre Ω , entonces*

$$\langle \nabla f(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle_2 \geq 0 \quad \forall \mathbf{y} \in \Omega. \quad (1.4.3)$$




Figura 1.4.1: Interpretación geométrica de la condición necesaria (1.4.3) del Teorema 1.4.2.

Como se puede apreciar en la Figura 1.4.1, para un punto óptimo $\mathbf{x}^*$ el vector gradiente forma un ángulo agudo (o recto) con todas las direcciones de la forma $\mathbf{y} - \mathbf{x}^*$. Esto se deduce del hecho que

$$\langle \nabla f(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle_2 = \underbrace{\|\nabla f(\mathbf{x}^*)\|_2}_{\geq 0} \underbrace{\|\mathbf{y} - \mathbf{x}^*\|_2}_{\geq 0} \cos \alpha \geq 0$$

si y solo si $\cos \alpha \geq 0$ (o equivalentemente, $0 \leq \alpha \leq \pi/2$).

Ahora bien, nosotros estamos interesados en hallar $\mathbf{x}^*$. En este sentido, la condición (1.4.3) nos sirve para identificar aquellos puntos $\mathbf{x} \in \Omega$ candidatos a ser óptimos (siguiendo la terminología habitual, los llamaremos *puntos críticos*). En consecuencia, si consideramos el vector opuesto al gradiente, los puntos críticos serán aquellos que verifiquen

$$\langle -\nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2 \leq 0 \quad \forall \mathbf{y} \in \Omega. \quad (1.4.4)$$

Esto vincula nuestro análisis con la definición de cono normal (Definición 7 de la Sección 2): la expresión (1.4.4) es equivalente a escribir $-\nabla f(\mathbf{x}) \in N_\Omega(\mathbf{x})$. Así, el Teorema 1.4.2 puede ser interpretado en términos de conos normales como sigue:

Bajo las condiciones del Teorema 1.4.2, si $\mathbf{x}^*$ es un minimizador de f sobre Ω , entonces

$$-\nabla f(\mathbf{x}^*) \in N_\Omega(\mathbf{x}^*).$$




Figura 1.4.2: Idea geométrica de la condición del gradiente para tres puntos críticos $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3 \in \Omega$ y un punto no crítico $\mathbf{x}_4 \in \Omega$. En el caso de $\mathbf{x}_3$, se tiene $\nabla f(\mathbf{x}_3) = \mathbf{0}$.

En la Figura 1.4.2 se presenta la geometría derivada de la condición necesaria establecida, para el caso en que Ω es un poliedro. Las posiciones de los puntos críticos corresponden a los ejemplos de conos normales vistos en la Sección 2. En particular, para puntos interiores de Ω , la condición se reduce a la ecuación $\nabla f(\mathbf{x}) = \mathbf{0}$, típica de los problemas sin restricciones.

Todos los casos están caracterizados por el siguiente hecho:

Los puntos críticos son aquellos en los cuales el opuesto del gradiente forma ángulos no agudos con todas las direcciones factibles.

Esta es, sin dudas, la idea principal de nuestro análisis, que procuraremos extender a formas más generales de Ω . Observar que la condición provista por el Teorema 2 es necesaria pero no suficiente. Podemos pensar rápidamente en ejemplos de mínimos locales en el interior de Ω , tales

como el Ejemplo 3 de la Sección 1. A continuación, veremos un ejemplo para cuando el punto crítico ocurre en la frontera de Ω , pero no es cierto que sea un punto óptimo.

Ejemplo 1.4.3: Punto crítico no óptimo en un poliedro


Consideremos el problema

$$\begin{aligned} &\text{minimizar} && x_2 - x_1^2 \\ &\text{sujeto a} && 2x_1 + x_2 \leq 1, \\ &&& -2x_1 + x_2 \leq 1, \\ &&& x_2 \geq 0. \end{aligned}$$

El conjunto factible Ω es el triángulo de vértices $(-\frac{1}{2}, 0)$, $(\frac{1}{2}, 0)$ y $(0, 1)$. En $\mathbf{x} = (0, 0)$ se tiene $\nabla f(0, 0) = (0, 1)$. La condición del Teorema 2 para este punto se expresa como

$$\langle (0, 1), \mathbf{y} - (0, 0) \rangle_2 = y_2 \geq 0 \quad \forall \mathbf{y} \in \Omega.$$

Esto es cierto, de acuerdo a la definición de Ω . De hecho, en la siguiente figura se puede ver que, efectivamente, $-\nabla f(0, 0) \in N_{\Omega}(0, 0)$.



Pese a verificar la condición necesaria (1.4.3), el punto $(0, 0)$ no es óptimo. De hecho, $f(0, 0) = 0$, mientras que el valor óptimo es $-\frac{1}{4}$ y ocurre en los vértices $(\pm\frac{1}{2}, 0)$.

Segundo supuesto

f una función convexa

Para el notable caso de las funciones convexas (Definición 8 de la Sección 2), la condición establecida en el Teorema 2 sí es suficiente.

Teorema 1.4.4 (Condición suficiente y necesaria de optimalidad de primer orden para un conjunto factible convexo y una función objetivo convexa). Sea $\Omega \subseteq \mathbb{R}^p$ convexo y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable convexa. Entonces $\mathbf{x}^*$ es un minimizador de f en Ω si y solo si se verifica

$$-\nabla f(\mathbf{x}^*) \in N_{\Omega}(\mathbf{x}^*). \quad (1.4.5)$$

🔍 *Prueba.* En virtud del Teorema 2, debemos probar únicamente la suficiencia. Sea $\mathbf{x} \in \Omega$ tal que $-\nabla f(\mathbf{x}) \in N_{\Omega}(\mathbf{x})$, entonces

$$\langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2 \geq 0 \quad \forall \mathbf{y} \in \Omega.$$

Por condición de primer orden para convexidad (Teorema 1 de Sección 2), resulta

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \underbrace{\langle \nabla f(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle_2}_{\geq 0} \geq f(\mathbf{x})$$

para todo $\mathbf{y} \in \Omega$, lo cual significa que $\mathbf{x}$ es un minimizador de f en Ω . ■



El Teorema 1.4.4 se puede aplicar a todo problema de optimización convexa, pero es un resultado más general.

Ejemplo 1.4.5: Aplicación de condición suficiente y necesaria de optimalidad en un problema de optimización convexa

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 \\ &\text{sujeto a} && x_1 + x_2 \leq 1.5, \\ &&& x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

con

$$A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \quad \text{y} \quad \mathbf{b} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

El conjunto factible Ω es el triángulo con vértices $(0,0)$, $(1.5,0)$ y $(0,1.5)$, por lo tanto es convexo. Respecto a la función objetivo, tenemos


$$\nabla f(\mathbf{x}) = A^\top (A\mathbf{x} - \mathbf{b}) = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \left[\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \mathbf{x} - \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right] = \begin{pmatrix} x_1 - 1 \\ 4x_2 - 2 \end{pmatrix},$$

y

$$\nabla^2 f(\mathbf{x}) = A^\top A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$$

Claramente $\nabla^2 f(\mathbf{x}) \succeq 0$, lo cual significa que f es convexa. Así, por Teorema 1.4.3, la condición (1.4.5) es suficiente y necesaria para que $\mathbf{x}$ sea un punto óptimo. Esto nos permite hacer el siguiente análisis:

- $\nabla f(\mathbf{x}) \neq \mathbf{0}$ para todo punto interior de Ω , lo cual implica que no hay puntos óptimos en el interior.
- En el lado $\{(0, t) \mid 0 < t < 1.5\}$, $-\nabla f(\mathbf{x}) = (1, 2 - 4t)$. Pero el cono normal está determinado por la dirección normal $(-1, 0)$, lo cual significa que $-\nabla f(\mathbf{x}) \in N_{\Omega}(\mathbf{x})$ si y solo si es de la forma $(-a, 0)$ con $a > 0$, lo cual no puede ocurrir. Por lo tanto, no hay puntos óptimos en esta porción de frontera.
- En el lado $\{(t, 1.5 - t) \mid 0 < t < 1.5\}$, tenemos que $-\nabla f(\mathbf{x}) = (1 - t, 4t - 4)$ y la dirección normal es $(1, 1)$. Esto significa que (1.4.5) es cierto si ambas componentes de $-\nabla f(\mathbf{x})$ son iguales, lo cual resulta en $t = 1$. De esta manera, el punto $(1, 0.5)$, con $\nabla f(1, 0.5) = \mathbf{0}$, es un punto óptimo del problema.
- Faltan los vértices del triángulo. En la siguiente figura se muestra el comportamiento de $-\nabla f(\mathbf{x})$ en cada uno de ellos. Dado que no cumplen la condición suficiente y necesaria (1.4.5), ningún vértice es un punto óptimo.



En conclusión, el problema tiene solución única

$$\mathbf{x}^* = (1, 0.5) \quad y \quad p^* = f(1, 0.5) = 0.$$

1.4.2 | Condiciones de Karush-Kuhn-Tucker (KKT)

Hasta ahora hemos visto que, para Ω convexo (*primer supuesto*), una condición necesaria para que un punto $\mathbf{x}$ sea óptimo es que el vector opuesto al gradiente de la función objetivo pertenezca

al cono normal $N_{\Omega}(\mathbf{x})$. Además, si la función objetivo es convexa (*segundo supuesto*), dicha condición resulta también suficiente.

Aunque el Teorema 1.4.4 es general, y contempla los problemas de optimización convexa, su aplicación práctica puede resultar poco directa. Afortunadamente, cuando el conjunto factible Ω está definido por restricciones funcionales diferenciables, es posible expresar estas condiciones de manera más estructurada a partir de la caracterización de los conos normales, lo cual conduce a las que se conocen como *condiciones de Karush-Kuhn-Tucker* (o, simplemente, condiciones KKT).

Nuestro objetivo es formular dichas condiciones. Comenzaremos analizando el caso particular de restricciones afines, para lograr intuición, y luego generalizaremos al caso de restricciones no lineales.

El caso particular de restricciones afines

Caso especial

Ω un poliedro

Vamos a considerar el caso en que Ω es un poliedro definido a partir de la intersección de un número finito de semiespacios e hiperplanos. Es decir, es de la forma

$$\Omega = \{\mathbf{x} \in \mathbb{R}^p \mid A\mathbf{x} \preceq \mathbf{b}, C\mathbf{x} = \mathbf{d}\}, \quad (1.4.6)$$

donde $A \in \mathbb{R}^{r \times p}$, $C \in \mathbb{R}^{m \times p}$, $\mathbf{b} \in \mathbb{R}^r$ y $\mathbf{d} \in \mathbb{R}^m$.

Definición 1.4.6 (Restricción activa). Una restricción de desigualdad $g(\mathbf{x}) \leq 0$ se dice que está *activa* en un punto $\mathbf{x}_0$ si allí se cumple con igualdad; es decir, si

$$g(\mathbf{x}_0) = 0.$$

Esto significa que $\mathbf{x}_0$ pertenece a la frontera del conjunto $\{\mathbf{x} \in \mathbb{R}^p \mid g(\mathbf{x}) \leq 0\}$.

En los ejemplos de conos normales en la Sección 2, analizamos su definición según la posición del punto de interés: si $\mathbf{x}$ es interior a Ω , resulta simplemente $N_{\Omega}(\mathbf{x}) = \{\mathbf{0}\}$, mientras que si $\mathbf{x}$ pertenece a la frontera de Ω , el cono normal queda determinado por las direcciones que definen los semiespacios e hiperplanos. Para este último caso, podemos resumirlo de la siguiente manera:

El cono normal en un punto en la frontera es la envolvente cónica de las
direcciones ortogonales a las restricciones activas.

No obstante, en dichos ejemplos hemos considerado casos particulares de Ω : un hiperplano, un semiespacio y la intersección de dos semiespacios. Necesitamos extender ese análisis a cualquier poliedro Ω y caracterizar el cono normal en cualquier punto de Ω . El siguiente resultado nos proporciona dicha caracterización.

Teorema 1.4.7 (Cono normal a un punto de un poliedro). Sea Ω el poliedro definido por (1.4.6). Para $\mathbf{x} \in \Omega$, sea $I(\mathbf{x})$ el conjunto de índices de las restricciones activas; esto es

$$I(\mathbf{x}) := \{i \in \{1, \dots, r\} \mid \mathbf{a}_i^\top \mathbf{x} = b_i\}.$$

Entonces, el cono normal en $\mathbf{x}$ está dado por

$$N_\Omega(\mathbf{x}) = \left\{ \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j \mid \lambda_i \in \mathbb{R}_0^+, \nu_j \in \mathbb{R} \right\}.$$

i

La suma en la expresión del cono normal puede ser reescrita sin restringir $i \in I(\mathbf{x})$, imponiendo $\lambda_i = 0$ para todo $i \notin I(\mathbf{x})$. Esta imposición queda implícita de forma inmediata si se escribe

$$\sum_{i=1}^r \lambda_i (\mathbf{a}_i^\top \mathbf{x} - b_i) = 0 \quad \lambda_i \in \mathbb{R}_0^+. \quad (1.4.7)$$

En forma vectorial, (1.4.7) puede escribirse como $\boldsymbol{\lambda}^\top (A\mathbf{x} - \mathbf{b}) = 0$, donde $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_m)^\top$. Con esta notación, podemos escribir el cono normal del Teorema 1.4.7 así:

$$N_\Omega(\mathbf{x}) = \left\{ A^\top \boldsymbol{\lambda} + C^\top \boldsymbol{\nu} \mid \boldsymbol{\lambda}^\top (A\mathbf{x} - \mathbf{b}) = 0, \boldsymbol{\lambda} \in (\mathbb{R}_0^+)^r, \boldsymbol{\nu} \in \mathbb{R}^m \right\}.$$

La condición de optimalidad $-\nabla f(\mathbf{x}) \in N_\Omega(\mathbf{x})$ se traduce como

$$-\nabla f(\mathbf{x}) = \sum_{i \in I(\mathbf{x})} \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j, \quad \lambda_i \in \mathbb{R}^+, \nu_j \in \mathbb{R}.$$

O, equivalentemente,

$$-\nabla f(\mathbf{x}) = \sum_{i \in I(\mathbf{x})} \lambda_i \nabla g_i(\mathbf{x}) + \sum_{j=1}^m \nu_j \nabla h_j(\mathbf{x}), \quad \lambda_i \in \mathbb{R}^+, \nu_j \in \mathbb{R}.$$

donde $g_i(\mathbf{x}) = \mathbf{a}_i^\top \mathbf{x} - b_i$ y $h_j(\mathbf{x}) = \mathbf{c}_j^\top \mathbf{x} - d_j$. Los coeficientes λ_i y ν_j son precisamente los *multiplicadores de Lagrange* asociados a las funciones de restricción.

 Verifique que el resultado del Teorema 1.4.7 contempla los ejemplos de conos normales vistos en la Sección 2.

Ahora bien, dado que Ω es un poliedro (y, por lo tanto, un conjunto convexo), los Teoremas 1.4.2 y 1.4.4 pueden ser aplicados en este contexto. Obtenemos así el siguiente resultado.

Corolario 1.4.8 (Titulo del teorema). Sea Ω el poliedro definido por (1.4.6), y sea $f : \mathbb{R}^p \rightarrow \mathbb{R}$ una función diferenciable. Si $\mathbf{x}^* \in \Omega$ es un minimizador de f sobre Ω , entonces existen $\boldsymbol{\lambda} \in (\mathbb{R}_0^+)^r$ y $\boldsymbol{\nu} \in \mathbb{R}^m$ tales que $\lambda_i(\mathbf{a}_i^\top \mathbf{x} - b_i) = 0$ para todo $i = 1, \dots, r$ y

$$-\nabla f(\mathbf{x}^*) = \sum_{i=1}^r \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j.$$

Además, si f es convexa, esta condición es también suficiente.



Las condiciones del Corolario 1.4.8, conocidas como *condiciones de Karush-Kuhn-Tucker* (KKT), permiten definir un criterio para obtener puntos críticos. Se formulan a partir de diferentes componentes:

- **Factibilidad primal:** El punto $\mathbf{x}$ debe ser un punto factible.
- **Factibilidad dual:** Los multiplicadores de Lagrange asociados a las restricciones de desigualdad deben ser no negativos.

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, r.$$

- **Holgura complementaria:** Los multiplicadores de Lagrange asociados a las restricciones de desigualdad solo pueden ser positivos si la restricción está activa.

$$\lambda_i (\mathbf{a}_i^\top \mathbf{x} - b_i) = 0 \quad \forall i = 1, \dots, r.$$

- **Estacionariedad:** El opuesto del vector gradiente debe ser una combinación lineal de los gradientes de las restricciones.

$$-\nabla f(\mathbf{x}) = \sum_{i=1}^r \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j,$$

o bien

$$\nabla f(\mathbf{x}) + \sum_{i=1}^r \lambda_i \mathbf{a}_i + \sum_{j=1}^m \nu_j \mathbf{c}_j = \mathbf{0}.$$

En particular, si $\mathbf{x}$ es un punto interior de Ω , las condiciones KKT se reducen a

$$\nabla f(\mathbf{x}) = \mathbf{0}.$$

Por supuesto, el resultado presentado en el Corolario 1.4.8 representa un criterio para obtener puntos críticos si Ω es un poliedro. En resumen:

Si Ω es un poliedro, entonces las condiciones KKT son necesarias para que un punto sea óptimo. Si, además, f es convexa, las condiciones KKT son también suficientes.

Ejemplo 1.4.9: Minimización cuadrática convexa con restricciones de igualdad

Sean $P \in \mathbf{S}_+^p$, $\mathbf{q} \in \mathbb{R}^p$, $c \in \mathbb{R}$, $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^p$. Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \mathbf{x}^\top P \mathbf{x} + \mathbf{q}^\top \mathbf{x} + c \\ &\text{sujeto a} && A \mathbf{x} = \mathbf{b}. \end{aligned}$$

Dado que la función objetivo es convexa, las condiciones KKT son suficientes y necesarias. Además, teniendo en cuenta que solo hay restricciones de igualdad, a saber, $h_j(\mathbf{x}) = \mathbf{a}_j^\top \mathbf{x} - b_j$, únicamente debemos analizar las condiciones de factibilidad primal y estacionariedad. La condición de estacionariedad es:

$$\begin{aligned} -\nabla f(\mathbf{x}^*) &= \sum_{j=1}^m \nu_j^* \nabla h_j(\mathbf{x}^*) \\ -(P \mathbf{x}^* + \mathbf{q}) &= A^\top \boldsymbol{\nu}^* \\ P \mathbf{x}^* + \mathbf{q} + A^\top \boldsymbol{\nu}^* &= \mathbf{0}. \end{aligned}$$

Agregando la factibilidad primal $A \mathbf{x}^* = \mathbf{b}$, obtenemos finalmente un sistema de $p + m$ ecuaciones con $p + m$ incógnitas:

$$\begin{pmatrix} P & A^\top \\ A & 0 \end{pmatrix} \begin{pmatrix} \mathbf{x}^* \\ \boldsymbol{\nu}^* \end{pmatrix} = \begin{pmatrix} -\mathbf{q} \\ \mathbf{b} \end{pmatrix}.$$

 Proponga casos para el Ejemplo 1.4.9, con $\mathbf{x} \in \mathbb{R}^2$ y $m = 2$.

Ejemplo 1.4.10: Minimización cuadrática convexa con restricciones de desigualdad

Consideremos el problema

$$\begin{aligned} &\text{minimizar} && \frac{1}{2} \mathbf{x}^\top P \mathbf{x} + \mathbf{q}^\top \mathbf{x} \\ &\text{sujeto a} && x_1 + x_2 \leq 1.5, \\ &&& x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

Dado que $P \succeq 0$, la función objetivo es convexa. Además, el conjunto factible Ω es un poliedro. Por lo tanto, por Corolario 1.4.8, las condiciones KKT son suficientes y necesarias para la optimalidad. Las definimos a continuación:

$$\begin{aligned} x_1^* + x_2^* - 1.5 &\leq 0, \quad x_1^* \geq 0, \quad x_2^* \geq 0 && \text{(Factibilidad primal)} \\ \lambda_i^* &\geq 0 \quad \forall i = 1, 2, 3 && \text{(Factibilidad dual)} \\ \lambda_1^*(x_1^* + x_2^* - 1.5) &= 0, \quad \lambda_2^* x_1^* = 0, \quad \lambda_3^* x_2^* = 0 && \text{(Holgura complementaria)} \\ (P \mathbf{x}^* + \mathbf{q}) + \lambda_1^* \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} \lambda_2^* \\ \lambda_3^* \end{pmatrix} &= \mathbf{0} && \text{(Estacionariedad)} \end{aligned}$$

Reemplazando P y $\mathbf{q}$, de la condición de estacionariedad resulta

$$\begin{pmatrix} x_1^* - 2 + \lambda_1^* - \lambda_2^* \\ 4x_2^* - 2 + \lambda_1^* - \lambda_3^* \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}. \quad (1.4.8)$$

Si $\lambda_1^* = 0$, se deduce $\lambda_2^* = x_1^* - 2$ y $\lambda_3^* = 4x_2^* - 2$. Luego, por holgura complementaria, resultan $(x_1^* - 2)x_1^* = 0$ y $(4x_2^* - 2)x_2^* = 0$, con soluciones factibles $(0, 0)$ y $(0, 0.5)$. Ambas deben ser descartadas, pues violan la factibilidad dual.

En consecuencia, debe ser $\lambda_1^* \neq 0$. Esto significa que la restricción $x_1 + x_2 \leq 1.5$ está activa, tal que

$$x_1^* + x_2^* - 1.5 = 0.$$

Ahora, veamos que $x_1^* \neq 0$ y $x_2^* \neq 0$. Si $x_1^* = 0$ (análogamente para x_2^*), de la primera ecuación en (1.4.8) se deduce $\lambda_2^* = \lambda_1^* - 2$, tal que $\lambda_1^* \geq 2$. La holgura complementaria resulta en $x_2^* = 1.5$, lo cual nos lleva una contradicción entre la segunda ecuación de (1.4.8), que resulta en $\lambda_3^* = 4$, y la holgura complementaria, que exige $\lambda_3^* = 0$.

En limpio, sabemos que debe ser $\lambda_1^* \neq 0$, $x_1^* \neq 0$, $x_2^* \neq 0$. Además, por holgura complementaria, $\lambda_2^* = 0$ y $\lambda_3^* = 0$. Luego, las condiciones KKT se reducen al siguiente sistema, que resulta de agregar a (1.4.8) la restricción activa:

$$\begin{pmatrix} 1 & 0 & 1 \\ 0 & 4 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} x_1^* \\ x_2^* \\ \lambda_1^* \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \\ 1.5 \end{pmatrix}.$$

La solución del sistema nos da el único punto óptimo del problema:

$$\mathbf{x}^* = (1.2, 0.3) \quad \text{con } \lambda_1^* = 0.8.$$

Generalización

Volvamos al caso general de nuestro interés:

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \mid \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right\}, \end{array}$$

donde Ω está definido como una intersección de restricciones funcionales diferenciables. La generalización del análisis previo surge del siguiente hecho:

El conjunto de direcciones que forma un ángulo obtuso (o recto) con todas las direcciones desde $\mathbf{x}^*$ que permanecen en Ω coincide con el cono normal de la linearización de las restricciones activas en $\mathbf{x}^*$.




Figura 1.4.3: Cono normal en puntos frontera de Ω definido por tres condiciones de desigualdad.

Esta idea es más bien intuitiva, por lo cual no estamos en condiciones de extender el Teorema 1.4.7 ni el Corolario 1.4.8 de manera rigurosa. Sin embargo, lo que sí haremos es extender el concepto de las condiciones KKT, dejando para más adelante el análisis de su aplicabilidad. Para ello, utilizaremos los resultados de la sección anterior en $\tilde{\Omega}$, la *linearización* de Ω en un punto dado.

En un punto óptimo $\mathbf{x}^*$, la linearización de las restricciones queda determinada por:

$$\tilde{g}_i(\mathbf{x}) := g_i(\mathbf{x}^*) + \nabla g_i(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*) \quad \text{y} \quad \tilde{h}_i(\mathbf{x}) := h_i(\mathbf{x}^*) + \nabla h_i(\mathbf{x}^*)^\top (\mathbf{x} - \mathbf{x}^*).$$

Es decir, resulta

$$\tilde{\Omega} := \left\{ \mathbf{x} \in \mathbb{R}^p \mid \begin{array}{l} \tilde{g}_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ \tilde{h}_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right\}.$$

Es importante notar que $\nabla \tilde{g}_i(\mathbf{x}) = \nabla g_i(\mathbf{x}^*)$ y $\nabla \tilde{h}_i(\mathbf{x}) = \nabla h_i(\mathbf{x}^*)$. En consecuencia, la aplicación del Teorema 1.4.7 a $\tilde{\Omega}$ resulta en el siguiente cono normal:

$$N_{\tilde{\Omega}}(\mathbf{x}^*) = \left\{ \sum_{i \in I(\mathbf{x}^*)} \lambda_i \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \nu_j \nabla h_j(\mathbf{x}^*) \mid \lambda_i \in \mathbb{R}_0^+, \nu_j \in \mathbb{R} \right\},$$

donde $I(\mathbf{x}^*) := \{i \in \{1, \dots, r\} \mid g_i(\mathbf{x}^*) = 0\}$ es el conjunto de restricciones activas. Por supuesto, el uso del conjunto índice I puede evitarse utilizando holgura complementaria, como hemos visto anteriormente.



Estamos en condiciones de formalizar el concepto de las condiciones KKT. Sin embargo, aún no vamos a poder afirmar que se tratan de condiciones de optimalidad.

Definición 1.4.11 (Condiciones de Karush-Kuhn-Tucker (KKT)). Sea un problema de optimización con función objetivo diferenciable y restricciones funcionales, de la forma

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ h_j(\mathbf{x}) = 0, \quad j = 1, \dots, m \end{array} \right. \right\}, \end{array}$$

Las *condiciones KKT* en $\mathbf{x}$ están dadas por:

■ **Factibilidad primal:**

$$\begin{aligned} g_i(\mathbf{x}) &\leq 0 & \forall i = 1, \dots, r, \\ h_j(\mathbf{x}) &= 0 & \forall j = 1, \dots, m. \end{aligned}$$

■ **Factibilidad dual:**

$$\lambda_i \geq 0 \quad \forall i = 1, \dots, r.$$

■ **Holgura complementaria:**

$$\lambda_i g_i(\mathbf{x}) = 0 \quad \forall i = 1, \dots, r.$$

■ **Estacionariedad:**

$$-\nabla f(\mathbf{x}) = \sum_{i=1}^r \lambda_i \nabla g_i(\mathbf{x}) + \sum_{j=1}^m \nu_j \nabla h_j(\mathbf{x}).$$



Las condiciones KKT indican que $-\nabla f(\mathbf{x})$ debe estar en el cono normal a la linearización $\tilde{\Omega}$ del conjunto de restricciones Ω .

La condición de holgura complementaria se resume en:

Si la restricción $g_i(\mathbf{x}) \leq 0$ no está activa, entonces $\lambda_i = 0$.

Hasta ahora tenemos claro que, si el conjunto factible es un poliedro, las condiciones KKT se cumplen en los puntos óptimos. Sin embargo, esto no siempre es cierto en condiciones generales; es decir, existen situaciones en las que un punto óptimo no satisface las condiciones KKT. En otras palabras:

Las condiciones KKT a menudo son necesarias para la optimalidad, pero no siempre.

A continuación, veremos un ejemplo que ilustra precisamente esta situación. Luego, estudiaremos bajo qué circunstancias podemos asegurar que las condiciones KKT sí constituyen un criterio necesario de optimalidad, análisis que se conoce bajo el concepto de *cualificación de restricciones*.

Ejemplo 1.4.12: Falla de condiciones KKT en un punto óptimo


Consideremos el problema

$$\begin{aligned} &\text{minimizar} && -x \\ &\text{sujeto a} && y - (1 - x)^3 \leq 0, \\ &&& x \geq 0, y \geq 0. \end{aligned}$$

La función objetivo es $f(x, y) = -x$, y las restricciones funcionales son $g_1(x, y) = y - (1 - x)^3 \leq 0$, $g_2(x, y) = -x \leq 0$ y $g_3(x, y) = -y \leq 0$. Entonces

$$\nabla f(x, y) = (-1, 0),$$

$$\nabla g_1(x, y) = (-3(1 - x)^2, 1), \quad \nabla g_2(x, y) = (-1, 0), \quad \nabla g_3(x, y) = (0, -1).$$



Como se puede apreciar en la figura, $(x^*, y^*) = (1, 0)$ es el único punto óptimo de este problema. Pero en él, los gradientes de la función objetivo y de las restricciones activas son

$$\nabla f(x^*, y^*) = (-1, 0),$$

$$\nabla g_1(x^*, y^*) = (0, 1), \quad \nabla g_3(x^*, y^*) = (0, -1).$$

Claramente, no hay manera de encontrar multiplicadores de Lagrange λ_1 y λ_3 que verifiquen la condición de estacionariedad

$$\underbrace{-\nabla f(x^*, y^*)}_{(1,0)} = \lambda_1 \underbrace{\nabla g_1(x^*, y^*)}_{(0,1)} + \lambda_3 \underbrace{\nabla g_3(x^*, y^*)}_{(0,-1)}.$$

En consecuencia, las condiciones KKT fallan en este caso.

Cualificación de restricciones

Una *cualificación de restricciones* es una condición adicional que se impone sobre las restricciones de un problema de optimización, con el fin de evitar comportamientos degenerados y garanti-

zar ciertas propiedades teóricas deseables. En particular, nuestro interés es asegurar que las condiciones KKT sean efectivamente condiciones necesarias de optimalidad.

Sea $\mathbf{x}^*$ un punto óptimo de Ω . Las cualificaciones de restricciones más frecuentes son:

- **Restricciones afines:** Esto lo hemos estudiado como caso particular en la sección anterior, por lo cual no hace falta imponer cualificaciones adicionales.
- **Restricciones de desigualdad cóncavas y restricciones de igualdad afines:** Si las restricciones de desigualdad activas $\{g_i \mid i \in I(\mathbf{x}^*)\}$ son funciones diferenciables cóncavas en una vecindad convexa de $\mathbf{x}^*$ y las restricciones de igualdad $\{h_j \mid j = 1, \dots, m\}$ son funciones afines, entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.
- **Independencia lineal de los gradientes (LICQ):** Si todas las funciones de restricción son continuamente diferenciables y el conjunto

$$\{\nabla g_i(\mathbf{x}^*) \mid i \in I(\mathbf{x}^*)\} \cup \{\nabla h_j(\mathbf{x}^*) \mid j = 1, \dots, m\}$$

es linealmente independiente, entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.

- **Condición de Slater:** Si las restricciones de desigualdad $\{g_i \mid i = 1, \dots, r\}$ son funciones diferenciables convexas, las restricciones de igualdad $\{h_j \mid j = 1, \dots, m\}$ son funciones afines y, además, existe un punto *estrictamente factible*; esto es

$$\exists \mathbf{x}_0 : g_i(\mathbf{x}_0) < 0 \wedge h_j(\mathbf{x}_0) = 0 \quad \forall i = 1, \dots, r, \forall j = 1, \dots, m,$$

entonces las condiciones KKT se cumplen para $\mathbf{x}^*$.

✍ Exprese la condición LICQ para el caso en que hay una única restricción. Luego, analice el problema

$$\begin{aligned} &\text{maximizar} && \|\mathbf{X} - \mathbf{w}\mathbf{w}^\top \mathbf{X}\|_F^2 \\ &\text{sujeto a} && \|\mathbf{w}\|_2 = 1, \end{aligned}$$

con $\mathbf{X} \in \mathbb{R}^{n \times p}$ y $\mathbf{w} \in \mathbb{R}^p$. Este problema corresponde a la formulación de PCA para hallar la primer componente principal de $\mathbf{X}$.

La condición de Slater es la cualificación de restricciones más común para garantizar que las condiciones KKT son necesarias para que un punto sea óptimo. Es importante remarcar que la condición de *factibilidad estricta* es fundamental y no puede relajarse.

✍ Confirme lo expresado anteriormente analizando el problema

$$\begin{aligned} &\text{minimizar} && x \\ &\text{sujeto a} && x^2 \leq 0. \end{aligned}$$

Además, la condición de convexidad tampoco puede relajarse, como se ve en el Ejemplo 1.4.12, donde la función de restricción $g_1(x, y) = y - (1 - x)^3$ no es convexa en un entorno del punto óptimo $(1, 0)$.

Ahora bien, si a la condición de Slater le añadimos la hipótesis de que la función objetivo f es convexa, entonces las condiciones KKT no solo son necesarias, sino que también resultan suficientes para garantizar la optimalidad. Este escenario corresponde a los problemas de optimización convexa con funciones diferenciables, en los cuales el punto óptimo queda completamente caracterizado por las condiciones KKT.

Teorema 1.4.13 (Caracterización de optimalidad mediante KKT). *Sea un problema de optimización convexa de la forma*

$$\begin{array}{ll} \text{minimizar} & f(\mathbf{x}) \\ \text{sujeto a} & \mathbf{x} \in \left\{ \mathbf{x} \in \mathbb{R}^p \left| \begin{array}{l} g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r \\ A\mathbf{x} = \mathbf{b} \end{array} \right. \right\}, \end{array}$$

con $A \in \mathbb{R}^{m \times p}$ y $\mathbf{b} \in \mathbb{R}^m$. Si la función objetivo f y las funciones de restricción g_i ($i = 1, \dots, r$) son diferenciables, y además las restricciones verifican la condición de Slater, entonces las condiciones KKT son suficientes y necesarias para que un punto sea óptimo.

✓ *Prueba.* Probaremos únicamente la suficiencia. Sea $\mathbf{x}_0$ un punto factible que verifica las condiciones KKT. Entonces, la condición de estacionariedad nos permite afirmar que existen $\boldsymbol{\lambda} \in \mathbb{R}^r$, con $\boldsymbol{\lambda} \succeq \mathbf{0}$, y $\boldsymbol{\nu} \in \mathbb{R}^m$ tales que

$$\nabla f(\mathbf{x}_0) + \sum_{i=1}^r \lambda_i \nabla g_i(\mathbf{x}_0) + A^\top \boldsymbol{\nu} = \mathbf{0}. \quad (1.4.9)$$

Dado que f y g_i son funciones convexas, también es convexa la función $L : \mathbb{R}^p \rightarrow \mathbb{R}$ definida por

$$L(\mathbf{x}) := f(\mathbf{x}) + \sum_{i=1}^r \lambda_i g_i(\mathbf{x}) + \boldsymbol{\nu}^\top (A\mathbf{x} - \mathbf{b}).$$

Por condición de optimalidad de primer orden sin restricciones para funciones convexas (Teorema 1.4.1), la expresión (1.4.9) implica que $\mathbf{x}_0$ es el minimizador de $L(\mathbf{x}_0)$. Además, es fácil ver que $L(\mathbf{x}) \leq f(\mathbf{x})$ para todo $\mathbf{x}$ factible. En consecuencia, se deduce

$$f(\mathbf{x}_0) = L(\mathbf{x}_0) \leq L(\mathbf{x}) \leq f(\mathbf{x}) \quad \forall \mathbf{x} \text{ factible},$$

donde la primera igualdad es cierta gracias a la condición de holgura complementaria $\lambda_i g_i(\mathbf{x}_0) = 0$ para todo $i = 1, \dots, r$. Luego, $\mathbf{x}_0$ es punto óptimo del problema, tal como queríamos probar. ■

✍ En la demostración anterior, verifique que L es una función convexa, $L(\mathbf{x}) \leq f(\mathbf{x})$ para todo $\mathbf{x}$ factible y $L(\mathbf{x}_0) = f(\mathbf{x}_0)$.

Ejemplo 1.4.14: Condiciones KKT suficientes y necesarias para optimalidad

Consideremos el problema

$$\begin{aligned} \text{minimizar} \quad & x_1^2 + x_2^2 \\ \text{sujeto a} \quad & x_1 + x_2 \leq 1, \\ & x_1 \geq 0, x_2 \geq 0. \end{aligned}$$

Claramente el único punto óptimo es $\mathbf{x}^* = \mathbf{0}$. Además, se cumple la condición de Slater para KKT: en primer lugar, las restricciones de desigualdad están definidas por funciones afines (y, por lo tanto, convexas); en segundo lugar, el punto $(0.2, 0.2)$ es estrictamente factible para las restricciones activas en $\mathbf{0}$. Por lo tanto, podemos afirmar que las condiciones KKT son suficientes y necesarias para la optimalidad.

Vamos a verificar la conclusión anterior. Las condiciones KKT son:

$$\begin{aligned} x_1^* + x_2^* - 1 &\leq 0, \quad x_1^* \geq 0, \quad x_2^* \geq 0 && \text{(Factibilidad primal)} \\ \lambda_i^* &\geq 0 \quad \forall i = 1, 2, 3 && \text{(Factibilidad dual)} \\ \lambda_1^*(x_1^* + x_2^* - 1) &= 0, \quad \lambda_2^*x_1^* = 0, \quad \lambda_3^*x_2^* = 0 && \text{(Holgura complementaria)} \\ -2x_1^* &= \lambda_1^* - \lambda_2^*, \quad -2x_2^* = \lambda_1^* - \lambda_3^* && \text{(Estacionariedad)} \end{aligned}$$

El único punto que cumple todas estas condiciones es $\mathbf{x}^* = \mathbf{0}$, con $\boldsymbol{\lambda}^* = \mathbf{0}$. Para justificar esto, veamos que suponer $x_1^* > 0$ (análogamente para $x_2^* > 0$) conduce a un absurdo:

1. Por holgura complementaria, debe ser $\lambda_2^* = 0$.
2. La primera condición de estacionariedad implica $\lambda_1^* < 0$. Esto contradice la factibilidad dual $\lambda_1^* \geq 0$.