



UNL. FACULTAD DE
INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez

Liliana Forzani

Regresión lineal y regresión logística

En esta sección estudiaremos dos modelos fundamentales de aprendizaje supervisado: la regresión lineal, utilizada para una variable de respuesta continua, y la regresión logística, empleada cuando la respuesta es categórica. Ambos modelos pueden ser formulados como problemas de optimización, lo que permite aplicar los conceptos vistos en el capítulo anterior. Para ambos modelos, analizaremos su formulación probabilística, las características del problema y los métodos de resolución más utilizados.

Notación

De ahora en adelante, consideraremos $\mathbf{X} = (X_1, \dots, X_p) \in \mathbb{R}^p$ un conjunto de variables predictoras y $Y \in \mathbb{R}$ una variable respuesta. Además, vamos a suponer que la distribución condicional de $Y|\mathbf{X}$ depende de un vector de parámetros $\boldsymbol{\theta} \in \mathbb{R}^q$.

Para un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, denotamos $\mathbf{y} \in \mathbb{R}^n$ el vector de respuestas, $\mathbf{X} \in \mathbb{R}^{n \times p}$ la matriz de predictoras y $\tilde{\mathbf{X}} := \begin{pmatrix} \mathbf{1} & \mathbf{X} \end{pmatrix} \in \mathbb{R}^{n \times (p+1)}$ la matriz ampliada, la cual permite extender resultados formulados para relaciones lineales de la forma $\boldsymbol{\theta}^\top \mathbf{X}$ al caso con intercepto $\theta_0 + \boldsymbol{\theta}^\top \mathbf{X}$.

En modelos probabilísticos, la tarea de obtener un estimador $\hat{\boldsymbol{\theta}}$ puede ser formulada a través de un problema de optimización de la forma

$$\text{minimizar } J(\boldsymbol{\theta}),$$

en principio sin restricciones. Aquí, la función objetivo $J : \mathbb{R}^q \rightarrow \mathbb{R}$, conocida como *función de costo*, mide que tan bien se ajusta $\boldsymbol{\theta}$ a los datos observados. De acuerdo con lo visto en la Sección 1, bajo la suposición que los datos son i.i.d. (independientes e idénticamente distribuidos) con distribución condicional $p(y | \mathbf{x}; \boldsymbol{\theta})$, una estrategia para formular J es el principio de máxima verosimilitud (MLE); es decir, J se deriva de la función de verosimilitud

$$L(\boldsymbol{\theta}) := \prod_{i=1}^n p(y_i | \mathbf{x}_i; \boldsymbol{\theta}).$$

Si bien J depende del problema específico, en general es de la forma

$$J(\boldsymbol{\theta}) = \sum_{i=1}^n \text{loss}(y_i, f(\mathbf{x}_i, \boldsymbol{\theta})),$$

donde $\text{loss} : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}_0^+$ mide, para cada observación, el error entre el valor observado de la variable respuesta y el valor estimado por el modelo.

I | Regresión lineal

Supuestos del modelo

$$Y = \theta_1 X_1 + \dots + \theta_p X_p + \varepsilon$$

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$

El conjunto de parámetros del modelo de regresión lineal es $\boldsymbol{\theta} \in \mathbb{R}^p$, mientras que $\varepsilon \in \mathbb{R}$ es un término de error que captura efectos no modelados (como características omitidas o ruido aleatorio). Podemos escribir el modelo de forma abreviada como

$$Y = \boldsymbol{\theta}^\top \mathbf{X} + \varepsilon.$$

El supuesto $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ significa que la función de densidad de la variable aleatoria ε es

$$p(\varepsilon) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right).$$

Distribución condicional

Dado $\mathbf{X} = \mathbf{x}$, tenemos que $Y = \underbrace{\boldsymbol{\theta}^\top \mathbf{x}}_{\text{cte}} + \varepsilon$. Por lo tanto, el supuesto $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ implica que⁴

$$Y|\mathbf{X} = \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2).$$

En consecuencia:

La función de densidad condicional de $Y|\mathbf{X}$ en el modelo de regresión lineal es

$$p(y | \mathbf{x}; \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y - \boldsymbol{\theta}^\top \mathbf{x})^2}{2\sigma^2}\right).$$

Función de verosimilitud

Para un conjunto de datos $\{\mathbf{x}_i, y_i\}_{i=1}^n$ i.i.d., la función de log-verosimilitud es

$$\ell(\boldsymbol{\theta}) = \log \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2}{2\sigma^2}\right) = n \log \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2.$$

Importante

Observar que maximizar $\ell(\boldsymbol{\theta})$ es equivalente a minimizar la función de costo asociada a mínimos cuadrados, dada por

$$J(\boldsymbol{\theta}) = \frac{1}{2} \sum_{i=1}^n (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2 = \frac{1}{2} \|\mathbf{X}\boldsymbol{\theta} - \mathbf{y}\|_2^2,$$

⁴Si $Z \sim \mathcal{N}(\mu, \sigma^2)$ y $a, b \in \mathbb{R}$, $aZ + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.




Figura 2.2.1: Interpretación geométrica del modelo de regresión lineal en $\mathbb{R}^2$. El objetivo es hallar la función lineal de X que minimice la suma de los residuos al cuadrado respecto de Y . (Figura 3.1 de (Hastie, Tibshirani & Friedman 2009)).

Optimalidad

El problema de optimización de interés,

$$\text{minimizar } \frac{1}{2} \|X\theta - \mathbf{y}\|_2^2,$$

es convexo y no tiene restricciones. Por lo tanto, en virtud del Teorema 1.4.1, la condición de optimalidad $\nabla J(\hat{\theta}) = \mathbf{0}$ es suficiente y necesaria. Resolvemos:

$$\begin{aligned} X^\top X \hat{\theta} - X^\top \mathbf{y} &= \mathbf{0} \\ X^\top X \hat{\theta} &= X^\top \mathbf{y}. \end{aligned}$$

La solución está caracterizada por $\hat{\theta} = X^+ \mathbf{y}$, donde X^+ es la *pseudoinversa de Moore–Penrose* de X . En particular:

Si X es de rango completo, entonces $X^\top X$ es invertible y

$$\hat{\theta} = (X^\top X)^{-1} X^\top \mathbf{y}$$

El vector de valores ajustados $\hat{\mathbf{y}} \in \mathbb{R}^n$ está dado por

$$\hat{\mathbf{y}} := X \hat{\theta}.$$

Observar que, si X es de rango completo, entonces $\hat{\mathbf{y}} = X(X^\top X)^{-1} X^\top \mathbf{y}$. Esto significa que $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio columna de X .

Resolución por descenso por gradiente

La aplicación del método de descenso por gradiente al problema de optimización en regresión lineal da lugar a lo que se denomina *algoritmo LMS (least mean squares)*. Resulta de sustituir

$\nabla J(\boldsymbol{\theta}_t) = X^\top X \boldsymbol{\theta}_t - X^\top \mathbf{y}$ en la regla de actualización

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t - \eta \nabla J(\boldsymbol{\theta}_t), \quad \eta > 0.$$

Esta regla de actualización también se conoce como *regla de aprendizaje Widrow-Hoff*.

Algoritmo LMS

Dado un *parámetro inicial* $\boldsymbol{\theta}_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t - \eta (X^\top X \boldsymbol{\theta}_t - X^\top \mathbf{y}).$$

hasta que el criterio de parada se satisfaga.

El algoritmo anterior trabaja con todas las observaciones a la vez en cada paso de actualización, por lo que se trata de un *descenso de gradiente por lotes*. Esta estrategia asegura una actualización estable del parámetro $\boldsymbol{\theta}$, aunque puede ser costosa si el número de observaciones es muy grande. Como alternativas, podemos utilizar descenso de gradiente estocástico o *mini-batch*. Observar que, para una observación $(\mathbf{x}_i, y_i)$, la función de costo resulta

$$\text{loss}(\mathbf{x}_i, y_i; \boldsymbol{\theta}) = \frac{1}{2} (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2,$$

tal que

$$\nabla_{\boldsymbol{\theta}} \text{loss}(\mathbf{x}_i, y_i; \boldsymbol{\theta}) = -(y_i - \boldsymbol{\theta}^\top \mathbf{x}_i) \mathbf{x}_i.$$

Algoritmo LMS estocástico

Dado un *parámetro inicial* $\boldsymbol{\theta}_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Elegir un índice $i \in \{1, \dots, n\}$ al azar.

 Actualizar

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t + \eta (y_i - \boldsymbol{\theta}_t^\top \mathbf{x}_i) \mathbf{x}_i.$$

hasta que el criterio de parada se satisfaga.

Observar que la magnitud de la actualización del algoritmo LMS estocástico es proporcional al término de error $(y_i - \boldsymbol{\theta}_t^\top \mathbf{x}_i)$. Si elegimos un ejemplo para el cual $\boldsymbol{\theta}_t^\top \mathbf{x}_i \approx y_i$, entonces el cambio en el parámetro será mínimo. Esto puede activar prematuramente el criterio de parada basado en la magnitud del gradiente, por lo cual para evitar detener el algoritmo demasiado pronto, suele ser recomendable basar el criterio de parada en el promedio del error sobre un conjunto de observaciones. También se puede imponer un número mínimo de iteraciones para asegurar que el algoritmo recorra suficientes ejemplos y aprenda de manera estable.

 Analice qué sucede al aplicar el método de Newton para resolver el problema de regresión lineal.

Ejemplo 2.2.1: Regresión lineal en datos de viviendas

Utilizaremos el conjunto de datos *California Housing* [disponible aquí](#), el cual consiste en 20640 observaciones con 8 variables predictoras que miden características de las viviendas y su entorno. La variable respuesta es la mediana del valor de una vivienda en cada bloque censal, por lo que efectivamente se trata de un problema de regresión. Ajustaremos un modelo de regresión lineal a los datos, evaluaremos el MSE en test y presentaremos los coeficientes estimados del modelo.

! En este ejemplo utilizamos la implementación `LinearRegression` de `scikit-learn`, la cual obtiene los coeficientes mediante métodos numéricos basados en álgebra lineal, en lugar de aplicar explícitamente el algoritmo de descenso por gradiente. La implementación del algoritmo LMS se realizará en las actividades prácticas.

```
1 import numpy as np
2 from sklearn.datasets import fetch_california_housing
3 from sklearn.linear_model import LinearRegression
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import mean_squared_error
7
8 # Datos:
9 X, y = fetch_california_housing(return_X_y=True)
10 scaler = StandardScaler()
11 X = scaler.fit_transform(X)
12
13 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
14     ↪ random_state=42)
15
16 # Modelo:
17 lr = LinearRegression()
18 lr.fit(X_train, y_train)
19
20 # Predicción y MSE:
21 y_pred = lr.predict(X_test)
22 mse_test = mean_squared_error(y_test, y_pred)
```

>

MSE en test: 0.556

Coefficientes estimados: $\theta_1 = 0.852$, $\theta_2 = 0.122$, $\theta_3 = -0.305$, $\theta_4 = 0.371$, $\theta_5 = -0.002$, $\theta_6 = -0.037$, $\theta_7 = -0.897$, $\theta_8 = -0.869$

Propiedades del estimador

Hemos visto que el algoritmo LMS permite aproximar el estimador de mínimos cuadrados $\hat{\theta}$ para el modelo de regresión lineal. Por supuesto, los resultados de convergencia para el método de descenso por gradiente son válidos. No obstante, recordemos que también es importante considerar las propiedades estadísticas del MLE $\hat{\theta}$.

Algunos resultados conocidos para el modelo de regresión lineal son:

- **Convergencia estadística.** Para $n > p$ y bajo los supuestos clásicos de

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^n \text{ i.i.d., } \mathbb{E}[\varepsilon_i | \mathbf{x}_i] = 0 \quad (\text{Exogeneidad})$$

$$\mathbb{E}[\varepsilon_i^2 | \mathbf{x}_i] = \sigma^2 < \infty, \mathbb{E}[\varepsilon_i^4] \quad (\text{Momentos})$$

$$\frac{1}{n} X^\top X \xrightarrow{p} \Sigma_X \succ 0 \quad (\text{Diseño bien condicionado})$$

se verifica

$$\hat{\theta}_n \xrightarrow{p} \theta_\star \quad \text{y} \quad \sqrt{n}(\hat{\theta}_n - \theta_\star) \xrightarrow{d} \mathcal{N}(0, \sigma^2 \Sigma_X^{-1}).$$

- **Convergencia computacional.** Sean $\lambda_{\min}, \lambda_{\max} > 0$ autovalores de $X^\top X$, y sea $\rho = \max\{|1 - \eta\lambda_{\min}|, |1 - \eta\lambda_{\max}|\}$. Si $0 < \eta < 2/\lambda_{\max}$, entonces

$$\theta_t \rightarrow \hat{\theta} \quad \text{y} \quad \|\theta_t - \hat{\theta}\|_2 \leq \rho^t \|\theta_0 - \hat{\theta}\|_2.$$


II | Regresión logística

Consideremos ahora un problema de clasificación binaria, con $Y \in \{0, 1\}$. Por ejemplo, si estamos tratando de construir un clasificador de spam para correos electrónicos, una observación $\mathbf{x}$ contendrá características de un correo electrónico, y su etiqueta y será 1 si es spam o 0 en caso contrario. Podríamos aplicar regresión lineal ignorando que Y es discreta, pero sus predicciones no estarían restringidas al intervalo $[0, 1]$. Para evitar esto, utilizaremos la *función logística*.

Función logística

Para $z \in \mathbb{R}$, se define la *función logística* o *función sigmoide* $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ mediante

$$\sigma(z) := \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$



Algunas características son:

- $\sigma(\mathbb{R}) = (0, 1)$ y $\sigma(0) = 0.5$.
- $\lim_{z \rightarrow -\infty} \sigma(z) = 0$ y $\lim_{z \rightarrow \infty} \sigma(z) = 1$.
- $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.
- Su inversa es la función logit : $(0, 1) \rightarrow \mathbb{R}$ definida por

$$\text{logit}(p) := \log \frac{p}{1-p}.$$

Ya estamos en condiciones de configurar el modelo de regresión logística. Para ello, primero definimos la función $h_{\theta} : \mathbb{R}^p \rightarrow \mathbb{R}$ como

$$h_{\theta}(\mathbf{x}) := \sigma(\boldsymbol{\theta}^{\top} \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^{\top} \mathbf{x}}}.$$

Supuestos del modelo

$$Y \in \{0, 1\}$$

$$\mathbb{P}(Y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = h_{\theta}(\mathbf{x})$$

Distribución condicional

Bajo el modelo de regresión logística, resulta

$$Y \mid \mathbf{X} = \mathbf{x} \sim \text{Binom}(1, h_{\theta}(\mathbf{x})),$$

de manera tal que

$$\begin{aligned} p(y \mid \mathbf{x}; \boldsymbol{\theta}) &= (h_{\theta}(\mathbf{x}))^y (1 - h_{\theta}(\mathbf{x}))^{1-y} \\ &= \exp \{y \log h_{\theta}(\mathbf{x}) + (1 - y) \log(1 - h_{\theta}(\mathbf{x}))\} \\ &= \exp \left\{ y \log \left(\frac{h_{\theta}(\mathbf{x})}{1 - h_{\theta}(\mathbf{x})} \right) + \log(1 - h_{\theta}(\mathbf{x})) \right\} \\ &= \exp \{y \text{logit}(h_{\theta}(\mathbf{x})) + \log(1 - h_{\theta}(\mathbf{x}))\}. \end{aligned}$$

Para simplificar la escritura, definamos el *parámetro natural* $\eta \in \mathbb{R}$ como

$$\eta(\mathbf{x}; \boldsymbol{\theta}) := \text{logit}(h_{\theta}(\mathbf{x})) = \boldsymbol{\theta}^{\top} \mathbf{x}.$$

y la función $A : \mathbb{R} \rightarrow \mathbb{R}$ mediante $A(\eta) = \log(1 + e^{\eta})$. Resulta:

La función de densidad condicional de $Y \mid \mathbf{X}$ en el modelo de regresión logística es

$$p(y \mid \eta) = \exp \{ \eta y - A(\eta) \}, \quad \eta = \boldsymbol{\theta}^{\top} \mathbf{x}. \quad (2.2.1)$$

Es importante observar que

$$\begin{aligned} A'(\eta) &= \frac{e^\eta}{1 + e^\eta} = \sigma(\eta) = h_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}], \\ A''(\eta) &= \sigma'(\eta) = \sigma(\eta)(1 - \sigma(\eta)) = h_{\boldsymbol{\theta}}(\mathbf{x})(1 - h_{\boldsymbol{\theta}}(\mathbf{x})) = \text{Var}[Y \mid \mathbf{X} = \mathbf{x}]. \end{aligned} \quad (2.2.2)$$

i

La forma (2.2.1) no es casual: corresponde a un caso particular de la representación de las denominadas *familias exponenciales*, que estudiaremos en la Sección 3 y que constituyen el marco teórico general de los modelos lineales generalizados.

Función de verosimilitud

Para un conjunto de datos $\{\mathbf{x}_i, y_i\}_{i=1}^n$ i.i.d., la función de log-verosimilitud es

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^n [\eta_i y_i - A(\eta_i)] = \sum_{i=1}^n \left[\boldsymbol{\theta}^\top \mathbf{x}_i y_i - \log(1 + e^{\boldsymbol{\theta}^\top \mathbf{x}_i}) \right].$$

Importante

En regresión logística, maximizar $\ell(\boldsymbol{\theta})$ es equivalente a minimizar

$$J(\boldsymbol{\theta}) = - \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)], \quad (2.2.3)$$

con

$$\hat{y}_i := h_{\boldsymbol{\theta}}(\mathbf{x}_i) = \frac{1}{1 + e^{-\boldsymbol{\theta}^\top \mathbf{x}_i}}.$$

La función J en (2.2.3), conocida como *entropía cruzada*, es la forma habitual de expresar la función de pérdida en problemas de clasificación binaria. Mide la disimilaridad entre las etiquetas reales y_i y las probabilidades $\hat{y}_i$ predichas por el modelo.

✍ Verifique que se cumple $J(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta})$.

Optimalidad

El problema de optimización resultante es

$$\text{minimizar} \quad \sum_{i=1}^n \left[\log(1 + e^{\boldsymbol{\theta}^\top \mathbf{x}_i}) - \boldsymbol{\theta}^\top \mathbf{x}_i y_i \right]. \quad (2.2.4)$$

✍ Justifique que la función objetivo J en (2.2.4) es convexa.

La condición de optimalidad $\nabla J(\hat{\theta}) = \mathbf{0}$ es suficiente y necesaria, pero $\nabla J(\theta)$ depende de θ de forma no lineal. En efecto,

$$\begin{aligned}\nabla J(\theta) &= \sum_{i=1}^n \left[\frac{e^{\theta^\top \mathbf{x}_i}}{1 + e^{\theta^\top \mathbf{x}_i}} \mathbf{x}_i - \mathbf{x}_i y_i \right] \\ &= \sum_{i=1}^n -\mathbf{x}_i [y_i - h_{\theta}(\mathbf{x}_i)] \\ &= -X^\top (\mathbf{y} - \hat{\mathbf{y}}),\end{aligned}\tag{2.2.5}$$

donde $\hat{\mathbf{y}} = (h_{\theta}(\mathbf{x}_1), \dots, h_{\theta}(\mathbf{x}_n)) \in \mathbb{R}^n$ es el vector de probabilidades predichas mediante θ .

En consecuencia, no es posible obtener una solución explícita de $\nabla J(\hat{\theta}) = \mathbf{0}$ y la única opción es recurrir a métodos iterativos para aproximar $\hat{\theta}$.

Resolución por descenso por gradiente

De los resultados anteriores, resultan de manera natural los algoritmos iterativos para aproximar el MLE $\hat{\theta}$ del parámetro poblacional θ_* , basados en métodos de gradiente.

Algoritmo de descenso por gradiente para regresión logística

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\theta_{t+1} := \theta_t + \eta X^\top (\mathbf{y} - \hat{\mathbf{y}}_t).$$

hasta que el criterio de parada se satisfaga.

Algoritmo de descenso por gradiente estocástico para regresión logística

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Elegir un índice $i \in \{1, \dots, n\}$ al azar.

 Actualizar

$$\theta_{t+1} := \theta_t + \eta (y_i - h_{\theta_t}(\mathbf{x}_i)) \mathbf{x}_i.$$

hasta que el criterio de parada se satisfaga.

Resolución por método de Newton

Recordemos que el método de Newton actualiza los parámetros mediante

$$\theta_{t+1} := \theta_t - [\nabla^2 J(\theta_t)]^{-1} \nabla J(\theta_t).$$

Para obtener los elementos de esta ecuación, tendremos en cuenta (2.2.2) y el cálculo del vector

gradiente en (2.2.5). Podemos escribir

$$\nabla J(\boldsymbol{\theta}) = \sum_{i=1}^n -\mathbf{x}_i [y_i - A'(\eta_i)] .$$

Por lo tanto,

$$\nabla^2 J(\boldsymbol{\theta}) = \sum_{i=1}^n -\mathbf{x}_i A''(\eta_i) \frac{\partial \eta_i}{\partial \boldsymbol{\theta}} = \sum_{i=1}^n A''(\eta_i) \mathbf{x}_i \mathbf{x}_i^\top = X^\top W X,$$

donde

$$W := \text{diag}(w_1, \dots, w_n) \quad \text{con } w_i := A''(\eta_i) = h_{\boldsymbol{\theta}}(\mathbf{x}_i)(1 - h_{\boldsymbol{\theta}}(\mathbf{x}_i)).$$

Algoritmo de Newton para regresión logística

Dado un *parámetro inicial* $\boldsymbol{\theta}_0 \in \mathbb{R}^p$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t + (X^\top W_t X)^{-1} X^\top (\mathbf{y} - \hat{\mathbf{y}}_t).$$

hasta que el criterio de parada se satisfaga.

Ejemplo 2.2.2: Regresión logística en datos de cáncer

Utilizaremos el conjunto de datos *Breast Cancer* [disponible aquí](#), el cual contiene información de tumores de mama y consta de 569 observaciones y 30 variables predictoras. La variable respuesta indica el tipo de tumor (0 para benigno y 1 para maligno), lo que convierte este problema en una tarea de clasificación binaria. Ajustaremos un modelo de regresión logística a los datos, evaluaremos la precisión en test y presentaremos los coeficientes estimados del modelo.

❗ En este ejemplo utilizamos la implementación `LogisticRegression` de `scikit-learn`, la cual emplea por defecto el algoritmo LBFGS, un método cuasi-Newton ampliamente utilizado en problemas de optimización convexa. La implementación de los algoritmos de descenso por gradiente y Newton se realizará en las actividades prácticas.

```
1 import numpy as np
2 from sklearn.datasets import load_breast_cancer
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import accuracy_score
7
8 # Datos:
9 X, y = load_breast_cancer(return_X_y=True)
10 scaler = StandardScaler()
```

```

11 X = scaler.fit_transform(X)
12
13 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
    ↪ random_state=42)
14
15 # Modelo:
16 logreg = LogisticRegression(max_iter=1000)
17 logreg.fit(X_train, y_train)
18
19 # Predicción y accuracy:
20 y_pred = logreg.predict(X_test)
21 acc_test = accuracy_score(y_test, y_pred)

```

>_

Accuracy en test: 0.974

Coefficientes estimados: $\theta_1 = -0.435$, $\theta_2 = -0.397$, $\theta_3 = -0.396$, $\theta_4 = -0.470$, $\theta_5 = -0.067$, $\theta_6 = 0.527$, $\theta_7 = -0.808$, $\theta_8 = -1.108$, $\theta_9 = 0.242$, $\theta_{10} = 0.078$, $\theta_{11} = -1.251$, $\theta_{12} = 0.189$, $\theta_{13} = -0.590$, $\theta_{14} = -0.920$, $\theta_{15} = -0.317$, $\theta_{16} = 0.669$, $\theta_{17} = 0.171$, $\theta_{18} = -0.314$, $\theta_{19} = 0.505$, $\theta_{20} = 0.612$, $\theta_{21} = -0.874$, $\theta_{22} = -1.358$, $\theta_{23} = -0.586$, $\theta_{24} = -0.838$, $\theta_{25} = -0.547$, $\theta_{26} = 0.006$, $\theta_{27} = -0.952$, $\theta_{28} = -0.780$, $\theta_{29} = -1.196$, $\theta_{30} = -0.163$.

Propiedades del estimador

Para el caso de regresión logística, algunos resultados importantes son:

- **Convergencia estadística.** Bajo supuestos clásicos, tales como

$$\{(\mathbf{x}_i, y_i)\}_{i=1}^n \text{ i.i.d.} \quad (\text{Independencia e idéntica distribución})$$

$$0 < \mathbb{P}(Y_i = 1 \mid \mathbf{x}_i) < 1 \quad (\text{No separabilidad})$$

$$\mathbb{E}[\|\mathbf{x}_i\|^2] < \infty \quad (\text{Momentos finitos})$$

$$\mathcal{I}(\boldsymbol{\theta}_*) = \mathbb{E} \left[h_{\boldsymbol{\theta}}(\mathbf{X})(1 - h_{\boldsymbol{\theta}}(\mathbf{X})) \mathbf{X} \mathbf{X}^\top \right] \succ 0 \quad (\text{Información de Fisher definida positiva})$$

se verifica

$$\hat{\boldsymbol{\theta}}_n \xrightarrow{p} \boldsymbol{\theta}_* \quad \text{y} \quad \sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}_*) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}(\boldsymbol{\theta}_*)^{-1}).$$

- **Convergencia computacional.** Como J es convexa y L -suave con

$$L \leq \frac{\lambda_{\max}(X^\top X)}{4n},$$

el método de descenso por gradiente con paso fijo $0 < \eta < 1/L$ converge al minimizador $\hat{\boldsymbol{\theta}}$.

Referencias

- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer Series in Statistics. New York: Springer.
- Ng, A. (2022). *Stanford CS229: Machine Learning*. Lecture notes. Stanford University. URL: https://cs229.stanford.edu/notes2022fall/main_notes.pdf.