



UNL. FACULTAD DE
INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez

Liliana Forzani

Regresión lineal y regresión logística

En esta sección estudiaremos dos modelos fundamentales de aprendizaje supervisado: la regresión lineal, utilizada para variables de respuesta cuantitativas, y la regresión logística, empleada cuando la respuesta es categórica. Ambos modelos pueden ser formulados como problemas de optimización, lo que permite aplicar los conceptos vistos en el capítulo anterior. Para ambos modelos, analizaremos su formulación probabilística, las características del problema y los métodos de resolución más utilizados.

Notación

Durante este capítulo, consideraremos $\mathbf{X} = (X_1, \dots, X_p) \in \mathbb{R}^p$ un conjunto de variables predictoras y $Y \in \mathbb{R}$ una variable respuesta. Además, vamos a suponer que la distribución condicional de $Y|\mathbf{X}$ depende de un vector de parámetros $\boldsymbol{\theta} \in \mathbb{R}^q$.

Para un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, denotamos $\mathbf{y} \in \mathbb{R}^n$ el vector de respuestas, $\mathbf{X} \in \mathbb{R}^{n \times p}$ la matriz de predictoras y $\tilde{\mathbf{X}} := \begin{pmatrix} \mathbf{1} & \mathbf{X} \end{pmatrix} \in \mathbb{R}^{n \times (p+1)}$ la matriz ampliada, la cual permite extender resultados formulados para relaciones lineales de la forma $\boldsymbol{\theta}^\top \mathbf{X}$ al caso con intercepto $\theta_0 + \boldsymbol{\theta}^\top \mathbf{X}$.

Además, denotamos $\mathbb{P}(A)$ la probabilidad de que ocurra un suceso A y, para una variable aleatoria Z , se denota $\mathbb{E}[Z]$ su valor esperado y $\text{Cov}[Z]$ su varianza.

I | Regresión lineal

Supuestos del modelo

$$Y = \theta_1 X_1 + \dots + \theta_p X_p + \varepsilon$$

$$\varepsilon \sim \mathcal{N}(0, \sigma^2)$$

El conjunto de parámetros del modelo de regresión lineal es $\boldsymbol{\theta} \in \mathbb{R}^p$, mientras que $\varepsilon \in \mathbb{R}$ es un término de error que captura efectos no modelados (como características omitidas o ruido aleatorio). Podemos escribir el modelo de forma abreviada como

$$Y = \boldsymbol{\theta}^\top \mathbf{X} + \varepsilon.$$

El supuesto $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ significa que la función de densidad de la variable aleatoria ε es

$$p(\varepsilon) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\varepsilon^2}{2\sigma^2}\right).$$




Figura 2.2.1: Interpretación geométrica del modelo de regresión lineal en $\mathbb{R}^2$. El objetivo es hallar la función lineal de X que minimice la suma de los residuos al cuadrado respecto de Y . (Figura 3.1 de (Hastie, Tibshirani & Friedman 2009)).

Distribución condicional

Dado $\mathbf{X} = \mathbf{x}$, tenemos que

$$Y = \underbrace{\boldsymbol{\theta}^\top \mathbf{x}}_{\text{cte}} + \varepsilon.$$

Por lo tanto, el supuesto $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ implica que¹

$$Y|\mathbf{X} = \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2).$$

En consecuencia:

La función de densidad condicional de $Y|\mathbf{X}$ en el modelo de regresión lineal es

$$p(y|\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \boldsymbol{\theta}^\top \mathbf{x})^2}{2\sigma^2}\right).$$

Función de verosimilitud

Para un conjunto de datos $\{\mathbf{x}_i, y_i\}_{i=1}^n$ i.i.d., la función de log-verosimilitud es

$$\begin{aligned} \ell(\boldsymbol{\theta}) &= \log \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2}{2\sigma^2}\right) \\ &= \sum_{i=1}^n \left[\log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2 \right] \end{aligned}$$

¹Si $Z \sim \mathcal{N}(\mu, \sigma^2)$ y $a, b \in \mathbb{R}$, $aZ + b \sim \mathcal{N}(a\mu + b, a^2\sigma^2)$.

$$= n \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2.$$

Importante

Observar, en esta última expresión, que maximizar $\ell(\boldsymbol{\theta})$ es equivalente a minimizar

$$J(\boldsymbol{\theta}) = \frac{1}{2} \sum_{i=1}^n (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2 = \frac{1}{2} \|X\boldsymbol{\theta} - \mathbf{y}\|_2^2,$$

lo cual es la función de costo asociada a mínimos cuadrados.

Optimalidad

El problema de optimización de interés,

$$\text{minimizar } \frac{1}{2} \|X\boldsymbol{\theta} - \mathbf{y}\|_2^2,$$

es convexo y no tiene restricciones. Por lo tanto, en virtud del Teorema 1.4.1, la condición de optimalidad $\nabla J(\boldsymbol{\theta}) = \mathbf{0}$ es suficiente y necesaria. Desarrollamos:

$$\begin{aligned} \nabla J(\hat{\boldsymbol{\theta}}) &= \mathbf{0} \\ X^\top X \hat{\boldsymbol{\theta}} - X^\top \mathbf{y} &= \mathbf{0} \\ X^\top X \hat{\boldsymbol{\theta}} &= X^\top \mathbf{y} \\ \hat{\boldsymbol{\theta}} &= X^+ \mathbf{y}. \end{aligned}$$

En particular:

Si X es de rango completo, entonces

$$\hat{\boldsymbol{\theta}} = (X^\top X)^{-1} X^\top \mathbf{y}$$

El vector de valores ajustados $\hat{\mathbf{y}} \in \mathbb{R}^n$ está dado por

$$\hat{\mathbf{y}} := X \hat{\boldsymbol{\theta}}.$$

Observar que, si X es de rango completo, entonces $\hat{\mathbf{y}} = X(X^\top X)^{-1} X^\top \mathbf{y}$. Esto significa que $\hat{\mathbf{y}}$ es la proyección de $\mathbf{y}$ sobre el espacio columna de X .

Resolución por descenso por gradiente

La aplicación del método de descenso por gradiente al problema de optimización en regresión lineal da lugar a lo que se denomina *algoritmo LMS (least mean squares)*. Resulta de sustituir $\nabla J(\boldsymbol{\theta}_t) = X^\top X \boldsymbol{\theta}_t - X^\top \mathbf{y}$ en la regla de actualización

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t - \eta \nabla J(\boldsymbol{\theta}_t), \quad \eta > 0.$$

Esta regla de actualización también se conoce como *regla de aprendizaje Widrow-Hoff*.

Algoritmo LMS

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\theta_{t+1} := \theta_t - \eta (X^\top X \theta_t - X^\top \mathbf{y}).$$

hasta que el criterio de parada se satisfaga.

El algoritmo anterior trabaja con todas las observaciones a la vez en cada paso de actualización, por lo que se trata de un *descenso de gradiente por lotes*. Esta estrategia asegura una actualización estable del parámetro θ , aunque puede ser costosa si el número de observaciones es muy grande. Como alternativas, podemos utilizar descenso de gradiente estocástico o *mini-batch*. Observar que, para una observación $(\mathbf{x}_i, y_i)$, la función de pérdida resulta

$$\text{loss}(\mathbf{x}_i, y_i; \theta) = \frac{1}{2} (y_i - \theta^\top \mathbf{x}_i)^2,$$

tal que

$$\nabla_{\theta} \text{loss}(\mathbf{x}_i, y_i; \theta) = -(y_i - \theta^\top \mathbf{x}_i) \mathbf{x}_i.$$

Algoritmo LMS estocástico

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Elegir un índice $i \in \{1, \dots, n\}$ al azar.

 Actualizar

$$\theta_{t+1} := \theta_t + \eta (y_i - \theta_t^\top \mathbf{x}_i) \mathbf{x}_i.$$

hasta que el criterio de parada se satisfaga.

Observar que la magnitud de la actualización del algoritmo LMS estocástico es proporcional al término de error $(y_i - \theta_t^\top \mathbf{x}_i)$. Si elegimos un ejemplo para el cual $\theta_t^\top \mathbf{x}_i \approx y_i$, entonces el cambio en el parámetro será mínimo. Esto puede activar prematuramente el criterio de parada basado en la magnitud del gradiente, por lo cual para evitar detener el algoritmo demasiado pronto, suele ser recomendable basar el criterio de parada en el promedio del error sobre un conjunto de observaciones. También se puede imponer un número mínimo de iteraciones para asegurar que el algoritmo recorra suficientes ejemplos y aprenda de manera estable.

Ejemplo 2.2.1: Regresión lineal en datos de viviendas

Utilizaremos el conjunto de datos *California Housing* [disponible aquí](#), el cual consiste en 20640 observaciones con 8 variables predictoras que miden características de las viviendas

y su entorno. La variable respuesta es la mediana del valor de una vivienda en cada bloque censal, por lo que efectivamente se trata de un problema de regresión. Ajustaremos un modelo de regresión lineal a los datos, evaluaremos el MSE en test y presentaremos los coeficientes estimados del modelo.

❗ En este ejemplo utilizamos la implementación `LinearRegression` de `scikit-learn`, la cual obtiene los coeficientes mediante métodos numéricos basados en álgebra lineal, en lugar de aplicar explícitamente el algoritmo de descenso por gradiente. La implementación del algoritmo LMS se realizará en las actividades prácticas.

```

1 import numpy as np
2 from sklearn.datasets import fetch_california_housing
3 from sklearn.linear_model import LinearRegression
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import mean_squared_error
7
8 # Datos:
9 X, y = fetch_california_housing(return_X_y=True)
10 scaler = StandardScaler()
11 X = scaler.fit_transform(X)
12
13 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
14     ↪ random_state=42)
15
16 # Modelo:
17 lr = LinearRegression()
18 lr.fit(X_train, y_train)
19
20 # Predicción y MSE:
21 y_pred = lr.predict(X_test)
22 mse_test = mean_squared_error(y_test, y_pred)

```

```
>
```

MSE en test: 0.556

Coeficientes estimados: $\theta_1 = 0.852$, $\theta_2 = 0.122$, $\theta_3 = -0.305$, $\theta_4 = 0.371$, $\theta_5 = -0.002$, $\theta_6 = -0.037$, $\theta_7 = -0.897$, $\theta_8 = -0.869$

Propiedades del estimador

Hemos visto que el algoritmo LMS permite aproximar el estimador de mínimos cuadrados $\hat{\theta}$ para el modelo de regresión lineal. Por supuesto, los resultados de convergencia para el método de descenso por gradiente son válidos.

No obstante, $\hat{\theta}$ es un estimador del valor verdadero θ^* , por lo que resulta relevante estudiar sus

propiedades estadísticas, tales como consistencia, sesgo y varianza, para entender qué tan buena es la estimación $\hat{\theta}$, incluso después de la convergencia del algoritmo LMS.

Importante

En base a lo descrito, es fundamental distinguir dos niveles de convergencia:

- **Convergencia estadística del estimador:** se refiere al hecho de que el estimador $\hat{\theta}_n$ converge en probabilidad al valor verdadero θ^* . Simbólicamente:

$$\text{plim}_{n \rightarrow \infty} \hat{\theta}_n = \theta^* \quad (\hat{\theta}_n \xrightarrow{p} \theta^*).$$

Observar que escribimos $\hat{\theta}_n$ para explicitar la dependencia del estimador respecto al tamaño muestral n .

- **Convergencia computacional del algoritmo:** se refiere a que la sucesión producida por un algoritmo iterativo (por ejemplo, descenso por gradiente) converge a $\hat{\theta}$ (aquí no escribimos el subíndice porque n es fijo). Esto es:

$$\lim_{t \rightarrow \infty} \theta_t = \hat{\theta} \quad (\theta_t \rightarrow \hat{\theta}).$$

Ahora sí estamos en condiciones de revisar algunos resultados conocidos para el modelo de regresión lineal.

- *Convergencia estadística:*

Para $n > p$ y bajo los supuestos clásicos de

$$\begin{aligned} \{(\mathbf{x}_i, y_i)\}_{i=1}^n \text{ i.i.d., } \mathbb{E}[\varepsilon_i | \mathbf{x}_i] &= 0 && \text{(Exogeneidad)} \\ \mathbb{E}[\varepsilon_i^2 | \mathbf{x}_i] &= \sigma^2 < \infty, \mathbb{E}[\varepsilon_i^4] && \text{(Momentos)} \\ \frac{1}{n} X^\top X &\xrightarrow{p} \Sigma_X \succ 0 && \text{(Diseño bien condicionado)} \end{aligned}$$

se verifica

$$\hat{\theta}_n \xrightarrow{p} \theta^* \quad \text{y} \quad \sqrt{n}(\hat{\theta}_n - \theta^*) \xrightarrow{d} \mathcal{N}(0, \sigma^2 \Sigma_X^{-1}).$$

- *Convergencia computacional:*

Sean $\lambda_{\min}, \lambda_{\max} > 0$ autovalores de $X^\top X$. Si $0 < \eta < 2/\lambda_{\max}$, entonces

$$\theta_t \rightarrow \hat{\theta} \quad \text{y} \quad \|\theta_t - \hat{\theta}\|_2 \leq \rho^t \|\theta_0 - \hat{\theta}\|_2,$$

con $\rho = \max\{|1 - \eta\lambda_{\min}|, |1 - \eta\lambda_{\max}|\}$.

II | Regresión logística


Consideremos ahora un problema de clasificación binaria, con variable respuesta $Y \in \{0, 1\}$. Por ejemplo, si estamos tratando de construir un clasificador de spam para correos electrónicos, entonces una observación $\mathbf{x}$ contendrá características de un correo electrónico, mientras que su etiqueta y será 1 si es spam o 0 en caso contrario.

Podríamos abordar el problema de clasificación ignorando el hecho de que y toma valores discretos y usar el método de regresión lineal. Sin embargo, no tendría sentido que la predicción para un valor de $\mathbf{x}$ sea un valor fuera del rango de 0 y 1. Para resolver este problema, es conveniente utilizar la *función logística*.

i Función logística

Para $z \in \mathbb{R}$, se define la *función logística* o *función sigmoide* $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ mediante

$$\sigma(z) := \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}.$$



Algunas características son:

- $\sigma(\mathbb{R}) = (0, 1)$ y $\sigma(0) = 0.5$.
- $\lim_{z \rightarrow -\infty} \sigma(z) = 0$ y $\lim_{z \rightarrow \infty} \sigma(z) = 1$.
- $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.
- Su inversa es la función logit : $(0, 1) \rightarrow \mathbb{R}$ definida por

$$\text{logit}(p) := \log \frac{p}{1 - p}.$$

Ya estamos en condiciones de configurar el modelo de regresión logística. Para ello, primero

definimos la función $h_{\boldsymbol{\theta}} : \mathbb{R}^p \rightarrow \mathbb{R}$ como

$$h_{\boldsymbol{\theta}}(\mathbf{x}) := \sigma(\boldsymbol{\theta}^\top \mathbf{x}) = \frac{1}{1 + e^{-\boldsymbol{\theta}^\top \mathbf{x}}}.$$

Supuestos del modelo

$$Y \in \{0, 1\}$$

$$\mathbb{P}(y = 1 \mid \mathbf{x}; \boldsymbol{\theta}) = h_{\boldsymbol{\theta}}(\mathbf{x})$$

Distribución condicional

Bajo el modelo de regresión logística, resulta

$$Y \mid \mathbf{X} = \mathbf{x} \sim \text{Binom}(1, h_{\boldsymbol{\theta}}(\mathbf{x})),$$

de manera tal que

$$\begin{aligned} p(y \mid \mathbf{x}; \boldsymbol{\theta}) &= (h_{\boldsymbol{\theta}}(\mathbf{x}))^y (1 - h_{\boldsymbol{\theta}}(\mathbf{x}))^{1-y} \\ &= \exp \{y \log h_{\boldsymbol{\theta}}(\mathbf{x}) + (1 - y) \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}))\} \\ &= \exp \left\{ y \log \left(\frac{h_{\boldsymbol{\theta}}(\mathbf{x})}{1 - h_{\boldsymbol{\theta}}(\mathbf{x})} \right) + \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x})) \right\} \\ &= \exp (y \text{logit}(h_{\boldsymbol{\theta}}(\mathbf{x})) + \log(1 - h_{\boldsymbol{\theta}}(\mathbf{x}))). \end{aligned}$$

Definimos el *parámetro natural* $\eta \in \mathbb{R}$ como

$$\eta(\mathbf{x}; \boldsymbol{\theta}) := \text{logit}(h_{\boldsymbol{\theta}}(\mathbf{x})) = \boldsymbol{\theta}^\top \mathbf{x}.$$

y la función $A : \mathbb{R} \rightarrow \mathbb{R}$ mediante $A(\eta) = \log(1 + e^\eta)$. Resulta:

La función de densidad condicional de $Y \mid \mathbf{X}$ en el modelo de regresión logística es

$$p(y \mid \eta) = \exp \{ \eta y - A(\eta) \}, \quad \eta = \boldsymbol{\theta}^\top \mathbf{x}. \quad (2.2.1)$$

Es importante observar que

$$\begin{aligned} A'(\eta) &= \frac{e^\eta}{1 + e^\eta} = \sigma(\eta) = h_{\boldsymbol{\theta}}(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}], \\ A''(\eta) &= \sigma'(\eta) = \sigma(\eta)(1 - \sigma(\eta)) = h_{\boldsymbol{\theta}}(\mathbf{x})(1 - h_{\boldsymbol{\theta}}(\mathbf{x})) = \text{Cov}[Y \mid \mathbf{X} = \mathbf{x}]. \end{aligned} \quad (2.2.2)$$

Importante

La forma (2.2.1) no es casual: corresponde a un caso particular de la representación de las denominadas *familias exponenciales*, que estudiaremos más adelante y que constituyen el marco teórico general de los modelos lineales generalizados.

Función de verosimilitud

Para un conjunto de datos $\{\mathbf{x}_i, y_i\}_{i=1}^n$ i.i.d., la función de log-verosimilitud es

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^n [\eta_i y_i - A(\eta_i)] = \sum_{i=1}^n \left[\boldsymbol{\theta}^\top \mathbf{x}_i y_i - \log(1 + e^{\boldsymbol{\theta}^\top \mathbf{x}_i}) \right].$$

Importante

En regresión logística, maximizar $\ell(\boldsymbol{\theta})$ es equivalente a minimizar

$$J(\boldsymbol{\theta}) = - \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)], \quad (2.2.3)$$

con

$$\hat{y}_i := h_{\boldsymbol{\theta}}(\mathbf{x}_i) = \frac{1}{1 + e^{-\boldsymbol{\theta}^\top \mathbf{x}_i}}.$$

La función $J(\boldsymbol{\theta})$ en (2.2.3), conocida como *entropía cruzada*, es la forma habitual de expresar la función de pérdida en problemas de clasificación binaria. Mide la disimilaridad entre las etiquetas reales y_i y las probabilidades $\hat{y}_i$ predichas por el modelo.

✍ Verifique que se cumple $J(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta})$.

Optimalidad

El problema de optimización resultante es

$$\text{minimizar } \sum_{i=1}^n \left[\log(1 + e^{\boldsymbol{\theta}^\top \mathbf{x}_i}) - \boldsymbol{\theta}^\top \mathbf{x}_i y_i \right]. \quad (2.2.4)$$

✍ Muestre que la función objetivo $J(\boldsymbol{\theta})$ en (2.2.4) es convexa.

Como antes, la condición de optimalidad $\nabla J(\boldsymbol{\theta}) = \mathbf{0}$ es suficiente y necesaria. Se tiene que

$$\begin{aligned} \nabla J(\boldsymbol{\theta}) &= \sum_{i=1}^n \left[\frac{e^{\boldsymbol{\theta}^\top \mathbf{x}_i}}{1 + e^{\boldsymbol{\theta}^\top \mathbf{x}_i}} \mathbf{x}_i - \mathbf{x}_i y_i \right] \\ &= \sum_{i=1}^n -\mathbf{x}_i [y_i - h_{\boldsymbol{\theta}}(\mathbf{x}_i)] \\ &= -X^\top (\mathbf{y} - \hat{\mathbf{y}}), \end{aligned} \quad (2.2.5)$$

donde $\hat{\mathbf{y}} = (h_{\boldsymbol{\theta}}(\mathbf{x}_1), \dots, h_{\boldsymbol{\theta}}(\mathbf{x}_n)) \in \mathbb{R}^n$ es el vector de probabilidades predichas.

La expresión (2.2.5) muestra que $\nabla J(\boldsymbol{\theta})$ depende de $\boldsymbol{\theta}$ de forma no lineal. Por lo tanto, no es posible obtener una solución explícita de $\nabla J(\hat{\boldsymbol{\theta}}) = \mathbf{0}$ y la única opción es recurrir a métodos iterativos para aproximar $\hat{\boldsymbol{\theta}}$.

Resolución por descenso por gradiente

De los resultados anteriores, resultan de manera natural algoritmos iterativos para la estimación del parámetro θ^* basados en métodos de gradiente.

Algoritmo de descenso por gradiente para regresión logística

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\theta_{t+1} := \theta_t + \eta X^\top (y - \hat{y}_t).$$

hasta que el criterio de parada se satisfaga.

Algoritmo de descenso por gradiente estocástico para regresión logística

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\eta > 0$:

repetir

para $t = 0, 1, 2, \dots$:

 Elegir un índice $i \in \{1, \dots, n\}$ al azar.

 Actualizar

$$\theta_{t+1} := \theta_t + \eta (y_i - h_{\theta_t}(\mathbf{x}_i)) \mathbf{x}_i.$$

hasta que el criterio de parada se satisfaga.

Resolución por método de Newton

Recordemos que el método de Newton actualiza los parámetros mediante

$$\theta_{t+1} = \theta_t - \left[\nabla^2 J(\theta_t) \right]^{-1} \nabla J(\theta_t).$$

Para obtener los elementos de esta ecuación, tendremos en cuenta (2.2.2) y el cálculo del vector gradiente en (2.2.5). Podemos escribir

$$\nabla J(\theta) = \sum_{i=1}^n -\mathbf{x}_i [y_i - A'(\eta_i)].$$

Por lo tanto,

$$\begin{aligned} \nabla^2 J(\theta) &= \sum_{i=1}^n -\mathbf{x}_i A''(\eta_i) \frac{\partial \eta_i}{\partial \theta} \\ &= \sum_{i=1}^n A''(\eta_i) \mathbf{x}_i \mathbf{x}_i^\top \\ &= X^\top W X, \end{aligned}$$

donde

$$W := \text{diag}(w_1, \dots, w_n) \quad \text{con } w_i := A''(\eta_i) = h_{\theta}(\mathbf{x}_i)(1 - h_{\theta}(\mathbf{x}_i)).$$

 Algoritmo de Newton para regresión logística

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$:

repetir

para $t = 0, 1, 2, \dots$:

 Actualizar

$$\theta_{t+1} := \theta_t + (X^\top W_t X)^{-1} X^\top (y - \hat{y}_t).$$

hasta que el criterio de parada se satisfaga.

Ejemplo 2.2.2: Regresión logística en datos de cáncer

Utilizaremos el conjunto de datos *Breast Cancer* [disponible aquí](#), el cual contiene información de tumores de mama y consta de 569 observaciones y 30 variables predictoras. La variable respuesta indica el tipo de tumor (0 para benigno y 1 para maligno), lo que convierte este problema en una tarea de clasificación binaria. Ajustaremos un modelo de regresión logística a los datos, evaluaremos la precisión en test y presentaremos los coeficientes estimados del modelo.

! En este ejemplo utilizamos la implementación `LogisticRegression` de `scikit-learn`, la cual emplea por defecto el algoritmo LBFGS, un método cuasi-Newton ampliamente utilizado en problemas de optimización convexa. La implementación de los algoritmos de descenso por gradiente y Newton se realizará en las actividades prácticas.

```
1 import numpy as np
2 from sklearn.datasets import load_breast_cancer
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.preprocessing import StandardScaler
5 from sklearn.model_selection import train_test_split
6 from sklearn.metrics import accuracy_score
7
8 # Datos:
9 X, y = load_breast_cancer(return_X_y=True)
10 scaler = StandardScaler()
11 X = scaler.fit_transform(X)
12
13 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
14     ↪ random_state=42)
15
16 # Modelo:
17 logreg = LogisticRegression(max_iter=1000)
18 logreg.fit(X_train, y_train)
19
20 # Predicción y accuracy:
21 y_pred = logreg.predict(X_test)
22 acc_test = accuracy_score(y_test, y_pred)
```

>

Accuracy en test: 0.974

Coefficientes estimados: $\theta_1 = -0.435$, $\theta_2 = -0.397$, $\theta_3 = -0.396$, $\theta_4 = -0.470$, $\theta_5 = -0.067$, $\theta_6 = 0.527$, $\theta_7 = -0.808$, $\theta_8 = -1.108$, $\theta_9 = 0.242$, $\theta_{10} = 0.078$, $\theta_{11} = -1.251$, $\theta_{12} = 0.189$, $\theta_{13} = -0.590$, $\theta_{14} = -0.920$, $\theta_{15} = -0.317$, $\theta_{16} = 0.669$, $\theta_{17} = 0.171$, $\theta_{18} = -0.314$, $\theta_{19} = 0.505$, $\theta_{20} = 0.612$, $\theta_{21} = -0.874$, $\theta_{22} = -1.358$, $\theta_{23} = -0.586$, $\theta_{24} = -0.838$, $\theta_{25} = -0.547$, $\theta_{26} = 0.006$, $\theta_{27} = -0.952$, $\theta_{28} = -0.780$, $\theta_{29} = -1.196$, $\theta_{30} = -0.163$.

Propiedades del estimador

Para el caso de regresión logística, algunos resultados importantes son:

■ Convergencia estadística:

Bajo supuestos clásicos, tales como

$\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ i.i.d. (Independencia e idéntica distribución)

$0 < \mathbb{P}(Y_i = 1 \mid \mathbf{x}_i) < 1$ (No separabilidad)

$\mathbb{E}[\|\mathbf{x}_i\|^2] < \infty$ (Momentos finitos)

$\mathcal{I}(\boldsymbol{\theta}^*) = \mathbb{E} \left[h_{\boldsymbol{\theta}}(\mathbf{X})(1 - h_{\boldsymbol{\theta}}(\mathbf{X})) \mathbf{X} \mathbf{X}^\top \right] \succ 0$ (Información de Fisher definida positiva)

se verifica

$$\hat{\boldsymbol{\theta}}_n \xrightarrow{p} \boldsymbol{\theta}^* \quad \text{y} \quad \sqrt{n}(\hat{\boldsymbol{\theta}}_n - \boldsymbol{\theta}^*) \xrightarrow{d} \mathcal{N}(0, \mathcal{I}(\boldsymbol{\theta}^*)^{-1}).$$

■ Convergencia computacional:

Como J es convexa y L -suave con

$$L \leq \frac{\lambda_{\max}(X^\top X)}{4n},$$

el método de descenso por gradiente con paso fijo $0 < \eta < 1/L$ converge al minimizador $\hat{\boldsymbol{\theta}}$.

Referencias

- Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer Series in Statistics. New York: Springer.
- Ng, A. (2022). *Stanford CS229: Machine Learning - Lecture Notes*. Stanford University. URL: https://cs229.stanford.edu/notes2022fall/main_notes.pdf.