



UNL. FACULTAD DE
INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez

Liliana Forzani

Año 2026

Modelos lineales generalizados

Tanto en el modelo de regresión lineal como en el de regresión logística, asumimos una cierta distribución condicional para $Y \mid \mathbf{X}$ que depende de un vector de parámetros $\boldsymbol{\theta} \in \mathbb{R}^p$.

- En regresión lineal, $Y \mid \mathbf{X} = \mathbf{x} \sim \mathcal{N}(\boldsymbol{\theta}^\top \mathbf{x}, \sigma^2)$.
- En regresión logística, $Y \mid \mathbf{X} = \mathbf{x} \sim \text{Bernoulli}(\sigma(\boldsymbol{\theta}^\top \mathbf{x}))$, con $\sigma : \mathbb{R} \rightarrow \mathbb{R}$ la función logística.

Además, vimos que en regresión logística, la incorporación del parámetro natural $\eta = \boldsymbol{\theta}^\top \mathbf{x}$ y de la función $A(\eta) = \log(1 + e^\eta)$ permiten escribir la función de probabilidad condicional como

$$p(y \mid \eta) = \exp \{ \eta y - A(\eta) \}.$$

Algo similar ocurre en regresión lineal si consideramos $\sigma^2 = 1$, $\eta = \boldsymbol{\theta}^\top \mathbf{x}$ y $A(\eta) = \eta^2/2$:

$$p(y \mid \eta) = \frac{1}{\sqrt{2\pi}} e^{-(y-\eta)^2/2} = h(y) \exp \{ \eta y - A(\eta) \}, \quad h(y) = \frac{1}{\sqrt{2\pi}} e^{-y^2/2}.$$

La elección $\sigma^2 = 1$ es sin pérdida de generalidad ya que, como vimos, el estimador de máxima verosimilitud de $\boldsymbol{\theta}$ no depende de σ^2 . De hecho, es fácil ver que para σ^2 arbitrario se mantiene la estructura lineal tomando $\eta = \tilde{\boldsymbol{\theta}}^\top \mathbf{x}$, con $\tilde{\boldsymbol{\theta}} = \boldsymbol{\theta}/\sigma^2$.

Por último, es importante remarcar que en ambos modelos se cumple

$$A'(\eta) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}; \boldsymbol{\theta}] \quad \text{y} \quad A''(\eta) = \text{Var}[Y \mid \mathbf{X} = \mathbf{x}; \boldsymbol{\theta}],$$

y que la predicción es

$$\hat{y} = h_{\hat{\boldsymbol{\theta}}}(\mathbf{x}) := \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}; \hat{\boldsymbol{\theta}}],$$

que resulta en $\hat{y} = \hat{\boldsymbol{\theta}}^\top \mathbf{x}$ en regresión lineal y $\hat{y} = \sigma(\hat{\boldsymbol{\theta}}^\top \mathbf{x})$ en regresión logística.

La estructura común de ambos modelos sugiere una generalización natural: elegir otras distribuciones con la misma forma para $Y \mid \mathbf{X}$, manteniendo $\eta = \boldsymbol{\theta}^\top \mathbf{x}$. Esto conduce a los *Modelos Lineales Generalizados* (GLM), una amplia familia de modelos que incluye a ambos como casos particulares y permite abordar una gran variedad de problemas de regresión y clasificación. Para estudiarlos, en primer lugar introduciremos formalmente la *familia exponencial*, que agrupa a todas las distribuciones con esta forma e incluye muchas de las comúnmente utilizadas en estadística.

Notación

Para el caso de un vector aleatorio $\mathbf{Z} \in \mathbb{R}^q$ con distribución de probabilidad $\mathbb{P}_{\mathbf{Z}}$, se definen el *vector de medias* $\mathbb{E}[\mathbf{Z}] \in \mathbb{R}^q$ y la *matriz de covarianza* $\text{Cov}[\mathbf{Z}] \in \mathbb{R}^{q \times q}$ como sigue:

$$\mathbb{E}[\mathbf{Z}] := \int \mathbf{z} d\mathbb{P}_{\mathbf{Z}}(\mathbf{z}),$$

$$\text{Cov}[\mathbf{Z}] := \mathbb{E}[(\mathbf{Z} - \mathbb{E}[\mathbf{Z}])(\mathbf{Z} - \mathbb{E}[\mathbf{Z}])^\top].$$

I | La familia exponencial

Definición 2.3.1 (Familia exponencial). Decimos que una clase de distribuciones pertenece a la *familia exponencial* si se puede escribir en la forma

$$p(y | \boldsymbol{\eta}) := h(y) \exp \left\{ \boldsymbol{\eta}^\top T(y) - A(\boldsymbol{\eta}) \right\}, \quad (2.3.1)$$

con $h : \mathbb{R} \rightarrow \mathbb{R}$, $\boldsymbol{\eta} \in \mathbb{R}^q$, $T : \mathbb{R} \rightarrow \mathbb{R}^q$ y $A : \mathbb{R}^q \rightarrow \mathbb{R}$.

En la expresión (2.3.1) se distinguen los siguientes elementos:

- $\boldsymbol{\eta} \in \mathbb{R}^q$ es el *parámetro natural*.
- $T : \mathbb{R} \rightarrow \mathbb{R}^q$ es el *estadístico suficiente*.
- $h : \mathbb{R} \rightarrow \mathbb{R}$ es la *función base* que depende únicamente de y .
- $A : \mathbb{R}^q \rightarrow \mathbb{R}$ es la *función de log-partición* que normaliza la expresión, garantizando que la distribución integre a 1.

Para un mismo h y T , la familia exponencial consiste en todas las distribuciones que se obtienen al variar el parámetro natural $\boldsymbol{\eta}$. Observar que (2.3.1) puede expresarse también como

$$p(y | \boldsymbol{\eta}) = \frac{h(y) \exp \left\{ \boldsymbol{\eta}^\top T(y) \right\}}{\exp \{A(\boldsymbol{\eta})\}} = \frac{h(y) \exp \left\{ \boldsymbol{\eta}^\top T(y) \right\}}{\int h(y) \exp \left\{ \boldsymbol{\eta}^\top T(y) \right\} dy}, \quad (2.3.2)$$

lo cual resulta del hecho que $\int p(y | \boldsymbol{\eta}) dy = 1$.

Ejemplo 2.3.2: Distribución Bernoulli

Sea $Y \in \{0, 1\}$ tal que $Y \sim \text{Bernoulli}(\phi)$, con $\phi := \mathbb{P}(Y = 1)$. Entonces

$$p(y | \phi) = \phi^y (1 - \phi)^{1-y}.$$

De acuerdo a lo visto en regresión logística, la distribución de Y se puede escribir como

$$p(y | \phi) = \exp \{ \eta y - A(\eta) \},$$

con parámetro natural

$$\eta = \text{logit } \phi = \log \left(\frac{\phi}{1 - \phi} \right) \in \mathbb{R},$$

y estadístico suficiente $T : \mathbb{R} \rightarrow \mathbb{R}$ definido por $T(y) = y$. Por lo tanto, la distribución Bernoulli es un miembro de la familia exponencial. El resto de los elementos son:

$$h(y) = 1, \quad A(\eta) = -\log(1 - \phi) = \log(1 + e^\eta).$$

Ejemplo 2.3.3: Distribución Normal univariada

Sea $Y \in \mathbb{R}$ tal que $Y \sim \mathcal{N}(\mu, \sigma^2)$. Entonces

$$\begin{aligned} p(y \mid \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2} y^2 + \frac{\mu}{\sigma^2} y - \frac{\mu^2}{2\sigma^2} - \log \sigma \right\} \\ &= \frac{1}{\sqrt{2\pi}} \exp \left\{ \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right)^\top (y, y^2) - \frac{\mu^2}{2\sigma^2} - \log \sigma \right\}. \end{aligned}$$

Por lo tanto, la distribución Normal univariada es un miembro de la familia exponencial, con parámetro natural

$$\boldsymbol{\eta} = \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right) \in \mathbb{R}^2,$$

y estadístico suficiente $T : \mathbb{R} \rightarrow \mathbb{R}^2$ definido por $T(y) = (y, y^2)$. El resto de los elementos son:

$$h(y) = \frac{1}{\sqrt{2\pi}}, \quad A(\boldsymbol{\eta}) = \frac{\mu^2}{2\sigma^2} + \log \sigma = -\frac{\eta_1^2}{4\eta_2} + \frac{1}{2} \log(-2\eta_2).$$

 Exprese la distribución normal univariada con varianza conocida como familia exponencial.

Existen muchas otras distribuciones que son miembros de la familia exponencial: la Multinomial (que veremos más adelante), la Poisson (para modelar datos de conteo), la Gamma y la Exponencial (para modelar variables continuas no negativas, como intervalos de tiempo), la Beta y la Dirichlet (para distribuciones sobre probabilidades), y muchas más.

Importante

La función de partición $A : \mathbb{R}^q \rightarrow \mathbb{R}$ queda definida a partir de la siguiente expresión:

$$A(\boldsymbol{\eta}) := \log \int h(y) \exp \{ \boldsymbol{\eta}^\top T(y) \} dy.$$

Se verifica que

$$\nabla A(\boldsymbol{\eta}) = \mathbb{E}[T(Y)] \in \mathbb{R}^q, \quad \nabla^2 A(\boldsymbol{\eta}) = \text{Cov}[T(Y)] \in \mathbb{R}^{q \times q}.$$

Demostración. Derivando respecto de $\boldsymbol{\eta}$, resulta

$$\nabla A(\boldsymbol{\eta}) = \frac{\nabla \left[\int h(y) \exp \{ \boldsymbol{\eta}^\top T(y) \} dy \right]}{\int h(y) \exp \{ \boldsymbol{\eta}^\top T(y) \} dy} = \frac{\int h(y) \exp \{ \boldsymbol{\eta}^\top T(y) \} T(y) dy}{\int h(y) \exp \{ \boldsymbol{\eta}^\top T(y) \} dy},$$

donde hemos asumido que la derivación bajo el signo integral es válida para $\boldsymbol{\eta}$ en un conjunto abierto. De (2.3.2) resulta

$$\nabla A(\boldsymbol{\eta}) = \int T(y) p(y | \boldsymbol{\eta}) dy = \mathbb{E}[T(Y)].$$

Ahora bien, aplicando regla del cociente, resulta

$$\begin{aligned} \nabla^2 A(\boldsymbol{\eta}) &= \int T(y) T(y)^\top p(y | \boldsymbol{\eta}) dy - \int T(y) p(y | \boldsymbol{\eta}) dy \int T(y)^\top p(y | \boldsymbol{\eta}) dy \\ &= \mathbb{E}[T(Y) T(Y)^\top] - \mathbb{E}[T(Y)] \mathbb{E}[T(Y)]^\top \\ &= \text{Cov}[T(Y)]. \end{aligned}$$

■

De lo anterior resulta que $\nabla^2 A(\boldsymbol{\eta}) \succeq 0$, lo cual significa que A es una función convexa.

 ¿Cuándo A es estrictamente convexa?

Ejemplo 2.3.4: Gradiente y Hessiana de $A(\boldsymbol{\eta})$ para las distribuciones Bernoulli y Normal univariada

Vamos a verificar la expresión de $\nabla A(\boldsymbol{\eta})$ y $\nabla^2 A(\boldsymbol{\eta})$ para los casos de las distribuciones Bernoulli y Normal univariada, utilizando las expresiones obtenidas en los ejemplos anteriores.

- Si $Y \sim \text{Bernoulli}(\phi)$, entonces

$$A'(\eta) = \frac{e^\eta}{1 + e^\eta} = \frac{\frac{\phi}{1-\phi}}{\frac{1}{1-\phi}} = \phi = \mathbb{E}[Y],$$

$$A''(\eta) = \frac{e^\eta}{(1 + e^\eta)^2} = \frac{\frac{\phi}{1-\phi}}{\left(\frac{1}{1-\phi}\right)^2} = \phi(1 - \phi) = \text{Cov}[Y].$$

- Para la distribución Normal univariada serán de utilidad sus momentos. Si $Y \sim \mathcal{N}(\mu, \sigma^2)$,

se tiene que

$$\begin{aligned}\mathbb{E}[Y] &= \mu, & \mathbb{E}[Y^2] &= \mu^2 + \sigma^2, \\ \mathbb{E}[Y^3] &= \mu^3 + 3\mu\sigma^2, & \mathbb{E}[Y^4] &= \mu^4 + 6\mu^2\sigma^2 + 3\sigma^4.\end{aligned}$$

Ahora sí derivamos:

$$\nabla A(\boldsymbol{\eta}) = \left(-\frac{\eta_1}{2\eta_2}, \frac{\eta_1^2}{4\eta_2^2} - \frac{1}{2\eta_2} \right)^\top = (\mu, \mu^2 + \sigma^2)^\top = \mathbb{E}[(Y, Y^2)] = \mathbb{E}[T(Y)],$$

$$\nabla^2 A(\boldsymbol{\eta}) = \begin{pmatrix} -\frac{1}{2\eta_2} & \frac{\eta_1}{2\eta_2^2} \\ \frac{\eta_1}{2\eta_2^2} & -\frac{\eta_1^2}{2\eta_2^3} + \frac{1}{2\eta_2^2} \end{pmatrix} = \begin{pmatrix} \sigma^2 & 2\mu\sigma^2 \\ 2\mu\sigma^2 & 4\mu^2\sigma^2 + 2\sigma^4 \end{pmatrix} = \text{Cov}[T(Y)],$$

donde para esta última igualdad se usaron las igualdades

$$\text{Var}[Y^2] = \mathbb{E}[Y^4] - \mathbb{E}[Y^2]^2, \quad \text{Cov}[Y, Y^2] = \mathbb{E}[Y^3] - \mathbb{E}[Y] \mathbb{E}[Y^2].$$

II | Modelo lineal generalizado

Supongamos que deseamos construir un modelo para estimar el número y de clientes que llegan a una tienda (o el número de visitas a páginas web en un sitio) en una hora determinada, basándonos en ciertas características $\mathbf{x}$ como promociones en la tienda, publicidad reciente, clima, día de la semana, etc.

¿Nos sirven los modelos que ya conocemos? La regresión lineal supone que $Y \mid \mathbf{X}$ es Normal: puede predecir valores negativos, algo absurdo para un conteo, y asume varianza constante, mientras que en conteos es natural que la variabilidad crezca con el promedio. La regresión logística, por su parte, está pensada para respuestas binarias, y aquí $Y \in \{0, 1, 2, \dots\}$. Por lo tanto, ninguno de los dos modelos se ajusta a la naturaleza de los datos.

Sabemos que la distribución Poisson usualmente proporciona un buen modelo para el número de visitantes. Afortunadamente, la Poisson pertenece a la familia exponencial, al igual que la Normal y la Bernoulli que dan lugar a los modelos anteriores, por lo que podemos aplicar un Modelo Lineal Generalizado (GLM): una misma construcción que nos permite adaptar el modelo a la distribución de la respuesta. En esta sección describiremos un método para construir modelos GLM para problemas como este.

En forma general, consideremos un problema de regresión o clasificación donde queremos predecir el valor de alguna variable aleatoria $Y \in \mathbb{R}$ a partir de un conjunto de predictoras $\mathbf{X} \in \mathbb{R}^p$. La familia exponencial será nuestra herramienta para modelar las distribuciones condicionales $Y \mid \mathbf{X}$. La parte *lineal* del nombre proviene de suponer que el parámetro natural de esa distribución depende linealmente de las predictoras: $\boldsymbol{\eta} = \boldsymbol{\Theta}^\top \mathbf{x}$ (en la mayoría de las aplicaciones, el parámetro natural es escalar: $\eta = \boldsymbol{\theta}^\top \mathbf{x}$).

Formalmente un GLM queda definido a partir del siguiente supuesto:

Supuesto del modelo

$Y \mid \mathbf{X} = \mathbf{x}$ sigue una distribución perteneciente a la familia exponencial,
con parámetro natural de la forma

$$\boldsymbol{\eta} := \boldsymbol{\Theta}^\top \mathbf{x}, \quad \boldsymbol{\Theta} \in \mathbb{R}^{p \times q}.$$

El parámetro natural $\boldsymbol{\eta} \in \mathbb{R}^q$ queda conectado a la función de regresión $\mathbb{E}[T(Y) \mid \mathbf{x}; \boldsymbol{\Theta}]$ a partir de una *función de enlace canónica* $g: \mathbb{R}^q \rightarrow \mathbb{R}^q$ que verifica

$$\boldsymbol{\eta} = g(\mathbb{E}[T(Y) \mid \mathbf{x}; \boldsymbol{\Theta}]).$$

Ejemplo 2.3.5: Función de enlace en regresión logística

En regresión logística, el estadístico suficiente es $T(y) = y$. Además, sabemos que

$$\boldsymbol{\eta} = \boldsymbol{\theta}^\top \mathbf{x}, \quad \mathbb{E}[Y \mid \mathbf{x}; \boldsymbol{\theta}] = \sigma(\boldsymbol{\theta}^\top \mathbf{x}).$$

Es decir, $\mathbb{E}[Y \mid \mathbf{x}; \boldsymbol{\theta}] = \sigma(\boldsymbol{\eta})$. Por lo tanto,

$$\boldsymbol{\eta} = \sigma^{-1}(\mathbb{E}[Y \mid \mathbf{x}; \boldsymbol{\theta}]).$$

Así, la función de enlace canónica para regresión logística es $\text{logit}: (0, 1) \rightarrow \mathbb{R}$ definida por

$$\text{logit } p := \log \frac{p}{1-p}.$$

 Determine la función de enlace canónica para regresión lineal.

En un GLM la estructura del modelo hace que, una vez estimado $\boldsymbol{\Theta}$, todo lo demás se obtiene por composición. El estimador $\hat{\boldsymbol{\Theta}}$ conduce a un estimador del parámetro natural para un $\mathbf{x}$ dado: $\hat{\boldsymbol{\eta}} = \hat{\boldsymbol{\Theta}}^\top \mathbf{x}$; y este último, a su vez, determina la función de regresión:

$$\mathbb{E}[T(Y) \mid \mathbf{x}; \hat{\boldsymbol{\theta}}] = \nabla A(\hat{\boldsymbol{\eta}}).$$

En conclusión:

El modelo GLM nos permite predecir

$$\hat{y} = h_{\hat{\boldsymbol{\Theta}}}(\mathbf{x}) := \mathbb{E}[T(Y) \mid \mathbf{x}; \hat{\boldsymbol{\Theta}}].$$

 A partir de lo visto, justifique que la regresión lineal y la regresión logística son casos particulares de GLM.

El caso particular de la distribución Poisson del ejemplo inicial de esta subsección se analizará en las actividades conceptuales.  4

A continuación, vamos a abordar el problema de estimación de los parámetros en un GLM de la manera habitual: definiendo el problema de optimización a partir del principio de máxima verosimilitud y luego, de ser posible, aplicando una condición de optimalidad. Por razones de simplicidad, supondremos

$$\eta = \boldsymbol{\theta}^\top \mathbf{x} \in \mathbb{R}, \quad \boldsymbol{\theta} \in \mathbb{R}^p.$$

Además, para una muestra $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ i.i.d., denotamos

$$\eta_i := \boldsymbol{\theta}^\top \mathbf{x}_i,$$

$$\mu_i := \mathbb{E}[T(Y) \mid \mathbf{X} = \mathbf{x}_i; \boldsymbol{\theta}] = \nabla A(\eta_i).$$

Función de verosimilitud

De (2.3.1) resulta

$$\log p(y_i \mid \eta) = \log(h(y_i)) + \eta T(y_i) - A(\eta).$$

Por lo tanto, la función de log-verosimilitud es

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^n [\eta_i T(y_i) - A(\eta_i)] + \text{cte.} \quad (2.3.3)$$

Importante

Observar que ℓ depende del modelo particular únicamente a través de T y de la función de log-partición A . Por eso, el gradiente y la Hessiana de ℓ pueden calcularse una sola vez, de forma general, para toda la familia exponencial, en términos de A' y A'' . Teniendo en cuenta que $\partial \eta_i / \partial \boldsymbol{\theta} = \mathbf{x}_i$, resulta

$$\nabla \ell(\boldsymbol{\theta}) = \sum_{i=1}^n [T(y_i) - A'(\eta_i)] \mathbf{x}_i = \mathbf{X}^\top [T(\mathbf{y}) - A'(\tilde{\boldsymbol{\eta}})], \quad (2.3.4)$$

donde $A'(\tilde{\boldsymbol{\eta}}) = (A'(\eta_1), \dots, A'(\eta_n))^\top \in \mathbb{R}^n$, con

$$A'(\eta_i) = \mathbb{E}[T(Y) \mid \mathbf{x}_i, \boldsymbol{\theta}]$$

Derivando nuevamente, se obtiene

$$\nabla^2 \ell(\boldsymbol{\theta}) = - \sum_{i=1}^n A''(\eta_i) \mathbf{x}_i \mathbf{x}_i^\top = -\mathbf{X}^\top \mathbf{W} \mathbf{X}, \quad (2.3.5)$$

donde $\mathbf{W} = \text{diag}(A''(\eta_1), \dots, A''(\eta_n)) \in \mathbb{R}^{n \times n}$. Observar que la matriz $\mathbf{W}$ actúa como una matriz de pesos: el peso de la i -ésima observación es $A''(\eta_i) = \text{Cov}[T(Y) \mid \mathbf{x}_i; \boldsymbol{\theta}]$, que en general depende de $\boldsymbol{\theta}$ y de $\mathbf{x}_i$. En el caso de la regresión lineal (varianza constante) estos pesos son todos iguales y se recupera $\mathbf{X}^\top \mathbf{X}$ salvo una constante; en cambio, en un GLM general los pesos varían entre observaciones y con $\boldsymbol{\theta}$.

Optimalidad

De (2.3.3), el problema de optimización resultante es

$$\text{minimizar } \underbrace{\sum_{i=1}^n [A(\eta_i) - \eta_i T(y_i)]}_{J(\boldsymbol{\theta})} \quad (2.3.6)$$

 Justifique la convexidad de la función objetivo $J(\boldsymbol{\theta})$ en (2.3.6).

La convexidad de la función objetivo J asegura que la condición de optimalidad $\nabla J(\boldsymbol{\theta}) = \mathbf{0}$ es suficiente y necesaria. De (2.3.4) y por propiedad de la derivada de la función de log-partición A , podemos escribir

$$\sum_{i=1}^n (\mathbb{E}[T(Y) \mid \mathbf{X} = \mathbf{x}_i] - T(y_i)) \mathbf{x}_i = \mathbf{0}.$$

La expresión en el paréntesis es el *residuo* entre el valor observado de $T(y_i)$ y su valor esperado según el modelo. La condición de optimalidad establece que, en el óptimo, el vector de residuos es ortogonal a cada una de las columnas de X : los residuos no están correlacionados (en sentido muestral) con ninguno de los predictores del modelo. En particular, si estamos trabajando con la matriz ampliada $\tilde{X}$, los residuos suman cero.

En general, no existe una solución explícita para el punto óptimo $\hat{\boldsymbol{\theta}}$, y ni siquiera está garantizado que exista: la convexidad asegura que todo punto con $\nabla J(\boldsymbol{\theta}) = \mathbf{0}$ es un mínimo global, pero la existencia depende de la familia y de los datos observados. Cuando existe, se aproxima mediante métodos iterativos; como conocemos el gradiente y la Hessiana de J , el método de Newton resulta una opción natural y da lugar a un algoritmo muy eficiente.

Resolución por descenso por gradiente

Algoritmo de descenso por gradiente para GLM

Dado un *parámetro inicial* $\boldsymbol{\theta}_0 \in \mathbb{R}^p$ y una *tasa de aprendizaje* $\gamma > 0$:

$t \leftarrow 0$.

repetir

Calcular $\boldsymbol{\mu}_t \in \mathbb{R}^n$ tal que $\mu_{t,i} = A'(\eta_{t,i}) = \mathbb{E}[T(Y) \mid \mathbf{x}_i; \boldsymbol{\theta}_t]$.

Actualizar

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t + \gamma X^\top (T(\mathbf{y}) - \boldsymbol{\mu}_t).$$

$t \leftarrow t + 1$

hasta que el criterio de parada se satisfaga.

Por supuesto, también puede emplearse descenso por gradiente estocástico o *mini-batch*. Es la opción habitual cuando n es muy grande.

Resolución por método de Newton: algoritmo IRLS

Recordemos que el método de Newton actualiza los parámetros mediante

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t - \left[\nabla^2 J(\boldsymbol{\theta}_t) \right]^{-1} \nabla J(\boldsymbol{\theta}_t). \quad (2.3.7)$$

Su aplicación al problema (2.3.6) deriva en un algoritmo denominado *IRLS* (*Iterative Reweighted Least Squares*), que se basa en resolver iterativamente problemas de mínimos cuadrados ponderados (WLS, *weighted least squares*). Para obtenerlo, reemplacemos en (2.3.7) las expresiones (??) y (??) obtenidas para el gradiente y la Hessiana de J ; resulta

$$\boldsymbol{\theta}_{t+1} := \boldsymbol{\theta}_t + (X^\top W_t X)^{-1} X^\top [T(\mathbf{y}) - A'(\tilde{\boldsymbol{\eta}}_t)]. \quad (2.3.8)$$

Formulación de IRLS

El paso de Newton (2.3.8) puede leerse como la solución de un problema de mínimos cuadrados ponderados (WLS). En efecto, dados $W_t = \text{diag}(A''(\eta_{t,1}), \dots, A''(\eta_{t,n}))$ y $\mathbf{z}_t \in \mathbb{R}^n$, la solución de

$$\text{minimizar} \quad \frac{1}{2} \|W_t^{1/2}(\mathbf{z}_t - X\boldsymbol{\theta})\|_2^2$$

es $(X^\top W_t X)^{-1} X^\top W_t \mathbf{z}_t$. Se busca entonces una *pseudo-respuesta* $\mathbf{z}_t$ tal que

$$\boldsymbol{\theta}_{t+1} = (X^\top W_t X)^{-1} X^\top W_t \mathbf{z}_t. \quad (2.3.9)$$

Definimos

$$z_{t,i} := \eta_{t,i} + \frac{T(y_i) - \mu_{t,i}}{w_{t,i}}, \quad i = 1, \dots, n,$$

con $\eta_{t,i} = \mathbf{x}_i^\top \boldsymbol{\theta}_t$, $\mu_{t,i} = A'(\eta_{t,i})$ y $w_{t,i} = A''(\eta_{t,i})$. Como W_t cancela el denominador $w_{t,i}$,

$$X^\top W_t \mathbf{z}_t = X^\top W_t X \boldsymbol{\theta}_t + \sum_{i=1}^n (T(y_i) - \mu_{t,i}) \mathbf{x}_i.$$

Multiplicando por $(X^\top W_t X)^{-1}$ resulta

$$(X^\top W_t X)^{-1} X^\top W_t \mathbf{z}_t = \boldsymbol{\theta}_t + (X^\top W_t X)^{-1} X^\top [T(\mathbf{y}) - A'(\tilde{\boldsymbol{\eta}}_t)],$$

que es exactamente (2.3.8). Por lo tanto, (2.3.8) y (2.3.9) son equivalentes.

Así, cada iteración de Newton equivale a resolver un problema de mínimos cuadrados ponderados con pesos W_t y pseudo-respuesta $\mathbf{z}_t$, ambos recalculados en cada paso. Una ventaja de esta interpretación es que permite reutilizar solvers de mínimos cuadrados, que resuelven el problema de forma numéricamente estable (por ejemplo, con QR o Cholesky sobre $W_t^{1/2} X$) sin formar explícitamente $X^\top W_t X$. Repitiendo el procedimiento se aproxima el estimador de máxima verosimilitud, aprovechando la curvatura de J para dar pasos más precisos que un simple descenso por gradiente.

Algoritmo IRLS

Dado un *parámetro inicial* $\theta_0 \in \mathbb{R}^p$:

$t \leftarrow 0$.

repetir

Calcular $\tilde{\eta}_t = X\theta_t$ y $\mu_t \in \mathbb{R}^n$ tal que $\mu_{t,i} = A'(\eta_{t,i}) = \mathbb{E}[T(Y) \mid \mathbf{x}_i; \theta_t]$.

Construir la matriz diagonal de pesos $W_t \in \mathbb{R}^{n \times n}$ tal que $w_{t,i} = A''(\eta_{t,i}) = \text{Var}[T(Y) \mid \mathbf{X} = \mathbf{x}_i; \theta_t]$.

Definir la pseudo-respuesta $\mathbf{z}_t = \tilde{\eta}_t + W_t^{-1}(T(\mathbf{y}) - \mu_t)$.

Actualizar

$$\theta_{t+1} := (X^\top W_t X)^{-1} X^\top W_t \mathbf{z}_t.$$

$t \leftarrow t + 1$.

hasta que el criterio de parada se satisfaga.

Ejemplo 2.3.6: Algoritmo IRLS para regresión logística

En regresión logística, dada la matriz de predictoras $X \in \mathbb{R}^{n \times p}$ y el vector de respuestas $\mathbf{y} \in \mathbb{R}^n$, el algoritmo IRLS se implementa de la siguiente manera. A partir del valor actual θ_t , en la siguiente iteración se calculan:

- El vector $\tilde{\eta}_t = X\theta_t \in \mathbb{R}^n$.
- El vector de medias $\mu_t = \sigma(\tilde{\eta}_t) \in \mathbb{R}^n$ tal que $\mu_{t,i} = \sigma(\theta_t^\top \mathbf{x}_i)$.
- La matriz de pesos $W_t \in \mathbb{R}^{n \times n}$ tal que

$$w_{t,i} = \sigma(\eta_{t,i})(1 - \sigma(\eta_{t,i})), \quad i = 1, \dots, n.$$

- La pseudo-respuesta

$$\mathbf{z}_t = \tilde{\eta}_t + W_t^{-1}(\mathbf{y} - \mu_t) \in \mathbb{R}^n.$$

Finalmente, se actualiza el vector de parámetros θ mediante la expresión (2.3.9).

III | Regresión softmax

Consideremos un problema de clasificación en el que $Y \in \{1, 2, \dots, k\}$. Por ejemplo, en lugar de clasificar correos electrónicos en dos clases (spam o no spam), podríamos clasificarlos en tres clases: spam, correo personal y correo relacionado con el trabajo. Para modelar esta situación, usaremos la *distribución multinomial* con un único ensayo (también llamada *distribución categórica*) como un elemento de la familia exponencial. De esta manera, podremos construir un modelo GLM para clasificación multiclase, conocido como *regresión softmax* o *regresión logística multinomial*, que generaliza la regresión logística binaria a problemas con más de dos clases.

Ejemplo 2.3.7: Distribución categórica

Sea $Y \in \mathbb{R}$ tal que $Y \sim \text{Multinomial}(1, \phi)$, con $\phi \in \mathbb{R}^k$ tal que $\sum_{i=1}^k \phi_i = 1$. Entonces

$$p(y | \phi) = \phi_1^{\mathbf{1}\{y=1\}} \phi_2^{\mathbf{1}\{y=2\}} \dots \phi_k^{\mathbf{1}\{y=k\}},$$

donde $\mathbf{1}\{\cdot\}$ es la función indicatriz, que vale 1 si su argumento es cierto y 0 en caso contrario.

Definimos el estadístico suficiente $T(y) \in \mathbb{R}^{k-1}$ mediante

$$(T(y))_i = \begin{cases} 1 & \text{si } y = i, \\ 0 & \text{si } y \neq i. \end{cases}$$

Podemos escribir

$$\begin{aligned} p(y | \phi) &= \phi_1^{(T(y))_1} \phi_2^{(T(y))_2} \dots \phi_{k-1}^{(T(y))_{k-1}} \phi_k^{1 - \sum_{i=1}^{k-1} (T(y))_i} \\ &= \exp \left\{ \left(\log \left(\frac{\phi_1}{\phi_k} \right), \log \left(\frac{\phi_2}{\phi_k} \right), \dots, \log \left(\frac{\phi_{k-1}}{\phi_k} \right) \right)^\top T(y) + \log \phi_k \right\}. \end{aligned}$$

Por lo tanto, el parámetro natural es

$$\boldsymbol{\eta} = \left(\log \left(\frac{\phi_1}{\phi_k} \right), \log \left(\frac{\phi_2}{\phi_k} \right), \dots, \log \left(\frac{\phi_{k-1}}{\phi_k} \right) \right)^\top \in \mathbb{R}^{k-1}. \quad (2.3.10)$$

El resto de los elementos son:

$$h(y) = 1, \quad A(\boldsymbol{\eta}) = -\log \phi_k = \log \left(1 + \sum_{i=1}^{k-1} e^{\eta_i} \right),$$

donde para hallar $A(\boldsymbol{\eta})$ se usó que $\phi_i = \phi_k e^{\eta_i}$ y $\sum_{i=1}^k \phi_i = 1$; en efecto,

$$\phi_k \left(1 + \sum_{i=1}^{k-1} e^{\eta_i} \right) = 1 \quad \text{tal que} \quad \frac{1}{\phi_k} = 1 + \sum_{i=1}^{k-1} e^{\eta_i}. \quad (2.3.11)$$

Para este modelo GLM, se tiene

$$\nabla A(\boldsymbol{\eta}) = \mathbb{E}[T(Y) | \mathbf{x}; \phi] = (\phi_1, \phi_2, \dots, \phi_{k-1})^\top.$$

De hecho,

$$\frac{\partial A}{\partial \eta_j} = \frac{e^{\eta_j}}{1 + \sum_{i=1}^{k-1} e^{\eta_i}} = \phi_j. \quad (2.3.12)$$

La expresión (2.3.10) es la función de enlace, conocida como *logit generalizado*. Su inversa es la *función softmax*, $\text{softmax} : \mathbb{R}^{k-1} \rightarrow \mathbb{R}^{k-1}$, definida por

$$\text{softmax}(\mathbf{z})_i = \frac{e^{z_i}}{1 + \sum_{i=1}^{k-1} e^{z_i}},$$

la cual permite obtener ϕ_j a partir de $\boldsymbol{\eta}$ mediante (2.3.12) para $j = 1, \dots, k-1$. El elemento restante ϕ_k se obtiene de despejarlo en (2.3.11). Observar que, si $k = 2$, la función softmax es la función logística vista en la Sección 2.