Métodos de regularización

Una estrategia clásica para simplificar modelos y mejorar su interpretabilidad es la selección de variables, que consiste en identificar un subconjunto de predictores relevantes y descartar el resto. A pesar de que este enfoque puede conducir a modelos más simples, el hecho de ser un procedimiento discreto (en el que una determinada variable o bien es retenida o bien es eliminada) suele traducirse en alta varianza, ya que una pequeña perturbación en los datos podría conducir a un modelo totalmente diferente.

Por tal motivo, una alternativa más estable y continua son los *métodos de regularización*, que ajustan los parámetros del modelo mediante penalizaciones. Estos métodos resultan particularmente útiles en presencia de predictores correlacionados (multicolinealidad), donde los estimadores de mínimos cuadrados pueden volverse muy inestables, así como en escenarios donde el número de predictores supera al número de observaciones ($p > n$), caso en el que la solución de mínimos cuadrados ni siquiera está definida. En ambas situaciones, la regularización permite obtener una solución única y estable.

Además, los métodos de regularización contribuyen a reducir la complejidad del modelo final, mejorar la precisión de las predicciones y controlar el sobreajuste. A diferencia de la selección de variables, estos métodos no descartan predictores de manera abrupta, sino que introducen una penalización continua que tiende a reducir (o incluso anular) la influencia de las variables menos relevantes.

En las secciones previas hemos visto que, en general, para un problema de aprendizaje supervisado con datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, donde se pretende modelar una función $f(\mathbf{x}; \boldsymbol{\theta})$ que dependa del parámetro $\boldsymbol{\theta}$, el desempeño del modelo se evalúa mediante una función de pérdida de la forma

$$J(\boldsymbol{\theta}) = \sum_{i=1}^{n} \text{loss}\left(y_i, f(\mathbf{x}_i; \boldsymbol{\theta})\right),$$

donde $\text{loss} : \mathbb{R} \times \mathbb{R} \to \mathbb{R}_0^+$ mide el error entre las predicciones y las observaciones reales. Por ejemplo, en regresión suele utilizarse la suma de errores al cuadrado (RSS) o el error cuadrático medio (MSE).

La idea general de los métodos de regularización es modificar la función objetivo, incorporando un término de penalización que depende de los parámetros del modelo. Esto deriva en el problema

$$\text{minimizar} \quad J(\boldsymbol{\theta}) + \lambda \cdot \text{Penalización}(\boldsymbol{\theta}), \tag{2.4.1}$$

donde $\lambda > 0$ es un *hiperparámetro de complejidad* que controla la intensidad de la regularización (a mayor λ, mayor intensidad), y $\text{Penalización}(\boldsymbol{\theta})$ es una función que restringe la complejidad del

modelo. El problema (2.4.1) puede reescribirse con restricciones como

$$\begin{aligned} &\text{minimizar} && J(\boldsymbol{\theta}) \\ &\text{sujeto a} && \text{Penalización}(\boldsymbol{\theta}) \leq t, \end{aligned} \tag{2.4.2}$$

donde $t > 0$ es un *hiperparámetro de umbral* ligado al valor de λ.

Dependiendo de la forma del término de penalización, se obtienen diferentes métodos de regularización. En este apunte nos centraremos en las dos variantes principales, *Ridge regression* y *Lasso*, aplicadas al problema de regresión lineal, analizando su formulación matemática y sus características principales. Ambos métodos serán estudiados tanto en su formulación penalizada (2.4.1) como en su versión restringida (2.4.2). Además, para un conjunto de datos de entrenamiento $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, la función de pérdida está determinada por

$$J(\boldsymbol{\theta}) := \frac{1}{2}\text{MSE} = \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 = \frac{1}{2n}\sum_{i=1}^n (y_i - \boldsymbol{\theta}^\top \mathbf{x}_i)^2.$$

> **Notación**
>
> Denotaremos $\hat{\boldsymbol{\theta}}^{\text{OLS}}$ al estimador de *mínimos cuadrados ordinarios* (OLS), solución del problema de regresión lineal sin regularización:
>
> $$\text{minimizar} \quad \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2.$$

I | Regresión Ridge

Definición 2.4.1 (Problema Ridge)**.** El *problema de regresión Ridge* es

$$\text{minimizar} \quad \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 + \lambda\|\boldsymbol{\theta}\|_2^2, \tag{2.4.3}$$

con $\boldsymbol{\theta} \in \mathbb{R}^p$ las variables de optimización y $\lambda > 0$ el hiperparámetro. El punto óptimo, denotado por $\hat{\boldsymbol{\theta}}^{\text{ridge}}$, es el *estimador Ridge* de los coeficientes de la regresión.

Importante

Vamos a ver que la expresión alternativa de (2.4.3) como problema de optimización con restricciones, a saber

$$\begin{aligned} &\text{minimizar} && \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 \\ &\text{sujeto a} && \|\boldsymbol{\theta}\|_2^2 \leq t, \end{aligned} \tag{2.4.4}$$

impone un valor de t adecuado para que efectivamente sea $\lambda > 0$. En primer lugar, la equivalencia entre (2.4.3) y (2.4.4) se deriva directamente del hecho que (2.4.4) es un problema de optimización convexa que verifica la condición de Slater. En efecto, por dualidad fuerte, las

condiciones KKT son suficientes y necesarias para la optimalidad (ver Sección 4 del Capítulo 1). En consecuencia, el punto óptimo $\hat{\boldsymbol{\theta}}$ de (2.4.4) debe ser un minimizador de

$$\mathcal{L}(\boldsymbol{\theta}, \lambda^\star) = \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 + \lambda^\star(\|\boldsymbol{\theta}\|_2^2 - t),$$

donde $\mathcal{L}$ es el Lagrangiano y $\lambda^\star$ es un punto óptimo del problema dual de Lagrange. Observar que esta última expresión coincide, salvo una constante aditiva, con la función objetivo de (2.4.3), tomando $\lambda = \lambda^\star$. Es decir, que (2.4.3) y (2.4.4) son equivalentes o, lo que es lo mismo, que $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}^{\text{ridge}}$.

No obstante, en la formulación penalizada (2.4.3) el parámetro $\lambda > 0$ es fijado arbitrariamente. Así, para que ambos problemas sean efectivamente equivalentes, el valor de t en (2.4.4) debe ser adecuado de modo que se satisfaga $\lambda^\star = \lambda$. Esto deriva en la siguiente pregunta:

¿Qué valor t corresponde a un $\lambda > 0$?

La respuesta radica en la condición KKT de holgura complementaria asociada a la formulación con restricciones (2.4.4): si $\lambda = \lambda^\star$, entonces debe cumplirse

$$\lambda(\|\hat{\boldsymbol{\theta}}^{\text{ridge}}\|_2^2 - t) = 0.$$

En consecuencia:

Si $\lambda > 0$, entonces $t = \|\hat{\boldsymbol{\theta}}^{\text{ridge}}\|_2^2$.

Debe quedar claro que la solución del problema (2.4.4) para un valor arbitrario de t no necesariamente activa la restricción de desigualdad. En caso de no hacerlo, la holgura complementaria impone $\lambda = 0$ y no hay penalización.

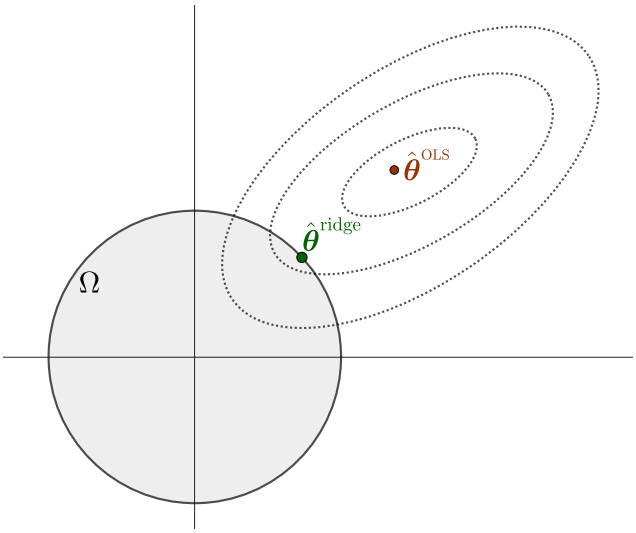


Figura 2.4.1: Interpretación geométrica del problema Ridge, de acuerdo a su formulación con restricciones (2.4.4). Bajo la suposición $\lambda > 0$, el punto óptimo ocurre en la frontera del conjunto factible $\Omega := \{\boldsymbol{\theta} \in \mathbb{R}^p \mid \|\boldsymbol{\theta}\|_2^2 \leq t\}$.

Características del problema Ridge

Desarrollemos la función objetivo del problema Ridge (2.4.3):

$$J(\boldsymbol{\theta}) = \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 + \lambda\|\boldsymbol{\theta}\|_2^2 = \frac{1}{2n}\boldsymbol{\theta}^\top X^\top X\boldsymbol{\theta} + \lambda\boldsymbol{\theta}^\top\boldsymbol{\theta} - \frac{1}{n}\boldsymbol{\theta}^\top X^\top\mathbf{y} + \frac{1}{2n}\mathbf{y}^\top\mathbf{y}.$$

Se tiene que

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{n}X^\top X\boldsymbol{\theta} + 2\lambda\boldsymbol{\theta} - \frac{1}{n}X^\top\mathbf{y} = \left(\frac{1}{n}X^\top X + 2\lambda I\right)\boldsymbol{\theta} - \frac{1}{n}X^\top\mathbf{y}, \tag{2.4.5}$$

$$\nabla^2 J(\boldsymbol{\theta}) = \frac{1}{n}X^\top X + 2\lambda I \succ 0.$$

> Verifique que $\frac{1}{n}X^\top X + 2\lambda I$ es simétrica definida positiva.

La función objetivo J es estrictamente convexa. Por lo tanto, de haber solución, es única. Además, la existencia de la solución es cierta, en virtud del hecho de que el conjunto factible en (2.4.4) es cerrado y acotado. Estamos en condiciones de hacer la siguiente afirmación:

El problema Ridge tiene solución única.

Importante

La existencia también puede justificarse directamente a partir de la formulación sin restricciones (2.4.3). La función objetivo J crece indefinidamente en cualquier dirección a partir de cualquier punto $\boldsymbol{\theta}$; esto es,

$$\lim_{t\to\infty} J(\boldsymbol{\theta} + t\mathbf{d}) = \infty \qquad \forall\boldsymbol{\theta} \in \mathbb{R}^p,\ \forall\mathbf{d} \in \mathbb{R}^p,\ \mathbf{d} \neq \mathbf{0}.$$

En efecto,

$$\lim_{t\to\infty} J(\boldsymbol{\theta} + t\mathbf{d}) \geq \lim_{t\to\infty} \lambda\|\boldsymbol{\theta} + t\mathbf{d}\|_2^2 = \lambda \lim_{t\to\infty} \left(t^2\|\mathbf{d}\|_2^2 + 2t\,\boldsymbol{\theta}^\top\mathbf{d} + \|\boldsymbol{\theta}\|_2^2\right) = \infty.$$

Este comportamiento de J permite afirmar que no tiene direcciones de decrecimiento, también llamadas *direcciones de recesión*. Resultados teóricos (ver, por ejemplo, Teorema 27.1 de (Rockafellar 1970)) aseguran que, en tales condiciones, un problema de optimización tiene al menos una solución.

Solución del problema Ridge

Para caracterizar la solución del problema Ridge, utilizaremos la condición de optimalidad $\nabla J(\hat{\boldsymbol{\theta}}^{\text{ridge}}) = \mathbf{0}$. De (2.4.5) resulta

$$\left(\frac{1}{n}X^\top X + 2\lambda I\right)\hat{\boldsymbol{\theta}}^{\text{ridge}} - \frac{1}{n}X^\top\mathbf{y} = \mathbf{0}.$$

Dado que $\frac{1}{n}X^\top X + 2\lambda I \succ 0$, es invertible. En consecuencia:

La fórmula cerrada para el estimador Ridge es

$$\hat{\boldsymbol{\theta}}^{\text{ridge}} = \frac{1}{n}\left(\frac{1}{n}X^\top X + 2\lambda I\right)^{-1} X^\top \mathbf{y}.$$

Por supuesto, en problemas donde la aplicación directa de esta fórmula resulta costosa, es más adecuado emplear métodos de optimización para aproximar la solución de manera eficiente.

Ejemplo 2.4.2: Regresión Ridge en datos de diabetes

Utilizaremos el conjunto de datos *Diabetes* disponible aquí, el cual consiste en 442 observaciones de 10 variables predictoras. La variable respuesta es una medida cuantitativa de la progresión de la diabetes, por lo que se trata de un problema de regresión. Veremos el efecto que causa el valor del parámetro λ en el valor de los coeficientes estimados para el modelo. Además, elegiremos λ por validación cruzada y presentaremos los coeficientes resultantes del modelo ajustado.

> En este ejemplo utilizamos la implementación `Ridge` de `scikit-learn`, la cual emplea por defecto un solver que selecciona automáticamente el algoritmo de optimización más adecuado para el problema. Entre los algoritmos disponibles se encuentran métodos directos e iterativos, como la factorización de Cholesky y LSQR.

```python
import numpy as np
from sklearn.datasets import load_diabetes
from sklearn.linear_model import Ridge, RidgeCV
from sklearn.model_selection import cross_val_score
from sklearn.preprocessing import StandardScaler

# Datos:
X, y = load_diabetes(return_X_y=True)
scaler = StandardScaler()
X = scaler.fit_transform(X)

# Parámetro lambda:
lambdas = np.logspace(-3, 7, 200)

# Entrenamiento de Ridge:
coefs = []
for a in lambdas:
    ridge = Ridge(alpha=a, fit_intercept=True)
    ridge.fit(X, y)
    coefs.append(ridge.coef_)

coefs = np.array(coefs)

```

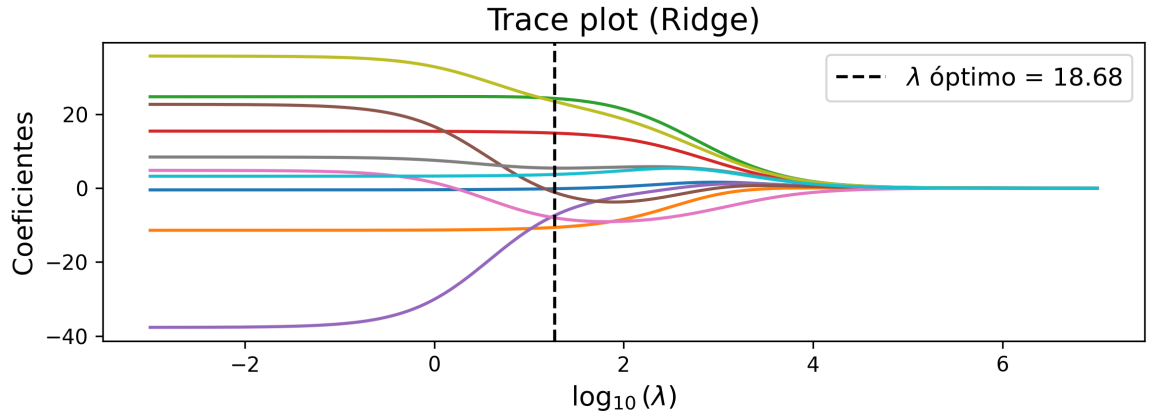
```python
# MSE:
mse_means = []
for a in lambdas:
    ridge = Ridge(alpha=a)
    mse_scores = -cross_val_score(ridge, X, y,
                                  scoring="neg_mean_squared_error",
                                  cv=10)
    mse_means.append(mse_scores.mean())

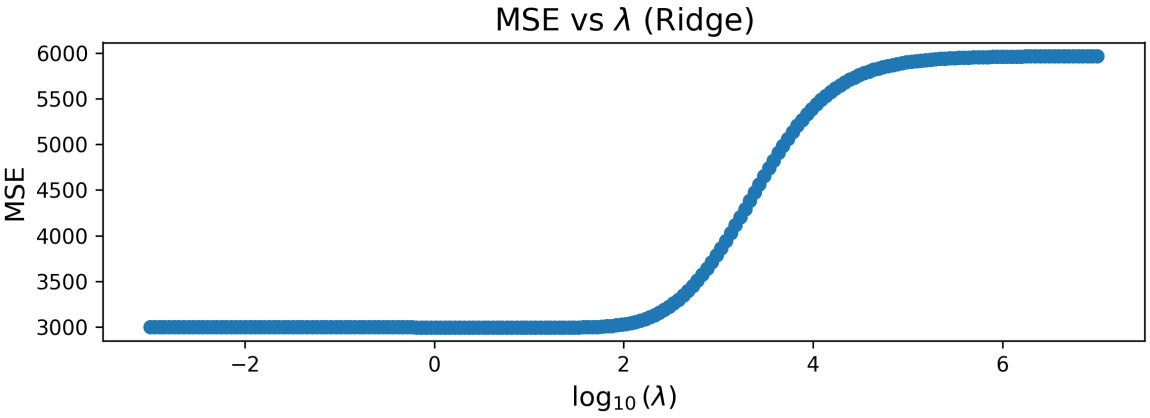
# Mejor lambda por CV:
Ridge_cv = RidgeCV(alphas=lambdas, cv=10, scoring="neg_mean_squared_error")
Ridge_cv.fit(X, y)
best_lambda = Ridge_cv.alpha_

idx_best = np.where(lambdas == best_lambda)[0][0]
mse_best = mse_means[idx_best]
```

```
>_
```

Coeficientes de Ridge con lambda óptimo (MSE = 2997.19): θ_1 = -0.16, θ_2 = -10.64, θ_3 = 24.28, θ_4 = 14.89, θ_5 = -7.39, θ_6 = -1.16, θ_7 = -8.03, θ_8 = 5.41, θ_9 = 23.45, θ_{10} = 3.70.





II | Lasso

Definición 2.4.3 (Problema Lasso)**.** El *problema de regresión Lasso* es

$$\text{minimizar} \quad \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 + \lambda\|\boldsymbol{\theta}\|_1, \tag{2.4.6}$$

con $\boldsymbol{\theta} \in \mathbb{R}^p$ las variables de optimización y $\lambda > 0$ el hiperparámetro. El punto óptimo, denotado por $\hat{\boldsymbol{\theta}}^{\text{lasso}}$, es el *estimador Lasso* de los coeficientes de la regresión.

De manera similar al análisis para el problema Ridge, el problema Lasso admite la siguiente formulación con restricciones:

$$\begin{aligned} \text{minimizar} \quad & \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 \\ \text{sujeto a} \quad & \|\boldsymbol{\theta}\|_1 \leq t. \end{aligned} \tag{2.4.7}$$

Análogamente a Ridge:

Si $\lambda > 0$, entonces $t = \|\hat{\boldsymbol{\theta}}^{\text{lasso}}\|_1$.

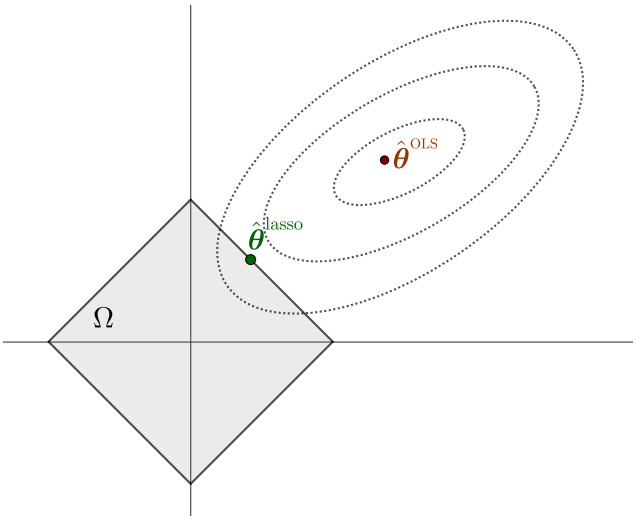


Figura 2.4.2: Interpretación geométrica del problema Lasso, de acuerdo a su formulación con restricciones (2.4.7). Bajo la suposición $\lambda > 0$, el punto óptimo ocurre en la frontera del conjunto factible $\Omega := \{\boldsymbol{\theta} \in \mathbb{R}^p \mid \|\boldsymbol{\theta}\|_1 \leq t\}$.

Características del problema Lasso

Una de las principales diferencias entre el problema Lasso y el problema Ridge es que:

El problema Lasso o bien tiene solución única o bien tiene infinitas soluciones.

Justifique la existencia de solución del problema Lasso.

Las dos posibilidades mencionadas se derivan de la matriz Hessiana de la función objetivo de la formulación con restricciones (2.4.7):

$$\nabla^2 J(\boldsymbol{\theta}) = \frac{1}{n} X^\top X.$$

- Si rango $X = p$, entonces $\frac{1}{n} X^\top X \succ 0$ (¿por qué?). Luego, la función objetivo es estrictamente convexa y concluimos que el problema tiene solución única.
- Si rango $X < p$, la solución puede no ser única. En caso de no ser única, habrá infinitas soluciones. Para justificar esto último, supongamos $\hat{\boldsymbol{\theta}}^{\text{lasso},1}$ y $\hat{\boldsymbol{\theta}}^{\text{lasso},2}$ diferentes estimadores Lasso; entonces

  $$t\hat{\boldsymbol{\theta}}^{\text{lasso},1} + (1-t)\hat{\boldsymbol{\theta}}^{\text{lasso},2}, \qquad t \in (0,1),$$

  también es una solución, por convexidad del conjunto solución de un problema de optimización convexa.

Otras características importantes del problema Lasso se enuncian en el siguiente lema.

Lema 2.4.4. *Sean $X \in \mathbb{R}^{n\times p}$, $\mathbf{y} \in \mathbb{R}^n$ y $\lambda > 0$. El valor fiteado $X\hat{\boldsymbol{\theta}}^{lasso}$ y la norma $\|\hat{\boldsymbol{\theta}}^{lasso}\|_1$ son independientes de la elección del estimador Lasso.*

Demostración. (i) Sean $\hat{\boldsymbol{\theta}}^{\text{lasso},1}$ y $\hat{\boldsymbol{\theta}}^{\text{lasso},2}$ soluciones del problema Lasso tales que $X\hat{\boldsymbol{\theta}}^{\text{lasso},1} \neq X\hat{\boldsymbol{\theta}}^{\text{lasso},2}$. Para $0 < t < 1$, denotemos

$$\hat{\boldsymbol{\theta}}^{\text{lasso},t} := t\hat{\boldsymbol{\theta}}^{\text{lasso},1} + (1-t)\hat{\boldsymbol{\theta}}^{\text{lasso},2}.$$

La convexidad estricta de $h(\mathbf{x}) = \|\mathbf{y} - \mathbf{x}\|_2^2$ y la suposición $X\hat{\boldsymbol{\theta}}^{\text{lasso},1} \neq X\hat{\boldsymbol{\theta}}^{\text{lasso},2}$ permiten escribir

$$\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},t}\|_2^2 < t\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},1}\|_2^2 + (1-t)\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},2}\|_2^2.$$

Además, la norma 1 es convexa, tal que

$$\|\hat{\boldsymbol{\theta}}^{\text{lasso},t}\|_1 \leq t\|\hat{\boldsymbol{\theta}}^{\text{lasso},1}\|_1 + (1-t)\|\hat{\boldsymbol{\theta}}^{\text{lasso},2}\|_1.$$

Combinando las desigualdades anteriores, se deduce

$$\frac{1}{2n}\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},t}\|_2^2 + \lambda\|\hat{\boldsymbol{\theta}}^{\text{lasso},t}\|_1 < tJ(\hat{\boldsymbol{\theta}}^{\text{lasso},1}) + (1-t)J(\hat{\boldsymbol{\theta}}^{\text{lasso},2}) = p^\star,$$

donde $p^\star$ es el valor óptimo del problema Lasso. El resultado contradice el hecho de que $p^\star$ es el valor óptimo y, en consecuencia, debe ser

$$X\hat{\boldsymbol{\theta}}^{\text{lasso},1} = X\hat{\boldsymbol{\theta}}^{\text{lasso},2}.$$

(ii) De la prueba anterior, está claro que

$$\frac{1}{2n}\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},1}\|_2^2 = \frac{1}{2n}\|\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso},2}\|_2^2.$$

Pero ambos minimizan la función objetivo en (2.4.6). Como $\lambda > 0$, debe ser

$$\|\hat{\boldsymbol{\theta}}^{\text{lasso},1}\|_1 = \|\hat{\boldsymbol{\theta}}^{\text{lasso},2}\|_1.$$

■

Solución del problema Lasso

A diferencia del problema Ridge, la función objetivo del problema Lasso no es una función diferenciable, debido a la presencia del término

$$\|\boldsymbol{\theta}\|_1 := |\theta_1| + \ldots + |\theta_p|.$$

Por tal motivo, para el análisis de las condiciones KKT es necesario primero hacer un breve repaso del concepto de subdiferencial. Luego, las condiciones KKT también pueden ser formuladas en términos de subdiferenciales, con el propósito de caracterizar la solución del problema Lasso.

Importante

El *subdiferencial* de una función convexa $f : \mathbb{R}^p \to \mathbb{R}$ en un punto $\mathbf{x}_0 \in \operatorname{dom} f$ es el conjunto

$$\partial f(\mathbf{x}_0) := \{\boldsymbol{\gamma} \in \mathbb{R}^p \mid f(\mathbf{x}) \geq f(\mathbf{x}_0) + \boldsymbol{\gamma}^\top (\mathbf{x} - \mathbf{x}_0) \quad \forall \mathbf{x} \in \operatorname{dom} f\}.$$

Un par de características importantes son:

- El subdiferencial $\partial f(\mathbf{x}_0)$ es siempre un conjunto convexo no vacío.
- Si f es diferenciable en $\mathbf{x}_0$, entonces $\partial f(\mathbf{x}_0) = \{\nabla f(\mathbf{x}_0)\}$.

La condición de optimalidad para problemas de optimización *sin restricciones* puede expresarse en términos del subdiferencial, tal como establece el siguiente resultado. La prueba es sencilla y se deriva de la definición de subdiferencial.

Teorema 2.4.5 (Condición suficiente y necesaria de optimalidad de primer orden para problemas convexos sin restricciones mediante subdiferenciales)**.** *Sea $f : \mathbb{R}^p \to \mathbb{R}$ una función convexa. Entonces $\mathbf{x}^\star \in \operatorname{dom} f$ es un minimizador de f si y solo si*

$$\mathbf{0} \in \partial f(\mathbf{x}^\star).$$

Ejemplo 2.4.6: Subdiferencial de la norma 1

Como ya sabemos, la norma 1 es la función $\|\cdot\|_1 : \mathbb{R}^p \to \mathbb{R}$ definida por

$$\|\mathbf{x}\|_1 := \sum_{i=1}^{p} |x_i|.$$

Esta función es diferenciable en todos los puntos $\mathbf{x}$ tales que $x_i \neq 0$ para todo $i = 1, \ldots, p$. En

tales puntos su subdiferencial está determinado por el vector gradiente; esto es,

$$\nabla\|\mathbf{x}\|_1 = (\text{sign}(x_1), \ldots, \text{sign}(x_p)) \qquad \forall \mathbf{x} \neq \mathbf{0}.$$

Sin embargo, si la i-ésima coordenada es 0, el subdiferencial tomará en esa componente el valor $[-1, 1]$. Por lo tanto, $\partial\|\mathbf{x}\|_1$ está formado por todos los vectores $\boldsymbol{\gamma}$ que verifican

$$\gamma_i = \begin{cases} \text{sign}(x_i) & \text{si } x_i \neq 0, \\ [-1, 1] & \text{si } x_i = 0. \end{cases}$$

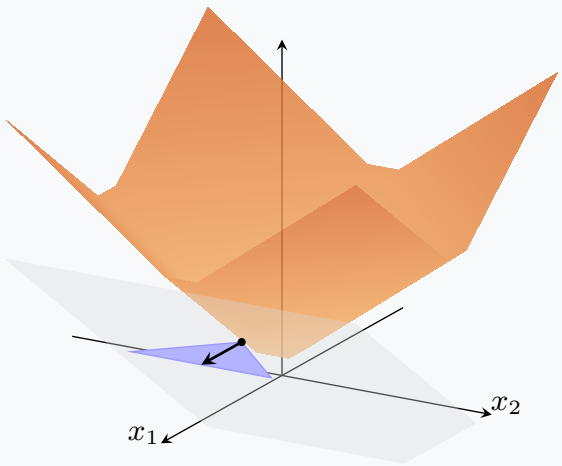


Figura 2.4.3: Subdiferencial de la norma 1 para $p = 2$ en el punto $(1, 0)$.

La condición de optimalidad para el problema Lasso es

$$\mathbf{0} \in \frac{1}{n} X^\top (X\hat{\boldsymbol{\theta}}^{\text{lasso}} - \mathbf{y}) + \lambda\, \partial\|\hat{\boldsymbol{\theta}}^{\text{lasso}}\|_1.$$

De manera equivalente, podemos afirmar que existe $\boldsymbol{\gamma} \in \partial\|\hat{\boldsymbol{\theta}}^{\text{lasso}}\|_1$ tal que

$$\begin{aligned} \frac{1}{n} X^\top (X\hat{\boldsymbol{\theta}}^{\text{lasso}} - \mathbf{y}) + \lambda\boldsymbol{\gamma} &= \mathbf{0}, \\ \frac{1}{n} X^\top (\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso}}) &= \lambda\boldsymbol{\gamma}. \end{aligned} \tag{2.4.8}$$

Del ejemplo anterior, el vector $\boldsymbol{\gamma}$ debe verificar lo siguiente:

$$\begin{aligned} \gamma_i = \text{sign}(\hat{\theta}_i^{\text{lasso}}) \quad & \text{si } \hat{\theta}_i^{\text{lasso}} \neq 0, \\ \gamma_i \in [-1, 1] \quad & \text{si } \hat{\theta}_i^{\text{lasso}} = 0. \end{aligned} \tag{2.4.9}$$

En la expresión (2.4.8), la componente i-ésima del vector del lado izquierdo mide la relación entre cada variable predictora X_i y el residuo $\mathbf{r} := \mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso}}$. En efecto, cuando X_i e $\mathbf{y}$ están estandarizados, esta cantidad es proporcional a la correlación de Pearson:

$$\text{cor}(X_i, \mathbf{r}) := \frac{\text{Cov}(X_i, \mathbf{r})}{\sqrt{\text{Var}(\mathbf{r})}} = \frac{\frac{1}{n} X_i^\top \mathbf{r}}{\sqrt{\frac{1}{n}\|\mathbf{r}\|_2^2}} \propto X_i^\top \mathbf{r}.$$

Ahora bien, de (2.4.8) y (2.4.9) podemos afirmar que:

$$\left|X_i^\top(\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso}})\right| \leq n\lambda \qquad \forall i = 1, \ldots, p.$$

Además, una condición suficiente para la igualdad es $\hat{\theta}_i^{\text{lasso}} \neq 0$.

Así, las variables que son incluidas en el modelo tienen correlación absoluta máxima con el residuo. Esto muestra que el valor de λ determina la exigencia del modelo para incluir una variable: valores grandes de λ indican que únicamente variables con correlación fuerte con el residuo son consideradas para el modelo, mientras que valores pequeños de λ relajan el criterio de inclusión de variables. Esta idea motiva la siguiente definición.

Definición 2.4.7 (Conjunto de equicorrelación)**.** Sea $\hat{\boldsymbol{\theta}}^{\text{lasso}}$ una solución del problema Lasso. Se define el *conjunto de equicorrelación* $\mathcal{E}$ como

$$\mathcal{E} := \left\{ i \in \{1, \ldots, p\} \mid \left| X_i^\top \left(\mathbf{y} - X\hat{\boldsymbol{\theta}}^{\text{lasso}} \right) \right| = n\lambda \right\}.$$

Justifique que el conjunto de equicorrelación es el mismo para cualquier solución del problema Lasso.

Vamos a separar el vector $\hat{\boldsymbol{\theta}}^{\text{lasso}}$ en dos subvectores, discriminando de acuerdo a si el índice está o no en $\mathcal{E}$. Para ello, denotamos

$$\hat{\boldsymbol{\theta}}_{\mathcal{E}}^{\text{lasso}} = (\hat{\theta}_i^{\text{lasso}})_{i \in \mathcal{E}}, \qquad \hat{\boldsymbol{\theta}}_{-\mathcal{E}}^{\text{lasso}} = (\hat{\theta}_i^{\text{lasso}})_{i \notin \mathcal{E}}.$$

Claramente, $\hat{\boldsymbol{\theta}}_{-\mathcal{E}}^{\text{lasso}}$ es un vector nulo. Por su parte, $\hat{\boldsymbol{\theta}}_{\mathcal{E}}^{\text{lasso}}$ puede o no tener componentes nulas, ya que $\mathcal{E}$ puede contener índices de variables que no sean incluidas en el modelo. En efecto, para algún índice i_0 puede ocurrir que $\hat{\theta}_{i_0}^{\text{lasso}} = 0$ y $\gamma_{i_0} = \pm 1$, tal que $i_0 \in \mathcal{E}$. En otras palabras:

El conjunto $\mathcal{E}$ incluye todos los índices candidatos a tener coeficientes no nulos. A las variables con coeficiente no nulo las llamaremos *variables activas*.

Ahora bien, llegados a este punto, cabe preguntarse:

¿Hay una expresión analítica para $\hat{\boldsymbol{\theta}}^{\text{lasso}}$?

En general, la respuesta es no. Si bien es posible obtener una caracterización analítica de $\hat{\boldsymbol{\theta}}^{\text{lasso}}$, esta depende del conjunto de equicorrelación $\mathcal{E}$ y de un vector de signos asociado (ver Lema 2 de (R. J. Tibshirani 2013)). Salvo en algunos casos particulares, ambos elementos se obtienen a partir de una solución del problema Lasso y, por lo tanto, no se conocen de antemano. En

consecuencia, dicha caracterización no proporciona un método efectivo para obtener el estimador. Por este motivo, en la práctica se recurre a algoritmos iterativos eficientes. Uno de los más populares y efectivos es el *descenso por coordenadas*, que describiremos a continuación.

Resolución por descenso por coordenadas

Si denotamos $Q = \frac{1}{n}X^\top X \in \mathbb{R}^{p\times p}$ y $\mathbf{v} = \frac{1}{n}X^\top \mathbf{y} \in \mathbb{R}^p$, la formulación (2.4.6) del problema Lasso es equivalente a

$$\text{minimizar} \quad \frac{1}{2}\boldsymbol{\theta}^\top Q\boldsymbol{\theta} - \boldsymbol{\theta}^\top \mathbf{v} + \lambda\|\boldsymbol{\theta}\|_1. \tag{2.4.10}$$

> Justifique la expresión (2.4.10).

La función objetivo en (2.4.10) puede escribirse como

$$f(\boldsymbol{\theta}) = \frac{1}{2}\sum_{i=1}^{p}\sum_{j=1}^{p}\theta_i Q_{ij}\theta_j - \sum_{i=1}^{p} v_i\theta_i + \lambda\sum_{i=1}^{p}|\theta_i|. \tag{2.4.11}$$

Nos planteamos lo siguiente:

> ¿Qué obtenemos al minimizar respecto a un solo parámetro θ_k, con los demás fijos?

Sea $k \in \{1,\dots,p\}$. Al dejar fijas todas las variables de optimización excepto θ_k, estamos formulando un problema de optimización univariada, cuya función objetivo es

$$\tilde{f}(\theta_k) = \frac{1}{2}Q_{kk}\theta_k^2 + \theta_k\sum_{\substack{i=1\\ i\neq k}}^{p} Q_{ik}\theta_i - v_k\theta_k + \lambda|\theta_k| + \text{cte}. \tag{2.4.12}$$

> Justifique la expresión (2.4.12).

Por lo tanto, resulta

$$\frac{\tilde{f}(\theta_k)}{Q_{kk}} = \frac{1}{2}\theta_k^2 - \frac{v_k - \sum_{\substack{i=1\\ i\neq k}}^{p} Q_{ik}\theta_i}{Q_{kk}}\theta_k + \frac{\lambda}{Q_{kk}}|\theta_k| + \text{cte}.$$

Finalmente, el problema de optimización univariada resultante es

$$\text{minimizar} \quad \frac{1}{2}\theta_k^2 - s\theta_k + \tau|\theta_k|, \tag{2.4.13}$$

con

$$s = \frac{v_k - \sum_{\substack{i=1\\ i\neq k}}^{p} Q_{ik}\theta_i}{Q_{kk}}, \qquad \tau = \frac{\lambda}{Q_{kk}}.$$

Nótese que cuando $\lambda = 0$, la solución es $\theta_k^\star = s$; es decir, s representa la *solución OLS parcial* para

θ_k con los demás coeficientes fijos. El estudio de (2.4.13) conduce a la *función de soft-thresholding*, que presentamos a continuación.

Función de *soft-thresholding*

Sean $s \in \mathbb{R}$ y $\tau > 0$. Un problema equivalente a (2.4.13) es

$$\text{minimizar} \quad \frac{1}{2}(\theta - s)^2 + \tau|\theta|.$$

La función objetivo f es convexa y su subdiferencial es

$$\partial f(\theta) = \begin{cases} \{\theta - s + \tau \operatorname{sign}\theta\} & \text{si } \theta \neq 0, \\ [-s-\tau, -s+\tau] & \text{si } \theta = 0. \end{cases}$$

Sabemos que $\theta^\star$ es punto óptimo si y solo si $0 \in \partial f(\theta^\star)$. Del análisis de esta condición resulta

$$\theta^\star = \begin{cases} s - \tau & \text{si } s > \tau, \\ 0 & \text{si } |s| \leq \tau, \\ s + \tau & \text{si } s < -\tau. \end{cases} \tag{2.4.14}$$

Demostración. (Caso $\theta^\star > 0$) Dado que $\operatorname{sign}\theta^\star = 1$, la condición resulta en $\theta^\star - s + \tau = 0$; esto es, $\theta^\star = s - \tau$, lo cual es válido siempre que $s - \tau > 0$. (Caso $\theta^\star < 0$) Análogamente al caso anterior, obtenemos $s + \tau < 0$. (Caso $\theta^\star = 0$) Esto ocurre si y solo si $|s| < \tau$. ■

Una expresión alternativa de (2.4.14) es

$$\theta^\star = \operatorname{sign}(s) \cdot \max\{|s| - \tau, 0\}.$$

Definición 2.4.8 (Función *soft-thresholding*)**.** Sea $\tau > 0$. La función *soft-thresholding* $\operatorname{soft}_\tau : \mathbb{R} \to \mathbb{R}$ se define por

$$\operatorname{soft}_\tau(s) := \operatorname{sign}(s) \cdot \max\{|s| - \tau, 0\}.$$

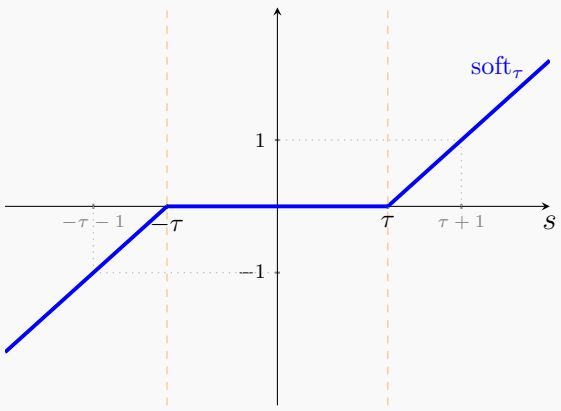


Figura 2.4.4: La función soft_τ desplaza los valores hacia cero en una cantidad τ, anulando aquellos con $|s| \leq \tau$.

Volviendo al problema de interés (2.4.13), recordemos que el propósito era analizar la solución del problema Lasso cuando fijamos todos los parámetros excepto uno. De acuerdo con lo visto, con penalización ($\lambda > 0$), la solución no es simplemente s sino que resulta o bien desplazada hacia cero en una cantidad τ, o bien directamente anulada si $|s| \leq \tau$. En efecto, resulta

$$\theta_k^\star = \mathrm{soft}_\tau\left(\frac{v_k - \sum_{\substack{i=1 \\ i\neq k}}^{p} Q_{ik}\theta_i}{Q_{kk}}\right), \qquad \tau = \frac{\lambda}{Q_{kk}}.$$

Ya estamos en condiciones de definir el algoritmo iterativo de descenso por coordenadas para resolver un problema Lasso.

Algoritmo de descenso por coordenadas

Dado un *parámetro inicial* $\boldsymbol{\theta}^{(0)} \in \mathbb{R}^p$ y un *hiperparámetro de penalización* $\lambda > 0$:

$t \leftarrow 1$.

repetir

  Inicializar $\boldsymbol{\theta}^{(t)} = \boldsymbol{\theta}^{(t-1)}$.

  para $k = 1, \ldots, p$ **:**

    Calcular $s_k = \left(v_k - \sum_{\substack{i=1 \\ i\neq k}}^{p} Q_{ik}\theta_i^{(t)}\right)/Q_{kk}$.

    Actualizar $\theta_k^{(t)} = \mathrm{soft}_\tau(s_k)$ con $\tau = \lambda/Q_{kk}$.

  $t \leftarrow t + 1$.

hasta *que el criterio de parada se satisfaga.*

Observar que, en cada iteración t, el vector $\boldsymbol{\theta}^{(t)}$ se va actualizando coordenada por coordenada, utilizando los valores más recientes dentro de la misma iteración. Otra alternativa es actualizar todas las coordenadas en bloque a partir del mismo vector $\boldsymbol{\theta}^{(t-1)}$, aunque este último enfoque suele presentar una convergencia más lenta en este algoritmo.

Ejemplo 2.4.9: Regresión Lasso en datos de diabetes

Al igual que en el ejemplo anterior para el caso de Ridge, implementaremos Lasso sobre el conjunto de datos de diabetes. Esta vez, podemos esperar que algunos coeficientes se anulen, lo que reflejará la selección de variables realizada por el modelo.

> En este ejemplo utilizamos la implementación `Lasso` de `scikit-learn`, la cual resuelve el problema mediante descenso por coordenadas.

```
# Entrenamiento de Lasso:
coefs = []
for a in lambdas:
    lasso = Lasso(alpha=a, fit_intercept=True, max_iter=5000)
    lasso.fit(X, y)
    coefs.append(lasso.coef_)
```

```

coefs = np.array(coefs)

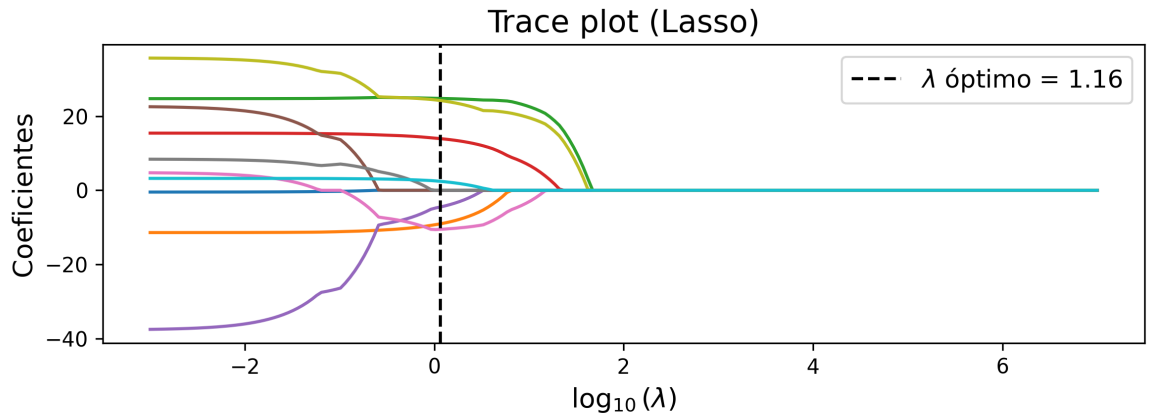
# MSE:
mse_means = []
for a in lambdas:
    lasso = Lasso(alpha=a, max_iter=5000)
    mse_scores = -cross_val_score(lasso, X, y,
                                  scoring="neg_mean_squared_error",
                                  cv=10)
    mse_means.append(mse_scores.mean())

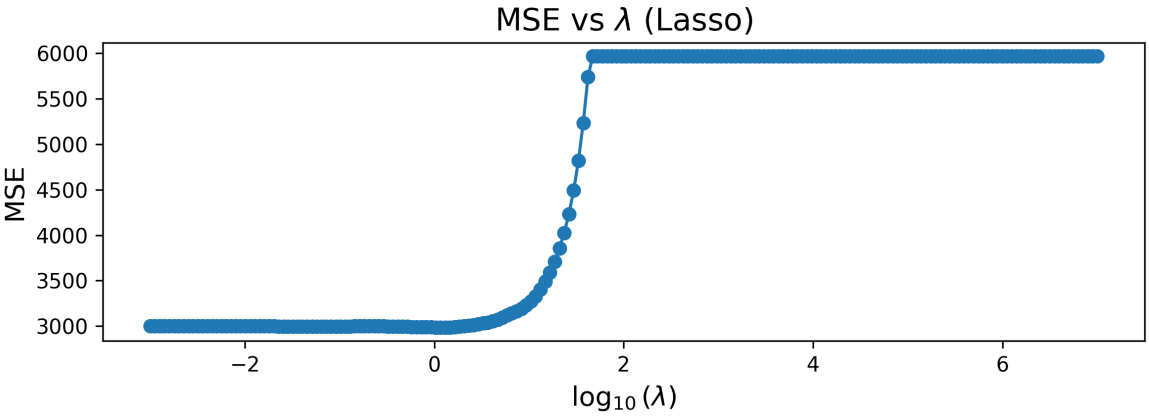
# Mejor lambda por CV:
Lasso_cv = LassoCV(alphas=lambdas, cv=10, max_iter=5000)
Lasso_cv.fit(X, y)
best_lambda = Lasso_cv.alpha_

idx_best = np.where(lambdas == best_lambda)[0][0]
mse_best = mse_means[idx_best]
```

```
>_
```

Coeficientes de Lasso con lambda óptimo (MSE = 2987.20): θ_1 = -0.00, θ_2 = -9.04, θ_3 = 24.80, θ_4 = 13.94, θ_5 = -4.49, θ_6 = -0.00, θ_7 = -10.53, θ_8 = 0.00, θ_9 = 24.21, θ_{10} = 2.42.





III | Elastic Net, convergencia y comparaciones

Hasta este punto hemos estudiado los métodos de regularización Ridge y Lasso. El método *Elastic Net* combina ambas penalizaciones en una única formulación, permitiendo equilibrar ambos enfoques. En esta sección presentaremos su formulación, veremos algunos ejemplos comparativos y discutiremos algunos aspectos relacionados con la convergencia de los algoritmos de optimización.

Definición 2.4.10 (Problema Elastic Net)**.** El *problema de regresión Elastic Net* es

$$\text{minimizar} \quad \frac{1}{2n}\|\mathbf{y} - X\boldsymbol{\theta}\|_2^2 + \lambda_1\|\boldsymbol{\theta}\|_1 + \lambda_2\|\boldsymbol{\theta}\|_2^2, \tag{2.4.15}$$

con $\boldsymbol{\theta} \in \mathbb{R}^p$ las variables de optimización y $\lambda_1, \lambda_2 > 0$ hiperparámetros. El punto óptimo, denotado por $\hat{\boldsymbol{\theta}}^{\text{EN}}$, es el *estimador Elastic Net* de los coeficientes de la regresión.

Resultados de convergencia

Asumiendo que $\boldsymbol{\theta}^\star$ es el vector de coeficientes verdadero que genera los datos, repasaremos cómo se comportan los estimadores penalizados Ridge, Lasso y Elastic Net.

- **Problema Ridge**. Bajo las condiciones $\frac{1}{n}X^\top X \to \Sigma$ y $\lambda = \lambda(n) \to 0$, el estimador Ridge es consistente y sus predicciones tienden a las verdaderas (Hoerl & Kennard 1970). Por otra parte, definiendo

  $$S_\lambda := X(X^\top X + n\lambda I)^{-1}X^\top,$$

  se puede descomponer el *riesgo* de la siguiente forma:

  $$\frac{1}{n}\mathbb{E}\|X(\hat{\boldsymbol{\theta}}^{\text{ridge}} - \boldsymbol{\theta}^\star)\|_2^2 = \frac{1}{n}\|(S_\lambda - I)X\boldsymbol{\theta}^\star\|_2^2 + \frac{\sigma^2}{n}\operatorname{tr}(S_\lambda^2).$$

  Esta descomposición exhibe un balance entre sesgo y varianza. El primer término (sesgo cuadrático) crece con λ, pues una penalización mayor aleja la solución de $\boldsymbol{\theta}^\star$. El segundo término (varianza) decrece con λ, ya que los autovalores de S_λ son de la forma $d_j^2/(d_j^2 + n\lambda)$, que son decrecientes en λ. Este balance garantiza la existencia de un valor óptimo $\lambda^\star > 0$ que minimiza el riesgo.

  En particular, en señales densas y de alta colinealidad, Ridge tiende a predecir mejor que los otros métodos (Hastie, R. Tibshirani & Friedman 2009).

- **Problema Lasso**. Existen resultados de tasas no-asintóticas que proveen cotas para la estimación del error de predicción

  $$\frac{1}{n}\|X(\hat{\boldsymbol{\theta}}^{\text{lasso}} - \boldsymbol{\theta}^\star)\|_2^2$$

  y para $\|\hat{\boldsymbol{\theta}}^{\text{lasso}} - \boldsymbol{\theta}^\star\|_1$ y $\|\hat{\boldsymbol{\theta}}^{\text{lasso}} - \boldsymbol{\theta}^\star\|_2$, bajo condiciones razonables conocidas como *compatibilidad* y *RE* (*restricted eigenvalue*) que controlan el comportamiento de los datos, evitando que haya confusiones entre variables relevantes e irrelevantes (Bühlmann & Geer 2011).

Además, bajo condiciones más estrictas, Lasso puede identificar exactamente qué variables son relevantes, es decir, recuperar el soporte de los coeficientes verdaderos (Zhao & Yu 2006).

- **Elastic Net**. Puede reescribirse como un problema Lasso sobre la matriz aumentada

$$\begin{pmatrix} X \\ \sqrt{n\lambda_2}\, I_p \end{pmatrix},$$

lo cual permite extender los resultados de convergencia de Lasso (Zou & Hastie 2005).

Ejemplos comparativos

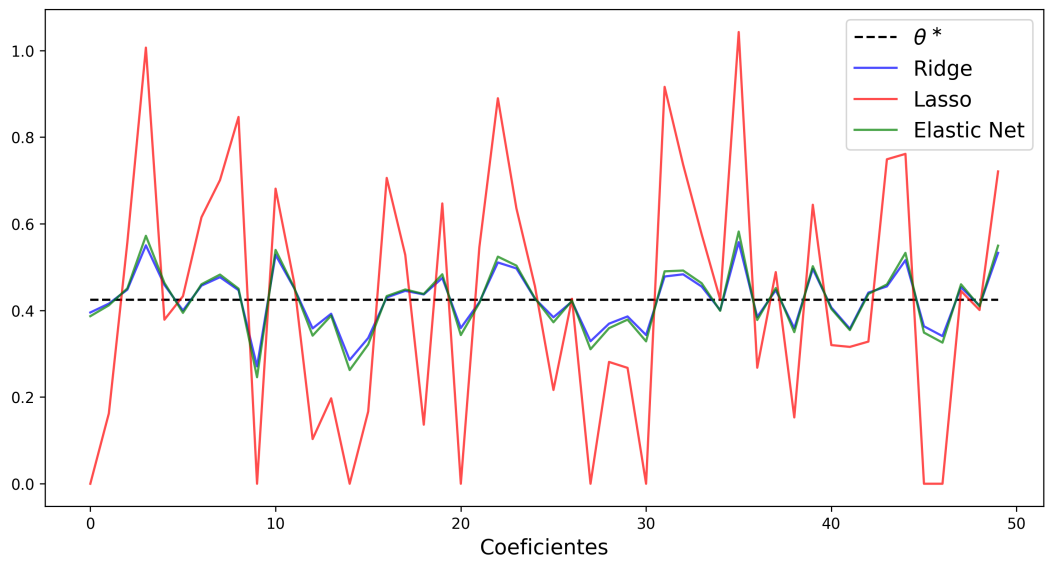
Ejemplo 2.4.11: Señal densa y alta correlación

Simulamos un escenario donde todas las variables predictoras contribuyen al modelo, con vector de coeficientes verdadero $\boldsymbol{\theta}^\star \in \mathbb{R}^p$ dado por

$$\theta_j^\star = \frac{c}{\sqrt{p}} \qquad \forall j = 1, \dots, p, \qquad c \in \mathbb{R}^+.$$

La matriz de datos X tiene correlación alta ($\rho = 0.9$) entre todas sus columnas.

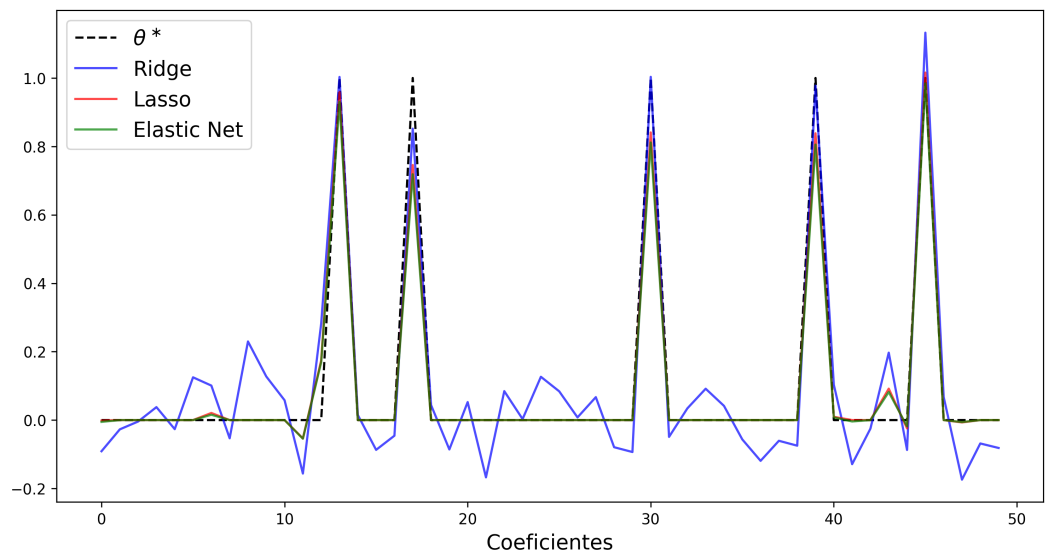
Se espera un mejor rendimiento de Ridge en comparación con Lasso, ya que Ridge reparte la señal entre todas las variables altamente correlacionadas, mientras que Lasso tiende a sobre-encoger muchos coeficientes útiles. Elastic Net seleccionará por validación cruzada un valor de λ_1 pequeño, comportándose de manera similar a Ridge en este escenario.



Ejemplo 2.4.12: Señal esparsa y casi ortogonal

Simulamos un escenario donde solo unas pocas variables predictoras contribuyen al modelo; a las s *variables activas* ($s \ll p$) les asignamos el mismo valor $c \in \mathbb{R}^+$. Además, la matriz de

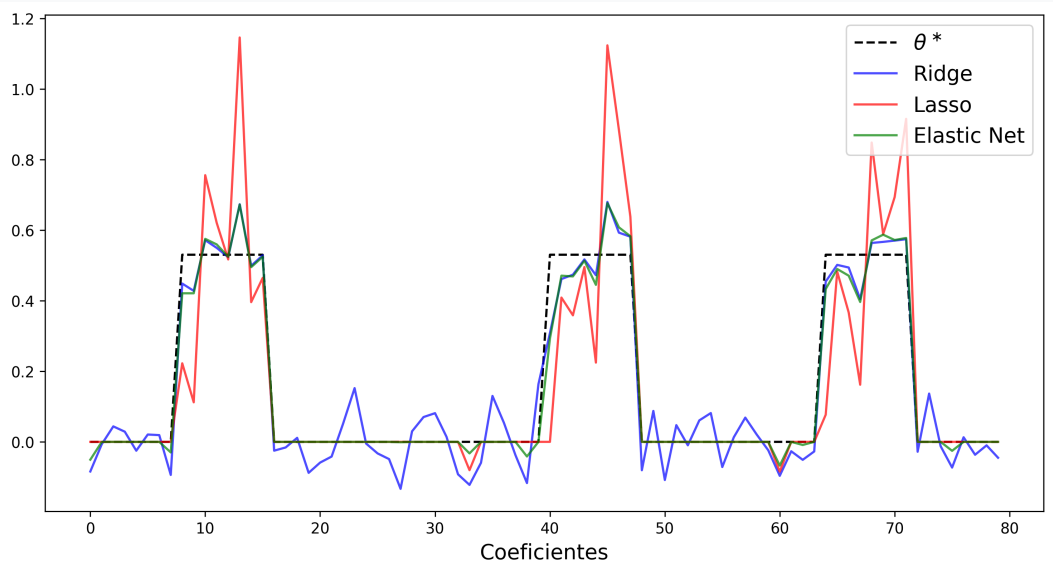
datos X es casi ortogonal ($X^\top X \approx nI_p$).
Se espera un mejor rendimiento de Lasso en comparación con Ridge, ya que Lasso identifica correctamente el soporte de las pocas variables activas y pone a cero los coeficientes irrelevantes. Elastic Net, en este escenario, tenderá a seleccionar un predominio de la penalización ℓ_1, acercándolo al comportamiento de Lasso.



Ejemplo 2.4.13: Esparsidad por grupos

Simularemos un escenario donde las variables predictoras se organizan en grupos, de los cuales solo unos pocos están activos. Además, dentro de cada grupo activo, hay alta correlación ($\rho = 0.9$) y todos los coeficientes son no nulos.

Se espera un mejor rendimiento de Elastic Net en comparación con Lasso y Ridge, ya que Elastic Net selecciona grupos completos de variables altamente correlacionadas, mientras que Lasso tiende a elegir solo un representante por grupo y Ridge no realiza selección de variables.



IV | Sobre GLM penalizados

En la Sección 3 hemos estudiado la aplicación del principio de máxima verosimilitud para el ajuste de parámetros de un modelo lineal generalizado (GLM). En la expresión (2.3.6) habíamos definido el problema de optimización asociado, que puede ser escrito también como

$$\text{minimizar} \quad \frac{1}{n}\sum_{i=1}^{n}\left[A(\boldsymbol{\theta}^\top \mathbf{x}_i) - \boldsymbol{\theta}^\top \mathbf{x}_i\, T(y_i)\right].$$

El vector gradiente de la función objetivo es

$$\nabla J(\boldsymbol{\theta}) = \frac{1}{n} X^\top (\boldsymbol{\mu} - T(\mathbf{y})),$$

donde $\boldsymbol{\mu} \in \mathbb{R}^n$ está determinado por $\mu_i := A'(\boldsymbol{\theta}^\top \mathbf{x}_i) = \mathbb{E}\left[T(Y) \mid \mathbf{X} = \mathbf{x}_i\right]$.

Por supuesto, la inclusión de un término de regularización sobre el vector de parámetros $\boldsymbol{\theta}$ da lugar a las versiones penalizadas de GLM: Ridge, Lasso y Elastic Net. Cada caso conserva una estructura convexa y, en consecuencia, las condiciones KKT son suficientes y necesarias. Como sabemos, para el caso de problemas de optimización sin restricciones, dichas condiciones se reducen a la condición de estacionariedad. Por ejemplo, para Elastic Net resulta

$$\mathbf{0} \in \frac{1}{n} X^\top (\boldsymbol{\mu} - T(\mathbf{y})) + \lambda_1 \partial \|\boldsymbol{\theta}\|_1 + 2\lambda_2 \boldsymbol{\theta}.$$

Los estimadores penalizados Ridge, Lasso y Elastic Net se comportan de manera análoga a los casos lineales: Ridge reduce varianza en señales densas y correlacionadas, Lasso permite recuperación de soporte bajo ciertas condiciones de curvatura, y Elastic Net combina la selección de Lasso con mayor estabilidad frente a colinealidad. Las tasas no-asintóticas y garantías de consistencia se expresan de forma similar, adaptando al contexto de la familia exponencial.

Respecto a los algoritmos iterativos que se utilizan para aproximar $\hat{\boldsymbol{\theta}}$, los más comunes son:

- **IRLS**. Para GLM con penalización Ridge, el algoritmo IRLS se mantiene esencialmente sin modificaciones respecto al caso no penalizado. En cada iteración se resuelve un problema de mínimos cuadrados ponderados (WLS), incorporando la penalización ℓ_2 al cálculo.
- **Descenso por coordenadas**. Para Lasso y Elastic Net, se actualiza cada componente secuencialmente aplicando el operador de *soft-thresholding*. La convergencia global está garantizada por la convexidad de la función objetivo y la actualización cíclica. Este es el enfoque utilizado, por ejemplo, en `sklearn.linear_model`.

Referencias

Bühlmann, P. & Geer, S. van de (2011). *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Springer Series in Statistics. Berlin: Springer.

Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer Series in Statistics. New York: Springer.

Hoerl, A. E. & Kennard, R. W. (1970). «Ridge Regression: Biased Estimation for Nonorthogonal Problems». In: *Technometrics* 12.1, pp. 55–67.

Rockafellar, R. T. (1970). *Convex Analysis*. Princeton Landmarks in Mathematics. Princeton: Princeton University Press.

Rothman, A. J. (2024). *STAT 5701: Lasso-penalized Least Squares*. Course material and lecture notes. University of Minnesota.

Tibshirani, R. J. (2013). «The Lasso Problem and Uniqueness». In: *Electronic Journal of Statistics* 7, pp. 1456–1490.

Zhao, P. & Yu, B. (2006). «On Model Selection Consistency of Lasso». In: *Journal of Machine Learning Research* 7, pp. 2541–2563.

Zou, H. & Hastie, T. (2005). «Regularization and Variable Selection via the Elastic Net». In: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 67.2, pp. 301–320.