FIQ UNL. FACULTAD DE INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez Liliana Forzani

Año 2026

Máquinas de vectores soporte

En esta sección vamos a estudiar un algoritmo de aprendizaje supervisado ampliamente utilizado para problemas de clasificación, que ha demostrado ser especialmente efectivo en tareas donde se requiere obtener fronteras de decisión robustas y con buena capacidad de generalización. Su construcción sigue una secuencia natural de conceptos: en primer lugar, se aborda la formulación básica basada en hiperplanos separadores óptimos, cuyo objetivo es maximizar el margen de separación entre clases perfectamente separables; luego, se incorpora el uso de *variables de holgura* para tratar datos no separables; y, finalmente, se presenta la generalización mediante *núcleos reproductores*, lo que permite obtener fronteras de decisión no lineales.

Una característica distintiva de estos métodos es que su desarrollo se apoya fuertemente en la formulación dual de problemas de optimización y en las condiciones de Karush-Kuhn-Tucker (KKT), lo que permite interpretar la solución en términos de los vectores soporte y comprender el funcionamiento del método.

> **Notación**
>
> Para un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ de un problema de clasificación binaria, denotaremos las etiquetas por $y_i \in \{-1, +1\}$.

I | Hiperplano separador óptimo

El caso más simple de análisis surge de suponer que las clases $\{\mathbf{x}_i \mid y_i = -1\}$ y $\{\mathbf{x}_i \mid y_i = +1\}$ pueden ser separadas totalmente por una frontera lineal.

Definición 2.5.1 (Separabilidad lineal)**.** Un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, con $y_i \in \{-1, +1\}$, se dice que es *linealmente separable* si existen $\boldsymbol{\beta} \in \mathbb{R}^p$ y $\beta_0 \in \mathbb{R}$ tales que

$$y_i = \operatorname{sign}(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \qquad \forall i = 1, \dots, n. \tag{2.5.1}$$

El hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ se denomina *hiperplano separador* y la función $f : \mathbb{R}^p \to \mathbb{R}$ definida por $f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$ se conoce como *función score*.

El vector normal al hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ es $\boldsymbol{\beta}$ y la distancia entre un punto $\mathbf{x} \in \mathbb{R}^p$ y dicho hiperplano es igual a $|f(\mathbf{x})|/\|\boldsymbol{\beta}\|_2$. Esto último es cierto ya que, si $\mathbf{x}_0$ es un punto sobre el

hiperplano, entonces dicha distancia resulta de la proyección de $\mathbf{x} - \mathbf{x}_0$ sobre el vector normal $\boldsymbol{\beta}/\|\boldsymbol{\beta}\|_2$:

$$\left| \frac{\boldsymbol{\beta}^\top}{\|\boldsymbol{\beta}\|} (\mathbf{x} - \mathbf{x}_0) \right| = \frac{\left| \boldsymbol{\beta}^\top \mathbf{x} - \boldsymbol{\beta}^\top \mathbf{x}_0 \right|}{\|\boldsymbol{\beta}\|_2} = \frac{\left| \boldsymbol{\beta}^\top \mathbf{x} + \beta_0 \right|}{\|\boldsymbol{\beta}\|_2} = \frac{|f(\mathbf{x})|}{\|\boldsymbol{\beta}\|_2}.$$

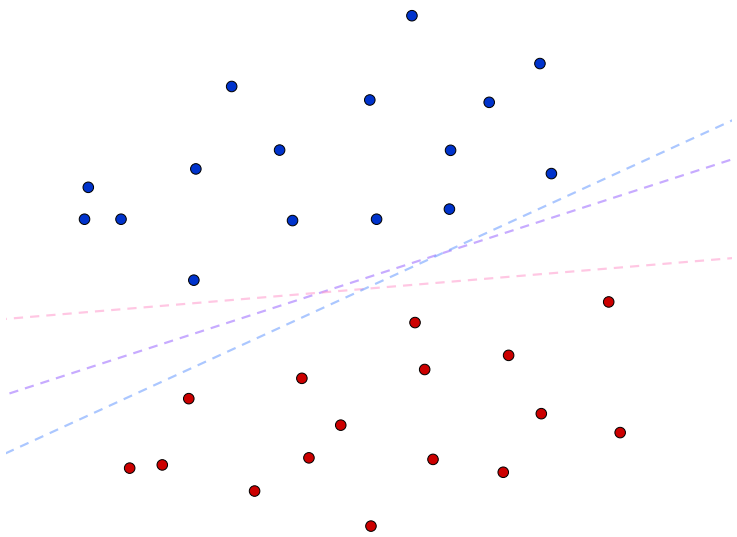


Figura 2.5.1: Datos linealmente separables y algunos hiperplanos separadores.

Observar que la expresión (2.5.1) es equivalente a requerir

$$y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) > 0 \qquad \forall i = 1, \ldots, n. \tag{2.5.2}$$

Algo intuitivo es que si las clases son totalmente separables, existen infinitos hiperplanos separadores. Por lo tanto, resulta necesario definir un criterio que permita seleccionar un hiperplano único y óptimo. En primer lugar, establecemos lo siguiente:

Primer principio

Cada vector $\boldsymbol{\beta} \in \mathbb{R}^p$ puede definir un único hiperplano separador.

Este primer principio justifica considerar a $\boldsymbol{\beta} \in \mathbb{R}^p$ como variable de optimización, ya que establece una correspondencia biunívoca entre cada vector $\boldsymbol{\beta}$ y un hiperplano separador, ¿cuál? Elegimos aquel que *equidista* de ambas clases. Para caracterizar esta propiedad, primero necesitamos imponer una restricción de normalización, ya que la distancia de un punto al hiperplano depende de $\|\boldsymbol{\beta}\|_2$.

Segundo principio

Se restringe la elección de $\boldsymbol{\beta}$ a aquellos vectores que cumplen $\|\boldsymbol{\beta}\|_2 = 1$.

Así, bajo este segundo principio, la distancia entre cualquier punto $\mathbf{x}_i$ y el hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ está dada por

$$|f(\mathbf{x}_i)| = |\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0| = y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0).$$

Con estas consideraciones, ya podemos definir el hiperplano separador asociado a un vector $\boldsymbol{\beta} \in \mathbb{R}^p$. Esta definición determina el valor del intercepto β_0, completando así la caracterización del hiperplano.

Definición 2.5.2 (Hiperplano separador asociado a un vector)**.** A un vector $\boldsymbol{\beta} \in \mathbb{R}^p$ se le asocia el hiperplano separador $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ cuya distancia mínima a ambas clases es la misma. Es decir, existe $M \in \mathbb{R}^+$ tal que

$$y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq M \qquad \forall i = 1, \ldots, n,$$

con igualdad para al menos un punto de cada clase. Al valor M lo denominamos *margen* del hiperplano separador asociado a $\boldsymbol{\beta}$.

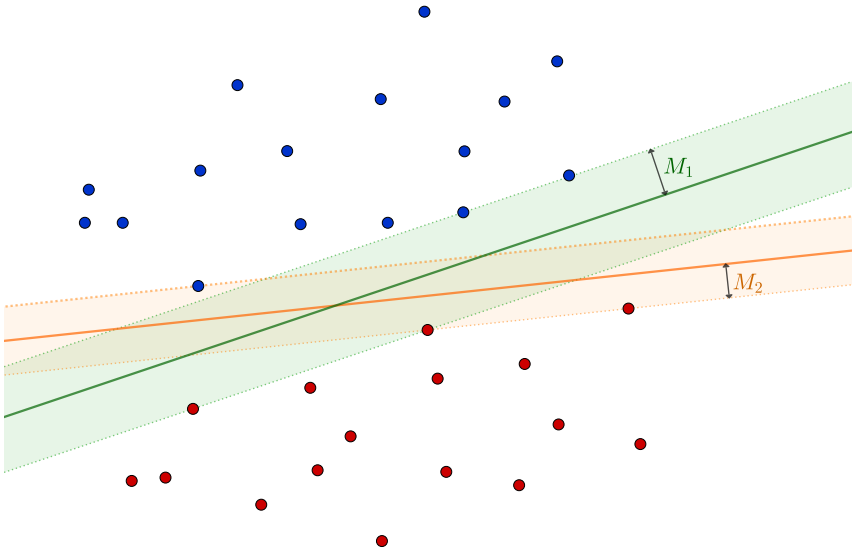


Figura 2.5.2: Hiperplanos separadores y sus margenes asociados.

Es importante observar que los puntos para los cuales se cumple la igualdad en la restricción son los que caracterizan al hiperplano; estos se denominan *vectores soporte* (su definición formal se presentará más adelante). A continuación, definiremos qué consideraremos como hiperplano separador óptimo de un conjunto de datos linealmente separables.

Definición 2.5.3 (Hiperplano separador óptimo)**.** Sea $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, con $y_i \in \{-1, +1\}$, un conjunto de datos linealmente separable. El *hiperplano separador óptimo* es aquel que maximiza el *margen* M, es decir, resuelve el problema

$$\begin{aligned} &\text{maximizar} && M \\ &\text{sujeto a} && y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq M, \qquad i = 1, \ldots, n, \\ &&& \|\boldsymbol{\beta}\|_2 = 1. \end{aligned} \tag{2.5.3}$$

Si bien esta formulación refleja directamente la intención de maximizar el margen, vamos a ajustarla para obtener una formulación clásica más conveniente.

Formulación clásica

En base a lo descripto anteriormente, la restricción $\|\boldsymbol{\beta}\|_2 = 1$ permite interpretar al margen M como la distancia mínima de los puntos al hiperplano. Si se relaja dicha condición, dicha interpretación sigue siendo cierta si se escribe

$$\frac{y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0)}{\|\boldsymbol{\beta}\|_2} \geq M, \qquad i = 1, \dots, n.$$

En consecuencia, el problema (2.5.3) se puede reescribir como

$$\begin{array}{ll} \text{maximizar} & M \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq \|\boldsymbol{\beta}\|_2 M, \qquad i = 1, \dots, n, \end{array} \tag{2.5.4}$$

con una importante diferencia: dado un punto óptimo $\boldsymbol{\beta}^\star$ de (2.5.4), también lo son los puntos $k\boldsymbol{\beta}^\star$, con $k \in \mathbb{R}^+$. Es decir, al eliminar la restricción $\|\boldsymbol{\beta}\|_2 = 1$, la elección del vector normal asociado a un hiperplano vuelve a ser arbitraria. Por tal motivo, elegiremos nuevamente un representante entre todos los múltiplos escalares de un mismo vector normal, aunque esta vez la elección dependerá del valor del margen M.

Entre todos los puntos óptimos del problema (2.5.4) que representan el mismo hiperplano separador, elegimos el único que verifica

$$\|\boldsymbol{\beta}^\star\|_2 = \frac{1}{M^\star},$$

donde $M^\star$ es el margen óptimo.

Esta idea nos va a permitir reformular nuestro problema de optimización. En efecto, bajo estas nuevas condiciones, maximizar M es equivalente a minimizar $\|\boldsymbol{\beta}\|_2$ y, convenientemente, también equivalente a minimizar $\frac{1}{2}\|\boldsymbol{\beta}\|_2^2$. Finalmente obtenemos la versión final del problema de optimización de interés.

Definición 2.5.4 (Problema de optimización del hiperplano separador óptimo)**.** Dado un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ linealmente separables, el hiperplano separador óptimo es

$$(\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star = 0,$$

con $\boldsymbol{\beta}^\star \in \mathbb{R}^p$ y $\beta_0^\star \in \mathbb{R}$ puntos óptimos del problema

$$\begin{array}{ll} \text{minimizar} & \dfrac{1}{2}\|\boldsymbol{\beta}\|_2^2 \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1, \qquad i = 1, \dots, n. \end{array} \tag{2.5.5}$$

Observar que:

El problema (2.5.5) es un problema de optimización convexa cuyo conjunto factible es un poliedro.

En consecuencia, el corolario de condiciones de optimalidad para conjuntos factibles poliedrales (Sección 4 del Capítulo 1) nos asegura que las condiciones de Karush-Kuhn-Tucker (KKT) son suficientes y necesarias para la optimalidad. Más aún, el Teorema de Slater de esa misma sección permite afirmar que hay dualidad fuerte.

Optimalidad

Las condiciones KKT son

$$
\begin{aligned}
y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \geq 0 \quad \forall i = 1, \dots, n && \text{(Factibilidad primal)} \\
\lambda_i^\star \geq 0 \quad \forall i = 1, \dots, n && \text{(Factibilidad dual)} \\
\lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \right] = 0 \quad \forall i = 1, \dots, n && \text{(Holgura complementaria)} \\
\boldsymbol{\beta}^\star = \sum_{i=1}^n \lambda_i^\star y_i \mathbf{x}_i, \quad 0 = \sum_{i=1}^n \lambda_i^\star y_i && \text{(Estacionariedad)}
\end{aligned}
$$



Si bien las condiciones KKT permiten caracterizar completamente la solución óptima, no proporcionan un método directo y eficiente para calcular $\boldsymbol{\lambda}^\star$. Por ello, resulta conveniente formular el problema dual de Lagrange, cuya resolución es computacionalmente más sencilla, esto último debido a que resulta ser un problema de optimización cuadrática.

El Lagrangiano asociado al problema (2.5.5) es $\mathcal{L} : \mathbb{R}^{p+1} \times \mathbb{R}^n \to \mathbb{R}$ definido por

$$
\mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\lambda}) = \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 - \sum_{i=1}^n \lambda_i \left[y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) - 1 \right].
$$

Dado que el Lagrangiano es una función convexa en $(\boldsymbol{\beta}, \beta_0)$, la ecuación $\nabla_{(\boldsymbol{\beta},\beta_0)} \mathcal{L} = \mathbf{0}$ caracteriza el ínfimo de $\mathcal{L}$ para cada $\boldsymbol{\lambda}$. Esto resulta en las expresiones

$$
\boldsymbol{\beta} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i, \qquad \sum_{i=1}^n \lambda_i y_i = 0.
$$

Observar que $\boldsymbol{\beta}$ queda definida en términos de $\boldsymbol{\lambda}$ y, aunque β_0 no queda determinado de forma directa, sí nos provee una restricción de consistencia sobre los multiplicadores. Reemplazando, obtenemos la función dual de Lagrange:

$$
\begin{aligned}
\mathcal{G}(\boldsymbol{\lambda}) :&= \inf_{\boldsymbol{\beta},\beta_0} \mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\lambda}) \\
&= \frac{1}{2}\left\| \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i \right\|_2^2 - \sum_{i=1}^n \lambda_i y_i \left(\sum_{j=1}^n \lambda_j y_j \mathbf{x}_j \right)^\top \mathbf{x}_i - \beta_0 \underbrace{\sum_{i=1}^n \lambda_i y_i}_{=0} + \sum_{i=1}^n \lambda_i \\
&= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i + \sum_{i=1}^n \lambda_i \\
&= \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j.
\end{aligned}
\tag{2.5.6}
$$

Importante

Observar, en el desarrollo de (2.5.6), el término

$$-\beta_0 \sum_{i=1}^{n} \lambda_i y_i.$$

Esto implica que $\mathcal{G}(\boldsymbol{\lambda}) = -\infty$ si $\sum_{i=1}^{n} \lambda_i y_i \neq 0$. Por lo tanto, para el problema dual, que pretende maximizar (2.5.6), solo tienen sentido los $\boldsymbol{\lambda}$ que cumplen justamente la restricción

$$\sum_{i=1}^{n} \lambda_i y_i = 0.$$

Incluir esta condición como restricción en el problema dual permite descartar automáticamente del conjunto factible los $\boldsymbol{\lambda}$ que no la cumplen . Además, favorece la simplificación de la función objetivo, tal como lo hicimos.

Finalmente, el problema dual es

$$\begin{aligned} \text{maximizar} \quad & \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{sujeto a} \quad & \sum_{i=1}^{n} \lambda_i y_i = 0, \ \boldsymbol{\lambda} \succeq \mathbf{0}. \end{aligned} \tag{2.5.7}$$

Hiperplano separador óptimo

Para obtener el hiperplano separador óptimo de un conjunto de datos linealmente separable, los pasos a seguir son los siguientes:

1. Se resuelve el problema dual (2.5.7) para obtener $\boldsymbol{\lambda}^\star$.
2. Se obtiene el punto óptimo $\boldsymbol{\beta}^\star$ mediante la condición de estacionariedad

$$\boldsymbol{\beta}^\star = \sum_{\substack{i=1 \\ \lambda_i^\star \neq 0}}^{n} \lambda_i^\star y_i \mathbf{x}_i.$$

3. Se calcula el intercepto $\beta_0^\star$ mediante el promedio

$$\beta_0^\star = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \left(y_i - (\boldsymbol{\beta}^\star)^\top \mathbf{x}_i \right),$$

donde $\mathcal{S} = \{i \mid \lambda_i^\star \neq 0\}$. Aquí, cada término se obtiene al despejar $\beta_0^\star$ de la condición de holgura complementaria para los puntos que verifican $\lambda_i^\star \neq 0$.

Hiperplano separador óptimo	$(\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star = 0$
Función score	$\hat{f}(\mathbf{x}) = (\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star$
Clasificador	$\hat{G}(\mathbf{x}) = \text{sign}(\hat{f}(\mathbf{x}))$

Interpretación de las condiciones KKT

Pongamos foco en la factibilidad primal y en la holgura complementaria:

$$y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \geq 0 \quad \forall i = 1, \dots, n \qquad \text{(Factibilidad primal)}$$
$$\lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \right] = 0 \quad \forall i = 1, \dots, n \qquad \text{(Holgura complementaria)}$$

De la condición de holgura complementaria, podemos afirmar que

$$\lambda_i^\star > 0 \Longrightarrow y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) = 1, \tag{2.5.8}$$

lo cual significa que $\mathbf{x}_i$ está sobre el *borde* del margen. Esto motiva la siguiente definición.

Definición 2.5.5 (Vector soporte)**.** Un dato $\mathbf{x}_i$ se denomina *vector soporte* si el multiplicador asociado λ_i es estrictamente positivo.

De la solución $\boldsymbol{\beta}^\star$ obtenida previamente, queda claro que los vectores soporte son quienes caracterizan el hiperplano separador óptimo. Además:

- La recíproca de la implicación (2.5.8) no es cierta. Es decir, que un punto esté sobre el borde del margen no garantiza que su multiplicador sea positivo. Esto puede ocurrir cuando hay redundancia lineal entre las restricciones activas (más puntos sobre el margen que los estrictamente necesarios para determinar el hiperplano), en cuyo caso el problema dual admite múltiples soluciones óptimas. En la práctica, este fenómeno difícilmente ocurre.
- Combinando la factibilidad primal con la holgura complementaria, se sigue que los puntos que no están en el borde necesariamente tienen multiplicador nulo. Por lo tanto, no pueden ser vectores soporte y no contribuyen a la solución del problema.

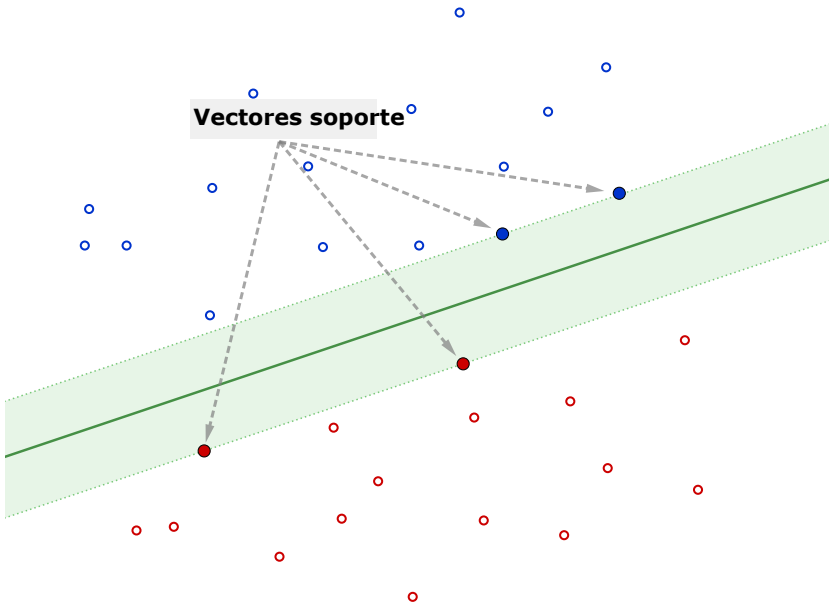


Figura 2.5.3: Vectores soporte del hiperplano separador óptimo de un conjunto de datos linealmente separables.

Ejemplo 2.5.6: Datos linealmente separables

Vamos a simular un conjunto de datos linealmente separables. Luego, obtendremos el hiperplano separador óptimo e identificaremos los vectores soporte.

> En este ejemplo utilizamos la implementación `SVC` de `scikit-learn`, la cual resuelve el problema de SVM con margen suave, que estudiaremos en la siguiente subsección. Al elegir un valor grande para el parámetro `C`, así el caso de margen duro, que permite obtener el hiperplano separador óptimo para datos linealmente separables.

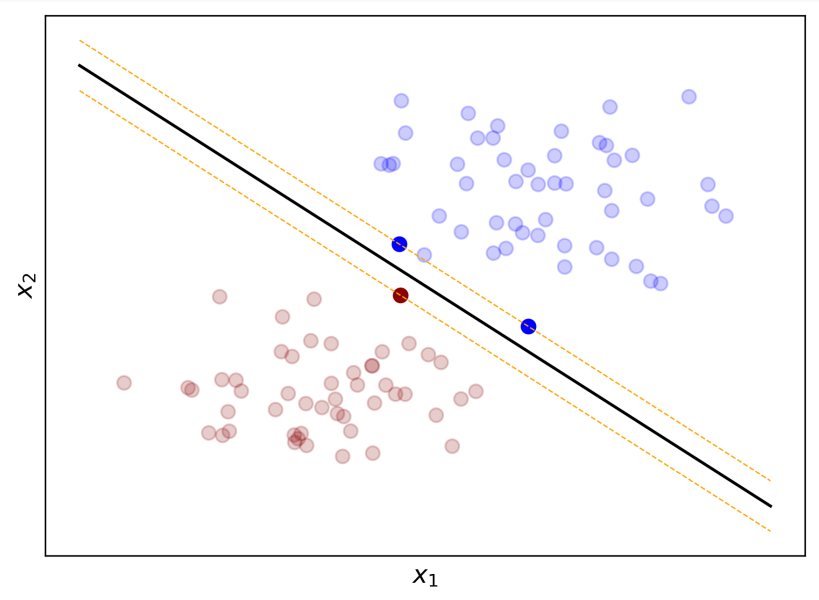
```python
import numpy as np
from sklearn.svm import SVC

# Datos:
np.random.seed(100)
X_pos = 2*np.random.randn(50, 2) + [3, 5]
X_neg = 1.5*np.random.randn(50, 2) + [-2, -2]
X = np.vstack((X_pos, X_neg))
y = np.array([1]*50 + [-1]*50)

# Hiperplano separador óptimo:
clf = SVC(kernel='linear', C=1e6)
clf.fit(X, y)

# Parámetros óptimos:
w = clf.coef_[0]
b = clf.intercept_[0]
```

```
Hiperplano óptimo: 1.125*x1 + 1.131*x2 + -1.987 = 0.
Número de vectores soporte: 3.
```



II | Variables de holgura y margen suave

En la formulación del hiperplano separador óptimo, se asume que el conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ es linealmente separable. Sin embargo, en la práctica lo habitual es que exista solapamiento entre las clases. Para extender el método, la estrategia consiste en introducir *variables de holgura*, simbolizadas con $\boldsymbol{\xi} \in \mathbb{R}^n$, que permitan que algunos puntos violen el margen o incluso queden mal clasificados. Este enfoque, conocido como *margen suave* (*soft-margin*, en inglés), es lo que desarrollaremos a continuación.

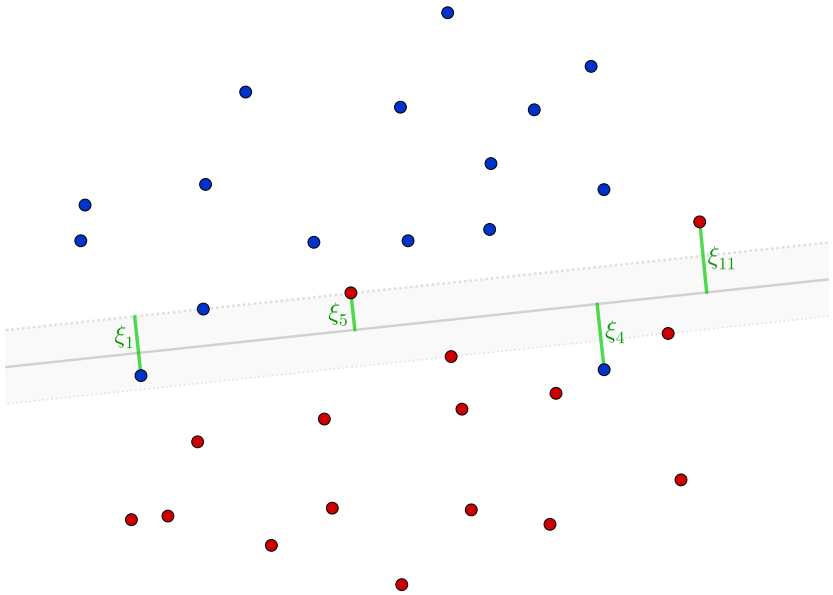


Figura 2.5.4: Variables de holgura en un conjunto de datos linealmente no separable.

La incorporación de las variables de holgura $\boldsymbol{\xi}$ al problema de optimización (2.5.5) conduce al siguiente problema de optimización:

$$\begin{aligned} &\text{minimizar} && \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 \\ &\text{sujeto a} && y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1 - \xi_i, \qquad i = 1, \ldots, n, \\ & && \boldsymbol{\xi} \succeq \mathbf{0}, \ \sum_{i=1}^n \xi_i \leq \text{cte}. \end{aligned} \tag{2.5.9}$$

Este nuevo problema de optimización tiene variables $\boldsymbol{\beta} \in \mathbb{R}^p$, $\beta_0 \in \mathbb{R}$ y $\boldsymbol{\xi} \in \mathbb{R}^n$. La restricción $\sum_{i=1}^n \xi_i \leq \text{cte}$ permite controlar el grado de tolerancia a puntos que están dentro o del lado incorrecto del margen. Este control es más natural pensarlo como una penalización en la función objetivo, lo cual deriva en la siguiente forma alternativa de (2.5.9):

$$\begin{aligned} &\text{minimizar} && \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 + C\sum_{i=1}^n \xi_i \\ &\text{sujeto a} && y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1 - \xi_i, \qquad i = 1, \ldots, n, \\ & && \boldsymbol{\xi} \succeq \mathbf{0}. \end{aligned} \tag{2.5.10}$$

A $C > 0$ se lo conoce como *hiperparámetro de costo*. Cuanto mayor es su valor, mayor es la penalización que el modelo impone sobre las violaciones del margen, lo que conduce a un

clasificador más estricto que busca minimizar los errores de clasificación a costa de un margen posiblemente más estrecho. Es claro que:

> El problema (2.5.10) es un problema de optimización convexa cuyo conjunto factible es un poliedro.

Estamos en condiciones de aplicar nuevamente las condiciones de Karush-Kuhn-Tucker (KKT) y la dualidad para caracterizar la solución de este problema. De ahora en adelante, nos referiremos a este nuevo método como *máquina de vectores soporte (SVM) lineal*.

Optimalidad

En el problema de optimización (2.5.10) se distinguen $2n$ restricciones de desigualdad. Para aquellas asociadas a las variables de holgura, $\boldsymbol{\xi} \succeq \mathbf{0}$, distinguiremos sus multiplicadores con la notación $\boldsymbol{\mu} = (\mu_1, \dots, \mu_n)$. Las condiciones KKT son

$$
\begin{aligned}
y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - (1 - \xi_i^\star) \geq 0 \quad \forall i && \text{(Factibilidad primal)} \\
\lambda_i^\star \geq 0,\ \mu_i^\star \geq 0 \quad \forall i && \text{(Factibilidad dual)} \\
\lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - (1 - \xi_i^\star) \right] = 0, \quad \mu_i^\star \xi_i^\star = 0 \quad \forall i && \text{(Holgura complementaria)} \\
\boldsymbol{\beta}^\star = \sum_{i=1}^n \lambda_i^\star y_i \mathbf{x}_i, \quad 0 = \sum_{i=1}^n \lambda_i^\star y_i, \quad C = \lambda_i^\star + \mu_i^\star \ (\forall i) && \text{(Estacionariedad)}
\end{aligned}
$$

Como antes, es conveniente formular el problema dual de Lagrange. En este caso, el Lagrangiano es $\mathcal{L} : \mathbb{R}^{p+1} \times \mathbb{R}^n \times \mathbb{R}^n \to \mathbb{R}$ definido por

$$
\mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\lambda}, \boldsymbol{\mu}) = \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 + C\sum_{i=1}^n \xi_i - \sum_{i=1}^n \lambda_i \left[y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) - (1 - \xi_i) \right] - \sum_{i=1}^n \mu_i \xi_i.
$$

La función dual resulta

$$
\begin{aligned}
\mathcal{G}(\boldsymbol{\lambda}) &= \frac{1}{2}\left\| \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i \right\|_2^2 + C\sum_{i=1}^n \xi_i - \sum_{i=1}^n \lambda_i y_i \left(\sum_{j=1}^n \lambda_j y_j \mathbf{x}_j \right)^\top \mathbf{x}_i \\
&\quad - \beta_0 \underbrace{\sum_{i=1}^n \lambda_i y_i}_{=0} + \sum_{i=1}^n \lambda_i - \sum_{i=1}^n \underbrace{(\lambda_i + \mu_i)}_{=C} \xi_i \\
&= \frac{1}{2}\sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i + \sum_{i=1}^n \lambda_i \\
&= \sum_{i=1}^n \lambda_i - \frac{1}{2}\sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j.
\end{aligned}
$$

Hemos obtenido la misma función dual del caso linealmente separable. El problema dual es

$$
\begin{aligned}
\text{maximizar} \quad & \sum_{i=1}^n \lambda_i - \frac{1}{2}\sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\
\text{sujeto a} \quad & \sum_{i=1}^n \lambda_i y_i = 0,\ \boldsymbol{\lambda} \succeq \mathbf{0},\ \boldsymbol{\mu} \succeq \mathbf{0}.
\end{aligned}
\tag{2.5.11}
$$

Sin embargo, podemos combinar las restricciones de no negatividad, en virtud de la condición de estacionariedad $C = \lambda_i + \mu_i$, y escribir en (2.5.11) simplemente $0 \leq \lambda_i \leq C$ para todo $i = 1, \ldots, n$. Esto deriva en la versión final del problema dual:

$$\begin{aligned} \text{maximizar} \quad & \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{sujeto a} \quad & \sum_{i=1}^{n} \lambda_i y_i = 0, \\ & 0 \leq \lambda_i \leq C, \quad i = 1, \ldots, n. \end{aligned} \tag{2.5.12}$$

SVM lineal

Para obtener el hiperplano óptimo de margen suave de un conjunto de datos, los pasos a seguir son los siguientes:

1. Se resuelve el problema dual (2.5.12) para obtener $\boldsymbol{\lambda}^\star$.
2. Se obtiene el punto óptimo $\boldsymbol{\beta}^\star$ mediante la condición de estacionariedad

$$\boldsymbol{\beta}^\star = \sum_{\substack{i=1 \\ \lambda_i^\star \neq 0}}^{n} \lambda_i^\star y_i \mathbf{x}_i.$$

3. Se calcula el intercepto $\beta_0^\star$ mediante el promedio

$$\beta_0^\star = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \left(y_i - (\boldsymbol{\beta}^\star)^\top \mathbf{x}_i \right),$$

donde $\mathcal{S} = \{i \mid \lambda_i^\star \neq 0 \wedge \xi_i^\star = 0\}$. Aquí, cada término se obtiene al despejar $\beta_0^\star$ de la condición de holgura complementaria para los puntos que verifican $\lambda_i^\star \neq 0$ y $\xi_i^\star = 0$.

Hiperplano separador óptimo	$(\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star = 0$
Función score	$\hat{f}(\mathbf{x}) = (\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star$
Clasificador	$\hat{G}(\mathbf{x}) = \text{sign}(\hat{f}(\mathbf{x}))$

Interpretación de las condiciones KKT

Nuevamente pongamos foco en la factibilidad primal y la holgura complementaria:

$$\begin{aligned} y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - (1 - \xi_i^\star) \geq 0 \quad \forall i = 1, \ldots, n \qquad & \text{(Factibilidad primal)} \\ \lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - (1 - \xi_i^\star) \right] = 0 \quad \forall i = 1, \ldots, n \qquad & \text{(Holgura complementaria)} \end{aligned}$$

En este caso, la holgura complementaria conduce a

$$\lambda_i^\star > 0 \implies y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) = 1 - \xi_i^\star,$$

lo cual implica dos opciones para los vectores soporte:

- Si $\xi_i^\star = 0$, $\mathbf{x}_i$ está sobre el *borde* del margen.
- Si, por el contrario, $\xi_i^\star > 0$, entonces $\mathbf{x}_i$ viola el margen.

> Analice en qué caso un punto soporte queda mal clasificado.

En consecuencia, podemos afirmar que:

Todo vector soporte se encuentra en una de las siguientes posiciones respecto al margen: en el borde, dentro del margen (bien o mal clasificado) o fuera del margen pero mal clasificado.

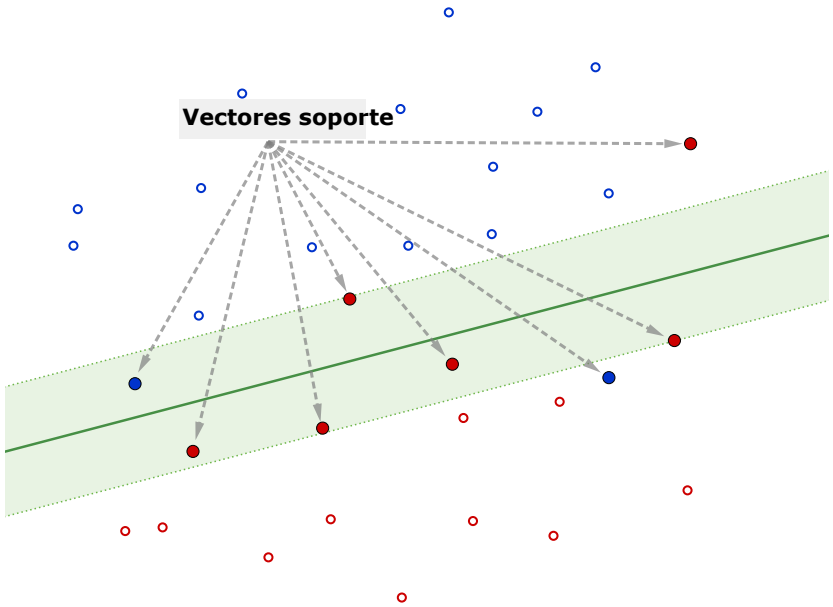


Figura 2.5.5: Vectores soporte del hiperplano separador óptimo con margen suave.

En este caso, la lectura combinada de la factibilidad primal y la holgura complementaria es: si $y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) > 1 - \xi_i^\star$, entonces debe ser $\lambda_i^\star = 0$. En este momento la pregunta de interés es:

¿Qué característica tienen los puntos con holgura positiva?

Si $\xi_i^\star > 0$, la condición de holgura complementaria $\mu_i^\star \xi_i^\star = 0$ junto a la condición de estacionariedad $C = \lambda_i^\star + \mu_i^\star$ nos permiten deducir que

$$\lambda_i^\star = C.$$

Dado que asumimos $C > 0$, concluimos que:

Todo punto con holgura positiva es un vector soporte.

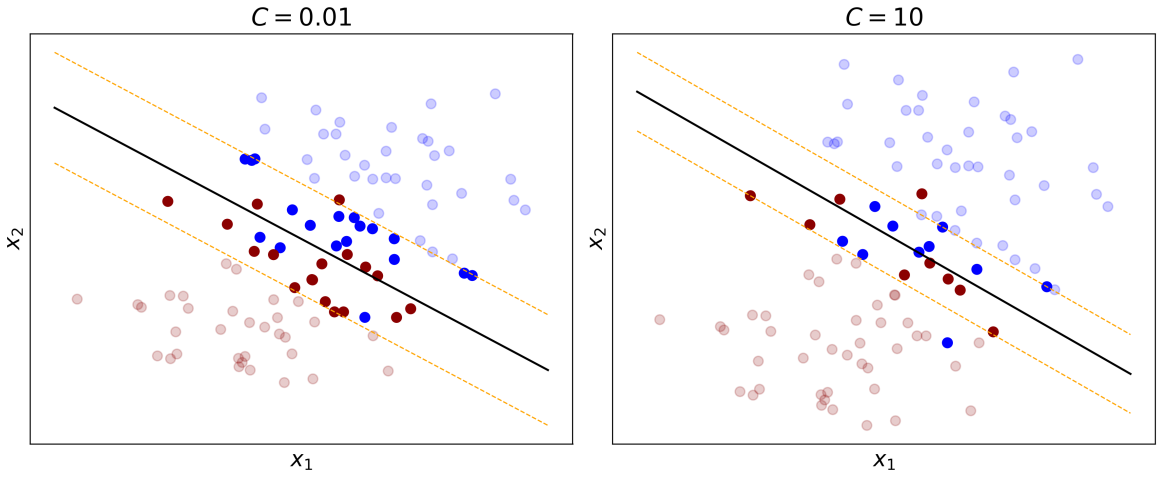
Responder qué ocurre con un punto $\mathbf{x}_i$ con multiplicador $\lambda_i^\star$, para cada caso. ¿Es vector soporte? ¿Tiene holgura positiva? ¿Cuál es su posición respecto al margen?

- $\lambda_i^\star = 0$.
- $0 < \lambda_i^\star < C$.
- $\lambda_i^\star = C$.

Ejemplo 2.5.7: Datos con solapamiento

Modificaremos el ejemplo anterior, generando datos de manera que las clases no sean linealmente separables, aunque la frontera de decisión lineal siga siendo una opción razonable. Luego, obtendremos el hiperplano óptimo e identificaremos los vectores soporte.

```
C: 0.01.
Hiperplano óptimo: 0.217*x1 + 0.313*x2 + -0.186 = 0.
Número de vectores soporte: 36.
-----
C: 10.
Hiperplano óptimo: 0.329*x1 + 0.559*x2 + -0.681 = 0.
Número de vectores soporte: 19.
```

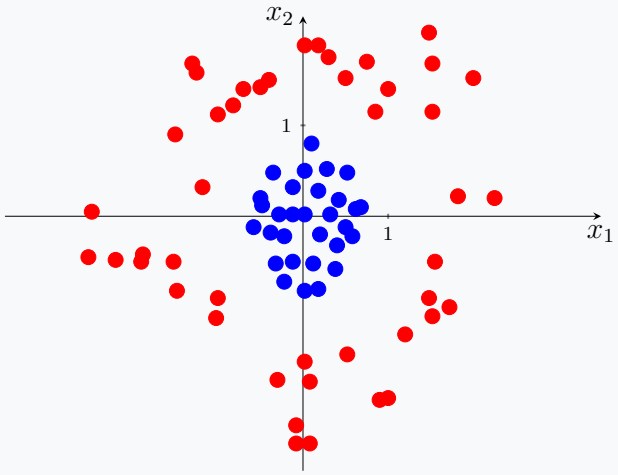


III | Máquinas de vectores soporte no lineales

El uso de hiperplanos separadores tiene la limitación de que determina una frontera de decisión lineal. En muchos problemas reales, esta hipótesis resulta demasiado restrictiva: los datos pueden estar distribuidos de manera tal que no exista un hiperplano capaz de separarlos correctamente, ni siquiera permitiendo un margen suave. Para graficar esto, veamos el siguiente ejemplo.

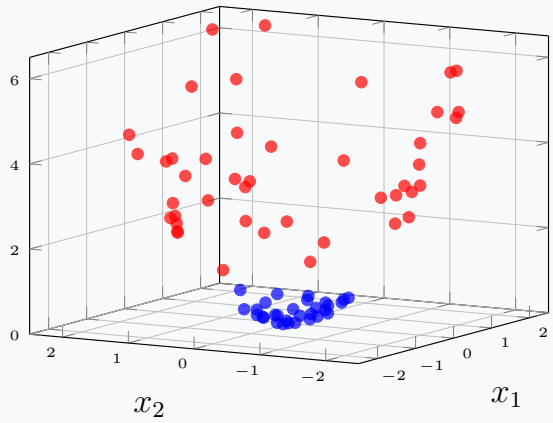
Ejemplo 2.5.8: Transformación de datos de $\mathbb{R}^2$ a $\mathbb{R}^3$

Consideremos un conjunto de datos de entrenamiento correspondiente a un problema de clasificación binaria con predictoras X_1 y X_2, dispuestos de manera tal que una clase rodea a la otra, tal como muestra la siguiente figura.



Claramente no sería conveniente intentar clasificar mediante una frontera de decisión lineal. Una estrategia más apropiada es transformar los datos a $\mathbb{R}^3$, añadiendo la variable

$$Z = X_1^2 + X_2^2.$$



En el espacio transformado $\mathbb{R}^3$, los puntos de las dos clases están ahora claramente separados a lo largo de la coordenada Z. Por lo tanto, es apropiado aplicar allí un hiperplano separador, ya que ahora existe una frontera lineal que separa perfectamente las dos clases.

El ejemplo anterior motiva la idea de usar transformaciones no lineales para mejorar las condiciones de un problema. Dicha transformación debe ser de la forma

$$\phi : \mathbb{R}^p \to \mathcal{H},$$

donde $\mathcal{H}$ es un *espacio de Hilbert*; es decir, un espacio donde tenemos un producto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ definido.

Importante

Observar que, en el ejemplo anterior, la transformación se hace entre dos espacios de dimensión finita, ya que allí $\mathcal{H} = \mathbb{R}^3$. No obstante, en general, es conveniente trabajar con $\mathcal{H}$ de dimensión infinita. Más aún, de ahora en adelante consideraremos $\mathcal{H}$ un espacio de funciones de la forma $h : \mathbb{R}^p \to \mathbb{R}$. Es decir, el mapeo será de la forma

$$\mathbf{x} \mapsto h.$$

Veremos que esto no representa ninguna dificultad adicional; por el contrario, permite utilizar una herramienta muy poderosa que justifica el éxito de las máquinas de vectores soporte.

Núcleos reproductores

El cálculo de productos internos en $\mathcal{H}$, de la forma

$$\langle \phi(\mathbf{x}_1), \phi(\mathbf{x}_2) \rangle_{\mathcal{H}} \qquad \forall \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p, \tag{2.5.13}$$

es fundamental para la generalización de SVM. Sin embargo, para un $\mathcal{H}$ arbitrario, conocer explícitamente su producto interno $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ resulta ser una limitación práctica. Una manera de sortear esto es trabajar con un tipo especial de espacios de Hilbert.

Definición 2.5.9 (Espacio de Hilbert con núcleo reproductor)**.** Un espacio de Hilbert $\mathcal{H}$ es un *espacio de Hilbert con núcleo reproductor* (RKHS, *reproducing kernel Hilbert space*) si admite un *núcleo reproductor* $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ que verifica las siguientes propiedades:

- Para todo $\mathbf{x} \in \mathbb{R}^p$, $k(\mathbf{x}, \cdot) \in \mathcal{H}$.
- Para todo $\mathbf{x} \in \mathbb{R}^p$ y toda $h \in \mathcal{H}$,
$$h(\mathbf{x}) = \langle h, k(\mathbf{x}, \cdot) \rangle_{\mathcal{H}}.$$

Veamos el efecto de trabajar con RKHS para el cálculo de productos internos de la forma (2.5.13). Las propiedades de la Definición 2.5.9 implican:

$$k(\mathbf{x}_1, \mathbf{x}_2) = \langle k(\mathbf{x}_1, \cdot), k(\mathbf{x}_2, \cdot) \rangle_{\mathcal{H}} \qquad \forall \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p.$$

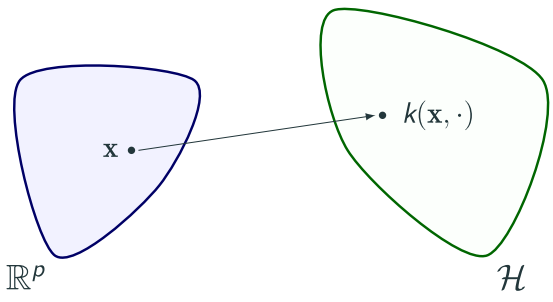


Figura 2.5.6: Mapeo característico $\phi : \mathbb{R}^p \to \mathcal{H}$ asociado a un RKHS.

Este último resultado es crucial: permite afirmar que, dado un *mapeo característico* de la forma

$$\mathbf{x} \mapsto k(\mathbf{x}, \cdot),$$

lo único que necesitamos para poder calcular productos internos en $\mathcal{H}$ es conocer explícitamente el núcleo reproductor k. Ahora bien:

¿Cómo se construye un núcleo k válido?

Para responder a esta pregunta, es necesario introducir la siguiente definición.

Definición 2.5.10 (Núcleo definido positivo y simétrico)**.** Una función $k : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$ se dice *definida positiva* si para todo $n \in \mathbb{N}$, $\alpha_1, \ldots, \alpha_n \in \mathbb{R}$ y $\mathbf{x}_1, \ldots, \mathbf{x}_n \in \mathbb{R}^p$ resulta

$$\sum_{i=1}^{n} \sum_{j=1}^{n} \alpha_i \alpha_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0. \tag{2.5.14}$$

Por otra parte, k es *simétrica* si

$$k(\mathbf{x}_1, \mathbf{x}_2) = k(\mathbf{x}_2, \mathbf{x}_1) \qquad \forall \mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^p.$$

La expresión (2.5.14) se puede escribir matricialmente como $K \succeq 0$, donde $K \in \mathbb{R}^{n \times n}$ es la *matriz de Gram* definida por

$$K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j).$$

Importante

Algunos de los núcleos más habituales en aplicaciones de SVM son:

- *Núcleo lineal*: corresponde a SVM lineal; es decir, no hay transformación de los datos.

$$k(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^\top \mathbf{x}_2.$$

- *Núcleo polinómico*:

$$k(\mathbf{x}_1, \mathbf{x}_2) = (\gamma\, \mathbf{x}_1^\top \mathbf{x}_2 + b)^d.$$

- *Núcleo gaussiano*:

$$k(\mathbf{x}_1, \mathbf{x}_2) = \exp\left\{-\gamma \left\|\mathbf{x}_1 - \mathbf{x}_2\right\|_2^2\right\}.$$

- *Núcleo sigmoide*:

$$k(\mathbf{x}_1, \mathbf{x}_2) = \tanh(\gamma\, \mathbf{x}_1^\top \mathbf{x}_2 + b).$$

Formulación del problema

La idea básica es aplicar la metodología de hiperplano separador con margen suave en $\mathcal{H}$. Esto resulta en la siguiente función dual:

$$\mathcal{G}(\boldsymbol{\lambda}) = \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j \underbrace{\langle k(\mathbf{x}_i, \cdot), k(\mathbf{x}_j, \cdot) \rangle_{\mathcal{H}}}_{k(\mathbf{x}_i, \mathbf{x}_j)}.$$

El problema dual correspondiente es

$$\begin{aligned} \text{maximizar} \quad & \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j k(\mathbf{x}_i, \mathbf{x}_j) \\ \text{sujeto a} \quad & \sum_{i=1}^{n} \lambda_i y_i = 0, \\ & 0 \leq \lambda_i \leq C, \quad i = 1, \ldots, n. \end{aligned} \tag{2.5.15}$$

SVM no lineal

Para obtener el hiperplano óptimo de un conjunto de datos en un RKHS, los pasos a seguir son:

1. Se resuelve el problema dual (2.5.15) para obtener $\boldsymbol{\lambda}^\star$.
2. Se obtiene el punto óptimo $\boldsymbol{\beta}^\star$ mediante la condición de estacionariedad

$$\boldsymbol{\beta}^\star = \sum_{\substack{i=1 \\ \lambda_i^\star \neq 0}}^{n} \lambda_i^\star y_i k(\mathbf{x}_i, \cdot).$$

3. Se calcula el intercepto $\beta_0^\star$ mediante el promedio

$$\beta_0^\star = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} (y_i - \langle \boldsymbol{\beta}^\star, k(\mathbf{x}_i, \cdot) \rangle_{\mathcal{H}}) = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \left(y_i - \sum_{\substack{j=1 \\ \lambda_j^\star \neq 0}}^{n} \lambda_j^\star y_j k(\mathbf{x}_i, \mathbf{x}_j) \right),$$

donde $\mathcal{S} = \{i \mid \lambda_i^\star \neq 0 \wedge \xi_i^\star = 0\}$. Como antes, esto último resulta de despejar $\beta_0^\star$ de la condición de holgura complementaria para los puntos que verifican $\lambda_i^\star \neq 0$ y $\xi_i^\star = 0$.

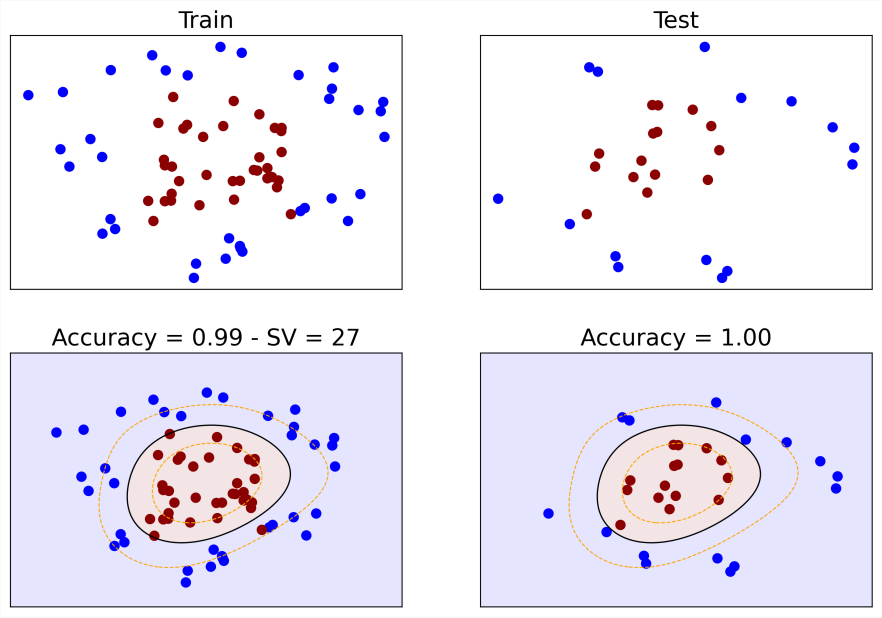
Función score	$\hat{f}(\mathbf{x}) = \sum_{\substack{i=1 \\ \lambda_i^\star \neq 0}}^{n} \lambda_i^\star y_i k(\mathbf{x}_i, \mathbf{x}) + \beta_0^\star$
Clasificador	$\hat{G}(\mathbf{x}) = \text{sign}(\hat{f}(\mathbf{x}))$

Ejemplo 2.5.11: Datos con diferentes patrones

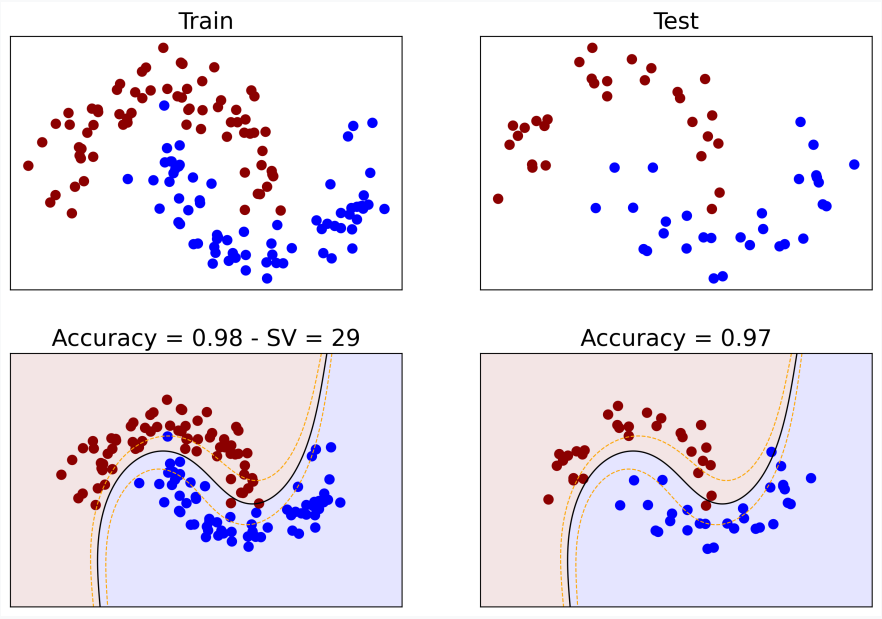
Mostraremos diferentes estructuras de datos de clasificación binaria y veremos cómo se adaptan los diferentes núcleos. Además, veremos el efecto del valor de C. Es importante remarcar que,

en estos ejemplos, los distintos hiperparámetros de los modelos se utilizan con sus valores por defecto. Sin embargo, el rendimiento de un modelo puede mejorarse significativamente seleccionando cuidadosamente los hiperparámetros mediante algún proceso de validación.

```
C: 1.
Kernel: gaussiano (rbf).
```




```
C: 1.
Kernel: polinómico (poly) grado 3.
```



Referencias

Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer Series in Statistics. New York: Springer.

Steinwart, I. & Christmann, A. (2008). *Support Vector Machines*. Information Science and Statistics. New York: Springer.