FIQ UNL. FACULTAD DE INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez Liliana Forzani

Año 2026

Máquinas de vectores soporte

En esta sección vamos a estudiar un algoritmo de aprendizaje supervisado ampliamente utilizado para problemas de clasificación, que ha demostrado ser especialmente efectivo en tareas donde se requiere obtener fronteras de decisión robustas y con buena capacidad de generalización. Su construcción sigue una secuencia natural de conceptos: en primer lugar, se aborda la formulación básica basada en hiperplanos separadores óptimos, cuyo objetivo es maximizar el margen de separación entre clases perfectamente separables; luego, se incorpora el uso de *variables de holgura* para tratar datos no separables; y, finalmente, se presenta la generalización mediante *núcleos reproductores*, lo que permite obtener fronteras de decisión no lineales.

Una característica distintiva de estos métodos es que su desarrollo se apoya fuertemente en la formulación dual de problemas de optimización y en las condiciones de Karush-Kuhn-Tucker (KKT), lo que permite interpretar la solución en términos de los vectores soporte y comprender el funcionamiento del método.

> **Notación**
>
> Para un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ de un problema de clasificación binaria, denotaremos las etiquetas por $y_i \in \{-1, +1\}$.

I | Hiperplano separador óptimo

El caso más simple de análisis surge de suponer que las clases $\{\mathbf{x}_i \mid y_i = -1\}$ y $\{\mathbf{x}_i \mid y_i = +1\}$ pueden ser separadas totalmente por una frontera lineal.

Definición 2.5.1 (Separabilidad lineal)**.** Un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, con $y_i \in \{-1, +1\}$, se dice que es *linealmente separable* si existen $\boldsymbol{\beta} \in \mathbb{R}^p$ y $\beta_0 \in \mathbb{R}$ tales que

$$y_i = \operatorname{sign}(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \qquad \forall i = 1, \dots, n. \tag{2.5.1}$$

El hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ se denomina *hiperplano separador* y la función $f : \mathbb{R}^p \to \mathbb{R}$ definida por $f(\mathbf{x}) = \boldsymbol{\beta}^\top \mathbf{x} + \beta_0$ se conoce como *función score*.

El vector normal al hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ es $\boldsymbol{\beta}$ y la distancia entre un punto $\mathbf{x} \in \mathbb{R}^p$ y dicho hiperplano es igual a $|f(\mathbf{x})|/\|\boldsymbol{\beta}\|_2$. Esto último es cierto ya que, si $\mathbf{x}_0$ es un punto sobre el

hiperplano, entonces dicha distancia resulta de la proyección de $\mathbf{x} - \mathbf{x}_0$ sobre el vector normal $\boldsymbol{\beta}/\|\boldsymbol{\beta}\|_2$:

$$\left| \frac{\boldsymbol{\beta}^\top}{\|\boldsymbol{\beta}\|} (\mathbf{x} - \mathbf{x}_0) \right| = \frac{\left| \boldsymbol{\beta}^\top \mathbf{x} - \boldsymbol{\beta}^\top \mathbf{x}_0 \right|}{\|\boldsymbol{\beta}\|_2} = \frac{\left| \boldsymbol{\beta}^\top \mathbf{x} + \beta_0 \right|}{\|\boldsymbol{\beta}\|_2} = \frac{|f(\mathbf{x})|}{\|\boldsymbol{\beta}\|_2}.$$

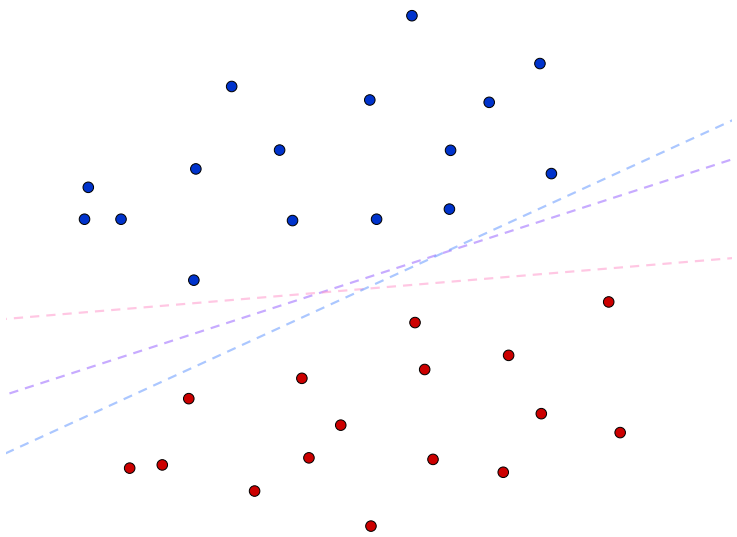


Figura 2.5.1: Datos linealmente separables y algunos hiperplanos separadores.

Observar que la expresión (2.5.1) es equivalente a requerir

$$y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) > 0 \qquad \forall i = 1, \ldots, n. \tag{2.5.2}$$

Algo intuitivo es que si las clases son totalmente separables, existen infinitos hiperplanos separadores. Por lo tanto, resulta necesario definir un criterio que permita seleccionar un hiperplano único y óptimo. En primer lugar, establecemos lo siguiente:

Primer principio

Cada vector $\boldsymbol{\beta} \in \mathbb{R}^p$ puede definir un único hiperplano separador.

Este primer principio justifica considerar a $\boldsymbol{\beta} \in \mathbb{R}^p$ como variable de optimización, ya que establece una correspondencia biunívoca entre cada vector $\boldsymbol{\beta}$ y un hiperplano separador, ¿cuál? Elegimos aquel que *equidista* de ambas clases. Para caracterizar esta propiedad, primero necesitamos imponer una restricción de normalización, ya que la distancia de un punto al hiperplano depende de $\|\boldsymbol{\beta}\|_2$.

Segundo principio

Se restringe la elección de $\boldsymbol{\beta}$ a aquellos vectores que cumplen $\|\boldsymbol{\beta}\|_2 = 1$.

Así, bajo este segundo principio, la distancia entre cualquier punto $\mathbf{x}_i$ y el hiperplano $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ está dada por

$$|f(\mathbf{x}_i)| = |\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0| = y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0).$$

Con estas consideraciones, ya podemos definir el hiperplano separador asociado a un vector $\boldsymbol{\beta} \in \mathbb{R}^p$. Esta definición determina el valor del intercepto β_0, completando así la caracterización del hiperplano.

Definición 2.5.2 (Hiperplano separador asociado a un vector)**.** A un vector $\boldsymbol{\beta} \in \mathbb{R}^p$ se le asocia el hiperplano separador $\boldsymbol{\beta}^\top \mathbf{x} + \beta_0 = 0$ cuya distancia mínima a ambas clases es la misma. Es decir, existe $M \in \mathbb{R}^+$ tal que

$$y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq M \qquad \forall i = 1, \ldots, n,$$

con igualdad para al menos un punto de cada clase. Al valor M lo denominamos *margen* del hiperplano separador asociado a $\boldsymbol{\beta}$.

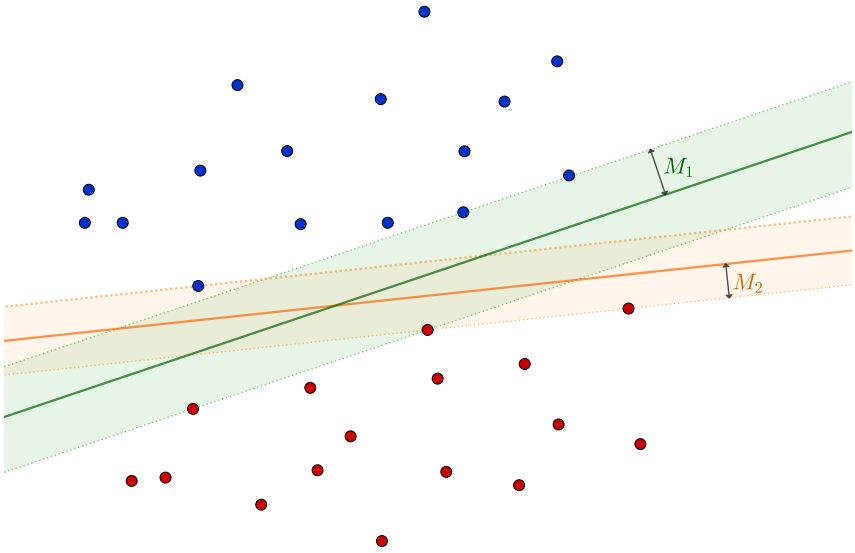


Figura 2.5.2: Hiperplanos separadores y sus margenes asociados.

Es importante observar que los puntos para los cuales se cumple la igualdad en la restricción son los que caracterizan al hiperplano; estos se denominan *vectores soporte* (su definición formal se presentará más adelante). A continuación, definiremos qué consideraremos como hiperplano separador óptimo de un conjunto de datos linealmente separables.

Definición 2.5.3 (Hiperplano separador óptimo)**.** Sea $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, con $y_i \in \{-1, +1\}$, un conjunto de datos linealmente separable. El *hiperplano separador óptimo* es aquel que maximiza el *margen* M, es decir, resuelve el problema

$$\begin{aligned} &\text{maximizar} && M \\ &\text{sujeto a} && y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq M, \qquad i = 1, \ldots, n, \\ &&& \|\boldsymbol{\beta}\|_2 = 1. \end{aligned} \tag{2.5.3}$$

Si bien esta formulación refleja directamente la intención de maximizar el margen, vamos a ajustarla para obtener una formulación clásica más conveniente.

Formulación clásica

En base a lo descripto anteriormente, la restricción $\|\boldsymbol{\beta}\|_2 = 1$ permite interpretar al margen M como la distancia mínima de los puntos al hiperplano. Si se relaja dicha condición, dicha interpretación sigue siendo cierta si se escribe

$$\frac{y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0)}{\|\boldsymbol{\beta}\|_2} \geq M, \qquad i = 1, \dots, n.$$

En consecuencia, el problema (2.5.3) se puede reescribir como

$$\begin{array}{ll} \text{maximizar} & M \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq \|\boldsymbol{\beta}\|_2 M, \qquad i = 1, \dots, n, \end{array} \tag{2.5.4}$$

con una importante diferencia: dado un punto óptimo $\boldsymbol{\beta}^\star$ de (2.5.4), también lo son los puntos $k\boldsymbol{\beta}^\star$, con $k \in \mathbb{R}^+$. Es decir, al eliminar la restricción $\|\boldsymbol{\beta}\|_2 = 1$, la elección del vector normal asociado a un hiperplano vuelve a ser arbitraria. Por tal motivo, elegiremos nuevamente un representante entre todos los múltiplos escalares de un mismo vector normal, aunque esta vez la elección dependerá del valor del margen M.

Entre todos los puntos óptimos del problema (2.5.4) que representan el mismo hiperplano separador, elegimos el único que verifica

$$\|\boldsymbol{\beta}^\star\|_2 = \frac{1}{M^\star},$$

donde $M^\star$ es el margen óptimo.

Esta idea nos va a permitir reformular nuestro problema de optimización. En efecto, bajo estas nuevas condiciones, maximizar M es equivalente a minimizar $\|\boldsymbol{\beta}\|_2$ y, convenientemente, también equivalente a minimizar $\frac{1}{2}\|\boldsymbol{\beta}\|_2^2$. Finalmente obtenemos la versión final del problema de optimización de interés.

Definición 2.5.4 (Problema de optimización del hiperplano separador óptimo)**.** Dado un conjunto de datos $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ linealmente separables, el hiperplano separador óptimo es

$$(\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star = 0,$$

con $\boldsymbol{\beta}^\star \in \mathbb{R}^p$ y $\beta_0^\star \in \mathbb{R}$ puntos óptimos del problema

$$\begin{array}{ll} \text{minimizar} & \dfrac{1}{2}\|\boldsymbol{\beta}\|_2^2 \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1, \qquad i = 1, \dots, n. \end{array} \tag{2.5.5}$$

Observar que:

El problema (2.5.5) es un problema de optimización convexa cuyo conjunto factible es un poliedro.

En consecuencia, el corolario de condiciones de optimalidad para conjuntos factibles poliedrales (Sección 4 del Capítulo 1) nos asegura que las condiciones de Karush-Kuhn-Tucker (KKT) son suficientes y necesarias para la optimalidad. Más aún, el Teorema de Slater de esa misma sección permite afirmar que hay dualidad fuerte.

Optimalidad

Las condiciones KKT son

$$
\begin{aligned}
y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \geq 0 \quad \forall i = 1, \dots, n && \text{(Factibilidad primal)} \\
\lambda_i^\star \geq 0 \quad \forall i = 1, \dots, n && \text{(Factibilidad dual)} \\
\lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \right] = 0 \quad \forall i = 1, \dots, n && \text{(Holgura complementaria)} \\
\boldsymbol{\beta}^\star = \sum_{i=1}^n \lambda_i^\star y_i \mathbf{x}_i, \quad 0 = \sum_{i=1}^n \lambda_i^\star y_i && \text{(Estacionariedad)}
\end{aligned}
$$



Si bien las condiciones KKT permiten caracterizar completamente la solución óptima, no proporcionan un método directo y eficiente para calcular $\boldsymbol{\lambda}^\star$. Por ello, resulta conveniente formular el problema dual de Lagrange, cuya resolución es computacionalmente más sencilla, esto último debido a que resulta ser un problema de optimización cuadrática.

El Lagrangiano asociado al problema (2.5.5) es $\mathcal{L} : \mathbb{R}^{p+1} \times \mathbb{R}^n \to \mathbb{R}$ definido por

$$
\mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\lambda}) = \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 - \sum_{i=1}^n \lambda_i \left[y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) - 1 \right].
$$

Dado que el Lagrangiano es una función convexa en $(\boldsymbol{\beta}, \beta_0)$, la ecuación $\nabla_{(\boldsymbol{\beta},\beta_0)} \mathcal{L} = \mathbf{0}$ caracteriza el ínfimo de $\mathcal{L}$ para cada $\boldsymbol{\lambda}$. Esto resulta en las expresiones

$$
\boldsymbol{\beta} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i, \qquad \sum_{i=1}^n \lambda_i y_i = 0.
$$

Observar que $\boldsymbol{\beta}$ queda definida en términos de $\boldsymbol{\lambda}$ y, aunque β_0 no queda determinado de forma directa, sí nos provee una restricción de consistencia sobre los multiplicadores. Reemplazando, obtenemos la función dual de Lagrange:

$$
\begin{aligned}
\mathcal{G}(\boldsymbol{\lambda}) :&= \inf_{\boldsymbol{\beta},\beta_0} \mathcal{L}(\boldsymbol{\beta}, \beta_0, \boldsymbol{\lambda}) \\
&= \frac{1}{2}\left\| \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i \right\|_2^2 - \sum_{i=1}^n \lambda_i y_i \left(\sum_{j=1}^n \lambda_j y_j \mathbf{x}_j \right)^\top \mathbf{x}_i - \beta_0 \underbrace{\sum_{i=1}^n \lambda_i y_i}_{=0} + \sum_{i=1}^n \lambda_i \\
&= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i - \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i + \sum_{i=1}^n \lambda_i \\
&= \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i.
\end{aligned}
\tag{2.5.6}
$$

Importante

Observar, en el desarrollo de (2.5.6), el término

$$-\beta_0 \sum_{i=1}^{n} \lambda_i y_i.$$

Esto implica que $\mathcal{G}(\boldsymbol{\lambda}) = -\infty$ si $\sum_{i=1}^{n} \lambda_i y_i \neq 0$. Por lo tanto, para el problema dual, que pretende maximizar (2.5.6), solo tienen sentido los $\boldsymbol{\lambda}$ que cumplen justamente la restricción

$$\sum_{i=1}^{n} \lambda_i y_i = 0.$$

Incluir esta condición como restricción en el problema dual permite descartar automáticamente del conjunto factible los $\boldsymbol{\lambda}$ que no la cumplen . Además, favorece la simplificación de la función objetivo, tal como lo hicimos.

Finalmente, el problema dual es

$$\begin{aligned} \text{maximizar} \quad & \sum_{i=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i \\ \text{sujeto a} \quad & \sum_{i=1}^{n} \lambda_i y_i = 0, \ \boldsymbol{\lambda} \succeq \mathbf{0}. \end{aligned} \tag{2.5.7}$$

Hiperplano separador óptimo

Para obtener el hiperplano separador óptimo de un conjunto de datos linealmente separable, los pasos a seguir son los siguientes:

1. Se resuelve el problema dual (2.5.7) para obtener $\boldsymbol{\lambda}^\star$.
2. Se obtiene el punto óptimo $\boldsymbol{\beta}^\star$ mediante la condición de estacionariedad

$$\boldsymbol{\beta}^\star = \sum_{\substack{i=1 \\ \lambda_i^\star \neq 0}}^{n} \lambda_i^\star y_i \mathbf{x}_i.$$

3. Se calcula el intercepto $\beta_0^\star$ mediante el promedio

$$\beta_0^\star = \frac{1}{|\mathcal{S}|} \sum_{i \in \mathcal{S}} \left(y_i - (\boldsymbol{\beta}^\star)^\top \mathbf{x}_i \right),$$

donde $\mathcal{S} = \{i \mid \lambda_i^\star \neq 0\}$. Aquí, cada término se obtiene al despejar $\beta_0^\star$ de la condición de holgura complementaria para los puntos que verifican $\lambda_i^\star \neq 0$.

Hiperplano separador óptimo	$(\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star = 0$
Función score	$\hat{f}(\mathbf{x}) = (\boldsymbol{\beta}^\star)^\top \mathbf{x} + \beta_0^\star$
Clasificador	$\hat{G}(\mathbf{x}) = \text{sign}(\hat{f}(\mathbf{x}))$

Interpretación de las condiciones KKT

Pongamos foco en la factibilidad primal y en la holgura complementaria:

$$y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \geq 0 \quad \forall i = 1, \dots, n \qquad \text{(Factibilidad primal)}$$
$$\lambda_i^\star \left[y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) - 1 \right] = 0 \quad \forall i = 1, \dots, n \qquad \text{(Holgura complementaria)}$$

De la condición de holgura complementaria, podemos afirmar que

$$\lambda_i^\star > 0 \Longrightarrow y_i((\boldsymbol{\beta}^\star)^\top \mathbf{x}_i + \beta_0^\star) = 1, \tag{2.5.8}$$

lo cual significa que $\mathbf{x}_i$ está sobre el *borde* del margen. Esto motiva la siguiente definición.

Definición 2.5.5 (Vector soporte)**.** Un dato $\mathbf{x}_i$ se denomina *vector soporte* si el multiplicador asociado λ_i es estrictamente positivo.

De la solución $\boldsymbol{\beta}^\star$ obtenida previamente, queda claro que los vectores soporte son quienes caracterizan el hiperplano separador óptimo. Además:

- La recíproca de la implicación (2.5.8) no es cierta. Es decir, que un punto esté sobre el borde del margen no garantiza que su multiplicador sea positivo. Esto puede ocurrir cuando hay redundancia lineal entre las restricciones activas (más puntos sobre el margen que los estrictamente necesarios para determinar el hiperplano), en cuyo caso el problema dual admite múltiples soluciones óptimas. En la práctica, este fenómeno difícilmente ocurre.
- Combinando la factibilidad primal con la holgura complementaria, se sigue que los puntos que no están en el borde necesariamente tienen multiplicador nulo. Por lo tanto, no pueden ser vectores soporte y no contribuyen a la solución del problema.

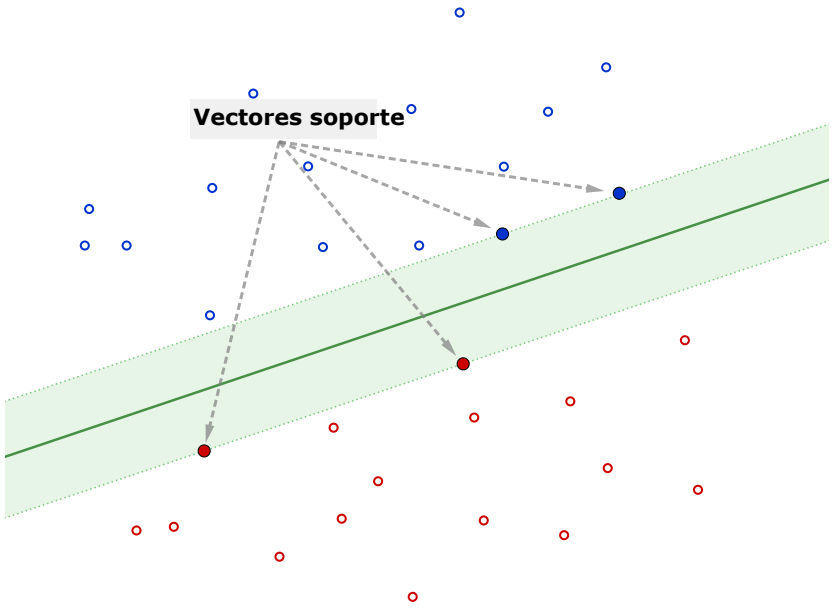


Figura 2.5.3: Vectores soporte del hiperplano separador óptimo de un conjunto de datos linealmente separables.

Ejemplo 2.5.6: Datos linealmente separables

Vamos a simular un conjunto de datos linealmente separables. Luego, obtendremos el hiperplano separador óptimo e identificaremos los vectores soporte.

> En este ejemplo utilizamos la implementación `SVC` de `scikit-learn`, la cual resuelve el problema de SVM con margen suave, que estudiaremos en la siguiente subsección. Al elegir un valor grande para el parámetro `C`, así el caso de margen duro, que permite obtener el hiperplano separador óptimo para datos linealmente separables.

```python
import numpy as np
from sklearn.svm import SVC

# Datos:
np.random.seed(100)
X_pos = 2*np.random.randn(50, 2) + [3, 5]
X_neg = 1.5*np.random.randn(50, 2) + [-2, -2]
X = np.vstack((X_pos, X_neg))
y = np.array([1]*50 + [-1]*50)

# Hiperplano separador óptimo:
clf = SVC(kernel='linear', C=1e6)
clf.fit(X, y)

# Parámetros óptimos:
w = clf.coef_[0]
b = clf.intercept_[0]
```

```
Hiperplano óptimo: 1.125*x1 + 1.131*x2 + -1.987 = 0.
Número de vectores soporte: 3.
```

