FIQ UNL. FACULTAD DE INGENIERÍA QUÍMICA

LICENCIATURA EN CIENCIA DE DATOS

Optimización y Aprendizaje Automático II

Isaías Ibañez Liliana Forzani

Año 2026

Métodos de clustering

Hasta ahora hemos abordado la tarea de predecir los valores de una variable respuesta $Y \in \mathbb{R}$, continua (*regresión*) o discreta (*clasificación*), a partir de un conjunto de variables predictoras $\mathbf{X} \in \mathbb{R}^p$. Este tipo de problemas se enmarca en lo que se conoce como *aprendizaje supervisado*.

En esta sección nos centraremos en el *aprendizaje no supervisado*. En este caso, el conjunto de entrenamiento es $\{\mathbf{x}_i\}_{i=1}^n$ y la distribución asociada es $p(\mathbf{x})$. El objetivo ya no es predecir una variable respuesta, sino descubrir estructuras o patrones en los datos que resulten de interés. En particular, una de las tareas más comunes es la *segmentación* o *clustering*, cuyo propósito es identificar grupos dentro del conjunto de datos que se diferencien entre sí de manera significativa.

El problema de *clustering* puede abordarse desde distintas perspectivas. De manera general, se distinguen tres tipos:

- *Métodos combinatorios*: trabajan directamente sobre los datos observados, sin asumir un modelo probabilístico subyacente. Veremos K-medias.
- *Modelos de mezcla*: suponen que los datos son una muestra i.i.d. de una distribución de probabilidad compuesta por varios componentes, y el agrupamiento surge de estimar sus parámetros. Veremos mezclas de Gaussianas.
- *Métodos basados en densidad*: adoptan una perspectiva no paramétrica sobre $p(\mathbf{x})$. Algunos estiman directamente sus modas (máximos locales) y asignan cada observación a la que la atrae, como *mean-shift*; otros identifican los clusters con regiones conexas de alta densidad, como DBSCAN, que es el que veremos.

I | K-medias

En los métodos combinatorios, las observaciones se asignan directamente a un cluster, estableciendo de antemano un número de clusters $K < n$. La tarea está caracterizada por un mapeo $C : \{1, \dots, n\} \to \{1, \dots, K\}$, definido por

$$k = C(i),$$

que asigna a la i-ésima observación el k-ésimo cluster. Los parámetros de este procedimiento son cada una de las asignaciones de las observaciones, y se ajustan de manera tal de *minimizar* una función de pérdida basada en una *medida de disimilaridad* $d(\mathbf{x}_i, \mathbf{x}_j)$ entre pares de observaciones.

Una elección natural de la función de pérdida deriva en el siguiente problema de optimización:

$$\text{minimizar} \quad W(C) = \frac{1}{2}\sum_{k=1}^{K}\sum_{C(i)=k}\sum_{C(j)=k} d(\mathbf{x}_i, \mathbf{x}_j). \tag{3.2.1}$$

> Analice la equivalencia entre (3.2.1) y
>
> $$\text{maximizar} \quad B(C) = \frac{1}{2}\sum_{k=1}^{K}\sum_{C(i)=k}\sum_{C(j)\neq k} d(\mathbf{x}_i, \mathbf{x}_j).$$

El problema de optimización planteado en (3.2.1) resulta computacionalmente intratable para conjuntos de datos de tamaño moderado, ya que el número de posibles asignaciones es K^n, lo cual crece muy rápido con n y K. Por ejemplo, existen más de 10^{10} formas de asignar $n = 19$ observaciones a $K = 4$ clusters. Por esta razón, los algoritmos existentes recurren a estrategias iterativas que buscan mejorar progresivamente una partición inicial. Entre estos métodos, el más utilizado y conceptualmente sencillo es el algoritmo de K-medias, que puede interpretarse como una forma de descenso iterativo sobre la función de pérdida $W(C)$.

En K-medias, la medida de disimilaridad es

$$d(\mathbf{x}_i, \mathbf{x}_j) = \|\mathbf{x}_i - \mathbf{x}_j\|_2^2,$$

y la función de pérdida resulta en

$$W(C) = \sum_{k=1}^{K} n_k \sum_{C(i)=k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|_2^2, \tag{3.2.2}$$

donde $\bar{\mathbf{x}}_k$ es el vector de medias del k-ésimo cluster y n_k es el tamaño de dicho cluster.

> Verifique la expresión (3.2.2). *Ayuda: escriba* $\mathbf{x}_i - \mathbf{x}_j = (\mathbf{x}_i - \bar{\mathbf{x}}_k) - (\mathbf{x}_j - \bar{\mathbf{x}}_k)$ *y desarrolle el cuadrado.*

Importante

La función

$$J(C, \boldsymbol{\mu}) := \sum_{i=1}^{n} \|\mathbf{x}_i - \boldsymbol{\mu}_{C(i)}\|_2^2$$

se denomina *función de distorsión*; mide la pérdida de fidelidad al representar cada observación $\mathbf{x}_i$ por su centroide $\boldsymbol{\mu}_{C(i)}$, donde $\boldsymbol{\mu} = (\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K)$ son centroides libres en $\mathbb{R}^p$, no necesariamente las medias $\bar{\mathbf{x}}_k$ de los clusters. El algoritmo de K-medias realiza exactamente un descenso por coordenadas de J. En primer lugar, se minimiza J con respecto a C manteniendo $\boldsymbol{\mu}$ fijo, y luego se minimiza J con respecto a $\boldsymbol{\mu}$ manteniendo C fijo.[1]

Conviene comparar esto con la estimación por máxima verosimilitud de la sección anterior,

donde también se optimizó alternando dos bloques y bastó una sola pasada. La diferencia no está en que allá un bloque no dependiera del otro: en $J(x,y)=(x-y)^2+(x-2)^2$ cada bloque depende del otro y, sin embargo, al sustituir $\hat{x}(y)=\frac{y+2}{2}$ queda $\frac{1}{2}(y-2)^2$, que se minimiza sin iterar. Lo que decide es si el problema *reducido* se puede resolver: la identidad $\inf_{C,\boldsymbol{\mu}} J = \inf_C \left(\inf_{\boldsymbol{\mu}} J\right)$ vale siempre, pero en K-medias, una vez sustituidos los centroides óptimos, lo que queda es minimizar sobre todas las asignaciones C, es decir el problema combinatorio intratable del que partimos. Por eso hay que iterar.

Para C fijo, J es convexa en $\boldsymbol{\mu}$; la dificultad aparece al minimizar también en C. La función reducida

$$\widetilde{W}(\boldsymbol{\mu}) = \sum_{i=1}^{n} \min_{k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2$$

es un mínimo puntual de funciones convexas y en general no es convexa, por lo que no está garantizado alcanzar un mínimo global. Aun así, K-medias funciona bien y produce agrupamientos muy buenos. Sin embargo, si se teme que el algoritmo quede atrapado en un mínimo local, una práctica común es ejecutar K-medias varias veces, usando diferentes valores iniciales para los centroides y, luego, entre todas las agrupaciones obtenidas, se elige aquella que tenga el menor valor de la distorsión J.[2]

> Verifique que $\widetilde{W}$ no es convexa. *Ayuda: tome $p=1$, $K=2$ y el conjunto $\{0,10\}$, y compare el valor de $\widetilde{W}$ en $(0,10)$ y en $(10,0)$ con el que toma en el punto medio de ambos.*

Algoritmo K-medias

Dado un conjunto de *centroides iniciales* $\{\boldsymbol{\mu}_1^{(0)},\dots,\boldsymbol{\mu}_K^{(0)}\}\subset\mathbb{R}^p$:

$t \leftarrow 0$.

repetir

Calcular, para todo $i=1,\dots,n$, la asignación

$$C^{(t+1)}(i) = \arg\min_{j} \|\mathbf{x}_i - \boldsymbol{\mu}_j^{(t)}\|_2^2.$$

Actualizar, para todo $j=1,\dots,K$, el centroide mediante

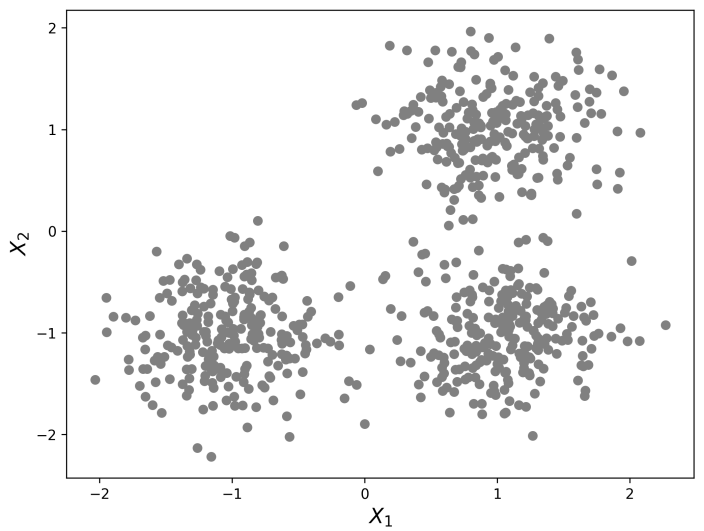
$$\boldsymbol{\mu}_j^{(t+1)} = \frac{\sum_{i=1}^{n} \mathbf{1}\{C^{(t+1)}(i)=j\}\,\mathbf{x}_i}{\sum_{i=1}^{n} \mathbf{1}\{C^{(t+1)}(i)=j\}}.$$

$t \leftarrow t+1$.

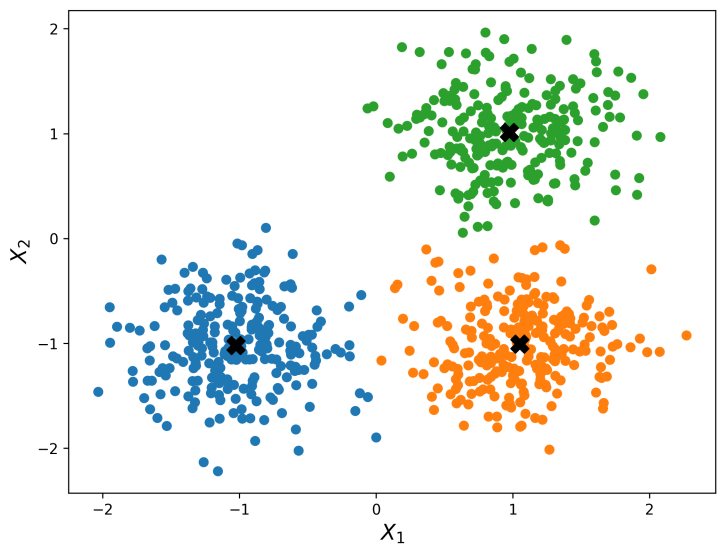
hasta *que el criterio de parada se satisfaga.*

Ejemplo 3.2.1: K-medias en datos simulados

Vamos a ver cómo evoluciona el agrupamiento del algoritmo de K-medias para el siguiente conjunto de datos simulados.



Considerando $K = 3$, al cabo de 4 iteraciones ya se logra convergencia en el algoritmo, con valor de la función de distorsión $J = 226.57$.



II | Mezcla de Gaussianas (GMM)

Los modelos de mezcla asumen que la función de densidad de $\mathbf{X} \in \mathbb{R}^p$ es de la forma

$$p(\mathbf{x}) = \sum_{k=1}^{K} \phi_k f(\mathbf{x} \mid \boldsymbol{\theta}_k), \tag{3.2.3}$$

donde $\phi_k \geq 0$ son pesos que verifican $\sum_{k=1}^{K} \phi_k = 1$ y $f(\mathbf{x} \mid \boldsymbol{\theta}_k)$ es la función de densidad de la componente k, parametrizada por $\boldsymbol{\theta}_k$.

El modelo de mezcla más popular es GMM (*Gaussian Mixture Model*), que surge de considerar

$$f(\mathbf{x} \mid \boldsymbol{\mu}_k, \Sigma_k) = \frac{1}{(2\pi)^{p/2}|\Sigma_k|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_k)^\top \Sigma_k^{-1}(\mathbf{x}-\boldsymbol{\mu}_k)\right\}.$$

Esta formulación puede describirse probabilísticamente mediante una *variable latente* $Z \in \{1, \ldots, K\}$, que indica a qué componente pertenece cada observación, de la siguiente manera.

Supuestos del modelo

$$Z \sim \text{Multinomial}(1, \boldsymbol{\phi})$$
$$\mathbf{X} \mid Z = k \sim \mathcal{N}(\boldsymbol{\mu}_k, \Sigma_k)$$

Los parámetros del modelo son $\boldsymbol{\phi}$, $\boldsymbol{\mu}_k$ y Σ_k. Observar que la densidad marginal de $\mathbf{X}$ tiene precisamente la forma (3.2.3), ya que la ley de la probabilidad total permite escribir

$$p(\mathbf{x}) = \sum_{k=1}^{K} \mathbb{P}(Z=k) f(\mathbf{x} \mid Z=k) = \sum_{k=1}^{K} \phi_k f(\mathbf{x} \mid \boldsymbol{\mu}_k, \Sigma_k)$$

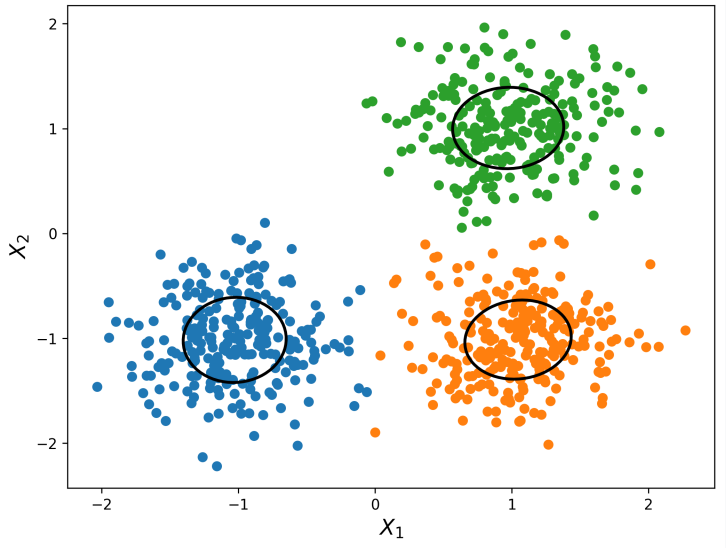
Para un conjunto de datos $\{\mathbf{x}_i\}_{i=1}^n$, la función de log-verosimilitud es

$$\ell(\boldsymbol{\phi}, \boldsymbol{\mu}, \Sigma) = \sum_{i=1}^{n} \log p(\mathbf{x}_i \mid \boldsymbol{\phi}, \boldsymbol{\mu}, \Sigma) = \sum_{i=1}^{n} \log \sum_{k=1}^{K} \phi_k \, p(\mathbf{x}_i \mid \boldsymbol{\mu}_k, \Sigma_k).$$

La optimización directa de esta función no es posible, ya que la suma dentro del logaritmo impide obtener una forma cerrada para los estimadores de máxima verosimilitud. Además, la variable latente Z no es observable, lo que complica aún más dicha tarea. En consecuencia, es necesario recurrir a un algoritmo iterativo para la estimación. En particular, el algoritmo *Expectation-Maximization* (EM) ofrece una forma práctica y eficiente de pasos alternados. Nos enfocaremos en dicho algoritmo en la próxima sección.

Ejemplo 3.2.2: GMM en datos simulados

Aplicaremos GMM a los mismos datos del ejemplo anterior, utilizando 3 componentes.



III | DBSCAN

Los métodos de clustering basado en densidad identifican grupos de observaciones como regiones densas del espacio de datos, separadas por áreas donde los puntos son escasos. Esto permite detectar clusters de forma arbitraria, no necesariamente esféricos, y además identificar puntos aislados o ruido que no pertenecen a ningún cluster.

Uno de los métodos más conocidos es DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*), el cual define un vecindario de radio $\varepsilon > 0$ alrededor de cada punto y considera *densos* aquellos puntos cuyo vecindario contiene al menos un número mínimo de puntos. Los puntos que cumplen esta condición se denominan *objetos núcleos* y sirven como semilla para formar clusters. Es importante remarcar que la idea de *vecindario* requiere trabajar con una métrica $d : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}$.

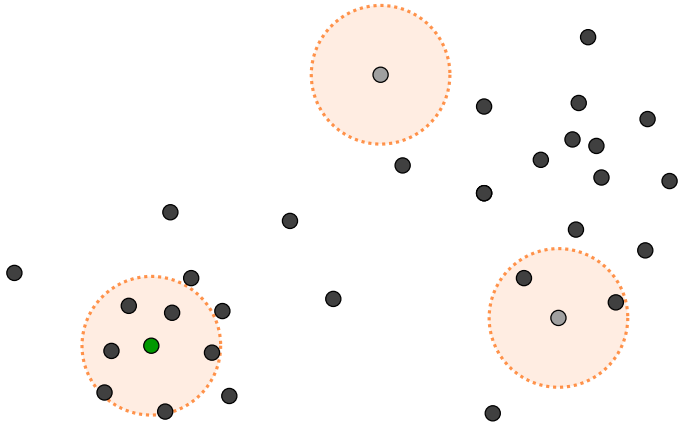


Figura 3.2.1: Interpretación geométrica de objetos núcleos (en verde) y objetos no núcleos (en gris), considerando un número mínimo de 3 vecinos.

Las siguientes definiciones son la base del método:

- Dos objetos núcleos $\mathbf{p}_1$ y $\mathbf{p}_2$ son *ε-alcanzables* si $d(\mathbf{p}_1, \mathbf{p}_2) < \varepsilon$.
- Dos objetos núcleos $\mathbf{p}_1$ y $\mathbf{p}_2$ están *conectados por densidad* si, o bien son ε-alcanzables, o bien existen objetos núcleos $\mathbf{r}_1, \ldots, \mathbf{r}_l$ tales que $\mathbf{p}_1$ y $\mathbf{r}_1$ son ε-alcanzables, $\mathbf{r}_i$ y $\mathbf{r}_{i+1}$ $(1 \leq i < l)$ son ε-alcanzables, y $\mathbf{r}_l$ y $\mathbf{p}_2$ son ε-alcanzables.

En base a esto, se define la noción de cluster para el método DBSCAN.

Dado $\varepsilon > 0$ y un mínimo de puntos, un cluster C es un subconjunto no vacío y maximal de objetos núcleos tal que cada par de puntos en C están conectados por densidad.

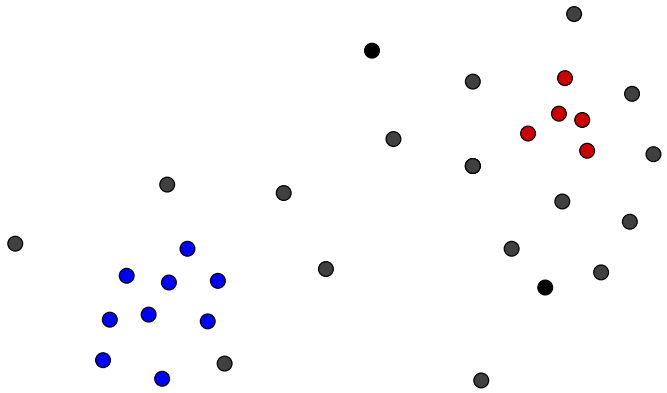


Figura 3.2.2: Clusters formados por objetos núcleos de un conjunto de puntos.

Observar que un cluster contiene únicamente objetos núcleos. Para el resto de los puntos se procede de la siguiente manera:

- Un *objeto de frontera* es un punto que no es núcleo, pero que se encuentra dentro del vecindario de al menos un objeto núcleo. Los objetos de frontera se asignan al cluster correspondiente al objeto núcleo del cual son vecinos.
- Un *ruido* es un punto que no pertenece al vecindario de ningún objeto núcleo y, por lo tanto, no se asigna a ningún cluster.

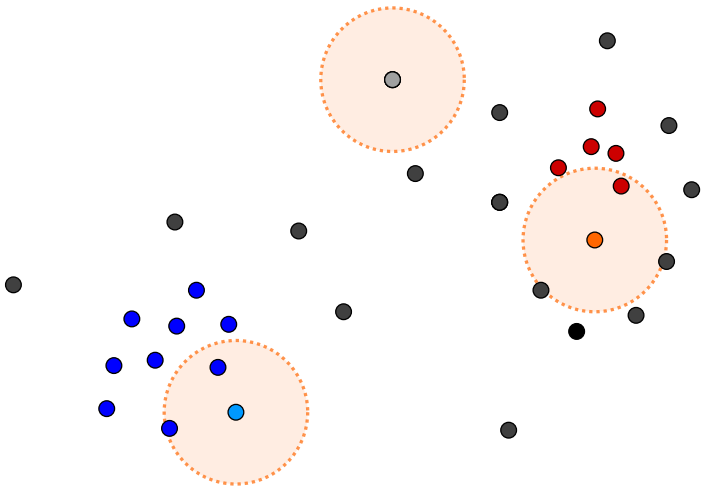


Figura 3.2.3: Interpretación geométrica de objetos frontera (uno por cada cluster) y ruidos (en gris), considerando un número mínimo de 3 vecinos.

A diferencia de K-medias, DBSCAN no requiere fijar de antemano el número de clusters: éste queda determinado por los datos a través de los hiperparámetros ε y el mínimo de puntos. A cambio, el resultado es sensible a esa elección, y el método tiene dificultades cuando los clusters presentan densidades muy distintas, ya que un mismo ε debe servir para todos. Su ventaja

principal es que, al no medir distancias a centroides, recupera clusters de forma arbitraria y además distingue las observaciones atípicas en lugar de forzar su asignación.

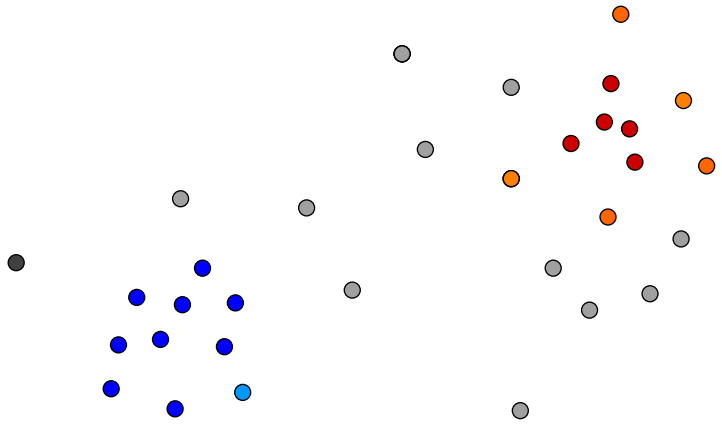
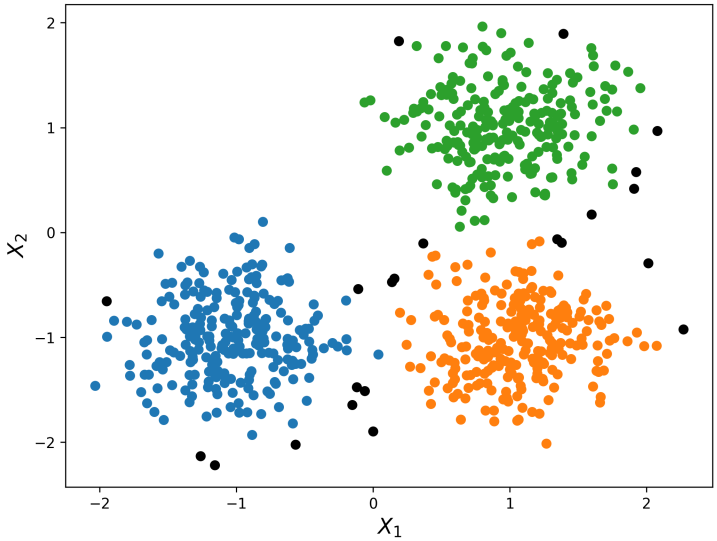


Figura 3.2.4: Agrupamiento obtenido por DBSCAN. Los hiperparámetros son $\varepsilon > 0$ y el número mínimo de vecinos.

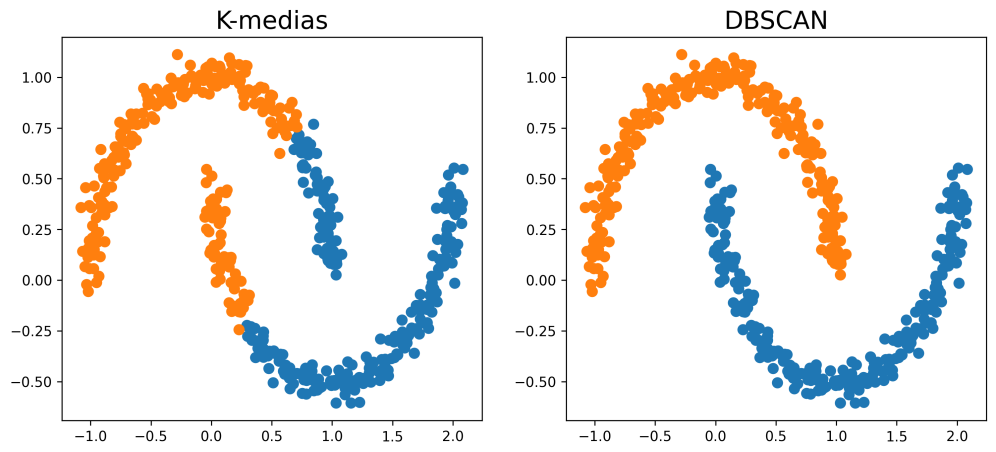
Ejemplo 3.2.3: DBSCAN en datos simulados

Aplicaremos DBSCAN a los mismos datos de los ejemplos anteriores. Utilizaremos un valor de ε adecuado que permita distinguir al menos 3 clusters.



Ejemplo 3.2.4: K-medias y DBSCAN en datos no esféricos

En este ejemplo aplicamos DBSCAN a un conjunto de datos con estructura no esférica. Este tipo de geometría es difícil de separar con métodos como K-medias.



Referencias

Han, J., Kamber, M. & Pei, J. (2012). *Data Mining: Concepts and Techniques*. 3rd ed. Waltham, MA: Morgan Kaufmann.

Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2nd ed. Springer Series in Statistics. New York: Springer.

Ng, A. (2022). *Stanford CS229: Machine Learning*. Lecture notes. Stanford University. URL: https://cs229.stanford.edu/notes2022fall/main_notes.pdf.