

Guía de actividades

2.2: Regresión lineal y regresión logística

 Actividades computacionales

1. Implemente la clase `myLinearRegression` que permita aplicar regresión lineal sobre datos de regresión multivariada. La clase debe recibir como parámetros el método a utilizar (solución explícita o descenso por gradiente) y, en caso de utilizar descenso por gradiente, la tasa de aprendizaje y el número de iteraciones. Asegúrese que la clase:
 - Considere el término de *bias* en los parámetros del modelo.
 - Devuelva la predicción del modelo para nuevas muestras.
 - En el caso de descenso por gradiente, almacene la evolución del costo a lo largo de las iteraciones.
2. Implemente la clase `myLogisticRegression` que permita aplicar regresión logística en datos de clasificación binaria. La clase debe recibir como parámetros el método a utilizar (descenso por gradiente o método de Newton), la tasa de aprendizaje y el número de iteraciones. Asegúrese que la clase:
 - Considere el término de *bias* en los parámetros del modelo.
 - Devuelva la predicción del modelo (probabilidad y etiqueta) para nuevas muestras.
 - Almacene la evolución del costo a lo largo de las iteraciones para ambos métodos de optimización.
3. Utilice la clase `myLinearRegression` para resolver un problema de regresión sobre el conjunto de datos `load.diabetes` de `scikit-learn`.

El dataset `load.diabetes` contiene información clínica de 442 pacientes, descritos mediante 10 variables fisiológicas (entre ellas edad, sexo, índice de masa corporal y presión arterial), todas estandarizadas. La variable respuesta es una medida cuantitativa de la progresión de la diabetes un año después de la línea de base.

- a. Divida los datos en conjuntos de entrenamiento y prueba (*train-test*), entrene el modelo con ambos métodos disponibles (solución analítica y descenso por gradiente) y reporte el error cuadrático medio (MSE) obtenido en cada conjunto. Para el caso de descenso por gradiente, grafique la evolución del costo en función del número de iteraciones.
- b. Compare los coeficientes estimados por `myLinearRegression` (ambos métodos) con los obtenidos mediante `LinearRegression` de `scikit-learn`, e indique si existen diferencias relevantes.

4. Utilice la clase `myLogisticRegression` para resolver un problema de clasificación binaria sobre el conjunto de datos `spector` de `statsmodels`.

El dataset `spector`, proveniente de un estudio sobre métodos de enseñanza en economía, contiene 32 observaciones de estudiantes descritos por tres variables: promedio académico (`GPA`), puntaje en un examen previo al curso (`TUCE`) y una variable binaria que indica si el estudiante fue expuesto a un método de enseñanza personalizado (`PSI`). La variable respuesta indica si el estudiante mejoró su calificación final en el curso.

- a. Ajuste el modelo sobre la totalidad de los datos utilizando ambos métodos de optimización disponibles, y compare los coeficientes obtenidos con los de un modelo equivalente de `statsmodels`.
- b. Dado el tamaño reducido del conjunto de datos, evalúe el modelo mediante validación *leave-one-out* y reporte el *accuracy* promedio obtenido.
- c. Compare la convergencia de ambos métodos de optimización graficando la evolución del costo en función del número de iteraciones, y discuta las diferencias observadas.