

Guía de actividades

2.3: Modelos lineales generalizados

Actividades conceptuales

1. Sea $\{y_1, \dots, y_n\}$ una muestra i.i.d. de $Y \sim \text{Exponencial}(\mu)$, con $\mu > 0$. La función de densidad es

$$p(y | \mu) = \frac{1}{\mu} e^{-y/\mu}, \quad y \geq 0,$$

con $E[Y] = \mu$ y $\text{Cov}[Y] = \mu^2$.

- Muestre que esta distribución pertenece a la familia exponencial e identifique el parámetro natural η , el estadístico suficiente $T(y)$ y la función de partición $A(\eta)$.
 - Derive el estimador de máxima verosimilitud (MLE) de μ .
2. A partir de la distribución Exponencial de la actividad anterior, formule el modelo lineal generalizado correspondiente.
- Indique la función de enlace canónica.
 - Escriba la función de log-verosimilitud para una muestra.
3. Escriba el algoritmo IRLS correspondiente al modelo de regresión Exponencial con enlace canónico. Indique explícitamente las expresiones de la media μ , la matriz de pesos W y la pseudo-respuesta $\mathbf{z}$. Finalmente, presente la fórmula de actualización de los parámetros.
4. Repita el ejercicio anterior para el modelo de regresión de Poisson con enlace canónico.

Actividades computacionales

- Implemente la clase `myIRLS` que permita aplicar el algoritmo IRLS para el ajuste de modelos lineales generalizados. La clase debe recibir como parámetro la familia del modelo a utilizar (regresión logística o regresión de Poisson) y a partir de la elección construir internamente μ , W y $\mathbf{z}$.
- Genere datos sintéticos a partir del modelo probabilístico correspondiente, tanto para regresión logística como para regresión de Poisson, y utilícelos para evaluar la clase `myIRLS`.
 - Compare los coeficientes estimados por `myIRLS` con los obtenidos mediante GLM de `statsmodels`, para ambas familias consideradas.

- b.** Para el caso de regresión logística, compare el rendimiento de `myIRLS` contra el algoritmo `myLogisticRegression` (con gradiente descendente) en términos de convergencia, tiempo de ejecución y calidad de las soluciones obtenidas.
- 3.** Implemente la clase `mySoftmaxRegression` que permita aplicar regresión softmax en datos de clasificación multiclase. La clase debe recibir como parámetros la tasa de aprendizaje y el número de iteraciones. Asegúrese que la clase:
 - Considere el término de *bias* en los parámetros del modelo.
 - Devuelva la predicción del modelo (probabilidades y etiqueta) para nuevas muestras.
 - Almacene la evolución del costo a lo largo de las iteraciones.
- 4.** Utilice la clase `mySoftmaxRegression` para resolver un problema de clasificación multiclase sobre el conjunto de datos `load_wine` de `scikit-learn`:
 - a.** Divida los datos en `train-test`, y reporte el *accuracy* obtenido en ambos.
 - b.** Compare los coeficientes y/o las predicciones obtenidas con las de un modelo equivalente de `scikit-learn`.
 - c.** Seleccione dos *features* del conjunto de datos, entrene nuevamente el modelo utilizando únicamente dichas *features*, y grafique las fronteras de decisión obtenidas.