

## Guía de actividades

## 2.3: Modelos lineales generalizados

 Actividades conceptuales

1. Sea  $\{y_1, \dots, y_n\}$  una muestra i.i.d. de  $Y \sim \text{Exponencial}(\mu)$ , con  $\mu > 0$ . La función de densidad es

$$p(y | \mu) = \frac{1}{\mu} e^{-y/\mu}, \quad y \geq 0,$$

con  $E[Y] = \mu$  y  $\text{Cov}[Y] = \mu^2$ .

- a. Muestre que esta distribución pertenece a la familia exponencial e identifique el parámetro natural  $\eta$ , el estadístico suficiente  $T(y)$  y la función de partición  $A(\eta)$ .
  - b. Derive el estimador de máxima verosimilitud (MLE) de  $\mu$ .
2. A partir de la distribución Exponencial de la actividad anterior, formule el modelo lineal generalizado correspondiente.
- Indique la función de enlace canónica.
  - Escriba la función de log-verosimilitud para una muestra.
3. Escriba el algoritmo IRLS correspondiente al modelo de regresión Exponencial con enlace canónico. Indique explícitamente las expresiones de la media  $\mu$ , la matriz de pesos  $W$  y la pseudo-respuesta  $\mathbf{z}$ . Finalmente, presente la fórmula de actualización de los parámetros.
4. Repita el ejercicio anterior para el modelo de regresión de Poisson con enlace canónico.

 Actividades computacionales

1. Implemente la clase `myIRLS` que permita aplicar el algoritmo IRLS para el ajuste de modelos lineales generalizados. La clase debe recibir como parámetro la familia del modelo a utilizar (regresión logística o regresión de Poisson) y a partir de la elección construir internamente  $\mu$ ,  $W$  y  $\mathbf{z}$ .
2. Genere datos sintéticos a partir del modelo probabilístico correspondiente, tanto para regresión logística como para regresión de Poisson, y utilícelos para evaluar la clase `myIRLS`.
  - a. Compare los coeficientes estimados por `myIRLS` con los obtenidos mediante GLM de `statsmodels`, para ambas familias consideradas.

- b.** Para el caso de regresión logística, compare el rendimiento de `myIRLS` contra el algoritmo `myLogisticRegression` (con gradiente descendente) en términos de convergencia, tiempo de ejecución y calidad de las soluciones obtenidas.
- 3.** Implemente la clase `mySoftmaxRegression` que permita aplicar regresión softmax en datos de clasificación multiclase. La clase debe recibir como parámetros la tasa de aprendizaje y el número de iteraciones. Asegúrese que la clase:
  - Considere el término de *bias* en los parámetros del modelo.
  - Devuelva la predicción del modelo (probabilidades y etiqueta) para nuevas muestras.
  - Almacene la evolución del costo a lo largo de las iteraciones.
- 4.** Utilice la clase `mySoftmaxRegression` para resolver un problema de clasificación multiclase sobre el conjunto de datos `load_wine` de `scikit-learn`:
  - a.** Divida los datos en `train-test`, y reporte el *accuracy* obtenido en ambos.
  - b.** Compare los coeficientes y/o las predicciones obtenidas con las de un modelo equivalente de `scikit-learn`.
  - c.** Seleccione dos *features* del conjunto de datos, entrene nuevamente el modelo utilizando únicamente dichas *features*, y grafique las fronteras de decisión obtenidas.