Guía de actividades

2.4: Métodos de regularización

Actividades conceptuales

1. A partir de la derivación de descenso por coordenadas para Lasso vista en la teoría, extienda el procedimiento para obtener la regla de actualización por coordenada correspondiente a Elastic Net.

2. El estimador de máxima verosimilitud (MLE), utilizado hasta ahora, busca los valores de los parámetros que mejor explican los datos observados, sin incorporar información a priori sobre dichos parámetros. Otra estrategia de estimación es *máximo a posteriori* (MAP), la cual incorpora una distribución de probabilidad *a priori* $p(\boldsymbol{\theta})$ que expresa qué valores de los parámetros se consideran más plausibles antes de observar los datos. De esta manera, el MAP combina la información aportada por los datos con las creencias previas sobre los parámetros. A partir del teorema de Bayes, el estimador MAP se define como

$$\hat{\boldsymbol{\theta}}_{\text{MAP}} = \arg\max_{\boldsymbol{\theta}} p(y \mid \mathbf{x}, \boldsymbol{\theta})\, p(\boldsymbol{\theta}).$$

   En particular, veremos que la elección de ciertas distribuciones *a priori* conduce a los métodos de regularización estudiados. Demuestre que:

   a. La solución de Ridge equivale al estimador MAP bajo un prior Gaussiano $\boldsymbol{\theta} \sim \mathcal{N}(\mathbf{0}, \tilde{\sigma}^2 I)$. Interprete qué creencia sobre los coeficientes expresa este prior y cómo influye su varianza $\tilde{\sigma}^2$ en la intensidad de la regularización.

   b. La solución de Lasso equivale al estimador MAP bajo un prior Laplaciano $\theta_j \sim \text{Laplace}(0, b)$, independiente e idénticamente distribuido para cada parámetro. Interprete qué creencia sobre los coeficientes expresa este prior, compárela con la del prior Gaussiano utilizado en Ridgeen a e indique cómo influye el parámetro de escala b en la intensidad de la regularización.

   Aclaración: las funciones de densidad de las distribuciones Gaussiana multivariada y Laplaciana univariada son, respectivamente,

$$p(\boldsymbol{\theta}) = \frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\mu})^\top \Sigma^{-1} (\boldsymbol{\theta} - \boldsymbol{\mu})\right),$$

$$p(\theta) = \frac{1}{2b} \exp\left(-\frac{|\theta - \mu|}{b}\right),$$

   donde $\boldsymbol{\mu} \in \mathbb{R}^p$ y $\Sigma \in \mathbb{R}^{p \times p}$ son el vector de medias y la matriz de covarianza de la distribución Gaussiana, mientras que μ y b son los parámetros de localización y escala de la distribución de Laplace.

Actividades computacionales

1. Implemente la clase `myElasticNet` que permita aplicar regresión lineal con penalización Elastic Net, utilizando el algoritmo de descenso por coordenadas para el ajuste. La clase debe recibir como parámetros la intensidad de las penalizaciones λ_1 y λ_2, donde $\lambda_1 = 0$ corresponde a Ridge puro y $\lambda_2 = 0$ a Lasso puro. Asegúrese que la clase:
   - No penalice el término de *bias*.
   - Devuelva la predicción del modelo para nuevas muestras.
   - Almacene la evolución del costo a lo largo de las iteraciones.

2. Implemente la clase `myLogisticRegressionElasticNet` que permita aplicar regresión logística con penalización Elastic Net mediante descenso por gradiente. Asegúrese que la clase:
   - No penalice el término de *bias*.
   - Devuelva la predicción del modelo (probabilidad y etiqueta) para nuevas muestras.
   - Almacene la evolución del costo a lo largo de las iteraciones.

3. Utilice la clase `myElasticNet` para resolver un problema de regresión sobre el conjunto de datos `load_diabetes` de `scikit-learn`.

   > *Este dataset contiene información clínica de 442 pacientes descritos mediante 10 variables fisiológicas (entre ellas edad, sexo, índice de masa corporal y presión arterial), todas estandarizadas. La variable de respuesta es una medida cuantitativa de la progresión de la diabetes un año después de la línea de base.*

   a. Seleccione el valor de λ_1 y λ_2 mediante validación cruzada. Luego, divida los datos en `train-test`, y reporte el error obtenido con los hiperparámetros seleccionados.
   b. Compare el error obtenido con el de la regresión lineal sin regularización ajustada en la Guía 2.2 sobre el mismo conjunto de datos, y discuta el efecto de la penalización.
   c. Compare los resultados obtenidos con los de un modelo equivalente de `scikit-learn`, e indique si existen diferencias relevantes.

4. Utilice `myLogisticRegressionElasticNet` para resolver un problema de clasificación binaria sobre el conjunto de datos `load_breast_cancer` de `scikit-learn`:

   > *El dataset `load_breast_cancer` contiene 569 muestras de tumores de mama, descritos por 30 variables numéricas que caracterizan propiedades geométricas y texturales de los núcleos celulares (radio, textura, perímetro, área, suavidad, entre otras), calculadas a partir de imágenes de biopsias. La variable de respuesta indica si el tumor es maligno (0) o benigno (1). Dado que varias de estas variables miden aspectos relacionados entre sí (por ejemplo, radio, perímetro y área están fuertemente correlacionadas), este dataset es especialmente adecuado para estudiar el efecto de la regularización sobre features correlacionadas.*

a. Analice la correlación entre las *features* del conjunto de datos. Identifique grupos de variables altamente correlacionadas y discuta qué comportamiento esperaría observar en los coeficientes al aplicar Ridge vs Lasso.

b. Seleccione el valor de λ_1 y λ_2 mediante validación cruzada. Luego, divida los datos en `train-test`, y reporte el *accuracy* obtenido con los hiperparámetros seleccionados.

c. Compare los coeficientes obtenidos con los de un modelo equivalente de `scikit-learn`, e indique si existen diferencias relevantes.

d. Grafique la magnitud de los coeficientes obtenidos junto con los del modelo sin regularización. Discuta el efecto de la penalización sobre las variables correlacionadas identificadas en el primer ítem: ¿distribuye Elastic Net el peso de manera uniforme entre ellas, o tiende a seleccionar una y anular las demás?