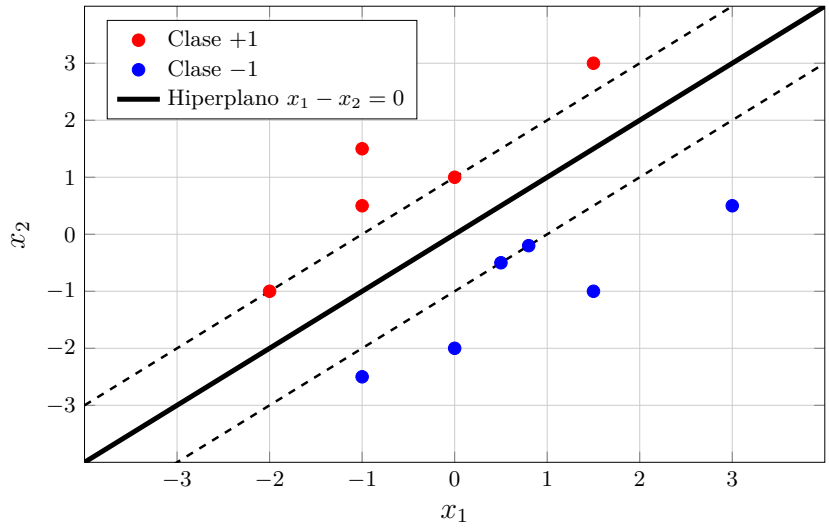
Guía de actividades

2.5: Máquinas de vectores soporte

Actividades conceptuales

1. La siguiente figura muestra la frontera de decisión obtenida al aplicar un clasificador SVM lineal a un problema de clasificación binaria.



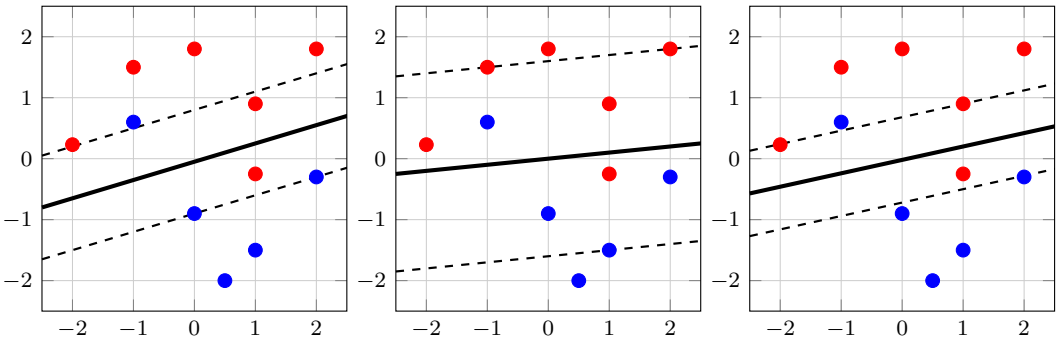
a. Liste los vectores soporte.

b. Seleccione dos observaciones y calcule sus distancias al hiperplano $x_1 - x_2 = 0$.

c. Si se elimina la observación $(0, 1)$, ¿cambiaría la frontera de decisión? ¿Qué sucede si en cambio se elimina la muestra $(-1, -2.5)$?

d. Si se agrega una nueva observación $(2, 0.5)$ con etiqueta positivo, ¿es posible que las clases sigan siendo linealmente separables? ¿Qué variante de SVM utilizaría si ya no fuera posible separarlas linealmente?

2. La siguiente figura muestra los resultados de aplicar un SVM lineal con margen suave a un mismo conjunto de datos, variando el valor del hiperparámetro C.



a. Ordene las figuras según los valores de C utilizados para obtener cada solución (de manera creciente), justificando brevemente su elección.

b. Identifique en cada caso cuáles son los vectores soporte.

c. Para cada solución, analice los valores de λ_i, μ_i y ξ_i de las observaciones, e indique qué representan y qué relaciones deben satisfacer según las condiciones KKT.

3. Considere el problema de optimización de SVM *soft-margin* visto en clase:

$$\begin{array}{ll} \text{minimizar} & \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 + C\sum_{i=1}^n \xi_i \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1 - \xi_i,\ \boldsymbol{\xi} \succeq \mathbf{0}, \end{array} \tag{1}$$

donde $C > 0$.

a. Justifique por qué (1) puede ser reformulado como

$$\text{minimizar} \quad \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 + C\sum_{i=1}^n \max\left\{0, 1 - y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0)\right\}.$$

b. Para cada uno de los siguientes valores de $y_i f(\mathbf{x}_i)$, determine el valor óptimo de la holgura ξ_i, indique si la observación está correctamente clasificada y describa su posición respecto del margen: 2.3, 1, 0.6, 0, -0.3, -1.8.

c. Suponga que se entrenó un SVM con un conjunto de datos de entrenamiento. Para cada una de las siguientes modificaciones, determine si la frontera de decisión permanece igual. En cada caso, suponga que tras la modificación queda al menos un punto de cada clase en el conjunto de entrenamiento, y justifique su respuesta utilizando figuras cuando sea pertinente.

- Eliminar los datos con margen mayor a 1.
- Eliminar los datos con margen menor a 1.
- Escalar los datos $\mathbf{x}_i$ por un factor constante α.

d. Una variante de (1) es utilizar la norma ℓ_2 en el término de regularización, lo cual deriva en:

$$\begin{array}{ll} \text{minimizar} & \frac{1}{2}\|\boldsymbol{\beta}\|_2^2 + C\sum_{i=1}^n \xi_i^2 \\ \text{sujeto a} & y_i(\boldsymbol{\beta}^\top \mathbf{x}_i + \beta_0) \geq 1 - \xi_i. \end{array}$$

Determine las condiciones KKT y justifique por qué no es necesario incluir la restricción $\boldsymbol{\xi} \succeq \mathbf{0}$.

Actividades computacionales

1. Implemente la clase `mySVM` que permita ajustar un clasificador SVM con margen suave. La clase debe recibir como parámetros el hiperparámetro de regularización C y el tipo de kernel a utilizar. Asegúrese que la clase:

- Resuelva el problema dual mediante `cvxpy`.
- Identifique y almacene los vectores soporte y sus multiplicadores de Lagrange.
- Devuelva la predicción del modelo (valor de decisión y etiqueta de clase) para nuevas muestras.

2. Utilice la clase `mySVM` para resolver un problema de clasificación binaria sobre el conjunto de datos `heart` del repositorio UCI.

> *El dataset* **`heart`** *contiene 303 pacientes descritos por 13 variables clínicas y fisiológicas (entre ellas edad, sexo, tipo de dolor torácico, presión arterial en reposo, colesterol sérico y frecuencia cardíaca máxima alcanzada durante una prueba de esfuerzo), y la variable de respuesta indica presencia (1) o ausencia (0) de enfermedad cardíaca. Por lo tanto, se trata de un problema de clasificación binaria.*

Para el análisis utilice únicamente dos *features*: la edad del paciente (`age`) y la frecuencia cardíaca máxima alcanzada (`thalach`), de modo que las fronteras de decisión puedan visualizarse en el plano.

a. Divida los datos en conjuntos de entrenamiento y prueba (*train-test*), estandarice las *features* y entrene `mySVM` con kernel lineal para distintos valores de $C \in \{0.01, 0.1, 1, 10, 100\}$. Para cada valor de C, reporte el *accuracy* en test y el número de vectores soporte obtenidos, y grafique la frontera de decisión junto con los márgenes y los vectores soporte. Discuta cómo varía el número de vectores soporte al modificar C.

b. Repita el experimento utilizando kernel RBF. Explore distintas combinaciones de C y γ y compare las fronteras de decisión obtenidas con las del kernel lineal.

c. Compare los coeficientes y el *accuracy* de `mySVM` (kernel lineal, $C = 1$) con los de `SVC` de `scikit-learn` con los mismos parámetros, e indique si existen diferencias relevantes.

d. Usando el mejor modelo encontrado, analice los vectores soporte obtenidos a partir de sus multiplicadores de Lagrange: distinga aquellos que se encuentran exactamente sobre el margen de los que violan el margen o están mal clasificados. Relacione el número total de vectores soporte con el valor de C utilizado.