Guía de actividades

3.1: Modelos generativos para clasificación

Actividades conceptuales

1. Sea $\mathbf{X} \in \mathbb{R}^{r+s}$ un vector aleatorio con distribución $\mathcal{N}(\boldsymbol{\mu}, \Sigma)$, particionado en bloques como

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix}, \qquad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \qquad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix},$$

con $\mathbf{X}_1 \in \mathbb{R}^r$ y $\mathbf{X}_2 \in \mathbb{R}^s$.

a. Desarrollando el producto que define $\mathrm{Cov}[\mathbf{X}]$, verifique que $\mathbb{E}[\mathbf{X}_1] = \boldsymbol{\mu}_1$ y $\mathrm{Cov}[\mathbf{X}_1] = \Sigma_{11}$.

b. Considere el caso $r = s = 1$, con $\boldsymbol{\mu} = (0, 0)$ y

$$\Sigma = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \qquad |\rho| < 1.$$

Escriba explícitamente la media y la varianza de $X_1 \mid X_2 = x_2$. ¿Qué ocurre cuando $\rho \to 0$? ¿Y cuando $|\rho| \to 1$?

c. Muestre que $\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \succeq 0$ y concluya que $\Sigma_{1|2} \preceq \Sigma_{11}$, es decir, que condicionar nunca aumenta la incertidumbre sobre $\mathbf{X}_1$. ¿En qué caso vale la igualdad?

2. Considere el modelo LDA asociado a un problema de clasificación binaria con $\mathbf{X} \in \mathbb{R}^2$ y clases $Y \in \{1, 2\}$ balanceadas. Suponga que los parámetros estimados son

$$\hat{\boldsymbol{\mu}}_1 = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \qquad \hat{\boldsymbol{\mu}}_2 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}, \qquad \hat{\Sigma} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

a. Obtenga la regla de clasificación y la frontera de decisión. Represéntela geométricamente junto con los puntos

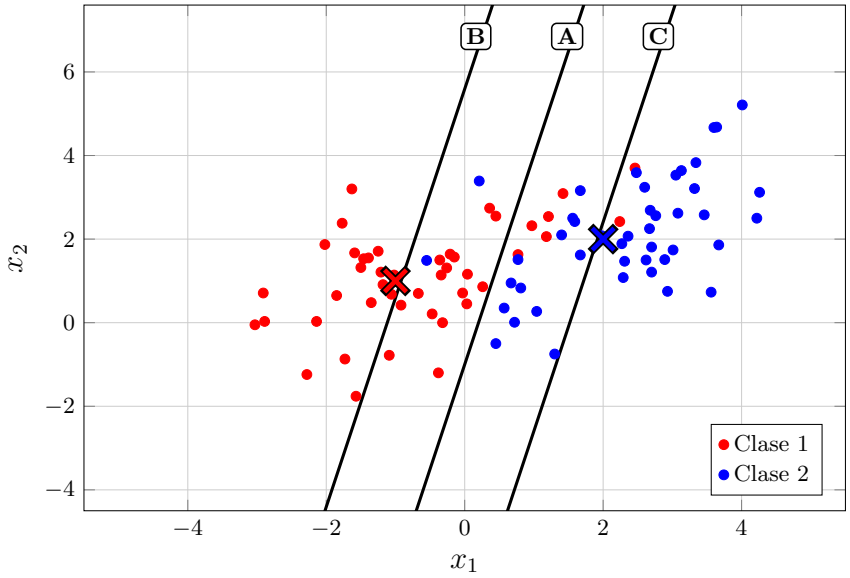
$$\mathbf{x}_1 = (0, 0), \qquad \mathbf{x}_2 = (1, 0), \qquad \mathbf{x}_3 = (1, 4),$$

y clasifique cada uno de ellos. Interprete el resultado obtenido para $\mathbf{x}_3$.

b. Suponga ahora que las clases dejan de estar balanceadas, con $\mathbb{P}(Y = 1) = \pi$ y $\mathbb{P}(Y = 2) = 1 - \pi$. Indique cómo se modifica la frontera hallada en el ítem anterior y calcule el desplazamiento en la dirección de $\boldsymbol{\beta}$. ¿Hacia qué clase se corre la frontera cuando una de ellas se vuelve más probable?

c. La siguiente figura muestra, sobre una muestra simulada de ambas clases, las fronteras de decisión obtenidas para tres valores distintos de π, identificadas como A, B y C. Ordene

las tres según el valor de π que las generó, de menor a mayor, justificando brevemente a partir del resultado del ítem anterior.



d. Vuelva al caso general con k clases balanceadas y suponga $\Sigma = \sigma^2 I$. Muestre que la regla de decisión se reduce a asignar $\mathbf{x}$ a la clase cuya media esté más cerca en norma euclídea, y que en ese caso coincide con la regla del modelo Naive Bayes gaussiano con varianzas comunes. ¿Con qué algoritmo que ya conoce se asocia esta regla?

3. En el modelo LDA, la distribución condicional $p(y \mid \mathbf{x})$ resulta necesariamente una función logística. La recíproca, en cambio, no es cierta: existen otras suposiciones sobre $\mathbf{X} \mid Y$ que conducen a la misma forma funcional.

a. Suponga $\mathbf{X} \mid Y = y \sim \text{Poisson}(\lambda_y)$, con $\lambda_0, \lambda_1 > 0$, y $Y \sim \text{Bernoulli}(\varphi)$. Muestre que $p(y = 1 \mid x)$ es una función logística de x, e identifique los coeficientes θ_0 y θ_1.

b. A partir de lo anterior, discuta la siguiente afirmación: *"LDA hace suposiciones más fuertes que la regresión logística; si esas suposiciones son correctas, LDA es un mejor modelo".* ¿En qué situaciones esperaría que la regresión logística funcione mejor?

4. Considere ahora el modelo QDA, que permite una matriz de covarianza distinta por clase:

$$Y \sim \text{Bernoulli}(\varphi), \qquad \mathbf{X} \mid Y = y \sim \mathcal{N}(\boldsymbol{\mu}_y, \Sigma_y), \quad y \in \{0, 1\}.$$

a. Demuestre que los MLE de los parámetros son

$$\hat{\varphi} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{1}\{y_i = 1\}, \qquad \hat{\boldsymbol{\mu}}_y = \frac{\sum_{i=1}^{n} \mathbf{1}\{y_i = y\}\, \mathbf{x}_i}{\sum_{i=1}^{n} \mathbf{1}\{y_i = y\}},$$

$$\hat{\Sigma}_y = \frac{\sum_{i=1}^{n} \mathbf{1}\{y_i = y\}(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_y)(\mathbf{x}_i - \hat{\boldsymbol{\mu}}_y)^\top}{\sum_{i=1}^{n} \mathbf{1}\{y_i = y\}}.$$

Para tener en cuenta: sean $\mathbf{x} \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times n}$ simétrica y $X, B \in \mathbb{R}^{n \times n}$. Se cumple:

- $\dfrac{\partial\,(\mathbf{x}^\top A\mathbf{x})}{\partial \mathbf{x}} = 2A\mathbf{x}$.
- $\dfrac{\partial\,\operatorname{tr}(X^{-1}B)}{\partial X} = -X^{-1}BX^{-1}$.
- $\dfrac{\partial \log|X|}{\partial X} = X^{-1}$.

b. Construya el clasificador de Bayes usando los estimadores obtenidos.

c. Encuentre la frontera de decisión e indique las diferencias con la del modelo LDA.

d. Cuente el número de parámetros libres que debe estimar cada modelo, LDA y QDA, en función de p y del número de clases k. Discuta en qué régimen de n, p y k esperaría que QDA se vuelva inestable.

5. En un estudio médico, 100 pacientes fueron clasificados en una de tres clases: **Neumonía**, **Gripe** o **Sano**. La siguiente base de datos indica cuántos pacientes en cada clase presentaron fiebre y dolor de cabeza.

Neumonía			**Gripe**			**Sano**		
F.	D.C.	Frec.	F.	D.C.	Frec.	F.	D.C.	Frec.
T	T	5	T	T	9	T	T	2
T	F	0	T	F	6	T	F	3
F	T	4	F	T	3	F	T	7
F	F	1	F	F	2	F	F	58
	Total:	**10**		**Total:**	**20**		**Total:**	**70**

Considere un paciente con fiebre pero sin dolor de cabeza.

a. ¿Qué valores asignaría a los tres diagnósticos un clasificador de Bayes que no suponga independencia entre los síntomas, es decir, que estime $\mathbb{P}(\text{Fiebre}, \text{D.C.} \mid Y)$ directamente de la tabla? Sus respuestas no necesitan sumar 1; explique por qué.

b. ¿Qué probabilidad asignaría ese clasificador a la proposición de que el paciente está sano? Muestre su procedimiento (los tres valores deben sumar 1).

c. ¿Qué valores asignaría a los tres diagnósticos un clasificador Naive Bayes? Muestre su procedimiento.

d. ¿Qué probabilidad asignaría un clasificador Naive Bayes a la proposición de que el paciente está sano? Compare con el resultado del ítem (b) y explique a qué se debe la diferencia.

e. ¿Qué ocurre con la estimación de $\mathbb{P}(\text{Fiebre} = \text{T},\ \text{D.C.} = \text{F} \mid \text{Neumonía})$ en cada uno de los dos clasificadores? Aplique suavizado de Laplace y rehaga el cálculo del ítem (b). ¿Hace falta hacer lo mismo en el ítem (c)?

6. Se quiere clasificar mensajes de correo electrónico como *spam* o legítimos a partir de la presencia de ciertas palabras. Para ello se dispone de un conjunto de entrenamiento de $n = 30$ mensajes, en el que se registró, para cada uno, si contiene la palabra *gratis* y si contiene la palabra *oferta*, además de su etiqueta. Considere $X_1 = 1$ si el mensaje contiene *gratis*, $X_2 = 1$ si contiene *oferta* e $Y = 1$ si el mensaje es *spam* (en caso negativo toman el valor 0). Los datos de entrenamiento son:

Y	X_1		Y	X_2	
	0	1		0	1
0	15	3	0	14	4
1	2	10	1	4	8

Suponga que llega un mensaje nuevo que contiene la palabra *gratis* pero no la palabra *oferta*.

a. ¿Qué tipo de clasificador de Bayes (naive o no) puede construir con la información dada? Justifique qué información adicional necesitaría para construir el otro.

b. ¿Se trata de *spam*? Muestre su procedimiento.

Actividades computacionales

1. Implemente las clases `myLDA` y `myQDA` que permitan aplicar análisis discriminante lineal y cuadrático sobre problemas de clasificación multiclase. Asegúrese que ambas clases:

- Estimen por máxima verosimilitud las probabilidades a priori $\hat{\pi}_y$, los vectores de medias $\hat{\boldsymbol{\mu}}_y$ y la matriz de covarianza (compartida en `myLDA`, por clase en `myQDA`).
- Clasifiquen nuevas muestras evaluando la función discriminante, sin construir explícitamente la densidad normal.
- Devuelvan tanto la etiqueta predicha como las probabilidades a posteriori $p(y \mid \mathbf{x})$.
- Reciban un parámetro de regularización $\varepsilon \geq 0$ que reemplace $\hat{\Sigma}$ por $\hat{\Sigma} + \varepsilon I$, de manera de poder operar cuando la matriz estimada resulte singular o mal condicionada.

2. Utilice las clases `myLDA` y `myQDA` sobre una serie de escenarios simulados en $\mathbb{R}^2$, construidos de manera de exponer las diferencias entre ambos modelos. En todos los casos genere las observaciones de cada clase a partir de una normal multivariada con los parámetros indicados, grafique las fronteras de decisión de ambos modelos sobre el plano, y explique lo observado.

a. *Dos clases esféricas.* Dos clases con matrices de covarianza iguales a la identidad y medias bien separadas.

b. *Tres clases esféricas.* Tres clases con matrices de covarianza iguales a la identidad.

c. *Tres clases con covarianzas distintas.* Tres clases cuyas matrices de covarianza difieren marcadamente entre sí, por ejemplo

$$\Sigma_1 = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \qquad \Sigma_2 = \begin{pmatrix} 5 & -4.5 \\ -4.5 & 5 \end{pmatrix}, \qquad \Sigma_3 = \begin{pmatrix} 5 & 4.5 \\ 4.5 & 5 \end{pmatrix}.$$

d. *Clases no separables linealmente.* Genere datos con `make_moons` de `scikit-learn`.

e. A partir de los cuatro escenarios anteriores, indique en cuáles la frontera lineal de LDA resulta suficiente, en cuáles la flexibilidad adicional de QDA se traduce en una mejora, y en cuáles fallan ambos modelos. Justifique en términos de los supuestos de cada modelo.

f. Compare, en los escenarios (a) a (c), los parámetros estimados y las predicciones con los obtenidos mediante `LinearDiscriminantAnalysis` y `QuadraticDiscriminantAnalysis` de `scikit-learn`.

3. Implemente la clase `myNaiveBayes` que permita aplicar el clasificador Naive Bayes sobre problemas de clasificación multiclase. La clase debe recibir como parámetro la variante a utilizar (gaussiana o Bernoulli) y un parámetro de suavizado $\alpha \geq 0$. Asegúrese que la clase:

- Estime, en la variante gaussiana, los parámetros $\hat{\mu}_{jy}$ y $\hat{\sigma}^2_{jy}$ de cada variable en cada clase.
- Estime, en la variante Bernoulli, los parámetros $\hat{\phi}_{j|y}$ con suavizado de Laplace, de manera que $\alpha = 0$ corresponda al MLE sin suavizar y $\alpha = 1$ al suavizado de Laplace.
- Opere sobre las log-probabilidades en lugar de los productos, para evitar desbordamiento numérico.
- Devuelva tanto la etiqueta predicha como las probabilidades a posteriori.

4. Utilice la variante Bernoulli de `myNaiveBayes` para resolver un problema de clasificación de texto sobre el conjunto de datos `fetch_20newsgroups` de `scikit-learn`.

> *El dataset `fetch_20newsgroups` reúne alrededor de 18000 mensajes publicados en foros de discusión de Usenet, clasificados en 20 categorías temáticas (deportes, política, religión, informática, entre otras). Para este ejercicio puede restringirse a un subconjunto de cuatro categorías. Cada mensaje es un texto libre, por lo que debe vectorizarse previamente: con `CountVectorizer(binary=True)` se obtiene, para cada documento, un vector que indica la presencia o ausencia de cada palabra del vocabulario.*

a. Construya el vocabulario limitando su tamaño a las palabras más frecuentes y vectorice los documentos en forma binaria. Ajuste el modelo y reporte el *accuracy* y la matriz de confusión en el conjunto de prueba.

b. Compare los resultados con los de `BernoulliNB` de `scikit-learn`.

c. Ajuste el modelo con $\alpha = 0$ y con $\alpha = 1$, y compare el desempeño. Identifique al menos un documento de prueba que contenga una palabra no vista en entrenamiento para la clase verdadera, y explique qué ocurre con su probabilidad a posteriori en cada caso.

5. Utilice las tres clases implementadas para comparar los modelos LDA, QDA y Naive Bayes gaussiano sobre el conjunto de datos `load_digits` de `scikit-learn`.

> *El dataset `load_digits` contiene 1797 imágenes de dígitos manuscritos de 8×8 píxeles, correspondientes a las diez clases del 0 al 9. Cada imagen se representa*

como un vector de 64 variables, donde cada componente es la intensidad del píxel correspondiente, expresada como un entero entre 0 y 16.

a. Divida los datos en conjuntos de entrenamiento y prueba, ajuste los tres modelos y reporte el *accuracy* en cada conjunto.

b. Al ajustar `myQDA` sin regularización, es esperable que alguna de las matrices $\hat{\Sigma}_y$ resulte singular o mal condicionada. Verifíquelo calculando su rango y su número de condición, y explique el fenómeno comparando el número de observaciones por clase con el número de parámetros que estima el modelo.

c. Repita el ajuste de `myQDA` para distintos valores del parámetro de regularización ε y grafique el *accuracy* en prueba en función de ε.

d. El Naive Bayes gaussiano puede verse como un caso particular de QDA. Explique bajo qué restricción sobre Σ_y se obtiene dicha equivalencia, y cuántos parámetros estima cada uno de los tres modelos sobre este conjunto de datos. Relacione el resultado con el desempeño observado en el ítem (a).