Guía de actividades

3.2: Métodos de clustering

Actividades conceptuales

1. Considere la función de distorsión asociada al algoritmo de K-medias,

$$J(C, \boldsymbol{\mu}) := \sum_{i=1}^{n} \|\mathbf{x}_i - \boldsymbol{\mu}_{C(i)}\|_2^2, \tag{1}$$

donde $C : \{1, \dots, n\} \to \{1, \dots, K\}$ es la asignación y $\boldsymbol{\mu} = (\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_K)$ son los centroides. El objetivo es justificar que el algoritmo visto en la teoría realiza un descenso por coordenadas sobre J.

a. *Paso de asignación.* Fije los centroides $\boldsymbol{\mu}$ y muestre que la asignación

$$C(i) = \arg\min_{j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2, \qquad i = 1, \dots, n,$$

minimiza $J(\cdot\,, \boldsymbol{\mu})$ sobre todas las asignaciones posibles. *Ayuda: observe que, con $\boldsymbol{\mu}$ fijo, los n términos de la suma (1) pueden minimizarse de forma independiente.*

b. *Paso de actualización.* Fije la asignación C y muestre que

$$\arg\min_{\boldsymbol{\mu}_j \in \mathbb{R}^p} \sum_{C(i)=j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|_2^2 = \bar{\mathbf{x}}_j := \frac{1}{n_j} \sum_{C(i)=j} \mathbf{x}_i,$$

donde n_j es el tamaño del j-ésimo cluster.

c. Concluya que la sucesión $J(C^{(t)}, \boldsymbol{\mu}^{(t)})$ es no creciente. Observando que, una vez realizado el paso de actualización, el valor de J queda determinado por la asignación C, y que el número de asignaciones posibles es finito, deduzca que el algoritmo se detiene en una cantidad finita de iteraciones.

d. ¿Garantiza lo anterior que el valor alcanzado sea el mínimo global de J? Justifique.

e. El paso de asignación del ítem (a) coincide con la regla de decisión del modelo LDA cuando $\Sigma = \sigma^2 I$ y las clases son balanceadas, deducida en el ejercicio 2 de la guía anterior. Señale en qué se diferencian los dos métodos a pesar de compartir la fórmula, y qué supuesto sobre la estructura de los datos queda implícito al elegir la distancia euclídea como disimilaridad.

2. Considere el conjunto de datos en $\mathbb{R}^2$ formado por los cuatro puntos

$$\mathbf{x}_1 = (0, 0), \qquad \mathbf{x}_2 = (0, 1), \qquad \mathbf{x}_3 = (6, 0), \qquad \mathbf{x}_4 = (6, 1),$$

y aplique el algoritmo de K-medias con $K = 2$, inicializando los centroides en dos de las observaciones.

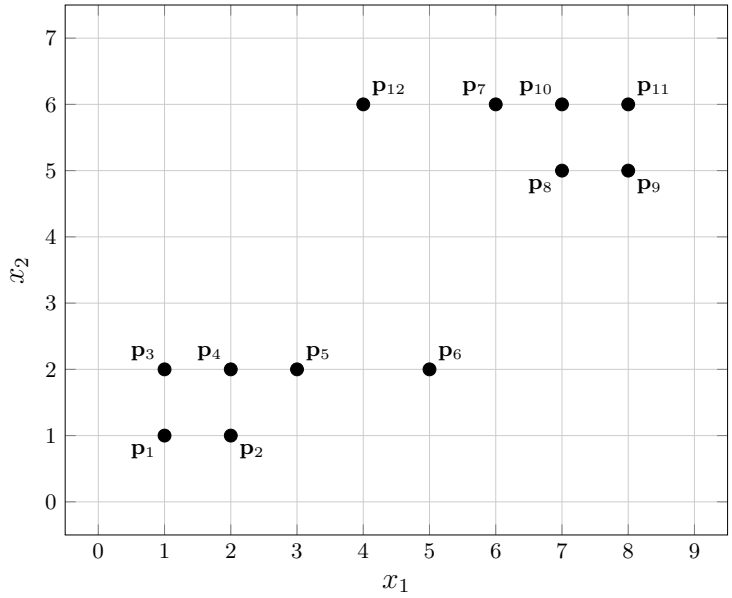
a. Ejecute el algoritmo tomando como centroides iniciales $\boldsymbol{\mu}_1 = \mathbf{x}_1$ y $\boldsymbol{\mu}_2 = \mathbf{x}_4$. Indique la asignación y los centroides en cada iteración, hasta que la asignación deje de cambiar, y calcule el valor final de la distorsión (1).

b. Repita el procedimiento tomando ahora $\boldsymbol{\mu}_1 = \mathbf{x}_1$ y $\boldsymbol{\mu}_2 = \mathbf{x}_2$, y calcule nuevamente el valor final de la distorsión.

c. Verifique que ambas soluciones son puntos fijos del algoritmo: ninguna de las dos se modifica al aplicar otra iteración. Compare los valores de J obtenidos y relacione el resultado con el ítem (d) de la actividad anterior.

d. ¿Qué estrategia sugiere el resultado anterior a la hora de utilizar K-medias en la práctica?

3. La siguiente figura muestra un conjunto de doce observaciones en $\mathbb{R}^2$, sobre el que se desea aplicar el algoritmo DBSCAN.



Considere la distancia euclídea y la convención de que el vecindario de un punto lo contiene a él mismo; es decir, $\mathbf{p}$ es un objeto núcleo si su vecindario de radio ε contiene al menos ν puntos, contándolo a él.

a. Tome $\varepsilon = 1{,}5$ y $\nu = 4$. Clasifique cada una de las doce observaciones como objeto núcleo, frontera o ruido, e indique los clusters que produce el algoritmo.

b. Repita el análisis con $\varepsilon = 2{,}5$ y $\nu = 4$. ¿Qué observaciones cambian de categoría? ¿Se modifica la cantidad de clusters?

c. Vuelva a $\varepsilon = 1{,}5$ y determine el menor valor de ν para el cual el algoritmo no encuentra ningún cluster. Explique qué ocurre con las etiquetas en ese caso.

d. A partir de lo anterior, discuta el rol de cada uno de los dos hiperparámetros y por qué DBSCAN no requiere fijar de antemano el número de clusters, a diferencia de K-medias y GMM.

Actividades computacionales

1. Implemente la clase `myKMeans` que permita aplicar el algoritmo de K-medias sobre un conjunto de datos en $\mathbb{R}^p$. Asegúrese que la clase:

   - Reciba el número de clusters K, un número máximo de iteraciones y una tolerancia para el criterio de parada.
   - Inicialice los centroides eligiendo K observaciones al azar del conjunto de datos.
   - Alterne el paso de asignación y el paso de actualización, deteniéndose cuando la asignación no cambie o el desplazamiento de los centroides sea menor que la tolerancia.
   - Almacene, además de las etiquetas y los centroides finales, el valor de la distorsión J alcanzado.

   a. Genere datos sintéticos con `make_blobs` de `scikit-learn` y verifique el funcionamiento de su implementación para distintos valores del parámetro `centers` y del número de clusters K. Grafique en cada caso el agrupamiento obtenido junto con los centroides.

   b. *Método del codo.* Ajuste el modelo para $K = 1, \ldots, 10$ sobre un conjunto generado con cuatro centros, grafique J en función de K y determine el valor óptimo. Explique por qué J no puede utilizarse directamente como criterio de selección, es decir, por qué no tiene sentido elegir el K que la minimice.

   c. *Dependencia de la inicialización.* Fije K y ejecute el algoritmo repetidas veces sobre los mismos datos, registrando en cada corrida el valor final de J. Reporte el mínimo, el máximo y la dispersión obtenidos, y grafique dos agrupamientos que difieran entre sí. Agregue luego a su implementación un parámetro `n_init` que repita el ajuste esa cantidad de veces y conserve la corrida de menor distorsión.

   d. *Clusters no esféricos.* Genere un conjunto de datos con cuatro centros y aplíquele una transformación lineal, de manera de obtener clusters elongados:

   ```
   X_raw, y_true = make_blobs(n_samples=400, centers=4, cluster_std=0.60,
   ↪  random_state=0)
   rng = np.random.RandomState(13)
   X_elip = X_raw @ rng.normal(size=(2, 2))
   ```

   Aplique `myKMeans` sobre `X_elip` y grafique el resultado. Explique el comportamiento observado a partir de la medida de disimilaridad que utiliza el método, e indique qué debería poder representar un modelo para recuperar estos grupos. Relacione su respuesta con los supuestos del modelo de mezcla de gaussianas y, en particular, con el rol de las matrices Σ_k. Guarde los datos y el gráfico: retomaremos este conjunto en la guía siguiente, una vez disponible el algoritmo que permite ajustar dicho modelo.

2. Implemente la clase `myDBSCAN` que permita aplicar el algoritmo DBSCAN sobre un conjunto de datos en $\mathbb{R}^p$. La clase debe recibir el radio ε y el número mínimo de puntos ν, y disponer de los métodos `obtener_vecinos`, `expandir_cluster` y `fit`, devolviendo este último un vector de etiquetas.

Para tener en cuenta: una forma posible de organizar la implementación es utilizar tres tipos de etiquetas: -2 para las observaciones aún no visitadas, -1 para las que son ruido o frontera, y un entero ≥ 0 para las asignadas a un cluster. Inicialmente todas las observaciones tienen etiqueta -2.

El bucle principal recorre las observaciones y, para cada una no visitada, calcula su vecindario. Si contiene menos de ν puntos, se le asigna la etiqueta -1 (podría ser frontera de algún cluster más adelante). Si contiene al menos ν, la observación es un objeto núcleo y se invoca `expandir_cluster` con el índice de cluster actual, que se incrementa una vez finalizada la expansión.

La función `expandir_cluster` parte de un objeto núcleo y de su lista de vecinos, y la va recorriendo: a un vecino con etiqueta -1 se le asigna el cluster actual (es frontera y no expande), mientras que a un vecino no visitado se le asigna el cluster actual y, si resulta ser a su vez un objeto núcleo, se agregan sus propios vecinos a la lista por recorrer. Conviene usar una `list` y sus métodos `pop(0)` y `extend`.

a. Verifique su implementación sobre un conjunto generado con `make_moons`. Pruebe distintos valores de ε y ν, y reporte en cada caso el número de clusters hallados y la cantidad de observaciones etiquetadas como ruido.

b. Compare los resultados del ítem anterior con los de `DBSCAN` de `scikit-learn`, prestando atención a la convención que utiliza dicha implementación para el parámetro `min_samples`.

3. Compare el comportamiento de K-medias y DBSCAN sobre los cinco conjuntos de datos siguientes, disponiendo los resultados en una grilla de gráficos con un conjunto por columna y un método por fila:

- dos conjuntos esféricos generados con `make_blobs`, uno con 2 centros y otro con 5;
- un conjunto generado con `make_circles`;
- un conjunto generado con `make_moons`;
- un conjunto de puntos distribuidos uniformemente en $[-1, 1]^2$.

Puede utilizar indistintamente sus propias implementaciones o las de `scikit-learn`. En cada caso elija los hiperparámetros de ambos métodos de manera de obtener el mejor resultado posible. Conserve el código: en la guía siguiente agregará una tercera fila a esta grilla.

a. ¿En qué conjuntos funciona bien cada método y en cuáles falla? Justifique en cada caso a partir de los supuestos que hace el método, no sólo de lo que se observa en el gráfico.

b. ¿Cuál de los dos métodos identifica observaciones que no pertenecen a ningún cluster? ¿Qué ventaja representa esto y en qué situaciones podría ser un problema?

c. ¿Qué devuelve cada método sobre el conjunto uniforme, en el que no hay estructura de grupos que descubrir? Discuta qué revela esto sobre el uso de algoritmos de clustering en datos reales, donde no se sabe de antemano si existen grupos.