Guía de actividades

3.3: Algoritmo EM

Actividades conceptuales

1. Un laboratorio farmacéutico evalúa la resistencia de un polímero utilizado para recubrir microcápsulas. Durante las pruebas se observa que las microcápsulas no fallan de manera homogénea: algunas se degradan rápidamente por defectos microscópicos en el recubrimiento, mientras que otras presentan una vida útil considerablemente mayor. El equipo de ingeniería sospecha que la población observada proviene de dos mecanismos de falla distintos, uno de falla temprana por microfisuras y otro de falla estructural normal.

Para modelar esta situación se supone que el tiempo hasta la degradación X sigue una mezcla de dos distribuciones exponenciales,

$$f(x;\boldsymbol{\theta}) = \varphi\,\lambda_1 e^{-\lambda_1 x} + (1-\varphi)\,\lambda_2 e^{-\lambda_2 x}, \qquad 0<\varphi<1,\ \lambda_1>0,\ \lambda_2>0,$$

con $\boldsymbol{\theta} = (\varphi, \lambda_1, \lambda_2)$. Dada una muestra aleatoria $\{x_1, \ldots, x_n\}$, el objetivo es estimar $\boldsymbol{\theta}$ mediante el algoritmo EM.

a. Determine la variable latente $\mathbf{Z}$ que se utilizaría en el algoritmo.

b. Escriba la log-verosimilitud de los datos completos $(\mathbf{X}, \mathbf{Z})$.

c. Dé la expresión de $Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)})$ en función de las responsabilidades y calcule dichas responsabilidades.

d. Obtenga las actualizaciones que definen $\boldsymbol{\theta}^{(t+1)}$. Compare la expresión de $\lambda_j^{(t+1)}$ con el estimador de máxima verosimilitud de una única exponencial e interprete el resultado.

e. Enuncie la inicialización, el paso E y el paso M del algoritmo para este problema.

2. El modelo de Poisson inflado en ceros (ZIP) fue introducido por Lambert (1992) para describir conteos en los que la cantidad de ceros es superior a la que puede generar una distribución de Poisson. El modelo supone que los ceros tienen dos orígenes distintos: cada observación proviene del *estado perfecto*, en el que no pueden ocurrir defectos y el conteo es cero con probabilidad uno, o bien del *estado imperfecto*, en el que los defectos surgen de un proceso de Poisson de parámetro $\lambda > 0$. Estos estados ocurren con probabilidad φ y $1-\varphi$, respectivamente, de modo que

$$f(x;\lambda,\varphi) = \varphi\,\mathbf{1}\{x=0\} + (1-\varphi)\,\frac{\lambda^x e^{-\lambda}}{x!}, \qquad x = 0, 1, 2, \ldots$$

Se introduce la variable latente $Z_i = 1$ si la i-ésima unidad está en el estado perfecto y $Z_i = 0$ en caso contrario, que no es observable: al registrar $x_i = 0$ no puede saberse de cuál de los dos estados proviene.

a. Escriba la log-verosimilitud de los datos completos, con $\boldsymbol{\theta} = (\varphi, \lambda)$.

b. Dé la expresión de $Q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^{(t)})$ en función de las responsabilidades y calcule dichas responsabilidades. Observe qué valor toman cuando $x_i > 0$ y explique a qué se debe.

c. Obtenga las actualizaciones que definen $\boldsymbol{\theta}^{(t+1)}$.

d. Enuncie la inicialización, el paso E y el paso M del algoritmo para este problema.

e. A diferencia del ejercicio anterior, aquí la variable latente queda determinada por el dato observado en una parte de la muestra. Discuta en qué se traduce esto sobre la información que aporta cada observación al algoritmo.

3. Los resultados de un experimento, $X_1, \ldots, X_n$, son variables aleatorias independientes e idénticamente distribuidas según una distribución Poisson(λ). Los resultados se registraron pero, desafortunadamente, $n - q$ de los registros se perdieron de manera accidental y aleatoria, de modo que sólo se observa $\mathbf{X} = (X_1, \ldots, X_q)$.

Para estimar λ por máxima verosimilitud utilizaremos el algoritmo EM, tomando los datos faltantes $\mathbf{Z} = (Z_1, \ldots, Z_{n-q}) = (X_{q+1}, \ldots, X_n)$ como variables latentes.

a. Escriba la log-verosimilitud de los datos completos $(\mathbf{X}, \mathbf{Z})$.

b. Obtenga $Q(\lambda \mid \lambda^{(t)})$. Observe que aquí no aparecen responsabilidades: identifique qué esperanza condicional es la que efectivamente hay que calcular y explique por qué resulta tan sencilla en este caso.

c. Halle la ecuación que define $\lambda^{(t+1)}$ en términos de $\lambda^{(t)}$ e interprete qué hace el algoritmo con los registros perdidos en cada iteración.

d. Enuncie la inicialización, el paso E y el paso M del algoritmo, y explique brevemente cómo itera.

e. Suponga que $\lambda^{(t)} \to \hat{\lambda}$ cuando $t \to \infty$. Utilizando el resultado del ítem (c), obtenga una expresión explícita de $\hat{\lambda}$. Interprete el resultado y verifique que coincide con el estimador de máxima verosimilitud que habría obtenido trabajando directamente con la muestra observada.

4. En el modelo de mezcla de gaussianas, considere el caso particular en que todas las componentes comparten una matriz de covarianza esférica conocida y son equiprobables; esto es,

$$\Sigma_j = \sigma^2 I, \qquad \phi_j = \frac{1}{k}, \qquad j = 1, \ldots, k.$$

a. Escriba las responsabilidades $w_{ij}^{(t)}$ bajo estos supuestos y verifique que dependen de las observaciones únicamente a través de las distancias $\|\mathbf{x}_i - \boldsymbol{\mu}_j^{(t)}\|_2^2$.

b. Sea $j^\star(i)$ el índice de la componente cuya media está más cerca de $\mathbf{x}_i$, y suponga que dicho mínimo es único. Muestre que

$$w_{ij}^{(t)} \xrightarrow[\sigma^2 \to 0]{} \mathbf{1}\{j = j^\star(i)\}.$$

Ayuda: divida numerador y denominador por el término correspondiente a $j^\star(i)$.

c. Concluya que, en ese límite, la actualización de $\boldsymbol{\mu}_j$ en el paso M coincide exactamente con la actualización de centroides del algoritmo de K-medias.

d. En la guía anterior se demostró que K-medias hace decrecer monótonamente la distorsión J, y en la teoría se demostró que EM hace crecer monótonamente la log-verosimilitud ℓ. A la luz del límite anterior, discuta qué relación hay entre ambos resultados y por qué ninguno de los dos garantiza alcanzar el óptimo global.

Actividades computacionales

1. Implemente la clase `myGMM` que permita ajustar un modelo de mezcla de gaussianas mediante el algoritmo EM. Asegúrese que la clase:

- Reciba el número de componentes k, un número máximo de iteraciones y una tolerancia sobre el incremento de la log-verosimilitud.
- Inicialice las medias con k observaciones elegidas al azar, las covarianzas con la covarianza muestral del conjunto completo y los pesos en $\phi_j = 1/k$.
- Implemente el paso E calculando las responsabilidades w_{ij}, y el paso M con las tres actualizaciones de $\boldsymbol{\phi}$, $\boldsymbol{\mu}_j$ y Σ_j.
- Registre el valor de $\ell(\boldsymbol{\theta}^{(t)})$ en cada iteración.
- Devuelva, además de los parámetros estimados, tanto la etiqueta de máxima responsabilidad como la matriz completa de responsabilidades.

> **Para tener en cuenta:** las responsabilidades involucran cocientes de densidades gaussianas, que para p moderado toman valores muy pequeños y producen desbordamiento numérico si se calculan directamente. Conviene trabajar con los logaritmos: si $a_{ij} = \log \phi_j + \log \mathcal{N}(\mathbf{x}_i; \boldsymbol{\mu}_j, \Sigma_j)$, entonces
>
> $$\log w_{ij} = a_{ij} - \log \sum_{l=1}^{k} e^{a_{il}},$$
>
> y el segundo término se evalúa de manera estable restando $\max_l a_{il}$ antes de exponenciar. La misma cantidad $\sum_i \log \sum_l e^{a_{il}}$ es la log-verosimilitud $\ell(\boldsymbol{\theta})$, de modo que se obtiene sin cálculo adicional.

a. Genere datos sintéticos con `make_blobs` y verifique el funcionamiento de su implementación. Grafique el agrupamiento obtenido junto con las elipses de covarianza de cada componente. Identifique alguna observación situada entre dos grupos y reporte sus responsabilidades, comparándolas con las de una observación central.

b. *Verificación de la monotonía.* Grafique $\ell(\boldsymbol{\theta}^{(t)})$ en función de t para varias inicializaciones distintas sobre los mismos datos. Verifique que cada curva es no decreciente, como asegura el Teorema de monotonía, y observe que los valores límite no son todos iguales. ¿Qué estrategia se desprende de esto?

c. *Clusters no esféricos.* Retome el conjunto `X_elip` de la guía anterior y ajuste sobre él `myGMM` con cuatro componentes. Compare el resultado con el que había obtenido entonces

con `myKMeans` y explique la diferencia en términos de los parámetros que estima cada modelo.

d. Compare los parámetros estimados y las etiquetas asignadas con los de `GaussianMixture` de `scikit-learn`.

2. Retome la grilla comparativa de la guía anterior y agregue una tercera fila correspondiente al modelo de mezcla de gaussianas, utilizando su implementación o la de `scikit-learn`. Analice en qué conjuntos de datos el nuevo método mejora a K-medias, en cuáles se comporta de manera similar y en cuáles sigue fallando. En particular, indique si existe algún conjunto en el que GMM resuelva lo que DBSCAN resuelve, y justifique su respuesta a partir de los supuestos de cada modelo.

3. Implemente el algoritmo EM para el modelo de mezcla de dos exponenciales de la actividad conceptual 1, utilizando las actualizaciones que obtuvo allí.

a. Simule una muestra de tamaño $n = 1000$ a partir del modelo, con valores de φ, λ_1 y λ_2 elegidos por usted, y verifique que el algoritmo recupera aproximadamente los parámetros utilizados en la simulación. Grafique el histograma de la muestra junto con la densidad de la mezcla estimada.

b. Repita el experimento acercando progresivamente λ_1 y λ_2 entre sí. Reporte qué ocurre con la cantidad de iteraciones hasta la convergencia y con la calidad de las estimaciones, y explique el fenómeno en términos de las responsabilidades.